

Metodi Matematici e Statistici

Guida completa per l'esame

Teoria, Laboratorio Python e le 9 prove d'esame svolte

Corso di Laurea Triennale in Informatica — Università di Catania

Questa guida raccoglie la teoria del corso di Metodi Matematici e Statistici (canale M-Z, A.A. 2024-2025 e 2025-2026) e le soluzioni complete delle nove prove d'esame disponibili, con il codice Python commentato.

Com'è organizzata:

- **Parte I — Teoria:** tutti gli argomenti del corso, con le definizioni nella forma esatta richiesta all'esame e le dimostrazioni.
- **Parte II — Laboratorio Python:** ricette per ciascun tipo di quesito, con il codice pronto e la spiegazione del perché.
- **Parte III — Le 9 prove svolte:** ogni appello risolto per intero, Laboratorio e Teoria.
- **Appendici:** formulario, riferimento `scipy.stats`, indice di tutte le domande di teoria già assegnate.

Indice

I	Teoria	1
1	Come usare questa guida	2
2	L'esame: com'è fatto e come si prepara	4
2.1	La struttura della prova	4
2.2	Cosa è stato chiesto, prova per prova	4
2.3	Cosa impariamo da queste tabelle	6
2.4	Le domande di teoria ricorrenti, parola per parola	8
2.5	Errori da non fare	9
3	Eventi e probabilità	10
3.1	Eventi	10
3.2	Le quattro definizioni di probabilità	11
3.3	Probabilità condizionale e indipendenza	13
3.4	Il teorema delle probabilità totali	13
3.5	Il teorema di Bayes	14
3.6	Richiami di calcolo combinatorio	14
3.7	Esercizi svolti	15
4	Variabili aleatorie	18
4.1	La definizione	18
4.2	Variabili discrete e variabili continue	18
4.2.1	Variabili aleatorie discrete	18
4.2.2	Variabili aleatorie continue	19
4.3	Momenti	19
4.4	Le distribuzioni notevoli discrete	20
4.4.1	Bernoulli	20
4.4.2	Binomiale	20
4.4.3	Ipergeometrica	21
4.4.4	Poisson	22
4.4.5	Geometrica	22
4.4.6	Uniforme discreta	23
4.5	Le distribuzioni notevoli continue	23
4.5.1	Uniforme continua	23
4.5.2	Esponenziale	23
4.5.3	Normale (gaussiana)	24
4.5.4	Chi-quadro	24
4.5.5	t di Student	25
4.6	Esercizi svolti	25
5	Legge dei grandi numeri e teorema del limite centrale	27
5.1	La media campionaria	27

5.2	Le disuguaglianze	27
5.3	La legge dei grandi numeri	28
5.4	Il teorema del limite centrale	29
5.5	Statistica descrittiva e statistica inferenziale	30
6	Statistica: stimatori, intervalli di confidenza, test	32
6.1	Popolazione, campione, stimatore	32
6.2	Stimatori non distorti	32
6.3	Lo stimatore della media	33
6.4	Lo stimatore della varianza	33
6.5	Statistica descrittiva: gli indici	35
6.6	Intervalli di confidenza	36
6.7	Test d'ipotesi	37
6.8	Esercizi svolti	39
7	Regressione lineare e correlazione	42
7.1	Il problema	42
7.2	Covarianza e coefficiente di correlazione	42
7.3	Il metodo dei minimi quadrati	43
7.4	Bontà dell'adattamento	44
7.5	Esercizi svolti	45
8	Numeri pseudorandom e metodi Monte Carlo	51
8.1	Numeri pseudorandom	51
8.2	Il generatore a congruenze lineari	51
8.3	Il metodo dell'inversione	52
8.4	I metodi Monte Carlo	53
8.5	Esercizi svolti	55
9	Processi stocastici e catene di Markov	57
9.1	Processi stocastici	57
9.2	La catena di Markov	58
9.3	La matrice di transizione	58
9.4	Classi, irriducibilità, ricorrenza	60
9.5	La distribuzione stazionaria	61
9.6	Esercizi svolti	62
II	Laboratorio Python	65
10	Come funziona il Laboratorio	66
10.1	Il problema: il Python che non ti hanno insegnato	66
10.2	Lo schema fisso di ogni quesito di Laboratorio	66
10.3	Le quattro cose che si fanno sempre	67
10.4	Consigli pratici per la prova	67
11	L'ambiente di lavoro	69
11.1	Le tre librerie	69
11.2	Generare numeri casuali	70
11.3	Le distribuzioni in <code>scipy.stats</code>	71
11.4	I grafici	72
11.5	Un modello completo da cui partire	72

12 Probabilità e simulazione in Python	74
12.1 Il trucco che risolve metà dei quesiti	74
12.2 L'errore standard: quanto bene ho stimato	74
12.3 Esercizi svolti	75
13 Confrontare teoria e simulazione	81
13.1 La ricetta in tre passi	81
13.2 Caso continuo: istogramma sovrapposto alla densità	81
13.3 Caso discreto: barre affiancate	82
13.4 Quanto deve essere piccolo lo scarto: la legge $1/\sqrt{N}$	82
13.5 Il Q-Q plot	83
13.6 Confrontare i momenti, non solo il grafico	84
13.7 Esercizi svolti	85
14 Statistica descrittiva in Python	92
14.1 Due modi di raggruppare i dati	92
14.2 Media e varianza: con e senza frequenze	93
14.3 Gli indici, in una schermata	93
14.4 Esercizi svolti	94
15 Regressione e correlazione in Python	101
15.1 Le formule, e come si chiamano le cose	101
15.2 Il modo rapido: <code>linregress</code>	101
15.3 Il modo "a mano"	102
15.4 Il grafico	102
15.5 La scala di ρ	103
15.6 Esercizi svolti	103
16 Intervalli di confidenza e test d'ipotesi in Python	109
16.1 Le due decisioni da prendere prima di scrivere una riga	109
16.2 Gli intervalli di confidenza	109
16.3 I test d'ipotesi	110
16.4 Esercizi svolti	110
17 Monte Carlo e integrazione	118
17.1 Hit or miss: quando si può usare	118
17.2 L'errore della stima: la formula che decide tutto	118
17.3 Il metodo del rigetto	119
17.4 Esercizi svolti	120
Nota: da dove vengono i numeri casuali	127
18 Catene di Markov in Python	128
18.1 Dal grafo alla matrice	128
18.2 La matrice a m passi: P^m	129
18.3 La distribuzione al tempo t	130
18.4 Trovare la distribuzione stazionaria	131
18.5 Disegnare il grafo associato	132
18.6 Esercizi svolti	133
III Le 9 prove d'esame svolte	140
19 Come usare le prove svolte	141

19.1	Che cosa contiene ogni capitolo	141
19.2	In che ordine studiarle	141
19.3	Le aree di teoria, in ordine di probabilità	142
19.4	Come si usa una prova svolta	142
19.5	Prima di iniziare l'ultima prova	143
20	Prova del 28 gennaio 2025	144
20.1	Il testo della prova	144
20.2	Q1 — Correlazione e retta di regressione	145
20.3	Q2 — Dieci monete: da $N = 200$ a $N = 2000$	146
20.4	Q3 — Teoria: stimatore, correttezza, varianza con media nota	147
20.5	Q4 — Teoria: leggere una catena di Markov	148
20.6	Cosa portare via da questa prova	149
21	Prova del 24 marzo 2025 (primo turno)	151
21.1	Il testo della prova	151
21.2	Q1 — Le due palestre	152
21.3	Q2 — Hit or miss su una gaussiana troncata	154
21.4	Q3 — Teoria: evento, evento incompatibile, indipendenza	156
21.5	Q4 — Teoria: la distribuzione geometrica	156
21.6	Cosa portare via da questa prova	158
22	Prova del 17 giugno 2025	159
22.1	Il testo della prova	159
22.2	Q1 — Il gioco dell'oca	160
22.3	Q2 — Il numero di lettere dei nomi delle vie	162
22.4	Q3 — Teoria: probabilità assiomatica e variabili aleatorie	163
22.5	Q4 — Teoria: la passeggiata con pareti riflettenti	164
22.6	Cosa portare via da questa prova	166
23	Prova del 2 settembre 2025	167
23.1	Il testo della prova	167
23.2	Q1 (Laboratorio) — Correlazione, regressione, tempo di attesa	168
23.3	Q2 (Laboratorio) — Hit or miss e il trucco della simmetria	169
23.4	Q1 (Teoria) — Descrittiva, inferenziale e legge dei grandi numeri	172
23.5	Q2 (Teoria) — Numeri pseudorandom e inversione	172
23.6	Cosa portare via da questa prova	173
24	Prova del 27 gennaio 2026	175
24.1	Il testo della prova	175
24.2	Q1 (Laboratorio) — Le carte Magic	176
24.3	Q2 (Laboratorio) — I biscotti: descrittiva, normale e test t	178
24.4	Q1 (Teoria) — Eventi, incompatibilità e De Morgan	179
24.5	Q2 (Teoria) — Catene di Markov: le quattro definizioni	180
24.6	Cosa portare via da questa prova	180
25	Prova del 17 febbraio 2026	182
25.1	Il testo della prova	182
25.2	Q1 (Laboratorio) — Probabilità totali, Bayes e simulazione	183
25.3	Q2 (Laboratorio) — Regressione con le formule, senza <code>linregress</code>	184
25.4	Q1 (Teoria) — Frequenze, media, quantili, varianza	186
25.5	Q2 (Teoria) — La distribuzione binomiale	186
25.6	Cosa portare via da questa prova	188

26 Prova del 1 aprile 2026	189
26.1 Il testo della prova	189
26.2 Laboratorio, Q1 — gli ovetti	190
26.3 Laboratorio, Q2 — hit or miss e rigetto	192
26.4 Teoria, Q1 — variabili aleatorie	194
26.5 Teoria, Q2 — media campionaria e legge dei grandi numeri	194
26.6 Cosa portare via da questa prova	195
27 Prova del 29 aprile 2026	196
27.1 Il testo della prova	196
27.2 Laboratorio, Q1 — la coda esponenziale	197
27.3 Laboratorio, Q2 — il test sui farmaci	198
27.4 Teoria, Q1 — stimatori	199
27.5 Teoria, Q2 — catene di Markov: le definizioni	200
27.6 Cosa portare via da questa prova	201
28 Prova del 23 giugno 2026	202
28.1 Il testo della prova	202
28.2 Laboratorio, Q1 — l'ufficio anagrafe	203
28.3 Laboratorio, Q2 — la catena di Markov	205
28.4 Teoria, Q1 — intervalli di confidenza	206
28.5 Teoria, Q2 — numeri pseudorandom e Monte Carlo	207
28.6 Cosa portare via da questa prova	208
Appendici	211
A Formulario	211
A.1 Probabilità	211
A.2 Variabili aleatorie	212
A.3 Distribuzioni notevoli discrete	213
A.4 Distribuzioni notevoli continue	214
A.5 Legge dei grandi numeri e teorema del limite centrale	215
A.6 Statistica descrittiva	216
A.7 Stimatori	217
A.8 Intervalli di confidenza	217
A.9 Test d'ipotesi	218
A.10 Regressione lineare	219
A.11 Monte Carlo e numeri pseudorandom	220
A.12 Catene di Markov	221
B Guida rapida: quale funzione chiamo?	223
B.1 Le tre righe di partenza	223
B.2 Generare numeri casuali: <code>np.random</code>	223
B.3 <code>scipy.stats</code> : le quattro funzioni	225
B.4 Il Q-Q plot: <code>probplot</code>	226
B.5 Media, varianza, deviazione standard: la trappola del <code>ddof</code>	227
B.6 Regressione: <code>scipy.stats.linregress</code>	228
B.7 <code>matplotlib</code> : i grafici che servono	228
B.8 L'errore che ho fatto, e come si risolve	230
C Le domande di teoria ricorrenti	232
C.1 Che cosa studiare per primo	233

C.2	Catene di Markov (4 su 9)	233
C.3	Probabilità: eventi, assiomi, indipendenza (3 su 9)	235
C.4	Stimatori (3 su 9)	237
C.5	Variabili aleatorie (2 su 9)	238
C.6	Distribuzioni notevoli: geometrica e binomiale (2 su 9)	239
C.7	Media campionaria e legge dei grandi numeri (2 su 9)	241
C.8	Statistica descrittiva (2 su 9)	242
C.9	Monte Carlo e numeri pseudorandom (2 su 9)	244
C.10	Intervalli di confidenza (1 su 9)	245

Parte I

Teoria

Capitolo 1

Come usare questa guida

Il problema che questa guida risolve

Il corso di Metodi Matematici e Statistici si valuta con un esame scritto che ha una caratteristica precisa: **metà del compito si svolge in Python**, ma Python non viene insegnato a lezione. Chi studia si trova quindi in una situazione scomoda: la teoria è sui libri e sugli appunti, ma il Laboratorio si impara solo guardando le prove degli anni precedenti.

Questa guida nasce esattamente da qui. Mette insieme tre cose che normalmente sono separate:

1. la **teoria** del corso, scritta nella forma in cui serve all'esame;
2. il **Python** che serve davvero, ridotto all'insieme di istruzioni che ricorrono nelle prove (non un corso di programmazione: solo ciò che viene chiesto);
3. le **nove prove d'esame** disponibili, risolte per intero e commentate.

Com'è organizzata

Parte I — Teoria

Sette capitoli che seguono il programma del corso, dagli eventi alle catene di Markov. Ogni definizione è scritta nella forma in cui va scritta sul compito. Dove l'esame chiede una *dimostrazione*, la dimostrazione c'è, completa.

Parte II — Laboratorio

Otto capitoli organizzati **per tipo di quesito**, non per argomento. Ogni ricetta risponde a tre domande: quando si usa, come si scrive, come si commenta il risultato. Il codice è pronto da trascrivere.

Parte III — Le prove svolte

Le nove prove risolte per intero: i due quesiti di Laboratorio con codice ed output, e i due di Teoria con le risposte scritte.

Appendici Il formulario, il riferimento rapido di `scipy.stats`, e l'indice di tutte le domande di teoria già assegnate.

I box che troverai

Definizione

Le definizioni nella forma esatta in cui vanno scritte all'esame. Questi sono i contenuti da sapere *a memoria*.

Cosa scrivere all'esame

Come impostare e strutturare la risposta a una domanda d'esame: cosa scrivere per primo, cosa non dimenticare, quanto dettaglio serve.

Errore tipico da evitare

Gli errori che vengono fatti davvero, e che costano punti. Sono segnalati perché sono tutti già comparsi nelle prove.

Da ricordare

Formule e risultati da tenere a portata di mano.

Perché si fa così

Nel Laboratorio: perché il codice è scritto così, e cosa giustifica la scelta di una distribuzione o di un metodo.

Come prepararsi: un piano realistico

Se l'esame è tra un mese, il tempo è sufficiente ma va usato bene. Un ordine che funziona:

1. **Leggi il capitolo 2 (“L’esame: com’è fatto e come si prepara”).** Sono poche pagine, ma ti dicono esattamente su cosa verterà la prova. Vale la pena leggerlo per primo.
2. **Parte I, capitoli 1–4.** Sono il cuore della teoria e coprono la grande maggioranza delle domande. Non saltare le dimostrazioni: all’esame vengono chieste esplicitamente.
3. **Parte II, capitoli da A a F.** Impara le ricette scrivendole a mano, non leggendole. Il Laboratorio si passa scrivendo codice, non riconoscendolo.
4. **Parte III.** Fai le prove una alla volta, *prima* provando a risolverle da solo e *poi* confrontando con la soluzione. Le nove prove coprono tutte le variazioni possibili dei quesiti.
5. **Ripasso finale:** appendice A (formulario) e appendice C (domande di teoria già assegnate). L’appendice C è il modo più veloce di verificare se sai rispondere a tutto.

Una nota onesta

Questa guida copre tutto ciò che è comparso nelle nove prove disponibili. Se un argomento non è mai stato chiesto, è segnalato come tale. Nessuno può garantire che il prossimo appello non introduca una variante nuova: quello che questa guida garantisce è che *tutte le varianti già viste* sono coperte, e che i metodi sono spiegati abbastanza da poterne affrontare una nuova.

Capitolo 2

L'esame: com'è fatto e come si prepara

Questa guida è costruita a partire da nove prove d'esame reali, dal gennaio 2025 al giugno 2026. Prima di studiare qualsiasi cosa conviene capire *come* è fatta la prova, perché la struttura è sorprendentemente stabile.

2.1 La struttura della prova

Ogni compito dura **2 ore** e contiene **quattro quesiti**, sempre gli stessi quattro:

Quesito	Tipo	Cosa chiede
Quesito 1	Laboratorio	Un problema di probabilità o statistica da risolvere <i>con Python</i> : calcoli teorici, simulazione, grafici.
Quesito 2	Laboratorio	Un secondo problema Python, di natura diversa dal primo.
Quesito 1	Teoria	Definizioni e proprietà, spesso con una dimostrazione.
Quesito 2	Teoria	Definizioni e proprietà su un secondo argomento.

La regola che fa perdere l'esame

Sul foglio c'è scritto, e viene ripetuto ogni volta:

“Per il superamento dell'esame è richiesta la sufficienza in entrambe le parti (Laboratorio e Teoria).”

Questo significa che **non basta essere forti in una sola parte**. Saper scrivere tutto il codice del mondo non serve se non si sanno scrivere le definizioni di teoria, e viceversa. Chi prepara solo il Laboratorio, o solo la Teoria, viene respinto. Va preparato tutto.

2.2 Cosa è stato chiesto, prova per prova

Le tabelle seguenti sono il risultato dell'analisi di tutte e nove le prove. Servono a rispondere alla domanda “su cosa devo concentrarmi?”.

Laboratorio — Quesito 1

Appello	Argomento	Competenze
28/01/25	Correlazione tra due variabili (6 dati, poi 10)	regressione, ρ , R
24/03/25	Due palestre: confronto di due campioni	stimatore combinato, IC, z -test
17/06/25	Gioco dell'oca	simulazione, uniforme discreta
02/09/25	Concorso: probabilità in funzione dell'ora	regressione, geometrica
27/01/26	Mazzo di carte Magic	ipergeometrica, simulazione
17/02/26	Tre linee di produzione	prob. totali, Bayes, simulazione
01/04/26	Ovetti di Pasqua	distribuzione empirica, test binomiale
29/04/26	Server web (processo di Poisson)	esponenziale, simulazione, QQ-plot
23/06/26	Carte d'identità	prob. da tabella, binomiale

Laboratorio — Quesito 2

Appello	Argomento	Competenze
28/01/25	Lancio di 10 monete equilibrate	binomiale, simulazione
24/03/25	Integrale di una gaussiana	hit or miss, varianza della stima
17/06/25	Numero di lettere dei nomi delle vie	descrittiva, momenti, skewness, curtosi
02/09/25	Funzione bimodale	hit or miss, sfruttare la simmetria
27/01/26	Peso dei biscotti	media/varianza, fit normale, t -test
17/02/26	Tempo di calcolo di un software	regressione <i>senza</i> linregress
01/04/26	$I = \int_0^1 x e^x dx$	hit or miss, metodo del rigetto
29/04/26	Concentrazione di un farmaco	z -test unilatero, p -value
23/06/26	Catena di Markov a 6 stati	matrice, potenza, distribuzione stazionaria

Teoria — Quesito 1

Appello	Argomento
28/01/25	Stimatore, stimatore non distorto, varianza con media nota (+ dimostrazione)
24/03/25	Evento, eventi incompatibili, evento composto, calcolo di probabilità
17/06/25	Probabilità assiomatica (Kolmogorov), variabile aleatoria, legge e densità discreta
02/09/25	Statistica descrittiva vs inferenziale, stimatore della media, legge dei grandi numeri (+ dim.)
27/01/26	Evento, eventi incompatibili, evento composto, calcolo di probabilità
17/02/26	Frequenze, media aritmetica, quantili/mediana/quartili/IQR, varianza empirica e campionaria
01/04/26	Variabile aleatoria, esempio, discreta vs continua, momento centrato di ordine k
29/04/26	Stimatore, non distorto, stimatore della varianza (media nota / non nota)
23/06/26	Stimatore puntuale, intervallo di confidenza, rappresentazione grafica, dipendenza da N, σ, α

Teoria — Quesito 2

Appello	Argomento
28/01/25	Processo stocastico, catena di Markov, classe chiusa, lettura di un grafo
24/03/25	Distribuzione geometrica, legame con la binomiale, assenza di memoria (+ dim.)
17/06/25	Matrice di transizione, catena irriducibile, random walk su $\{1, \dots, 6\}$
02/09/25	Numeri pseudorandom, congruenze lineari, metodo dell'inversione (+ caso esponenziale)
27/01/26	Matrice di transizione e proprietà, matrice a m passi, distribuzione di X_t , stazionaria
17/02/26	Distribuzione binomiale: definizione, esempio, media e varianza (+ derivazione)
01/04/26	Media campionaria, sua media e varianza, legge dei grandi numeri, significato
29/04/26	Processo stocastico, catena di Markov, classe chiusa e irriducibile, catena irriducibile
23/06/26	Numero pseudorandom, metodo Monte Carlo, vantaggi e svantaggi, hit or miss

2.3 Cosa impariamo da queste tabelle

Teoria: quattro argomenti coprono quasi tutto

Contando le occorrenze sui nove appelli analizzati:

Argomento	Volte	Dove studiarlo
Catene di Markov (definizioni e proprietà)	4	Cap. 9
Stimatori (definizione, non distorsione, varianza)	3	Cap. 6
Eventi e probabilità (definizioni, composizione)	2	Cap. 3
Variabili aleatorie (definizioni, densità)	2	Cap. 4
Statistica descrittiva (frequenze, momenti)	2	Cap. 6
Pseudorandom e Monte Carlo	2	Cap. 8
Distribuzioni notevoli (binomiale, geometrica)	2	Cap. 4
Media campionaria e legge dei grandi numeri	2	Cap. 5
Intervalli di confidenza	1	Cap. 6

Cosa scrivere all'esame

Se hai poco tempo, la priorità è questa: **catene di Markov** (chieste 4 volte su 9, sempre come Quesito 2), **stimatori** (3 volte, sempre come Quesito 1), poi **eventi**, **variabili aleatorie** e **pseudorandom/Monte Carlo**. Queste cinque aree coprono la quasi totalità delle domande di teoria già assegnate.

Due domande sono già state chieste identiche

Confrontando i testi parola per parola salta fuori la cosa più utile di tutta questa analisi: **non solo gli argomenti si ripetono, ma due domande sono già ricomparse quasi identiche**. Vale la pena guardarle in faccia.

La stessa domanda nel 24/03/25 (Q1) e nel 27/01/26 (Q1) — a dieci mesi di distanza

Entrambe chiedono, nell'ordine:

1. la definizione di **evento**;
2. la definizione di **evento incompatibile**;
3. di **scrivere un evento composto** in termini di eventi elementari;
4. di **calcolarne la probabilità** usando l'**indipendenza**.

Cambia solo il vestito: nel 24/03/25 gli eventi sono $A = \text{"Giorgino ha studiato"}$ e $B = \text{"Giorgino ha passato l'esame"}$, con $P(A) = 0.3$, $P(B) = 0.5$; nel 27/01/26 sono i guasti di tastiera, mouse e monitor, con $P(A) = 0.45$, $P(B) = 0.35$, $P(C) = 0.2$. La struttura della risposta è *la stessa*.

La stessa domanda nel 02/09/25 (Q1) e nel 01/04/26 (Q2)

Entrambe chiedono:

1. la definizione di **media campionaria**, e se sia ancora una variabile aleatoria (con argomentazione);
2. **media e varianza** della media campionaria;
3. l'enunciato della **legge dei grandi numeri** e la sua **dimostrazione a partire dalla disuguaglianza di Čebyšëv**;
4. il **significato intuitivo** della legge e come si usa in statistica.

Nel 02/09/25 è il Quesito 1, nel 01/04/26 è il Quesito 2: cambia la posizione, non la richiesta. Nel 02/09/25 c'è in più il punto su statistica descrittiva vs inferenziale, che nel testo del 01/04/26 non compare.

Cosa farne, concretamente

Queste due coppie vanno **preparate come copioni**: una scaletta scritta, con le definizioni da recitare a memoria e i passaggi delle due dimostrazioni (l'indipendenza per il punto 4 della prima; Čebyšëv per il punto 3 della seconda). Non è "studiare la teoria sperando che capiti": è che è *già* capitato, due volte ciascuna, e la probabilità che ricapitino è alta esattamente perché sono già ricapitate. Le due dimostrazioni per esteso sono nel Cap. 6 e nel Cap. 5.

Laboratorio: il confronto teoria-simulazione c'è sempre

Guardando i quesiti di Laboratorio emerge un dato netto:

Competenza richiesta	Volte (su 18 quesiti)
Simulare e confrontare con la teoria (istogramma, overlay, QQ-plot)	14
Calcolare una probabilità da un modello teorico	11
Rappresentare graficamente i dati (plot, bar, scatter)	10
Usare <code>scipy.stats</code> (pmf/pdf/cdf/ppf)	9
Regressione lineare e correlazione	3
Test d'ipotesi o intervallo di confidenza	4
Metodi Monte Carlo (hit or miss, rigetto)	3
Catene di Markov in Python	2

Cosa scrivere all'esame

Il Laboratorio ruota quasi sempre attorno a **quattro passi fissi**:

1. calcolare la quantità **teoricamente** (con la formula);
2. **simulare** con `np.random`;
3. **confrontare** i due risultati con un grafico;
4. **commentare** la differenza (fluttuazione campionaria, $\sim 1/\sqrt{N}$).

Se impari questo schema, sei in grado di impostare qualunque quesito di Laboratorio, anche uno mai visto prima. La Parte II di questa guida è costruita esattamente su questi quattro passi.

2.4 Le domande di teoria ricorrenti, parola per parola

Alcune domande compaiono *identiche* in appelli diversi. Vale la pena impararle a memoria. Le principali:

- “Dare la definizione di *stimatore*” (28/01/25, 29/04/26, 23/06/26) — e la variante “*stimatore puntuale*”.
- “Dare la definizione di *stimatore non distorto*” (28/01/25, 29/04/26).
- “Dare la definizione di *evento*” e “di *evento incompatibile*” (24/03/25, 27/01/26) — le due domande compaiono sempre **insieme**.
- “Dare la definizione di *processo stocastico*” e “di *catena di Markov*” (28/01/25, 29/04/26) — anche queste sempre in coppia.
- “Dare la definizione di *matrice di transizione*” (17/06/25, 27/01/26).
- “Dare la definizione di *catena di Markov irriducibile*” (17/06/25, 29/04/26).
- “Che cos'è un *numero pseudorandom*?” (02/09/25, 23/06/26).
- “Dare la definizione di *variabile aleatoria*” (17/06/25, 01/04/26).

Tutte queste definizioni sono raccolte, nella forma da scrivere sul compito, nella Parte I e ripetute nell'Appendice C.

2.5 Errori da non fare

Dall'analisi delle prove e delle soluzioni emergono errori ricorrenti che costano punti in modo prevedibile. Sono segnalati nel testo con un box rosso, ma i tre più gravi vale la pena anticiparli:

1. Confondere “non rigetto H_0 ” con “ H_0 è vera”

Quando un test non rigetta l'ipotesi nulla, **non** si può concludere che l'ipotesi nulla sia vera: il test semplicemente non è concludente. Diverse prove d'esame sono costruite apposta su questo (es. 01/04/26, punto d), dove la risposta corretta è “non possiamo affermarlo”).

2. Dividere per il numero sbagliato nelle simulazioni

Per stimare una probabilità da una simulazione si divide per il **numero di esperimenti simulati**, non per il numero di oggetti del problema. Nella prova del 27/01/26 (carte Magic) dividere per le 60 carte del mazzo invece che per le 350 mani simulate produce “ $P(\text{buona}) = 3.18$ ”, che non è una probabilità.

3. Usare la distribuzione sbagliata

- Estrazione **senza** reinserimento $\Rightarrow$ **ipergeometrica**, non binomiale (27/01/26).
- Varianza della popolazione **non nota** $\Rightarrow$ t di Student, non normale (27/01/26).
- Varianza **nota** $\Rightarrow$ z , non t (29/04/26, 24/03/25).
- Domanda **direzionale** (“più grande”, “minore”) $\Rightarrow$ test **unilatero**, non bilatero (29/04/26, 24/03/25).

L'interpretazione del testo è, in queste prove, metà del lavoro.

Capitolo 3

Eventi e probabilità

3.1 Eventi

Definizione di evento

Dato lo **spazio campionario** Ω , cioè l'insieme di tutti i risultati possibili di un esperimento aleatorio, un **evento** è un sottoinsieme $A \subseteq \Omega$. L'evento si realizza se il risultato dell'esperimento appartiene ad A .

Cosa scrivere all'esame

Questa definizione è stata chiesta **per intero** il 24/03/25 e il 27/01/26. Va scritta menzionando *tutti e tre* gli elementi: che Ω è lo spazio campionario, che un evento è un suo sottoinsieme, e che si realizza quando il risultato appartiene ad A . Le tre informazioni valgono un punto ciascuna.

Alcuni eventi hanno un nome particolare:

- **Evento certo**: si indica con Ω ; la proposizione può essere solo vera.
- **Evento impossibile**: si indica con $\emptyset$; la proposizione può essere solo falsa.
- **Evento contrario** di A : si indica con A^c (o $\bar{A}$); è vero quando A è falso e viceversa.

Eventi incompatibili

Due eventi A e B si dicono **incompatibili** (o disgiunti) se $A \cap B = \emptyset$, cioè se non possono verificarsi contemporaneamente. In tal caso

$$P(A \cup B) = P(A) + P(B).$$

Cosa scrivere all'esame

Chiesta il 24/03/25 e il 27/01/26, *sempre insieme* alla definizione di evento. La risposta completa contiene due parti: la condizione $A \cap B = \emptyset$ e la conseguenza $P(A \cup B) = P(A) + P(B)$. Scrivere solo la formula, senza la condizione insiemistica, è una risposta incompleta.

Operazioni tra eventi

Date due eventi A e B :

Operazione	Notazione	Significato
Implicazione	$A \subseteq B$	A vero implica B vero
Contrario	A^c	vero quando A è falso
Unione (somma logica)	$A \cup B$	vero se almeno uno tra A e B è vero
Intersezione (prodotto logico)	$A \cap B$	vero se entrambi sono veri

Proprietà delle probabilità

Dagli assiomi si dimostrano:

$$\begin{aligned}P(A^c) &= 1 - P(A) \\ A \subseteq B &\implies P(A) \leq P(B) \\ P(A \cup B) &= P(A) + P(B) - P(A \cap B)\end{aligned}$$

e in generale, per l'unione di n eventi (formula di inclusione-esclusione):

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \sum_{i < j < k} P(A_i \cap A_j \cap A_k) - \dots + (-1)^{n-1} P\left(\bigcap_{i=1}^n A_i\right).$$

Tradurre un testo in simboli

Un tipo di esercizio che compare spesso (24/03/25, 27/01/26, 01/04/26) chiede di tradurre una frase in un'espressione con A , B , A^c , $\cap$, $\cup$.

Come tradurre una frase in simboli

Procedi in tre passi:

1. **Isola le frasi elementari** e assegna a ciascuna un nome. Attenzione: a volte il testo definisce gli eventi in *forma negativa* (es. “ A = la tastiera *non* funziona”), e questo va rispettato.
2. **Individua i connettivi**: “e” $\rightarrow \cap$, “o” $\rightarrow \cup$, “non” $\rightarrow$ complementare.
3. **Scrivi l'espressione** e, se serve calcolarla, semplificala con le leggi di De Morgan.

Esempio svolto (27/01/26)

Giorgino lavora se il monitor funziona e almeno uno tra tastiera e mouse funziona. Con

A = “tastiera non funziona”, B = “mouse non funziona”, C = “monitor non funziona”,

l'evento “lavora” è $\bar{C} \cap (\bar{A} \cup \bar{B})$. L'evento richiesto G = “non può lavorare” è il suo complementare:

$$G = \overline{\bar{C} \cap (\bar{A} \cup \bar{B})} = C \cup (A \cap B)$$

per la legge di De Morgan. A parole: *non può lavorare se il monitor è rotto oppure se sono rotti sia tastiera che mouse.*

3.2 Le quattro definizioni di probabilità

1. Definizione classica

Se ho n eventi elementari *equiprobabili*, e l'evento E si verifica in h di essi, allora

$$P(E) = \frac{h}{n} = \frac{\text{\#casi favorevoli}}{\text{\#casi totali}}.$$

2. Definizione frequentista

Ripeto n volte un fenomeno ripetibile e conto quante volte (k) si verifica E :

$$P(E) = \frac{k}{n}.$$

Più n è grande, più la stima è accurata. Questa è l'idea che sta dietro a *tutte* le simulazioni Python della Parte II.

3. Definizione soggettiva (De Finetti)

È una misura di fiducia sul verificarsi di un evento. Si formalizza con una *quota* $p \geq 0$ e una somma $S > 0$: si effettua una scommessa di quota p su E versando pS e ricevendo S solo se E si verifica. Il guadagno è

$$G_1 = S(1 - p) \text{ se } E \text{ si verifica,} \quad G_2 = -Sp \text{ se } E \text{ non si verifica.}$$

La scommessa si dice **coerente** se $G_1 G_2 \leq 0$ (guadagni di segno discorde), il che accade se e solo se $0 \leq p \leq 1$. In tal caso p è la probabilità di E .

4. Definizione assiomatica (Kolmogorov)

Spazio di probabilità e assiomi di Kolmogorov

Uno **spazio di probabilità** è una terna $(\Omega, \mathcal{A}, P)$ dove:

- Ω è lo **spazio campionario**, l'insieme di tutti i risultati possibili;
- $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ è la famiglia degli **eventi**, che gode delle proprietà:

1. $\emptyset, \Omega \in \mathcal{A}$;
2. $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$;
3. $A_1, \dots, A_n \in \mathcal{A} \Rightarrow \bigcup_{i=1}^n A_i \in \mathcal{A}$.

(cioè $\mathcal{A}$ è una **σ -algebra**);

- $P : \mathcal{A} \rightarrow [0, 1]$ è una funzione che soddisfa gli **assiomi**:

1. $P(A) \geq 0$ per ogni $A \in \mathcal{A}$ (non negatività)
2. $P(\Omega) = 1$ (normalizzazione)
3. $P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$ per eventi a due a due incompatibili (additività numerabile)

Cosa scrivere all'esame

Chiesta il 17/06/25. Il punto d'esame è ricordare che servono **tre** elementi (insieme, famiglia di eventi, misura) e che $\mathcal{A}$ deve essere una σ -algebra. Quasi tutti dimenticano la chiusura rispetto al complementare o all'unione numerabile: sono i due punti che fanno la differenza.

3.3 Probabilità condizionale e indipendenza

Probabilità condizionale

Dati due eventi A, B con $P(B) > 0$, la **probabilità condizionale** di A dato B è

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Un **evento condizionato** $A|B$ (“ A noto B ”) è un ente a tre valori: è vero se, essendo vero B , è vero anche A ; è falso se, essendo vero B , A è falso; è *indeterminato* se B è falso.

Eventi indipendenti

Due eventi A e B sono **indipendenti** se

$$P(A \cap B) = P(A) P(B),$$

e di conseguenza $P(A | B) = P(A)$.

Errore tipico da evitare

La condizione è **necessaria e sufficiente**: se so che A e B sono indipendenti posso moltiplicare le probabilità; se trovo che il prodotto vale, posso concludere che sono indipendenti. Attenzione però a non confondere *indipendenti* con *incompatibili*: due eventi incompatibili con probabilità positiva hanno $P(A \cap B) = 0 \neq P(A)P(B)$, quindi sono *dipendenti* (anzi, “massimamente” dipendenti: il verificarsi dell’uno esclude l’altro).

Indipendenza a due a due e indipendenza congiunta

Tre eventi A, B, C sono **a due a due indipendenti** se $P(A \cap B) = P(A)P(B)$, $P(A \cap C) = P(A)P(C)$, $P(B \cap C) = P(B)P(C)$. Sono una **famiglia di eventi indipendenti** se vale anche

$$P(A \cap B \cap C) = P(A) P(B) P(C).$$

Le due cose *non* sono equivalenti: l’indipendenza a due a due **non** implica quella congiunta. La prova del 27/01/26 usa esattamente questa distinzione (la roulette semplificata: A, B, C sono a due a due indipendenti ma non formano una famiglia indipendente, perché $P(A \cap B \cap C) = \frac{1}{12}$ mentre $P(A)P(B)P(C) = \frac{1}{8}$).

3.4 Il teorema delle probabilità totali

Teorema delle probabilità totali

Siano $A_1, A_2, \dots, A_n \in \mathcal{A}$ tali che

$$\bigcup_{i=1}^n A_i = \Omega, \quad A_i \cap A_j = \emptyset \quad \forall i \neq j, \quad P(A_i) > 0 \quad \forall i$$

(cioè gli A_i formano una **partizione** di Ω). Allora, per ogni evento B :

$$P(B) = \sum_{i=1}^n P(B | A_i) P(A_i).$$

Svolgimento. [Dimostrazione]

$$P(B) = P(B \cap \Omega) = P\left(B \cap \bigcup_{i=1}^n A_i\right) = P\left(\bigcup_{i=1}^n (B \cap A_i)\right) = \sum_{i=1}^n P(B \cap A_i) = \sum_{i=1}^n P(B | A_i) P(A_i),$$

dove la penultima uguaglianza usa il fatto che i $B \cap A_i$ sono a due a due incompatibili (perché lo sono gli A_i), e l'ultima la definizione di probabilità condizionale. ■

3.5 Il teorema di Bayes

Teorema di Bayes

Dati due eventi A, B con $P(A), P(B) > 0$:

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)}.$$

Svolgimento. [Dimostrazione] Poiché $P(A \cap B) = P(B \cap A)$, dalla definizione di probabilità condizionale si ha

$$P(A | B) = \frac{P(B \cap A)}{P(B)} = \frac{P(B | A) P(A)}{P(B)},$$

avendo sostituito $P(B \cap A) = P(B | A)P(A)$. ■

La forma che serve negli esercizi

Nella pratica $P(B)$ al denominatore non è nota e va calcolata con il teorema delle probabilità totali. La forma operativa è quindi

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{\sum_j P(B | A_j) P(A_j)}.$$

Come impostare un problema di Bayes

1. Identifica le **cause** A_i (le linee di produzione, le monete, le stazioni): sono loro a partizionare Ω .
2. Scrivi i dati del problema come $P(A_i)$ (probabilità *a priori*) e $P(B | A_i)$ (verosimiglianze).
3. Calcola $P(B)$ con le probabilità totali.
4. Applica Bayes per la probabilità “a ritroso” $P(A_i | B)$.

Controllo di sanità: dopo Bayes la probabilità “a ritroso” deve essere maggiore dell’“a priori” se l’evidenza B è più probabile sotto quella causa. Se viene un numero fuori da $[0, 1]$, c’è un errore.

3.6 Richiami di calcolo combinatorio

Tutto il calcolo combinatorio si riduce a una domanda: **l’ordine conta?** Le *disposizioni* considerano l’ordine, le *combinazioni* no.

Tipo	Formula	Significato
r -disposizioni	n^r	r elementi <i>ordinati</i> da n , con ripetizione
r -disposizioni semplici	$D_{n,r} = \frac{n!}{(n-r)!}$	r elementi ordinati da n , senza ripetizione
r -combinazioni	$\binom{n+r-1}{r}$	r elementi <i>non</i> ordinati da n , con ripetizione
r -combinazioni semplici	$C_{n,r} = \binom{n}{r} = \frac{n!}{r!(n-r)!}$	r elementi non ordinati da n , senza ripetizione

Per $r = n$ le disposizioni semplici diventano le **permutazioni**: $D_{n,n} = n!$.

Partizioni

Dato un insieme di n elementi e interi $n_1 + n_2 + \dots + n_k = n$, il numero di modi di partizionare l'insieme in k gruppi di dimensioni $n_1, \dots, n_k$ è il **coefficiente multinomiale**

$$C_{n_1, n_2, \dots, n_k}^n = \frac{n!}{n_1! n_2! \dots n_k!}.$$

La domanda da farsi sempre

- **L'ordine conta?** Codice del telefono $\rightarrow$ sì $\rightarrow$ disposizioni. Cartella della tombola $\rightarrow$ no $\rightarrow$ combinazioni.
- **Si può ripetere?** Estrazione con reinserimento $\rightarrow$ sì. Estrazione di carte da un mazzo $\rightarrow$ no.

Le quattro combinazioni danno le quattro formule della tabella. Sbagliare qui è l'errore più comune di tutto il capitolo.

3.7 Esercizi svolti

Esercizio 1 — Urna con palline di tre colori

Un'urna contiene 5 palline bianche, 6 nere e 4 rosse. Se ne estraggono due. Calcolare la probabilità che siano dello stesso colore nel caso in cui (a) l'estrazione sia istantanea; (b) l'estrazione sia con reinserimento.

Svolgimento. Il numero totale di palline è $n = 5 + 6 + 4 = 15$.

(a) Estrazione simultanea (senza reinserimento $\rightarrow$ combinazioni semplici). I casi totali sono $\binom{15}{2}$. I casi favorevoli sono l'unione di tre eventi incompatibili (“entrambe bianche” $\cup$ “entrambe nere” $\cup$ “entrambe rosse”):

$$p = \frac{\binom{5}{2} + \binom{6}{2} + \binom{4}{2}}{\binom{15}{2}} = \frac{10 + 15 + 6}{105} = \frac{31}{105} \approx 0.2952.$$

(b) Estrazione con reinserimento (l'ordine conta $\rightarrow$ disposizioni). Ogni estrazione è indipendente, quindi posso anche ragionare per colori:

$$p = p_{BB} + p_{NN} + p_{RR} = \left(\frac{5}{15}\right)^2 + \left(\frac{6}{15}\right)^2 + \left(\frac{4}{15}\right)^2 = \frac{25 + 36 + 16}{225} = \frac{77}{225} \approx 0.3422.$$

Esercizio 2 — Probabilità empiriche e test binomiale (Oveti, 01/04/26)

20 buste contengono 10 oveti ciascuna, di tre tipi. Il numero di oveti *bianchi* per busta è

3, 5, 2, 3, 2, 4, 3, 3, 4, 4, 3, 2, 4, 5, 4, 4, 3, 2, 4, 3.

Con confidenza al 95%, è possibile affermare che la probabilità di trovare un ovetto bianco sia maggiore di $1/3$?

Svolgimento. Si contano gli oveti bianchi: $k = 67$ su un totale di $n = 200$ oveti, quindi $\hat{p} = 0.335$, appena sopra $1/3 \approx 0.333$.

Sotto $H_0 : p = 1/3$, il numero di oveti bianchi è $X \sim \text{Bin}(200, 1/3)$. La domanda è direzionale, quindi il p -value è unilaterale destro:

$$p\text{-value} = P(X \geq 67) \approx 0.50.$$

Essendo $0.50 > 0.05$, **non rigettiamo** H_0 . Non c'è evidenza statistica per affermare che $p > 1/3$: la differenza osservata è perfettamente compatibile con la fluttuazione casuale.

Errore tipico da evitare

La risposta sbagliata tipica è “no, quindi $p = 1/3$ ”. **Non rigettare H_0 non significa che H_0 sia vera**: significa solo che il test non è concludente. La risposta corretta è “*non possiamo affermare che $p > 1/3$* ”.

Esercizio 3 — Metal detector (Bayes)

Tutte le borse imbarcate su un aereo passano al metal detector. Si sa che: la probabilità che una borsa *con* ordigno faccia scattare l'allarme è 0.99; la probabilità che una borsa *senza* ordigno faccia scattare l'allarme è 0.05; una borsa ogni 5000 contiene un ordigno. Calcolare (a) la probabilità che scatti l'allarme; (b) la probabilità che una borsa che ha fatto scattare l'allarme contenga un ordigno; (c) di quanto aumenta la probabilità che ci sia un ordigno sapendo che l'allarme è scattato.

Svolgimento. Siano A = “la borsa contiene l'ordigno” e B = “la borsa fa scattare l'allarme”. I dati sono

$$P(A) = \frac{1}{5000}, \quad P(B | A) = 0.99, \quad P(B | A^c) = 0.05.$$

(a) Con le probabilità totali:

$$P(B) = P(B | A)P(A) + P(B | A^c)P(A^c) = 0.99 \cdot \frac{1}{5000} + 0.05 \cdot \frac{4999}{5000} \approx 0.0502.$$

(b) Con Bayes:

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)} = \frac{0.99 \cdot \frac{1}{5000}}{0.0502} \approx 0.0039.$$

(c) Il fattore di proporzionalità è

$$\gamma = \frac{P(A | B)}{P(A)} = \frac{0.0039}{0.0002} \approx 19.5.$$

L'informazione che l'allarme è scattato ha reso l'evento “c'è un ordigno” quasi **venti volte** più probabile. (Resta comunque piccolo in assoluto: è il classico effetto di una malattia rara con un test poco specifico.)

Esercizio 4 — Stazione radio (probabilità totali)

Una stazione riceve segnale da due sorgenti A e B , equidistribuite. La probabilità che il segnale da A sia distorto è 0.1; da B è 0.2. Qual è la probabilità di ricevere un segnale distorto?

Svolgimento. Con S_A, S_B gli eventi “il segnale proviene da A/B ” e S = “segnale distorto”, si ha $P(S_A) = P(S_B) = 0.5$, $S_A \cup S_B = \Omega$, $S_A \cap S_B = \emptyset$. Per le probabilità totali:

$$P(S) = P(S | S_A)P(S_A) + P(S | S_B)P(S_B) = 0.1 \cdot 0.5 + 0.2 \cdot 0.5 = 0.15.$$

Capitolo 4

Variabili aleatorie

4.1 La definizione

Variabile aleatoria

Dato uno spazio di probabilità $(\Omega, \mathcal{A}, P)$, una **variabile aleatoria** è una funzione

$$X : \Omega \longrightarrow \mathbb{R}$$

che associa a ogni risultato elementare $\omega \in \Omega$ un numero reale $X(\omega)$, ed è tale che per ogni $x \in \mathbb{R}$ l'insieme $\{X \leq x\} = \{\omega \in \Omega : X(\omega) \leq x\}$ appartiene a $\mathcal{A}$ (cioè è un evento).

In parole: una variabile aleatoria è una **funzione che numera i risultati** di un esperimento aleatorio.

Cosa scrivere all'esame

Chiesta il 17/06/25 e il 01/04/26. La risposta che prende il punteggio pieno contiene *tre* cose:

1. è una **funzione** da Ω a $\mathbb{R}$ (questo è il punto centrale: quasi tutti dimenticano di dire che è una funzione e la confondono con una variabile);
2. l'argomento della funzione sono i **risultati elementari** ω , non gli eventi;
3. la condizione di **misurabilità**, cioè che $\{X \leq x\} \in \mathcal{A}$.

Se l'esercizio chiede anche “fai un esempio”, vale sempre la scelta più semplice: il lancio di una moneta, con $\Omega = \{T, C\}$ e $X(T) = 0$, $X(C) = 1$.

4.2 Variabili discrete e variabili continue

4.2.1 Variabili aleatorie discrete

Variabile aleatoria discreta e densità discreta

Una variabile aleatoria X è **discreta** se la sua immagine $X(\Omega)$ è un insieme *finito o numerabile* di valori $\{x_1, x_2, \dots\}$.

La sua distribuzione si descrive con la **densità discreta** (o funzione di probabilità)

$$p_X(x_i) = P(X = x_i) = P(\{\omega \in \Omega : X(\omega) = x_i\}),$$

che deve soddisfare le due condizioni

$$p_X(x_i) \geq 0 \quad \forall i, \quad \sum_i p_X(x_i) = 1.$$

Valore atteso e varianza — caso discreto

$$\mathbb{E}[X] = \sum_i x_i p_X(x_i), \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \sum_i (x_i - \mathbb{E}[X])^2 p_X(x_i).$$

4.2.2 Variabili aleatorie continue

Variabile aleatoria continua e densità continua

X è **continua** se esiste una funzione $f_X : \mathbb{R} \rightarrow [0, +\infty)$, detta **densità continua** (o funzione di densità), tale che

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx \quad \forall a < b,$$

e che soddisfi

$$f_X(x) \geq 0 \quad \forall x, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1.$$

Errore tipico da evitare

Due conseguenze della definizione che vengono sbagliate sistematicamente:

- Per una variabile continua $P(X = x) = \int_x^x f = 0$ per ogni x . **Quindi nella probabilità continua $\leq$ e $<$ sono la stessa cosa.**
- $f_X(x)$ **non** è una probabilità: può valere più di 1 (es. $\mathcal{U}(0, 0.5)$ ha densità $f(x) = 2$ su $[0, 0.5]$). Solo l'*integrale* di f è una probabilità.

Funzione di ripartizione

Per una variabile aleatoria X (discreta o continua) la **funzione di ripartizione** è

$$F_X(x) = P(X \leq x).$$

Valgono $F_X(-\infty) = 0$, $F_X(+\infty) = 1$, F_X non decrescente e continua a destra. Inoltre

$$P(a < X \leq b) = F_X(b) - F_X(a), \quad f_X(x) = F'_X(x) \text{ (caso continuo)}.$$

Perché in Python si usano `cdf` e `ppf`

`scipy.stats` implementa esattamente questi oggetti:

Metodo	Cosa calcola	Formula
<code>pmf(k)</code> / <code>pdf(x)</code>	densità puntuale	$p_X(k)$ oppure $f_X(x)$
<code>cdf(x)</code>	funzione di ripartizione	$P(X \leq x) = F_X(x)$
<code>sf(x)</code>	coda destra	$P(X > x) = 1 - F_X(x)$
<code>ppf(q)</code>	inversa della cdf	l' x tale che $F_X(x) = q$

`ppf` è quello che si usa per i **quantili** e per gli **intervalli di confidenza**: `norm.ppf(0.975)` = 1.96 è il valore critico che serve in tutti gli IC al 95%.

4.3 Momenti

Momenti

Sia X una variabile aleatoria.

- Il **momento semplice** (o momento rispetto all'origine) di ordine k è $\mathbb{E}[X^k]$.

- Il **momento centrato** di ordine k è

$$\mathbb{E}[(X - \mathbb{E}[X])^k].$$

I casi che servono:

$$\begin{array}{ccc} \mathbb{E}[X] & , & \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2], & \mathbb{E}[(X - \mathbb{E}[X])^3] \\ \text{|\{Z\}|} & & \text{|\{Z\}|} & \text{|\{Z\}|} \\ k=1 \text{ semplice} & & k=2 \text{ centrato} & k=3 \text{ centrato (asimmetria)} \end{array}$$

Cosa scrivere all'esame

Il “momento centrato di ordine k ” è stato chiesto il 01/04/26. La risposta è la formula $\mathbb{E}[(X - \mathbb{E}[X])^k]$, con la precisazione che per $k = 1$ vale 0 (perché $\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = 0$) e per $k = 2$ è la varianza. Questa coppia di osservazioni è esattamente ciò che il correttore cerca.

Le formule del valore atteso che si usano di continuo

$$\mathbb{E}[aX + b] = a \mathbb{E}[X] + b, \quad \text{Var}(aX + b) = a^2 \text{Var}(X), \quad \text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

La varianza è invariante per traslazione: aggiungere una costante non cambia la dispersione, moltiplicare per a la scala di a^2 .

Linearità del valore atteso

Vale *sempre*, anche senza indipendenza:

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y], \quad \mathbb{E}\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \mathbb{E}[X_i].$$

Per la varianza invece serve l'indipendenza:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y), \quad \text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y],$$

e se $X \perp Y$ allora $\text{Cov}(X, Y) = 0$ e $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

4.4 Le distribuzioni notevoli discrete

4.4.1 Bernoulli

$X \sim \text{Ber}(p)$: un solo esperimento con esito successo (1) o insuccesso (0).

$$P(X = 1) = p, \quad P(X = 0) = 1 - p = q, \quad \mathbb{E}[X] = p, \quad \text{Var}(X) = pq.$$

4.4.2 Binomiale

Distribuzione binomiale

$X \sim \text{Bin}(n, p)$ conta il **numero di successi** in n prove *indipendenti* con la *stessa* probabilità di successo p . La densità è

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n,$$

e inoltre

$$\mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p).$$

Svolgimento. [Derivazione di $\mathbb{E}[X] = np$] Usando l'identità $k \binom{n}{k} = n \binom{n-1}{k-1}$:

$$\mathbb{E}[X] = \sum_{k=0}^n k \binom{n}{k} p^k q^{n-k} = \sum_{k=1}^n n \binom{n-1}{k-1} p^k q^{n-k} = np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} q^{n-k}.$$

Posto $j = k - 1$ la somma diventa

$$np \sum_{j=0}^{n-1} \binom{n-1}{j} p^j q^{(n-1)-j} = np (p+q)^{n-1} = np,$$

per il teorema del binomio e perché $p+q=1$. ■

Svolgimento. [Derivazione di $\text{Var}(X) = np(1-p)$] Conviene calcolare $\mathbb{E}[X(X-1)]$, usando $k(k-1) \binom{n}{k} = n(n-1) \binom{n-2}{k-2}$:

$$\mathbb{E}[X(X-1)] = \sum_{k=0}^n k(k-1) \binom{n}{k} p^k q^{n-k} = n(n-1)p^2 \sum_{k=2}^n \binom{n-2}{k-2} p^{k-2} q^{n-k} = n(n-1)p^2.$$

Quindi

$$\begin{aligned} \mathbb{E}[X^2] &= \mathbb{E}[X(X-1)] + \mathbb{E}[X] = n(n-1)p^2 + np, \\ \text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 = n(n-1)p^2 + np - n^2p^2 = np - np^2 = np(1-p). \end{aligned} \quad \blacksquare$$

Cosa scrivere all'esame

La binomiale è stata chiesta per intero il 17/02/26: definizione, esempio, media e varianza *con derivazione*. La strada più rapida che il correttore si aspetta è quella per **indipendenza**: scrivere $X = X_1 + \dots + X_n$ con $X_i \sim \text{Ber}(p)$ indipendenti, e usare $\mathbb{E}[X] = \sum \mathbb{E}[X_i] = np$ e $\text{Var}(X) = \sum \text{Var}(X_i) = npq$. Se hai tempo, fai anche la derivazione esplicita con i coefficienti binomiali: dimostra di saper maneggiare la formula.

4.4.3 Ipergeometrica**Distribuzione ipergeometrica**

$X \sim \text{Iper}(N, K, n)$ conta il **numero di successi** in n estrazioni *senza reinserimento* da una popolazione di N elementi, dei quali K hanno la caratteristica di interesse:

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad \mathbb{E}[X] = n \frac{K}{N}, \quad \text{Var}(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}.$$

Errore tipico da evitare

Senza reinserimento $\Rightarrow$ **ipergeometrica**. **Con reinserimento** (o prove indipendenti) $\Rightarrow$ **binomiale**. Nella prova del 27/01/26 (mazzo di carte Magic, 60 carte) la distribuzione corretta era l'ipergeometrica, non la binomiale. Distinguere le due è un punto d'esame. Il fattore finale $\frac{N-n}{N-1}$ è la *correzione per popolazione finita*: tende a 1 quando N è molto più grande di n , ed è ciò che rende l'ipergeometrica "più concentrata" della binomiale.

4.4.4 Poisson**Distribuzione di Poisson**

$X \sim \text{Pois}(\lambda)$ conta il numero di eventi che si verificano in un intervallo fissato di tempo o di spazio, quando gli eventi sono rari e indipendenti e λ è il numero medio atteso:

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots, \quad \mathbb{E}[X] = \text{Var}(X) = \lambda.$$

Il legame con la binomiale e con l'esponenziale

- **Binomiale $\rightarrow$ Poisson:** $\text{Bin}(n, p)$ con n grande, p piccolo e $np \rightarrow \lambda$ si approssima con $\text{Pois}(\lambda)$. Regola pratica: $n \geq 50$ e $p \leq 0.05$.
- **Poisson $\leftrightarrow$ esponenziale:** se gli *arrivi* contano $\text{Pois}(\lambda)$ per unità di tempo, allora il *tempo tra due arrivi* è $\text{Exp}(\lambda)$. È il caso della prova del 29/04/26 (server web).

4.4.5 Geometrica**Distribuzione geometrica**

$X \sim \text{Geom}(p)$ conta il numero di **prove necessarie per ottenere il primo successo**, con prove indipendenti di probabilità p :

$$P(X = k) = (1 - p)^{k-1} p, \quad k = 1, 2, 3, \dots$$

$$\mathbb{E}[X] = \frac{1}{p}, \quad \text{Var}(X) = \frac{1 - p}{p^2}.$$

Proprietà di assenza di memoria

X ha **assenza di memoria** se

$$P(X > n + k \mid X > n) = P(X > k) \quad \forall n, k \geq 0.$$

Svolgimento. [La geometrica non ha memoria] Poiché $P(X > m) = \sum_{j>m} (1 - p)^{j-1} p = (1 - p)^m$ (serie geometrica), si ha

$$P(X > n + k \mid X > n) = \frac{P(X > n + k)}{P(X > n)} = \frac{(1 - p)^{n+k}}{(1 - p)^n} = (1 - p)^k.$$

D'altra parte $P(X > k) = (1 - p)^k$. Le due quantità coincidono:

$$P(X > n + k \mid X > n) = P(X > k). \quad \blacksquare$$

A parole: *il tempo già trascorso non cambia la distribuzione del tempo rimanente*. Se ho lanciato un dado 10 volte senza mai fare 6, la probabilità di dover aspettare ancora 5 lanci è la stessa di chi comincia adesso.

Il legame con la binomiale

C'è un rapporto diretto tra le due distribuzioni:

$$P(X \geq k) = P(\text{nessun successo nelle prime } k-1 \text{ prove}) = (1-p)^{k-1},$$

cioè l'evento "servono almeno k prove" è il complementare di "almeno un successo in $k-1$ prove", che è governato dalla binomiale. Simmetricamente: il numero di insuccessi *prima* del primo successo, $Y = X - 1$, ha $\mathbb{E}[Y] = \frac{1-p}{p}$ ed è la stessa variabile con un'altra convenzione.

Errore tipico da evitare

La geometrica si può definire in **due modi**, a seconda di cosa si conta:

Convenzione	Supporto	$\mathbb{E}[X]$	$\text{Var}(X)$
numero di prove fino al 1° successo	$1, 2, \dots$	$1/p$	$(1-p)/p^2$
numero di insuccessi prima del 1° successo	$0, 1, \dots$	$(1-p)/p$	$(1-p)/p^2$

Dichiara sempre quale convenzione stai usando prima di scrivere la formula. All'esame del 24/03/25 è chiesto esplicitamente il legame fra geometrica e binomiale proprio per verificare che questa distinzione sia chiara.

4.4.6 Uniforme discreta

$X \sim \mathcal{U}\{x_1, \dots, x_n\}$: tutti i valori hanno la stessa probabilità $1/n$. Per $\mathcal{U}\{1, \dots, n\}$:

$$\mathbb{E}[X] = \frac{n+1}{2}, \quad \text{Var}(X) = \frac{n^2-1}{12}.$$

È la distribuzione del lancio di un dado e del gioco dell'oca (17/06/25).

4.5 Le distribuzioni notevoli continue

4.5.1 Uniforme continua

$X \sim \mathcal{U}(a, b)$: densità costante sull'intervallo,

$$f_X(x) = \frac{1}{b-a} \mathbf{1}_{a \leq x \leq b}, \quad \mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$

4.5.2 Esponenziale

Distribuzione esponenziale

$X \sim \text{Exp}(\lambda)$ descrive il **tempo di attesa** tra due eventi di un processo di Poisson di intensità λ :

$$f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{x \geq 0}, \quad F_X(x) = 1 - e^{-\lambda x}, \quad \mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

Come la geometrica nel discreto, l'esponenziale è **senza memoria**: $P(X > s+t \mid X > s) = P(X > t) = e^{-\lambda t}$.

λ è un tasso, non una probabilità

Attenzione all'unità di misura: se $\lambda = 4$ significa “4 eventi per *unità* di tempo”, allora $\mathbb{E}[X] = 1/4$ di quella stessa unità. Se il problema dà “un evento ogni 15 minuti”, allora $\lambda = 1/15$ se il tempo è misurato in minuti. Sbagliare qui rende il risultato sbagliato di un fattore arbitrario, e nella prova del 29/04/26 questo era uno dei punti di controllo.

4.5.3 Normale (gaussiana)**Distribuzione normale**

$X \sim N(\mu, \sigma^2)$ ha densità

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \quad x \in \mathbb{R},$$

con $\mathbb{E}[X] = \mu$ e $\text{Var}(X) = \sigma^2$. È simmetrica rispetto a μ , ha forma a campana, e la sua densità ha due flessi in $\mu \pm \sigma$. La **normale standard** è $Z \sim N(0, 1)$, con funzione di ripartizione Φ , e ogni normale si riconduce a essa con la **standardizzazione**

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

I quantili che tornano sempre

$$\Phi(1.645) = 0.95, \quad \Phi(1.96) = 0.975, \quad \Phi(2.576) = 0.995.$$

Da cui gli intervalli di confidenza “a memoria”: $90\% \Rightarrow 1.645$, $95\% \Rightarrow 1.96$, $99\% \Rightarrow 2.576$. In Python: `norm.ppf(0.975) = 1.959964`.

Perché la normale è così importante

Non perché i dati siano normali, ma per il **teorema del limite centrale** (Capitolo 5): qualunque sia la distribuzione di partenza, la *somma* di molte variabili indipendenti si distribuisce approssimativamente come una normale. È il motivo per cui la normale compare nelle simulazioni anche quando il fenomeno non è affatto gaussiano.

4.5.4 Chi-quadro**Distribuzione chi-quadro**

Se $Z_1, \dots, Z_n$ sono $N(0, 1)$ indipendenti, allora

$$X = Z_1^2 + Z_2^2 + \dots + Z_n^2 \sim \chi^2(n),$$

con $\mathbb{E}[X] = n$ e $\text{Var}(X) = 2n$. È asimmetrica a destra e si usa per la **varianza campionaria** e per i test di bontà di adattamento.

4.5.5 t di StudentDistribuzione t di Student

Se $Z \sim N(0, 1)$ e $V \sim \chi^2(n)$ sono indipendenti, allora

$$T = \frac{Z}{\sqrt{V/n}} \sim t(n).$$

Ha media 0 ($n > 1$), varianza $\frac{n}{n-2}$ ($n > 2$) e code più pesanti della normale. Per $n \rightarrow \infty$ tende alla $N(0, 1)$ (già per $n > 30$ la differenza è trascurabile).

Quando t e quando z

È la scelta che determina se un test è giusto o sbagliato:

- **varianza della popolazione σ^2 nota** $\Rightarrow z$ (normale);
- **varianza non nota, stimata dal campione con S^2** $\Rightarrow t$ di Student con $n - 1$ gradi di libertà.

È lo stesso motivo per cui in `scipy.stats` esistono sia `norm` sia `t`: si usano in situazioni diverse. Nella prova del 27/01/26 (peso dei biscotti) σ non era nota, quindi serviva la t ; nella prova del 29/04/26 (farmaco) σ era nota, quindi serviva la z .

4.6 Esercizi svolti

Esercizio 1 — Variabile aleatoria da un esperimento

Si lanciano due monete equilibrate. Sia X il numero di teste ottenute. (a) Definire lo spazio campionario e X come funzione. (b) Scrivere la densità discreta. (c) Calcolare $\mathbb{E}[X]$ e $\text{Var}(X)$.

Svolgimento. (a) $\Omega = \{TT, TC, CT, CC\}$. La variabile aleatoria è la funzione $X : \Omega \rightarrow \{0, 1, 2\}$ definita da

$$X(TT) = 2, \quad X(TC) = X(CT) = 1, \quad X(CC) = 0.$$

(b) Con $p = 1/2$ si ha $X \sim \text{Bin}(2, 1/2)$:

$$P(X = 0) = \frac{1}{4}, \quad P(X = 1) = \frac{1}{2}, \quad P(X = 2) = \frac{1}{4}.$$

Verifica: $\frac{1}{4} + \frac{1}{2} + \frac{1}{4} = 1$.

(c) $\mathbb{E}[X] = np = 2 \cdot \frac{1}{2} = 1$ e $\text{Var}(X) = np(1-p) = 2 \cdot \frac{1}{2} \cdot \frac{1}{2} = 0.5$.

Esercizio 2 — Densità discreta da verificare

Sia X con densità discreta $p_X(k) = ck$ per $k = 1, 2, 3, 4$. Determinare c , poi $\mathbb{E}[X]$ e $\text{Var}(X)$.

Svolgimento. La somma delle probabilità deve valere 1:

$$\sum_{k=1}^4 ck = c(1 + 2 + 3 + 4) = 10c = 1 \implies c = \frac{1}{10}.$$

Quindi

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=1}^4 k \cdot \frac{k}{10} = \frac{1 + 4 + 9 + 16}{10} = \frac{30}{10} = 3, \\ \mathbb{E}[X^2] &= \sum_{k=1}^4 k^2 \cdot \frac{k}{10} = \frac{1 + 8 + 27 + 64}{10} = 10, \quad \text{Var}(X) = 10 - 3^2 = 1. \end{aligned}$$

Esercizio 3 — Tempo di attesa

Il tempo di vita di una lampadina è distribuito esponenzialmente con media 1000 ore. (a) Qual è la probabilità che duri più di 1500 ore? (b) Sapendo che è già durata 1000 ore, qual è la probabilità che ne duri almeno altre 1500?

Svolgimento. Parametrizziamo con $\lambda = 1/1000 = 0.001$ ore⁻¹.

(a) $P(X > 1500) = e^{-\lambda \cdot 1500} = e^{-1.5} \approx 0.2231$.

(b) Per l'assenza di memoria dell'esponenziale il tempo già trascorso non conta:

$$P(X > 1000 + 1500 \mid X > 1000) = P(X > 1500) = e^{-1.5} \approx 0.2231.$$

Verifica diretta: $\frac{P(X > 2500)}{P(X > 1000)} = \frac{e^{-2.5}}{e^{-1}} = e^{-1.5}$. Questo è il punto che l'esame vuole vedere: non serve ricalcolare, basta invocare l'assenza di memoria.

Esercizio 4 — Approssimazione normale

Il numero di errori di battitura per pagina in un libro è $\text{Pois}(3)$. Calcolare la probabilità che in una pagina ci siano esattamente 2 errori, e che ce ne siano al massimo 2.

Svolgimento.

$$P(X = 2) = \frac{3^2}{2!} e^{-3} = 4.5 e^{-3} \approx 0.2240,$$

$$P(X \leq 2) = e^{-3} \left(\frac{3^0}{0!} + \frac{3^1}{1!} + \frac{3^2}{2!} \right) = e^{-3} (1 + 3 + 4.5) = 8.5 e^{-3} \approx 0.4232.$$

In Python: `poisson.pmf(2, 3)` e `poisson.cdf(2, 3)`.

Capitolo 5

Legge dei grandi numeri e teorema del limite centrale

Questo capitolo risponde a una domanda che sta sotto a *tutta* la Parte II: *perché una simulazione funziona?* La risposta sono due teoremi limite.

5.1 La media campionaria

Media campionaria

Siano $X_1, \dots, X_n$ variabili aleatorie **indipendenti e identicamente distribuite** (i.i.d.) con media μ e varianza σ^2 (finite). La **media campionaria** è

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Valgono:

$$\mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{errore standard} = \frac{\sigma}{\sqrt{n}}.$$

Svolgimento. [Dimostrazione] Per la linearità del valore atteso (valida *senza* indipendenza):

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot n\mu = \mu.$$

Per la varianza serve l'indipendenza, che annulla tutte le covarianze:

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}. \quad \blacksquare$$

Cosa scrivere all'esame

Questo è il risultato più richiesto di tutto il capitolo (chiesto il 02/09/25 e il 01/04/26). Nel compito vanno scritte **tre** cose:

1. la definizione $\bar{X}_n = \frac{1}{n} \sum X_i$;
2. $\mathbb{E}[\bar{X}_n] = \mu$: la media campionaria è uno stimatore *non distorto* di μ ;
3. $\text{Var}(\bar{X}_n) = \sigma^2/n$: la sua precisione migliora come $1/n$, cioè l'errore standard diminuisce come $1/\sqrt{n}$.

Il punto concettuale da aggiungere: la varianza **tende a zero** al crescere di n . È esattamente questo che rende la media campionaria una buona stima, ed è il motore della legge dei grandi numeri.

5.2 Le disuguaglianze

Servono a maggiorare una probabilità senza conoscere la distribuzione, usando solo media e varianza.

Disuguaglianza di Markov

Se X è una variabile aleatoria **non negativa** ($X \geq 0$) e $\varepsilon > 0$:

$$P(X \geq \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}.$$

Svolgimento. [Dimostrazione]

$$\mathbb{E}[X] = \int_0^{+\infty} x f_X(x) dx \geq \int_{\varepsilon}^{+\infty} x f_X(x) dx \geq \varepsilon \int_{\varepsilon}^{+\infty} f_X(x) dx = \varepsilon P(X \geq \varepsilon),$$

da cui dividendo per ε si ottiene la tesi. ■

Disuguaglianza di Chebyshev

Per ogni variabile aleatoria X con media μ e varianza σ^2 finite, e per ogni $\varepsilon > 0$:

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

Equivalente, ponendo $\varepsilon = k\sigma$: $P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$.

Svolgimento. [Dimostrazione] Si applica Markov alla variabile non negativa $Y = (X - \mu)^2$ con soglia ε^2 :

$$P((X - \mu)^2 \geq \varepsilon^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}.$$

Ma $(X - \mu)^2 \geq \varepsilon^2$ accade esattamente quando $|X - \mu| \geq \varepsilon$, quindi il primo membro è $P(|X - \mu| \geq \varepsilon)$. ■

Lettura pratica

Chebyshev dice che **nessuna distribuzione** può concentrare troppa massa lontano dalla media. Per $k = 2$: al massimo il 25% dei valori sta oltre due deviazioni standard. Per $k = 3$: al massimo l'11%. Sono limiti *grossolani* (per la normale, oltre 2σ sta solo il 5%), ma valgono per *qualunque* distribuzione, e questo è precisamente ciò che serve per dimostrare la legge dei grandi numeri.

5.3 La legge dei grandi numeri**Legge dei grandi numeri (debole)**

Siano $X_1, X_2, \dots$ variabili aleatorie i.i.d. con $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Allora, per ogni $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \varepsilon) = 0,$$

cioè $\bar{X}_n$ **converge in probabilità** a μ : $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$.

Svolgimento. [Dimostrazione] Applicando Chebyshev a $\bar{X}_n$, che ha media μ e varianza σ^2/n :

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0,$$

perché σ^2 ed ε sono fissati e il denominatore cresce indefinitamente. ■

Cosa scrivere all'esame

La legge dei grandi numeri è stata chiesta con dimostrazione ben *due* volte (02/09/25 e 01/04/26). La dimostrazione è di tre righe: **Chebyshev** + $\text{Var}(\bar{X}_n) = \sigma^2/n$. Va scritta per esteso, non citata.

Il **significato** da aggiungere sempre: al crescere del numero di prove, la media dei risultati osservati si avvicina alla media teorica μ . È ciò che giustifica il metodo frequentista ($P(E) \approx$ frequenza relativa per n grande) e, in concreto, tutte le simulazioni di questa guida: quando nel Quesito di Laboratorio si simula N volte e si divide per N , la quantità ottenuta è una stima attendibile proprio in virtù di questo teorema.

Errore tipico da evitare

La legge dei grandi numeri **non** dice che $\bar{X}_n$ diventa *esattamente* uguale a μ . Dice che la probabilità di **allontanarsi** da μ di una quantità fissata ε diventa trascurabile. Per ogni n finito c'è sempre una probabilità positiva di osservare uno scostamento. È la differenza tra “converge in probabilità” e “è uguale”.

5.4 Il teorema del limite centrale**Teorema del limite centrale (TLC)**

Siano $X_1, X_2, \dots$ variabili aleatorie i.i.d. con $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Allora

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1),$$

cioè per n grande $\bar{X}_n$ si distribuisce approssimativamente come $N(\mu, \frac{\sigma^2}{n})$ qualunque sia la distribuzione delle X_i .

La differenza tra i due teoremi, in una riga

- **Legge dei grandi numeri:** $\bar{X}_n \rightarrow \mu$ (convergenza *in probabilità* verso un *numero*).
- **TLC:** descrive *come* $\bar{X}_n$ fluttua attorno a μ per n finito (convergenza *in distribuzione* verso una *variabile*).

La prima dice “ci si avvicina”; il secondo dice “l'errore residuo è gaussiano, di ampiezza $\sigma/\sqrt{n}$ ”.

La regola dell' $\sqrt{n}$

$$\text{errore standard} = \frac{\sigma}{\sqrt{n}}.$$

Da cui: per **ridurre l'errore a metà** serve il **quadruplo** delle simulazioni; per **un ordine di grandezza in meno** serve 100 volte il numero di prove. È il vincolo che limita i metodi Monte Carlo, ed è la ragione per cui una simulazione con $N = 100$ è rumorosa e una con $N = 100\,000$ è stabile.

Perché nelle simulazioni si vede sempre la gaussiana

In tutti i quesiti di Laboratorio si confronta la distribuzione empirica con la distribuzione teorica. Quando il quesito chiede di ripetere l'esperimento molte volte e guardare la *media* o la *somma* dei risultati, ciò che appare è una normale *anche se il singolo esperimento non è normale*, per il TLC. Per esempio: il singolo lancio di un dado è uniforme discreto, ma la media di 30 lanci è approssimativamente normale. Questo è il contenuto della prova del 28/01/25 (lancio di 10 monete: la binomiale è somma di Bernoulli).

5.5 Statistica descrittiva e statistica inferenziale

Descrittiva e inferenziale

- La **statistica descrittiva** organizza e riassume i dati *osservati*: frequenze, media, mediana, varianza, grafici. Non ipotizza nulla e non conclude nulla oltre al campione.
- La **statistica inferenziale** usa i dati di un *campione* per trarre conclusioni sulla *popolazione*, con un margine di errore dichiarato: stime puntuali, intervalli di confidenza, test d'ipotesi.

	Descrittiva	Inferenziale
Oggetto	il campione osservato	la popolazione
Strumenti	frequenze, indici, grafici	stimatori, IC, test
Domanda	“com'è fatto questo campione?”	“cosa posso dire della popolazione?”
Certezza	esatta (sono i dati)	probabilistica (margine d'errore)

Cosa scrivere all'esame

La distinzione è stata chiesta il 02/09/25. La risposta si costruisce così: definizione delle due, poi il criterio distintivo (**il campione contro la popolazione**), poi un esempio concreto per ciascuna. Esempio efficace: “calcolo la media dei voti del mio campione di 50 studenti” è descrittiva; “stimo la media dei voti di tutti gli studenti dell'ateneo, con un intervallo di confidenza al 95%” è inferenziale.

Esercizio 1 — Verifica di Chebyshev su una simulazione

Sia X il risultato del lancio di un dado a 6 facce. (a) Calcolare μ e σ^2 . (b) Usando Chebyshev, maggiorare $P(|X - \mu| \geq 2)$ e confrontare con il valore esatto. (c) Ripetere per $\bar{X}_{100}$, la media di 100 lanci.

Svolgimento. (a) $\mu = \frac{1+6}{2} = 3.5$ e $\sigma^2 = \frac{6^2-1}{12} = \frac{35}{12} \approx 2.9167$, da cui $\sigma \approx 1.7078$.

(b) Chebyshev: $P(|X - 3.5| \geq 2) \leq \frac{2.9167}{4} \approx 0.7292$. Valore esatto: gli esiti con $|X - 3.5| \geq 2$ sono $\{1, 6\}$, quindi $P = \frac{2}{6} \approx 0.3333$. Chebyshev è vero ma molto largo — come previsto, è un limite universale, non su misura.

(c) Per $\bar{X}_{100}$: $\text{Var} = \sigma^2/100 = 0.029167$, quindi

$$P(|\bar{X}_{100} - 3.5| \geq 2) \leq \frac{0.029167}{4} \approx 0.0073.$$

Il valore reale è ancora più piccolo. Il punto dell'esercizio: la stessa distanza $\varepsilon = 2$ diventa improbabile al crescere di n , ed è esattamente il meccanismo della legge dei grandi numeri.

Esercizio 2 — Il TLC in azione

Sia $X_i \sim \mathcal{U}(0, 1)$ i.i.d. Calcolare $\mathbb{E}[\bar{X}_n]$ e $\text{Var}(\bar{X}_n)$, e dire come si distribuisce $\bar{X}_n$ per n grande.

Svolgimento. Per $\mathcal{U}(0, 1)$: $\mu = \frac{1}{2}$ e $\sigma^2 = \frac{1}{12}$. Quindi

$$\mathbb{E}[\bar{X}_n] = \frac{1}{2}, \quad \text{Var}(\bar{X}_n) = \frac{1}{12n}, \quad \text{errore standard} = \frac{1}{\sqrt{12n}}.$$

Per il TLC, per n grande

$$\bar{X}_n \approx N\left(\frac{1}{2}, \frac{1}{12n}\right) \iff \frac{\bar{X}_n - 1/2}{1/\sqrt{12n}} \approx N(0, 1).$$

È il caso del Quesito 2 del 24/03/25 e del 02/09/25: la distribuzione di partenza è piatta, ma la media di molte repliche è a campana. Il grafico che si produce simulando 1000 medie di $n = 30$ valori uniformi mostra la campana in modo netto.

Capitolo 6

Statistica: stimatori, intervalli di confidenza, test

Questo è il capitolo con il maggior numero di domande d'esame già assegnate: gli **stimatori** sono comparsi tre volte su nove, *sempre* come Quesito 1 di teoria. Vale la pena studiarlo con attenzione particolare.

6.1 Popolazione, campione, stimatore

Campione e stimatore

Sia X una variabile aleatoria che descrive una caratteristica di una **popolazione**, con distribuzione F_θ dipendente da un parametro incognito θ .

Un **campione casuale** di dimensione n è una n -upla $(X_1, \dots, X_n)$ di variabili aleatorie **indipendenti** e con la *stessa* distribuzione di X .

Uno **stimatore** di θ è una funzione del campione

$$T = T(X_1, \dots, X_n)$$

che non dipende da θ . Il valore $t = T(x_1, \dots, x_n)$ assunto su un campione concreto si chiama **stima**.

Cosa scrivere all'esame

“Dare la definizione di stimatore” è la domanda di teoria più frequente in assoluto (28/01/25, 29/04/26, 23/06/26). La risposta completa ha **tre** elementi, e vale un punto ciascuno:

1. è una **funzione del campione**: $T = T(X_1, \dots, X_n)$;
2. **non dipende dal parametro incognito** θ (se dipendesse da θ non servirebbe a stimarlo);
3. è una **variabile aleatoria** (perché funzione di variabili aleatorie), mentre la *stima* è un numero.

Il terzo punto è quello che distingue una risposta da manuale da una risposta da lode. Aggiungi sempre l'esempio: $\bar{X}_n$ è lo stimatore di μ .

6.2 Stimatori non distorti

Stimatore non distorto (corretto)

Uno stimatore T di θ si dice **non distorto** (o *corretto*, *unbiased*) se

$$\mathbb{E}[T] = \theta \quad \text{per ogni possibile valore di } \theta.$$

La differenza $\mathbb{E}[T] - \theta$ si chiama **distorsione** (*bias*).

Errore quadratico medio

$$\text{MSE}(T) = \mathbb{E}[(T - \theta)^2] = \text{Var}(T) + (\mathbb{E}[T] - \theta)^2 = \text{Var}(T) + \text{bias}(T)^2.$$

Per uno stimatore non distorto, $\text{MSE}(T) = \text{Var}(T)$.

Come si legge questa scomposizione

L'errore di una stima ha **due** componenti indipendenti:

- la **distorsione**: un errore *sistematico*, che non si riduce aumentando n ;
- la **varianza**: un errore *casuale*, che si riduce aumentando n .

Uno stimatore distorto è sbagliato “in media”: nessuna quantità di dati lo aggiusta. È il motivo per cui la non distorsione è la prima proprietà che si verifica.

6.3 Lo stimatore della media

Stimatore della media

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad \mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

È quindi uno stimatore **non distorto** di μ .

Cosa scrivere all'esame

La dimostrazione è stata chiesta esplicitamente. Va scritta in due righe:

$$\mathbb{E}[\bar{X}_n] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot n\mu = \mu \implies \text{non distorto},$$

e poi, per mostrare che è anche *consistente*, si aggiunge $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \rightarrow 0$, che per Chebyshev dà la convergenza in probabilità (legge dei grandi numeri, Capitolo 5). **Non distorto + varianza che tende a zero** è la risposta completa.

6.4 Lo stimatore della varianza

È il punto tecnicamente più delicato del capitolo, e l'esame lo chiede nella forma “*stimatore della varianza con media nota e con media non nota*”. La distinzione non è un cavillo: cambia lo stimatore.

Caso 1: media μ nota

Stimatore di σ^2 con μ nota

$$S_\mu^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

Questo stimatore è **non distorto**:

$$\mathbb{E}[S_\mu^2] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] = \frac{1}{n} \cdot n\sigma^2 = \sigma^2.$$

La sua varianza

Se $\mu_4 = \mathbb{E}[(X - \mu)^4]$ è il momento centrato quarto,

$$\text{Var}(S_\mu^2) = \frac{1}{n}(\mu_4 - \sigma^4).$$

Nel caso normale $\mu_4 = 3\sigma^4$, quindi $\text{Var}(S_\mu^2) = \frac{2\sigma^4}{n}$, che è la varianza minima possibile tra gli stimatori non distorti di σ^2 . Non serve a memoria: serve a rispondere se l'esercizio chiede “quanto è preciso questo stimatore”.

Caso 2: media μ non nota

Se μ non è nota non posso usarla, e la sostituisco con $\bar{X}_n$:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Errore tipico da evitare

Questo stimatore è distorto. Vale

$$\mathbb{E}[S^2] = \frac{n-1}{n} \sigma^2 < \sigma^2,$$

quindi S^2 **sottostima sistematicamente** σ^2 . È l'errore concettuale più insidioso del capitolo: la formula “naturale” (dividere per n) dà la risposta sbagliata.

Svolgimento. [Perché $\mathbb{E}[\sum (X_i - \bar{X})^2] = (n-1)\sigma^2$] Scriviamo $X_i - \bar{X} = (X_i - \mu) - (\bar{X} - \mu)$ ed eleviamo al quadrato:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \mu) + n(\bar{X} - \mu)^2.$$

Ora $\sum_{i=1}^n (X_i - \mu) = n(\bar{X} - \mu)$, quindi il termine centrale vale $-2n(\bar{X} - \mu)^2$ e

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2.$$

Prendendo il valore atteso e usando $\mathbb{E}[(X_i - \mu)^2] = \sigma^2$ e $\mathbb{E}[(\bar{X} - \mu)^2] = \text{Var}(\bar{X}) = \sigma^2/n$:

$$\mathbb{E}\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = n\sigma^2 - \sigma^2 = (n-1)\sigma^2. \quad \blacksquare$$

Stimatore non distorto di σ^2 , media non nota

Dividendo per $n-1$ invece che per n si ottiene lo stimatore **non distorto**

$$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad \mathbb{E}[S_{n-1}^2] = \sigma^2.$$

La correzione “dividere per $n-1$ ” si chiama **correzione di Bessel**.

I gradi di libertà: perché $n - 1$

Dopo aver calcolato $\bar{X}_n$, gli n scarti $X_i - \bar{X}_n$ non sono liberi: la loro somma è *sempre* zero, $\sum_{i=1}^n (X_i - \bar{X}_n) = 0$. Quindi noti $n - 1$ scarti, il rimanente è determinato. Si dice che i dati hanno $n - 1$ **gradi di libertà**: una unità di informazione è stata “spesa” per stimare μ . Dividere per $n - 1$ invece che per n è esattamente ciò che compensa quella perdita. Questo è anche il motivo per cui nella t di Student i gradi di libertà sono $n - 1$.

Errore tipico da evitare

Non confondere le due notazioni, che si assomigliano ma sono cose diverse:

	Formula	Ruolo
σ^2	$\mathbb{E}[(X - \mu)^2]$	parametro della <i>popolazione</i> (incognito)
S_μ^2	$\frac{1}{n} \sum (X_i - \mu)^2$	stimatore, μ <i>nota</i> , non distorto
S^2	$\frac{1}{n} \sum (X_i - \bar{X})^2$	stimatore, μ non nota, distorto
S_{n-1}^2	$\frac{1}{n-1} \sum (X_i - \bar{X})^2$	stimatore, μ non nota, non distorto
S^2	$\frac{1}{N-1} \sum (x_i - \bar{x})^2$	<i>varianza campionaria</i> (dati osservati)

All'esame, se chiede “lo stimatore della varianza” senza specificare, **di esplicitamente entrambi i casi** e concludi che quello non distorto in generale è quello con $n - 1$. È la risposta che il 28/01/25 e il 29/04/26 premiavano.

6.5 Statistica descrittiva: gli indici

Queste definizioni sono state chieste il 17/02/26, tutte insieme.

Frequenze

Per dati $x_1, \dots, x_N$:

- **frequenza assoluta** f_i : quante volte compare il valore x_i ;
- **frequenza relativa** $r_i = f_i/N$;
- **frequenza percentuale** $100 r_i$;
- **frequenze cumulate**: $F_i = \sum_{j \leq i} f_j$.

Vale sempre $\sum_i f_i = N$ e $\sum_i r_i = 1$.

Media, mediana, quantili**Indici di posizione**

Media aritmetica (dati grezzi): $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$.

Media da una tabella di frequenze: se il valore x_i ha frequenza assoluta f_i , $\bar{x} = \frac{1}{N} \sum_i x_i f_i$.

Mediana: il valore che divide il campione in due parti di uguale numerosità. Con i dati ordinati in modo crescente, è il valore centrale se N è dispari, la media dei due valori centrali se N è pari. È il **quantile di ordine 0.5**.

Quantile di ordine p ($0 < p < 1$): il valore sotto cui cade una frazione p dei dati.

Primo e terzo quartile: $Q_1 = \text{quantile } 0.25$, $Q_3 = \text{quantile } 0.75$.

Differenza interquartile: $IQR = Q_3 - Q_1$.

Media o mediana?

La media è sensibile ai valori anomali (*outlier*); la mediana no. Un solo dato molto grande sposta la media ma lascia la mediana quasi invariata. È il motivo per cui per i redditi si pubblica la mediana, e perché l'IQR è una misura di dispersione più robusta della deviazione standard.

Indici di dispersione

Varianza empirica e varianza campionaria

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

|—————{z—————}|
varianza empirica

$$S^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

|—————{z—————}|
varianza campionaria

La prima divide per N ed è un indice puramente descrittivo: descrive la dispersione *di quel campione*, senza riferimento a una popolazione. La seconda divide per $N-1$ ed è lo **stimatore non distorto** di σ^2 . Le due differiscono per il fattore $\frac{N-1}{N}$, trascurabile per N grande ma tutt'altro che trascurabile per N piccolo.

Scarto quadratico medio (o deviazione standard): $s = \sqrt{S^2}$.

Coefficiente di variazione: $CV = s/\bar{x}$, utile per confrontare la variabilità di fenomeni con scale diverse.

Cosa scrivere all'esame

Il 17/02/26 ha chiesto esattamente: frequenze, media aritmetica, quantili/mediana/quartili/IQR, varianza empirica e campionaria. È una domanda "a elenco": il modo di prenderci il punteggio pieno è dare *per ciascun indice* la definizione, la formula, e una frase sul significato. La frase decisiva è quella che distingue empirica e campionaria: **la prima descrive il campione, la seconda stima la popolazione** (divisione per N contro $N-1$).

6.6 Intervalli di confidenza

Intervallo di confidenza

Un **intervallo di confidenza** di livello $1 - \alpha$ per un parametro θ è un intervallo casuale $[T_1, T_2]$, con T_1, T_2 funzioni del campione, tale che

$$P(T_1 \leq \theta \leq T_2) = 1 - \alpha.$$

Errore tipico da evitare

L'interpretazione corretta è **del procedimento**, non del singolo intervallo. Dopo aver calcolato l'intervallo su un campione concreto, non si può dire " θ cade in $[T_1, T_2]$ con probabilità 0.95": θ è un numero fisso, l'intervallo è ormai calcolato, o lo contiene o non lo contiene.

La frase corretta: "*il procedimento che ho usato produce intervalli che contengono θ nel 95% dei campioni*". Nella prova del 23/06/26 questa precisazione era parte della domanda.

Intervallo per la media, σ nota

$$\left[\bar{X}_n - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X}_n + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right],$$

dove $z_{1-\alpha/2}$ è il quantile della normale standard, e la quantità $z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$ si chiama **margin di errore**.

Intervallo per la media, σ non nota

Sostituendo σ con lo scarto campionario s e la normale con la t :

$$\left[\bar{X}_n - t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}}, \quad \bar{X}_n + t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}} \right].$$

Come dipende l'ampiezza dell'intervallo

Il 23/06/26 ha chiesto esattamente di discutere la dipendenza da N , σ e α , e di rappresentarla graficamente. La risposta:

$$\text{ampiezza} = 2 z_{1-\alpha/2} \frac{\sigma}{\sqrt{N}}.$$

- All'aumentare di N l'ampiezza **diminuisce** come $1/\sqrt{N}$: più dati, stima più precisa. Per dimezzare l'ampiezza serve quadruplicare N .
- All'aumentare di σ l'ampiezza **aumenta** in modo proporzionale: più variabilità, meno precisione.
- All'aumentare del livello di confidenza $1 - \alpha$ (cioè al *diminuire* di α) $z_{1-\alpha/2}$ cresce, quindi l'ampiezza **aumenta**: per essere più sicuri bisogna accettare un intervallo più largo.

Il **grafico** richiesto è l'ampiezza in funzione di N (una curva che decresce come $1/\sqrt{N}$), oppure tre intervalli affiancati per $\alpha = 0.10, 0.05, 0.01$ a mostrare il restringimento/allargamento.

Valori critici

$$\alpha = 0.10 \Rightarrow z = 1.645, \quad \alpha = 0.05 \Rightarrow z = 1.96, \quad \alpha = 0.01 \Rightarrow z = 2.576.$$

In Python: `norm.ppf(1 - alpha/2)` oppure `t.ppf(1 - alpha/2, n-1)`.

Numerosità campionaria

Se si vuole un margine di errore non superiore a E , con livello $1 - \alpha$:

$$N \geq \left(\frac{z_{1-\alpha/2} \sigma}{E} \right)^2.$$

6.7 Test d'ipotesi**I due errori**

	H_0 è vera	H_0 è falsa
Rigetto H_0	Errore di I tipo (α)	decisione corretta
Non rigetto H_0	decisione corretta	Errore di II tipo (β)

α = probabilità di errore di I tipo (rigettare H_0 vera) = **livello di significatività**. β = probabilità di errore di II tipo (non rigettare H_0 falsa). La **potenza** del test è $1 - \beta$.

Righe e colonne non si scambiano

L'errore di I tipo è “*condannare un innocente*”; quello di II tipo è “*assolvere un colpevole*”. α è fissato da noi (0.05 di solito); β non è controllato direttamente, e diminuisce se aumenta N o se aumenta α . Non si possono ridurre entrambi contemporaneamente senza più dati.

Il p -value

Il **p -value** è la probabilità di osservare un valore della statistica test *almeno tanto estremo* quanto quello osservato, **assumendo vera** H_0 . Si rigetta H_0 se $p\text{-value} < \alpha$.

Errore tipico da evitare

Il p -value **non** è la probabilità che H_0 sia vera. È la probabilità dei dati *condizionata* a H_0 , non di H_0 condizionata ai dati (sarebbe il ruolo di Bayes, che però richiede una probabilità a priori su H_0). È l'errore interpretativo più diffuso, e vale la pena scrivere questo distinguo esplicitamente nel compito.

Come si impostano i test che servono

Situazione	Statistica test	Distribuzione sotto H_0	Quando
Media, σ nota	$z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$N(0, 1)$	29/04/26, 24/03/25
Media, σ non nota	$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$	$t(n - 1)$	27/01/26
Proporzione (grande n)	$z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$	$N(0, 1)$	—
Proporzione (piccolo n)	$X \sim \text{Bin}(n, p_0)$	binomiale esatta	01/04/26

Unilaterale o bilaterale?

La prima cosa da decidere, prima di qualsiasi calcolo:

- testo del tipo “*diverso da*”, “*c'è una differenza*” $\Rightarrow H_1 : \mu \neq \mu_0 \Rightarrow$ test **bilaterale**, p -value a due code;
- testo del tipo “*maggiore di*”, “*più grande*” $\Rightarrow H_1 : \mu > \mu_0 \Rightarrow$ test **unilaterale destro**;
- “*minore di*”, “*riduce*” $\Rightarrow H_1 : \mu < \mu_0 \Rightarrow$ test **unilaterale sinistro**.

Nel 29/04/26 (concentrazione del farmaco) e nel 24/03/25 la domanda era *direzionale*: serviva il test unilaterale. Usare quello bilaterale dimezza la potenza e porta a una conclusione sbagliata.

Lo schema fisso di risposta

Qualunque test, all'esame, va scritto in questi cinque passi:

1. **Ipotesi**: H_0 e H_1 , specificando se è uni- o bilaterale.
2. **Livello**: α (di solito 0.05), e il valore critico corrispondente.

3. **Statistica test:** la formula, la distribuzione sotto H_0 e il valore calcolato.
4. **Decisione:** confronto statistica con il valore critico, oppure p -value con α .
5. **Conclusione nel contesto,** in italiano, con la formula corretta: “*rifiuto/accetto H_0 al livello α* ”.

Senza il passo 5 il test non è concluso: un compito che si ferma al valore di z perde i punti della conclusione.

La frase da non scrivere mai

Se non si rigetta H_0 , **non** si scrive “quindi H_0 è vera” né “quindi $\mu = \mu_0$ ”. Si scrive:

“Non c’è evidenza sufficiente, al livello α , per rifiutare H_0 .”

Il test non-dimostra mai un’uguaglianza: assenza di evidenza non è evidenza di assenza. Questo errore è costato punti in più di una prova (01/04/26 punto d).

6.8 Esercizi svolti

Esercizio 1 — Stimatore della varianza, due casi (28/01/25 e 29/04/26)

Sia $X_1, \dots, X_n$ un campione da una popolazione con media μ e varianza σ^2 . Determinare uno stimatore non distorto di σ^2 nel caso in cui μ sia nota, e nel caso in cui μ non sia nota.

Svolgimento. Caso μ nota. Lo stimatore naturale è la media dei quadrati degli scarti da μ :

$$S_\mu^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

Per la linearità del valore atteso:

$$\mathbb{E}[S_\mu^2] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] = \frac{1}{n} \sum_{i=1}^n \sigma^2 = \sigma^2.$$

È **non distorto**, senza correzioni.

Caso μ non nota. Sostituendo μ con $\bar{X}_n$ si ottiene $S^2 = \frac{1}{n} \sum (X_i - \bar{X}_n)^2$, ma

$$\mathbb{E}[S^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2,$$

dunque è **distorto** e sottostima σ^2 . Moltiplicando per $\frac{n}{n-1}$ si corregge la distorsione:

$$S_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad \mathbb{E}[S_{n-1}^2] = \frac{n}{n-1} \cdot \frac{n-1}{n} \sigma^2 = \sigma^2.$$

Conclusione. Con μ nota si divide per n ; con μ non nota si divide per $n-1$. Il “prezzo” della stima di μ è un grado di libertà.

Esercizio 2 — t -test sul peso dei biscotti (27/01/26)

Un campione di $n = 12$ biscotti ha media $\bar{x} = 21.3$ g e scarto campionario $s = 1.8$ g. Il produttore dichiara un peso medio di 20 g. Al livello $\alpha = 0.05$, il peso medio è diverso da quello dichiarato?

Svolgimento. 1. Ipotesi. La domanda è “diverso”, quindi bilaterale:

$$H_0 : \mu = 20, \quad H_1 : \mu \neq 20.$$

2. Livello. $\alpha = 0.05$, campione piccolo, σ non nota $\Rightarrow t$ di Student con $n - 1 = 11$ gradi di libertà. Il valore critico è $t_{0.975, 11} = 2.201$.

3. Statistica test.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{21.3 - 20}{1.8/\sqrt{12}} = \frac{1.3}{0.5196} \approx 2.502.$$

4. Decisione. Poiché $|t| = 2.502 > 2.201 = t_{0.975, 11}$, si **rigetta** H_0 . (Equivalente: p -value $= 2 \cdot P(T_{11} > 2.502) \approx 0.029 < 0.05$.)

5. Conclusione. Al livello di significatività del 5%, c'è evidenza statistica che il peso medio dei biscotti sia **diverso** da 20 g.

Esercizio 3 — z -test unilaterale su una concentrazione (29/04/26)

Un farmaco deve avere concentrazione media $\mu_0 = 50$ mg/L e si sa che $\sigma = 4$ mg/L (nota). Su $n = 25$ campioni si osserva $\bar{x} = 52$ mg/L. Al livello $\alpha = 0.05$, si può affermare che la concentrazione sia *maggiore* di 50?

Svolgimento. 1. Ipotesi. “Maggiore” $\Rightarrow$ unilaterale destro:

$$H_0 : \mu = 50, \quad H_1 : \mu > 50.$$

2. Livello. $\alpha = 0.05$, σ nota $\Rightarrow z$, valore critico $z_{0.95} = 1.645$.

3. Statistica test.

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{52 - 50}{4/\sqrt{25}} = \frac{2}{0.8} = 2.5.$$

4. Decisione. $z = 2.5 > 1.645$, e il p -value è $P(Z > 2.5) \approx 0.0062 < 0.05$. Si **rigetta** H_0 .

5. Conclusione. Al livello del 5% c'è evidenza che la concentrazione media sia maggiore di 50 mg/L.

Nota. Se avessi usato il test bilaterale il p -value sarebbe stato 0.0124, ancora < 0.05 , ma la conclusione non sarebbe stata quella richiesta: la domanda era direzionale e la risposta deve esserlo.

Esercizio 4 — Confronto di due palestre (24/03/25)

In due palestre si misura il tempo di recupero dopo uno sforzo. Palastra A: $n_A = 15$, $\bar{x}_A = 32$ s, $\sigma_A = 5$ s. Palastra B: $n_B = 18$, $\bar{x}_B = 36$ s, $\sigma_B = 6$ s. Le varianze sono note. C'è differenza significativa al 5%?

Svolgimento. 1. Ipotesi. “C'è differenza” $\Rightarrow$ bilaterale:

$$H_0 : \mu_A = \mu_B, \quad H_1 : \mu_A \neq \mu_B.$$

2. Livello. $\alpha = 0.05$, varianze note $\Rightarrow z$, valore critico 1.96.

3. Statistica test. Con varianze note l'errore standard della differenza è $\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}$:

$$z = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} = \frac{32 - 36}{\sqrt{\frac{25}{15} + \frac{36}{18}}} = \frac{-4}{\sqrt{1.6667 + 2}} = \frac{-4}{1.9155} \approx -2.088.$$

4. Decisione. $|z| = 2.088 > 1.96$, quindi si **rigetta** H_0 (p -value ≈ 0.0368).

5. Conclusione. Al 5% c'è evidenza di una differenza significativa tra i tempi medi di recupero delle due palestre.

Nota sulla scelta. Qui σ è nota, quindi z e non t : è esattamente la trappola della prova. Se σ fosse stata stimata dal campione si sarebbe dovuta usare la t con l'errore standard *combinato* (pooled).

Esercizio 5 — Test binomiale esatto (01/04/26)

Su $n = 200$ ovetti, 67 sono bianchi. Al 95%, la probabilità di trovare un ovetto bianco è maggiore di $1/3$?

Svolgimento. $\hat{p} = 67/200 = 0.335$, contro $p_0 = 1/3 \approx 0.3333$.

1. Ipotesi. Direzionale: $H_0 : p = 1/3$, $H_1 : p > 1/3$.

2. Statistica test. Con n grande si potrebbe usare lo z , ma con una proporzione e un test esatto conviene la binomiale: sotto H_0 , $X \sim \text{Bin}(200, 1/3)$, con $\mathbb{E}[X] = 66.67$ e $\sigma_X = 6.67$. Il valore osservato 67 è praticamente *sulla media*.

3. p -value.

$$P(X \geq 67) \approx 0.50.$$

4–5. Decisione e conclusione. Essendo $0.50 > 0.05$ **non si rigetta** H_0 : non c'è evidenza, al 95%, per affermare che $p > 1/3$.

La frase corretta è: “non possiamo affermare che la probabilità sia maggiore di $1/3$ ”. **Non** “quindi $p = 1/3$ ”.

Capitolo 7

Regressione lineare e correlazione

7.1 Il problema

Immaginiamo di voler determinare se c'è una relazione tra due variabili. Spesso alcune grandezze “camminano in coppia”: il peso di una persona e le calorie che assume, la dimensione di un input e il tempo che un programma impiega a elaborarlo. Dati n punti $(x_1, y_1), \dots, (x_n, y_n)$, vogliamo rispondere a due domande diverse:

- **C'è** una relazione? E quanto è forte? $\rightarrow$ la *correlazione*, che risponde con un numero.
- **Quale** relazione? Posso prevedere y noto x ? $\rightarrow$ la *regressione*, che risponde con un'equazione.

Correlazione non implica causalità

Le note lo ripetono esplicitamente, e vale la pena ricordarlo all'esame: esistono le **correlazioni spurie**, cioè andamenti correlati tra variabili che non hanno nessun legame di causa-effetto. Il caso classico è il numero di annegamenti in piscina che cresce insieme alle vendite di gelati: non c'è causalità, c'è una terza variabile (la stagione) che muove entrambe.

Correlazione e regressione non sono la stessa cosa

- La **correlazione** ρ è un numero **simmetrico**: misura quanto i punti stanno vicini a una retta, senza distinguere causa ed effetto. $\rho(x, y) = \rho(y, x)$.
- La **regressione** è **asimmetrica**: x è la variabile esplicativa, y la variabile risposta. Scambiandole si ottiene una retta diversa.

7.2 Covarianza e coefficiente di correlazione

Le note definiscono la covarianza empirica e, da quella, il coefficiente di correlazione lineare.

Covarianza empirica $\bar{\sigma}_{xy}$

$$\bar{\sigma}_{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Misura il legame *lineare* tra X e Y , ma dipende dalle unità di misura: moltiplicando x per 1000 la covarianza cambia.

Coefficiente di correlazione lineare ρ

$$\rho = \frac{\sum_{i=1}^n x_i y_i - \bar{x} \bar{y}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x \bar{\sigma}_y}.$$

Vale sempre $-1 \leq \rho \leq 1$.

Come si legge ρ : i tre gradi delle note

Le note classificano la correlazione in tre gradi — usate *questi* aggettivi nella risposta, non altri:

- $0 < |\rho| \leq 0.3$: correlazione **debole**;
- $0.3 < |\rho| \leq 0.7$: correlazione **moderata**;
- $0.7 < |\rho| \leq 1$: correlazione **forte**.

Il **segno** dice la direzione: $\rho > 0$ le variabili sono correlate linearmente, $\rho < 0$ antilinearmente. Il **modulo** dice la forza. $\rho = \pm 1$ significa che i punti stanno *esattamente* su una retta.

Errore tipico da evitare

“ $\rho = 0$ ” significa **solo** “nessuna relazione *lineare*”. Se il grafico a dispersione mostra una curva (a U, a campana, periodica) con $\rho \approx 0$, la conclusione corretta è “la relazione non è lineare”, non “non c’è relazione”. **Guardare sempre lo scatter plot prima di commentare** ρ , e dirlo nel commento: è esattamente ciò che il correttore cerca.

7.3 Il metodo dei minimi quadrati

Dalle note: stiamo cercando un modo sensato di determinare β_0 e β_1 tali che la retta

$$y = \beta_0 + \beta_1 x$$

sia quella che meglio si adatta ai dati. Questo problema è noto come problema di **best fit**. La retta non passerà per tutte le coppie di punti, ma passerà per la media dei dati.

Il metodo è quello dei **minimi quadrati**: si minimizza la somma delle distanze di ogni punto da quello predetto dal modello. Per ogni x_i il modello lineare prevede $\hat{y}_i = \beta_0 + \beta_1 x_i$. Consideriamo la differenza tra il punto reale e quello predetto

$$d_i = y_i - \hat{y}_i,$$

e costruiamo la funzione

$$S^2 = \sum_{i=1}^n d_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2,$$

che quantifica sostanzialmente la distanza tra i dati e quelli ottenuti dal modello. S^2 è una funzione di β_0 e β_1 : vogliamo i parametri che la rendono minima.

Stimatori dei minimi quadrati

Annullando le derivate parziali $\partial S^2 / \partial \beta_0$ e $\partial S^2 / \partial \beta_1$ si ottiene

$$\beta_1 = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}.$$

La retta stimata è $\hat{y} = \beta_0 + \beta_1 x$ e passa **sempre** per il punto $(\bar{x}, \bar{y})$.

Svolgimento. [La derivazione, come la fanno le note] Annulliamo la prima derivata parziale:

$$\frac{\partial S^2}{\partial \beta_0} = 2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \iff \sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0 \iff n\bar{y} - n\beta_0 - n\beta_1 \bar{x} = 0,$$

da cui

$$\beta_0 = \bar{y} - \beta_1 \bar{x}.$$

Passiamo alla seconda:

$$\frac{\partial S^2}{\partial \beta_1} = 2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0 \iff \sum_{i=1}^n x_i y_i - n\bar{x}\beta_0 - \beta_1 \sum_{i=1}^n x_i^2 = 0.$$

Sostituendo $\beta_0 = \bar{y} - \beta_1 \bar{x}$:

$$\sum_{i=1}^n x_i y_i - n \bar{x}(\bar{y} - \beta_1 \bar{x}) - \beta_1 \sum_{i=1}^n x_i^2 = 0 \iff \sum_{i=1}^n (x_i y_i - \bar{x} \bar{y}) - \beta_1 \sum_{i=1}^n (x_i^2 - \bar{x}^2) = 0,$$

cioè

$$n \bar{\sigma}_{xy} - n \beta_1 \bar{\sigma}_x^2 = 0 \implies \beta_1 = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2}. \quad \blacksquare$$

Attenzione a un punto che le note dichiarano apertamente: annullare le derivate garantisce solo di trovare un *punto di estremo*. Per essere sicuri che sia un minimo bisognerebbe valutare il segno della matrice Hessiana. Le note “omettono questa dimostrazione e si fidano ciecamente” che i due punti trovati siano di minimo — quindi all’esame è lecito fermarsi qui, ma è bene *dire* che quel passaggio si sta saltando.

Formule computazionali

Per il calcolo a mano conviene usare le forme “scorciatoia”, che evitano di calcolare tutti gli scarti:

$$S_{xx} = \sum x_i^2 - n \bar{x}^2 = n \bar{\sigma}_x^2, \quad S_{yy} = \sum y_i^2 - n \bar{y}^2 = n \bar{\sigma}_y^2, \quad S_{xy} = \sum x_i y_i - n \bar{x} \bar{y} = n \bar{\sigma}_{xy}.$$

Le due notazioni convivono: $\bar{\sigma}_x^2$ è la varianza empirica (divisore n , come nelle note), S_{xx} è la stessa quantità moltiplicata per n . Nelle formule dei coefficienti il fattore n si semplifica, quindi β_1 e ρ si possono scrivere indifferentemente in un modo o nell’altro.

Come si scrive senza `linregress`

La prova del 17/02/26 lo vieta esplicitamente (“*NOTA: Non è consentito l’uso della funzione `scipy.stats.linregress`*”). Le formule qui sopra si traducono direttamente:

```
1  n = len(x)
2  xbar, ybar = x.mean(), y.mean()
3
4  sxx = np.sum(x**2) - n * xbar**2      # = n * sigma2_x
5  syy = np.sum(y**2) - n * ybar**2      # = n * sigma2_y
6  sxy = np.sum(x*y) - n * xbar * ybar   # = n * sigma_xy
7
8  beta1 = sxy / sxx
9  beta0 = ybar - beta1 * xbar
10 rho = sxy / np.sqrt(sxx * syy)
11 R = rho**2
```

Con `linregress` la stessa cosa è `stats.linregress(x, y)`, che restituisce `slope` ($= \beta_1$), `intercept` ($= \beta_0$), `rvalue` ($= \rho$), `pvalue`, `stderr`. Saper fare entrambe le versioni è la garanzia di non restare bloccati qualunque cosa chieda il compito. Usate `linregress` come *verifica* del codice scritto a mano.

7.4 Bontà dell’adattamento

Coefficiente di determinazione R

Le note lo definiscono direttamente come

$$R = \frac{\bar{\sigma}_{xy}^2}{\bar{\sigma}_x^2 \bar{\sigma}_y^2} = \rho^2.$$

Tanto più il coefficiente di determinazione è vicino a uno, tanto migliore sarà il modello. Vale $0 \leq R \leq 1$ ed è la frazione di variabilità di y spiegata dalla regressione.

Il nome della cosa: R , non R^2

Questa è una differenza che fa perdere punti se non la si rispetta. Le note chiamano R il coefficiente di determinazione, e vale $R = \rho^2$. Molti libri di testo (e molti notebook online) chiamano la stessa quantità R^2 . Sono lo stesso numero con due nomi diversi, ma *all'esame usate il nome delle note*. Analogamente: le note chiamano β_0, β_1 i coefficienti della retta, altri testi usano a, b oppure α, β . Nei testi d'esame compaiono “retta di regressione” e “coefficiente di determinazione” senza simboli, quindi siete liberi — purché siate *coerenti* dall'inizio alla fine e diciate una volta cosa state usando.

Scomposizione della devianza

$$\underbrace{\sum (y_i - \bar{y})^2}_{S_{yy}} = \underbrace{\sum (\hat{y}_i - \bar{y})^2}_{\text{spiegata}} + \underbrace{\sum (y_i - \hat{y}_i)^2}_{S^2 \text{ residua}}.$$

Devianza totale = devianza spiegata dalla regressione + devianza residua. Da qui $R = 1 - S^2/S_{yy}$.

Un'estensione che le note segnalano

Anche se abbiamo visto solo l'analisi lineare, questa permette di fittare dipendenze più variegata. Se i dati mostrano un andamento *parabolico*, un modello credibile è $y = \beta_0 + \beta_1 x^2$, che non è lineare — ma ponendo $z = x^2$ il modello si riduce a $y = \beta_0 + \beta_1 z$, esattamente quello che abbiamo studiato. È il trucco del **cambio di variabile**: vale la pena citarlo se il compito chiede “cosa fareste se la relazione non fosse lineare?”.

7.5 Esercizi svolti

Esercizio 1 — I dati sono correlati? (28/01/25, Q1 Laboratorio)

Uno studente trova scritti su un foglio i seguenti dati

X	1213	1518	1550	1215	2120	2207
Y	15474	16497	17224	14459	22186	23483

e vuole capire se sono correlati.

- Stabilire se tra i dati X e i dati Y c'è correlazione.
- Usare il metodo dei minimi quadrati per determinare la retta di regressione. In un plot mostrare i dati e la retta ricavata.
- Calcolare il coefficiente di determinazione e commentare il risultato.

Guardando meglio, lo studente si accorge che mancavano alcuni dati e che la tabella completa era

X	1213	1518	3050	852	1550	1215	2120	2207	2175	1128
Y	15474	16497	29349	11314	17224	14459	22186	23483	24095	13982

- Usare il metodo dei minimi quadrati per determinare la retta di regressione e confrontarla con la precedente. Com'è cambiato il risultato?

Svolgimento. Prima cosa: leggere i dati. Le due scale sono molto diverse (X in centinaia, Y in decine di migliaia): è esattamente il motivo per cui serve un coefficiente *adimensionale* come ρ , che non dipende dalle unità di misura.

```

1 import numpy as np
2 from scipy import stats
3
4 X = np.array([1213, 1518, 1550, 1215, 2120, 2207], dtype=float)
5 Y = np.array([15474, 16497, 17224, 14459, 22186, 23483], dtype=float)
6 n = len(X)
7 xbar, ybar = X.mean(), Y.mean()
8
9 Sxx = np.sum(X**2) - n * xbar**2
10 Syy = np.sum(Y**2) - n * ybar**2
11 Sxy = np.sum(X * Y) - n * xbar * ybar
12
13 rho = Sxy / np.sqrt(Sxx * Syy)
14 betal = Sxy / Sxx
15 beta0 = ybar - betal * xbar
16 R = rho**2
17
18 print(f"xbar = {xbar:.4f}   ybar = {ybar:.4f}")
19 print(f"Sxx = {Sxx:.4f}   Syy = {Syy:.4f}   Sxy = {Sxy:.4f}")
20 print(f"rho = {rho:.6f}   R = {R:.6f}")
21 print(f"retta: y = {beta0:.4f} + {betal:.4f} x")
22
23 # verifica incrociata con linregress (NON richiesta, ma utile per controllare)
24 lr = stats.linregress(X, Y)
25 print(f"linregress: slope={lr.slope:.6f} intercept={lr.intercept:.6f} "
26       f"rvalue={lr.rvalue:.6f}")

```

```

xbar = 1637.1667   ybar = 18220.5000
Sxx = 937778.8333   Syy = 69074705.5000   Sxy = 7958622.5000
rho = 0.988845   R = 0.977814
retta: y = 4326.4015 + 8.4867 x
linregress: slope=8.486673 intercept=4326.401513 rvalue=0.988845

```

(a) **C'è correlazione?** Sì, ed è **forte**: $\rho = 0.9888$ cade nell'intervallo $0.7 < |\rho| \leq 1$ delle note. Il segno è positivo, quindi al crescere di X cresce Y in modo quasi perfettamente lineare. La verifica incrociata con `linregress` dà lo stesso ρ : il codice scritto a mano è corretto.

(b) **La retta.** $\hat{y} = 4326.4015 + 8.4867x$. Il passaggio per il baricentro si controlla subito: $4326.4015 + 8.4867 \cdot 1637.1667 = 18220.5 = \bar{y}$.

Nota metodologica da scrivere nel commento: l'intercetta $\beta_0 \approx 4326$ sarebbe “il valore di Y per $X = 0$ ”, ma $X = 0$ non ha senso nel contesto (nessun dato ha dimensione zero). Va commentata come *intercetta matematica*, non come previsione fisica.

(c) **Il coefficiente di determinazione.** $R = 0.9778$: la retta spiega il 97.8% della variabilità di Y . Il modello è ottimo su questi 6 punti.

(d) **Aggiungendo i 4 dati mancanti.** Ora $n = 10$. Rifacendo gli stessi conti:

```

xbar = 1702.8000   ybar = 18806.3000
Sxx = 4055801.6000   Syy = 289660976.1000   Sxy = 34037216.6000
rho = 0.993049   R = 0.986146
retta: y = 4516.0121 + 8.3922 x

```

Il confronto, che è il punto del quesito.

	6 punti	10 punti	variazione
β_0 (intercetta)	4326.40	4516.01	+189.61
β_1 (pendenza)	8.4867	8.3922	-0.0944
ρ	0.988845	0.993049	+0.004204
$R = \rho^2$	0.977814	0.986146	+0.008332

La pendenza cambia poco (-1.1%) e la correlazione **migliora**: i quattro punti ritrovati erano coerenti con la tendenza e hanno *rinforzato* il legame. Il messaggio da consegnare al correttore: ρ e β_1 sono **stime**, e come tutte le stime dipendono dal campione. Qui il campione era piccolo e *incompleto*; aggiungere dati coerenti rende la stima più stabile e più affidabile. Se i quattro punti fossero stati lontani dalla retta, avremmo visto ρ crollare — la robustezza della stima dipende da quanto i nuovi dati seguono il pattern.

Esercizio 2 — Regressione vietando `linregress` (17/02/26, Q2 Laboratorio)

Viene osservato il tempo di calcolo in secondi utilizzato da un software nell'elaborazione di diversi insiemi di dati:

dimensione dati	105	511	401	622	330
tempo (s)	44	214	193	299	143

- Determinare la retta di regressione lineare.
- Rappresentare i dati e la retta di regressione in un unico grafico.
- Calcolare il coefficiente di correlazione lineare e il coefficiente di determinazione e commentarli.
- Stimare in base alla retta di regressione il tempo necessario all'elaborazione di un insieme di 200 dati.

NOTA: Non è consentito l'uso della funzione `scipy.stats.linregress`.

Svolgimento. Perché la nota è la vera difficoltà del quesito. Vietare `linregress` obbliga a scrivere le formule dei minimi quadrati a mano. Ecco il codice minimo, con il plot richiesto al punto (b):

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 x = np.array([105, 511, 401, 622, 330], dtype=float)
5 y = np.array([44, 214, 193, 299, 143], dtype=float)
6 n = len(x)
7 xbar, ybar = x.mean(), y.mean()
8
9 Sxx = np.sum(x**2) - n * xbar**2
10 Syy = np.sum(y**2) - n * ybar**2
11 Sxy = np.sum(x * y) - n * xbar * ybar
12
13 betal = Sxy / Sxx
14 beta0 = ybar - betal * xbar
15 rho = Sxy / np.sqrt(Sxx * Syy)
16 R = rho**2
17
18 print(f"betal = {betal:.6f}    beta0 = {beta0:.6f}")
19 print(f"rho = {rho:.6f}    R = {R:.6f}")
20 print(f"retta: y = {beta0:.4f} + {betal:.4f} x")
21
22 # (d) previsione per 200 dati
23 print(f"tempo previsto per 200 dati: {beta0 + betal*200:.4f} s")
24
25 # (b) grafico

```

```

26 xs = np.linspace(x.min() - 50, x.max() + 50, 100)
27 plt.scatter(x, y, color="tab:blue", zorder=3, label="dati osservati")
28 plt.plot(xs, beta0 + beta1 * xs, "r-", label="retta di regressione")
29 plt.xlabel("dimensione dell'insieme di dati")
30 plt.ylabel("tempo di calcolo (s)")
31 plt.legend(); plt.grid(alpha=0.3)
32 plt.savefig("regressione_17-02-26.png", dpi=150, bbox_inches="tight")
33 plt.show()

```

```

beta1 = 0.475233    beta0 = -8.546607
rho    = 0.989901    R = 0.979903
retta: y = -8.5466 + 0.4752 x
tempo previsto per 200 dati: 86.4999 s

```

(c) **Commento.** $\rho = 0.9899$ è una correlazione **forte** e positiva; $R = 0.9799$ significa che il modello spiega il 98.0% della variabilità del tempo di calcolo. La relazione è quindi quasi perfettamente lineare: raddoppiare la dimensione dell'input raddoppia circa il tempo impiegato.

(d) **La previsione.** 200 dati cadono *dentro* l'intervallo osservato (105–622), quindi la previsione $\hat{y} = 86.50$ s è un'interpolazione ragionevole, non un'estrapolazione.

L'intercetta negativa non è un errore

$\beta_0 = -8.55$ secondi. Un tempo *negativo* sembra assurdo, e la tentazione è di “correggere” il risultato. Non farlo: β_0 è semplicemente il valore dove la retta interseca l'asse y , e $x = 0$ (zero dati da elaborare) è fuori dal campo di validità del modello. Va *commentato*: “l'intercetta non ha interpretazione fisica perché $x = 0$ non è un caso osservato”. Lo stesso discorso vale per il $\beta_0 = 4326$ della prova del 28/01/25.

La trappola vera: i residui devono sommare a zero

Il controllo più veloce che avete a disposizione in ogni esercizio di regressione: $\sum_i (y_i - \hat{y}_i) = 0$. Se non viene zero, avete sbagliato un conto. Su questi dati:

$$d_i = [2.6472, -20.2973, 10.9783, 11.9519, -5.2802], \quad \sum d_i = 2.1 \times 10^{-14} \approx 0. \checkmark$$

Vale a meno dell'errore di arrotondamento in virgola mobile. È una verifica da una riga che vale la pena fare *sempre* prima di consegnare.

Esercizio 3 — Regressione con previsione e attesa (02/09/25, Q1 Laboratorio)

Giorgino partecipa a un gioco: la probabilità di vittoria p dipende dall'ora t in cui gioca, secondo la tabella

p	0.08	0.24	0.33	0.35	0.39	0.64	0.70	0.74	0.86
t	7	8	10	12	13	17	19	21	22

- Calcolare il coefficiente di correlazione lineare tra p e t .
- Calcolare la retta di regressione e plottare il risultato.
- Giorgino ha accesso al computer solo alle 14 di ogni giorno. Qual è la probabilità di vittoria a $t = 14$?
- Quanto dovrà aspettare (in media) prima di vincere qualcosa? (*hint: la vittoria sarebbe il primo successo di Giorgino in questo gioco!*)

Svolgimento. Attenzione all'ordine delle variabili. La traccia chiede la probabilità *in funzione* dell'ora, quindi la variabile esplicativa è t (asse x) e la risposta è p (asse y). Scambiarle produce una retta diversa: è il punto sull'asimmetria della regressione.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 t = np.array([7, 8, 10, 12, 13, 17, 19, 21, 22], dtype=float)
5 p = np.array([0.08, 0.24, 0.33, 0.35, 0.39, 0.64, 0.70, 0.74, 0.86], dtype=float)
6 n = len(t)
7 tbar, pbar = t.mean(), p.mean()
8
9 Sxx = np.sum(t**2) - n * tbar**2
10 Syy = np.sum(p**2) - n * pbar**2
11 Sxy = np.sum(t * p) - n * tbar * pbar
12
13 betal = Sxy / Sxx
14 beta0 = pbar - betal * tbar
15 rho = Sxy / np.sqrt(Sxx * Syy)
16
17 print(f"betal = {betal:.6f}    beta0 = {beta0:.6f}")
18 print(f"rho = {rho:.6f}    R = {rho**2:.6f}")
19
20 # (c) previsione a t = 14
21 p14 = beta0 + betal * 14
22 print(f"p(14) = {p14:.6f}    ({p14*100:.4f}%)")
23
24 # (d) attesa del primo successo = 1/p (geometrica)
25 print(f"attesa media = 1/p = {1/p14:.6f} giorni")

```

```

betal = 0.046138    beta0 = -0.180194
rho = 0.986607    R = 0.973393
p(14) = 0.465732    (46.5732%)
attesa media = 1/p = 2.147158 giorni

```

(a) **La correlazione.** $\rho = 0.9866$: forte e positiva. La probabilità di vincere cresce in modo quasi lineare con l'ora del giorno.

(b) **La retta.** $\hat{p} = -0.1802 + 0.04614t$. Il coefficiente angolare ha un'unità di misura precisa: “+0.046 di probabilità per ogni ora in più”. Dirlo esplicitamente nel commento è ciò che il correttore cerca.

(c) **La previsione.** $p(14) = 0.4657$, cioè il 46.57%. Anche qui: $t = 14$ cade *dentro* l'intervallo osservato (7–22), quindi è interpolazione.

(d) **Quanto deve aspettare.** L'hint indirizza verso il modello giusto: “il *primo* successo” è la definizione della **geometrica**. Se ogni giorno la vittoria ha probabilità p indipendente dalle altre, il numero di giorni di attesa $T \sim \text{Geom}(p)$ ha valore atteso

$$\mathbb{E}[T] = \frac{1}{p}.$$

Con $p = p(14) = 0.465732$:

$$\mathbb{E}[T] = \frac{1}{0.465732} = 2.147158 \approx 2.15 \text{ giorni.}$$

Il collegamento tra i due mondi. Questo quesito è un buon esempio di come lo stesso compito mescoli argomenti diversi: serve la regressione per *stimare* p a un'ora mai osservata, e serve la teoria delle variabili aleatorie (la geometrica, Cap. 4) per usare quella p e rispondere alla domanda sull'attesa. Il modello della geometrica va scelto e *giustificato*: l'indipendenza tra i giorni è l'ipotesi che lo rende applicabile.

Esercizio 4 — Stimatori (richiama la regressione) (28/01/25, Q1 Teoria)

- (a) Dare la definizione di stimatore.
- (b) Dare la definizione di stimatore non distorto.
- (c) Quale stimatore usereste per stimare la varianza di una distribuzione con media nota?
- (d) Dimostrare che lo stimatore scelto al punto precedente è non distorto.

Svolgimento. Il collegamento con questo capitolo è che β_0 , β_1 e ρ sono *stimatori*: funzioni dei dati che approssimano quantità incognite della popolazione. La **definizione** e la dimostrazione di **non distorsione** sono nel Cap. 6, dove è anche spiegato perché lo stimatore della varianza con media nota ha divisore n e non $n - 1$. Il punto (c) è esattamente il caso in cui si usa $\bar{\sigma}_n^2$.

Capitolo 8

Numeri pseudorandom e metodi Monte Carlo

Questo capitolo risponde a due domande di teoria già assegnate: “*che cos’è un numero pseudo-random?*” (02/09/25, 23/06/26) e “*descrivere il metodo Monte Carlo, con vantaggi e svantaggi*” (23/06/26). È anche la giustificazione teorica di tutto ciò che si fa in Python con `np.random`.

8.1 Numeri pseudorandom

Numero pseudorandom

Un **numero pseudorandom** è un numero che *sembra* estratto a caso ma è prodotto da una **sequenza deterministica** di operazioni aritmetiche, a partire da un valore iniziale detto **seme** (*seed*).

Non è quindi realmente casuale: nota la regola e il seme, la sequenza è completamente prevedibile e riproducibile. Il suo uso è legittimo perché possiede le *proprietà statistiche* di una sequenza casuale (uniformemente distribuita, senza correlazioni apprezzabili, con periodo lungo).

Cosa scrivere all’esame

La domanda “che cos’è un numero pseudorandom?” è stata chiesta *due volte*, identica. La risposta completa ha tre parti:

1. è generato da un **algoritmo deterministico** (non da un processo fisico casuale);
2. dipende da un **seme**: semi diversi danno sequenze diverse, lo stesso seme dà sempre la stessa sequenza (**riproducibilità**);
3. deve **imitare statisticamente** una sequenza di variabili indipendenti uniformi su $(0, 1)$.

Il punto 2 è quello che si dimentica: la *riproducibilità* non è un difetto ma una proprietà voluta, ed è ciò che permette di verificare un esperimento. È il motivo per cui in Python si scrive `np.random.seed(42)` prima di una simulazione.

8.2 Il generatore a congruenze lineari

È il generatore storico, quello che l’esame chiede di saper descrivere.

Generatore congruenziale lineare (LCG)

Fissati quattro interi

$m > 0$ (modulo), $0 \leq a < m$ (moltiplicatore), $0 \leq c < m$ (incremento), X_0 (seme),

si genera la successione

$$X_{n+1} = (a X_n + c) \bmod m,$$

e da essa i numeri in $(0, 1)$

$$U_n = \frac{X_n}{m} \in [0, 1).$$

Se $c = 0$ il generatore si dice **moltiplicativo**, altrimenti **misto**.

Periodo e teorema di Hull–Dobell

La successione X_n è necessariamente **periodica** (i valori possibili sono solo m). Il **periodo** è il più piccolo T tale che $X_{n+T} = X_n$. Un generatore ha **periodo pieno** se $T = m$, cioè se esaurisce tutti i valori possibili prima di ripetersi.

Il generatore **misto** ha periodo pieno m se e solo se:

1. c e m sono **coprimi** ($\gcd(c, m) = 1$);
2. $a - 1$ è divisibile per **ogni fattore primo** di m ;
3. $a - 1$ è divisibile per 4 se m è divisibile per 4.

Un esempio numerico da citare

$m = 16$, $a = 5$, $c = 3$, $X_0 = 0$:

$$X_1 = (5 \cdot 0 + 3) \bmod 16 = 3, \quad X_2 = (5 \cdot 3 + 3) \bmod 16 = 2, \quad X_3 = 13, \quad X_4 = 4, \dots$$

Le condizioni sono soddisfatte: $\gcd(3, 16) = 1$; $a - 1 = 4$, e l'unico fattore primo di 16 è 2, che divide 4; 16 è divisibile per 4 e 4 divide 4. Il periodo è pieno, $T = 16$. I valori $U_n = X_n/16$ sono 0.1875, 0.125, 0.8125, 0.25, ...

Errore tipico da evitare

Un generatore LCG ha difetti noti che l'esame può chiedere di commentare:

- **correlazione seriale**: punti successivi (U_n, U_{n+1}) si dispongono su un numero finito di iperpiani, non riempiono il quadrato;
- **periodo limitato**: al massimo m , e per avere un periodo lungo serve m grande (i generatori reali usano $m \approx 2^{31}$ o 2^{64});
- i bit meno significativi sono i “peggiori” (poco casuali).

Per questo il `np.random` di NumPy *non* usa un LCG, ma il **Mersenne Twister**, con periodo $2^{19937} - 1$. L'LCG resta però il modello didattico che l'esame descrive.

8.3 Il metodo dell'inversione

Serve a trasformare un numero uniforme in un numero con una distribuzione assegnata.

Metodo dell'inversione

Sia $U \sim \mathcal{U}(0, 1)$ e sia F la funzione di ripartizione (strettamente crescente) della distribuzione che voglio ottenere. Allora

$$X = F^{-1}(U)$$

ha funzione di ripartizione F .

Svolgimento. [Dimostrazione]

$$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x),$$

dove l'ultima uguaglianza usa il fatto che U è uniforme su $(0, 1)$, per cui $P(U \leq t) = t$ per ogni $t \in [0, 1]$. ■

Caso esponenziale

Per $X \sim \text{Exp}(\lambda)$ la ripartizione è $F(x) = 1 - e^{-\lambda x}$. Ponendo $F(x) = u$ e invertendo:

$$1 - e^{-\lambda x} = u \implies x = -\frac{1}{\lambda} \ln(1 - u).$$

Poiché se $U \sim \mathcal{U}(0, 1)$ allora anche $1 - U \sim \mathcal{U}(0, 1)$, si può semplificare in

$$X = -\frac{1}{\lambda} \ln U.$$

Perché il caso esponenziale è quello che l'esame chiede

Perché è l'unico in cui l'inversione si fa *a mano*, con un logaritmo. Per la normale F^{-1} non ha forma chiusa (si usa `norm.ppf`, che internamente fa un'approssimazione numerica). L'esponenziale invece ha una formula esplicita, e la prova del 02/09/25 la chiede esattamente per questo.

In Python:

```
lam = 1/15 # un evento ogni 15 minuti
u = np.random.uniform(size=10000)
x = -np.log(u) / lam # ~ Exp(lam)
# equivalente, ma per capire il metodo: np.random.exponential(1/lam, 10000)
```

Il secondo comando dà lo stesso risultato: internamente fa *esattamente* questo. Sapere *perché* è il punto d'esame.

8.4 I metodi Monte Carlo**Metodo Monte Carlo**

Si dice **metodo Monte Carlo** qualunque tecnica che stimi una quantità (una probabilità, un integrale, una media) **campionando** numeri casuali e usando la legge dei grandi numeri per garantire che la stima converga al valore vero.

Metodo hit or miss

Stima un'area. Sia $\mathcal{R}$ una regione contenuta in un rettangolo $[a, b] \times [c, d]$, di cui voglio l'area. Procedimento:

1. Genero N punti uniformi nel rettangolo: $x_i \sim \mathcal{U}(a, b)$, $y_i \sim \mathcal{U}(c, d)$.
2. Conto quanti cadono in $\mathcal{R}$: $H = \#\{i : (x_i, y_i) \in \mathcal{R}\}$.
3. Stimiamo

$$\widehat{\text{Area}} = \text{Area}(\text{rettangolo}) \cdot \frac{H}{N} = (b - a)(d - c) \frac{H}{N}.$$

Precisione della stima

La frazione $\hat{p} = H/N$ è una media di N variabili di Bernoulli di parametro $p = \text{Area}(\mathcal{R})/\text{Area}(\text{rettangolo})$, quindi

$$\mathbb{E}[\hat{p}] = p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{N}, \quad \text{errore standard} = \sqrt{\frac{p(1-p)}{N}}.$$

È non distorto, e l'errore **diminuisce come** $1/\sqrt{N}$. Il commento da scrivere sempre: per

guadagnare una cifra decimale di precisione servono *cento volte* tante simulazioni.

Metodo del rigetto

Più generale dell'hit or miss: serve a simulare da una densità f qualunque, quando non si sa invertire F . Si sceglie una densità g facile da simulare (es. uniforme) con $f(x) \leq Mg(x)$ per una costante $M \geq 1$, e:

1. genero $Y \sim g$ e $U \sim \mathcal{U}(0, 1)$ indipendenti;
2. se $U \leq \frac{f(Y)}{Mg(Y)}$ **accetto** e pongo $X = Y$;
3. altrimenti **rigetto** e ripeto.

La probabilità di accettazione è $1/M$: più M è grande, meno efficiente è il metodo. È il metodo del Quesito 2 del 01/04/26 ($\int_0^1 xe^x dx$).

Integrazione Monte Carlo

Per stimare $I = \int_a^b f(x) dx$ si può anche usare direttamente la definizione di valore atteso. Se $X \sim \mathcal{U}(a, b)$:

$$\mathbb{E}[f(X)] = \frac{1}{b-a} \int_a^b f(x) dx \quad \Rightarrow \quad \hat{I} = (b-a) \cdot \overline{f(X_1), \dots, f(X_N)}.$$

È lo stimatore *più efficiente* dell'hit or miss (varianza minore), ed è quello che si usa quando f non è limitata in modo comodo.

Vantaggi e svantaggi: la domanda del 23/06/26

Vantaggi

- **Generalità:** funziona per qualunque funzione, anche senza primitiva, anche in dimensione alta, anche su regioni di forma arbitraria.
- **Semplicità:** poche righe di codice, nessuna teoria analitica.
- **Errore indipendente dalla dimensione:** l'errore va come $1/\sqrt{N}$ *qualunque sia* il numero di dimensioni. È il vantaggio decisivo rispetto all'integrazione numerica classica, il cui errore peggiora esponenzialmente con la dimensione.
- **Intervallo di errore:** l'errore standard è stimabile dai dati stessi.

Svantaggi

- **Convergenza lenta:** $1/\sqrt{N}$. Servono $100\times$ più simulazioni per una cifra in più.
- **Errore, non certezza:** il risultato è una stima, mai un valore esatto.
- **Dipendenza dal generatore:** se i numeri pseudorandom hanno correlazioni, la stima è distorta e l'errore stimato è sbagliato.
- **Costo computazionale** elevato per alta precisione.

L'errore da non fare, già visto in una prova

Nella prova del 27/01/26 (carte Magic) la probabilità simulata è venuta 3.18. **Una probabilità non può superare 1:** il errore era dividere per il numero di oggetti del problema (le 60 carte) invece che per il **numero di esperimenti simulati** (le 350 mani). La formula è sempre

$$\hat{p} = \frac{\text{\#casi favorevoli}}{\text{\#simulazioni}}.$$

Se il risultato non sta in $[0, 1]$, l'errore è quasi sempre questo.

8.5 Esercizi svolti**Esercizio 1 — Generatore congruenziale a mano (02/09/25)**

Sia $X_{n+1} = (5X_n + 3) \bmod 16$ con $X_0 = 0$. (a) Verificare le condizioni di Hull–Dobell. (b) Calcolare i primi 5 valori di X_n e i corrispondenti U_n . (c) Usare il metodo dell'inversione per generare un valore esponenziale con $\lambda = 0.5$ a partire da U_1 .

Svolgimento. (a) $m = 16 = 2^4$, $a = 5$, $c = 3$.

- $\gcd(c, m) = \gcd(3, 16) = 1$
- l'unico primo che divide 16 è 2; $a - 1 = 4$ è divisibile per 2
- m è divisibile per 4 e $a - 1 = 4$ è divisibile per 4

Le tre condizioni valgono, quindi il generatore ha **periodo pieno** $T = 16$.

(b)

$$\begin{aligned} X_1 &= (5 \cdot 0 + 3) \bmod 16 = 3 & U_1 &= 3/16 = 0.1875 \\ X_2 &= (5 \cdot 3 + 3) \bmod 16 = 2 & U_2 &= 2/16 = 0.1250 \\ X_3 &= (5 \cdot 2 + 3) \bmod 16 = 13 & U_3 &= 13/16 = 0.8125 \\ X_4 &= (5 \cdot 13 + 3) \bmod 16 = 4 & U_4 &= 4/16 = 0.2500 \\ X_5 &= (5 \cdot 4 + 3) \bmod 16 = 7 & U_5 &= 7/16 = 0.4375 \end{aligned}$$

(Nota: $5 \cdot 13 + 3 = 68 = 4 \cdot 16 + 4$, quindi $68 \bmod 16 = 4$.)

(c) Con $U_1 = 0.1875$ e $\lambda = 0.5$:

$$X = -\frac{1}{\lambda} \ln U_1 = -\frac{1}{0.5} \ln(0.1875) = -2 \cdot (-1.6739) \approx 3.348.$$

Il valore è ragionevole: la media di $\text{Exp}(0.5)$ è $1/0.5 = 2$, e 3.35 è nella fascia alta ma plausibile (il 75% della massa sta sotto $-\ln(0.25)/0.5 \approx 2.77$).

Esercizio 2 — Hit or miss per un integrale (24/03/25 e 02/09/25)

Stimare $I = \int_0^1 e^{-x^2} dx$ con il metodo hit or miss.

Svolgimento. Impostazione. La funzione e^{-x^2} su $[0, 1]$ va da $e^0 = 1$ a $e^{-1} \approx 0.3679$, quindi sta nel rettangolo $[0, 1] \times [0, 1]$. L'area della regione sotto la curva è esattamente I .

Algoritmo.

1. genero N punti (x_i, y_i) uniformi in $[0, 1]^2$;
2. conto i successi: $H = \#\{i : y_i \leq e^{-x_i^2}\}$;
3. $\hat{I} = H/N$ (l'area del rettangolo è 1).

Proprietà dello stimatore. $\hat{I}$ è la media di N Bernoulli di parametro I , quindi

$$\mathbb{E}[\hat{I}] = I, \quad \text{errore standard} = \sqrt{\frac{I(1-I)}{N}}.$$

Il valore vero è $I \approx 0.7468$ (si calcola con `scipy.special.erf`: $I = \frac{\sqrt{\pi}}{2} \text{erf}(1)$). Con $N = 10\,000$ l'errore standard vale $\sqrt{0.7468 \cdot 0.2532/10000} \approx 0.0043$, quindi il risultato sarà tipicamente 0.747 ± 0.009 .

Commento. Lo stimatore è non distorto ma la sua varianza è massima quando $I \approx 0.5$: l'hit or miss è inefficiente se la regione occupa circa metà del rettangolo. Per questo si preferisce, quando possibile, lo stimatore $(b-a)\overline{f(X)}$, che ha varianza molto minore.

Esercizio 3 — Metodo del rigetto (01/04/26)

Usare il metodo del rigetto per stimare $\int_0^1 x e^x dx$ e confrontare con il valore esatto.

Svolgimento. Il valore esatto si ottiene per parti:

$$\int_0^1 x e^x dx = [x e^x]_0^1 - \int_0^1 e^x dx = e - (e - 1) = 1.$$

Con il rigetto. Su $[0, 1]$ la funzione $g(x) = x e^x$ ha massimo in $x = 1$ (perché $g'(x) = (x+1)e^x > 0$, quindi è crescente) e vale $g(1) = e$. Prendo come densità di comodo l'uniforme $h(x) = 1$ su $[0, 1]$ e $M = e$:

$$\frac{g(x)}{M h(x)} = \frac{x e^x}{e} = x e^{x-1} \leq 1 \quad \text{su } [0, 1].$$

Algoritmo: genero $Y \sim \mathcal{U}(0, 1)$ e $U \sim \mathcal{U}(0, 1)$; accetto Y se $U \leq Y e^{Y-1}$. La probabilità di accettazione è $\frac{1}{M} = \frac{1}{e} \approx 0.368$, quindi servono circa 2.7 tentativi per ogni punto accettato.

Commento. Il metodo del rigetto qui è corretto ma inefficiente (accetta il 37%). Conviene, come nel quesito, usare direttamente $\hat{I} = \overline{f(X)}$ con $X \sim \mathcal{U}(0, 1)$, che non scarta nulla:

$$\hat{I} = \frac{1}{N} \sum_{i=1}^N X_i e^{X_i}, \quad \text{errore standard} = \frac{\sigma_f}{\sqrt{N}},$$

dove $\sigma_f^2 = \text{Var}(X e^X)$. È il confronto che il quesito chiede di fare.

Capitolo 9

Processi stocastici e catene di Markov

Il capitolo più importante della parte di teoria

Le catene di Markov sono l'argomento più chiesto in assoluto: **quattro volte su nove**, e *sempre* come Quesito 2 di teoria (28/01/25, 17/06/25, 27/01/26, 29/04/26). Se il tempo è poco, è da qui che conviene cominciare.

Le domande ricorrenti sono sempre le stesse cinque: *processo stocastico*, *catena di Markov*, *matrice di transizione*, *classe chiusa*, *catena irriducibile*. Le definizioni che seguono sono scritte nella forma esatta in cui vanno riportate sul compito.

9.1 Processi stocastici

Processo stocastico

Un **processo stocastico** è una famiglia di variabili aleatorie

$$\{X_t : t \in T\}$$

definite su uno stesso spazio di probabilità $(\Omega, \mathcal{A}, P)$, indicizzate da un parametro t che rappresenta il **tempo**.

L'insieme T dei valori di t può essere **discreto** ($T = \mathbb{N}$ o $\{0, 1, 2, \dots\}$) oppure **continuo** ($T = \mathbb{R}$ o $[0, +\infty)$). I valori che ciascuna X_t può assumere formano lo **spazio degli stati** S , anch'esso discreto o continuo.

	Tempo discreto	Tempo continuo
Stati discreti	catene di Markov (il nostro caso)	processi di Poisson, catene di Markov a tempo continuo
Stati continui	successioni di variabili aleatorie	moto browniano

Cosa scrivere all'esame

“Dare la definizione di processo stocastico” è stata chiesta il 28/01/25 e il 29/04/26. La risposta ha due elementi:

1. è una **famiglia di variabili aleatorie** indicizzata da un parametro t (non *una* variabile aleatoria: è questo il punto);
2. tutte definite sullo **stesso** spazio di probabilità.

Aggiungi la distinzione tempo discreto / tempo continuo e la nozione di spazio degli stati: mostra di avere il quadro completo. L'esempio da fare è sempre lo stesso: il prezzo di un'azione giorno per giorno, oppure la posizione di un pedone che si sposta a ogni passo.

9.2 La catena di Markov

Catena di Markov

Un processo stocastico a **tempo discreto** $\{X_n : n \in \mathbb{N}\}$ con **spazio degli stati discreto** S è una **catena di Markov** se soddisfa la **proprietà di Markov**:

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = P(X_{n+1} = j \mid X_n = i)$$

per ogni n e per ogni scelta di stati $i_0, \dots, i_{n-1}, i, j$.

Se inoltre $P(X_{n+1} = j \mid X_n = i)$ **non dipende da n** , la catena si dice **omogenea** (nel tempo), e si scrive

$$p_{ij} = P(X_{n+1} = j \mid X_n = i).$$

La proprietà di Markov in una frase

Il futuro dipende dal presente, e solo dal presente. Tutta la storia passata è irrilevante una volta noto lo stato attuale. È l'assenza di memoria, la stessa proprietà della geometrica e dell'esponenziale. Il gioco dell'oca è una catena di Markov (le 6 prove del 28/01/25 e il Quesito 1 del 17/06/25): la posizione futura del segnalino dipende solo dalla casella in cui si trova ora, non da come ci è arrivato.

Cosa scrivere all'esame

La definizione di catena di Markov (28/01/25, 29/04/26) va scritta in **tre passi**, e i tre passi valgono un punto ciascuno:

1. è un **processo stocastico a tempo discreto** con **spazio degli stati discreto**;
2. vale la **proprietà di Markov** (scrivila in formula: è ciò che il correttore cerca);
3. eventualmente l'**omogeneità**: p_{ij} non dipende da n .

Dimenticare il punto 1 è l'errore più frequente: la proprietà di Markov da sola non basta, serve dire su che tipo di processo è definita.

9.3 La matrice di transizione

Matrice di transizione

La **matrice di transizione** (o matrice delle probabilità di transizione) è la matrice $P = (p_{ij})$ con $i, j \in S$, dove p_{ij} è la probabilità di passare dallo stato i allo stato j in *un* passo.

Se $S = \{1, 2, \dots, k\}$:

$$P = \begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1k} \\ p_{21} & p_{22} & \cdots & p_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ p_{k1} & p_{k2} & \cdots & p_{kk} \end{pmatrix}$$

Le sue proprietà caratterizzanti:

$$p_{ij} \geq 0 \quad \forall i, j, \quad \sum_{j \in S} p_{ij} = 1 \quad \forall i.$$

Una matrice con queste proprietà si chiama **matrice stocastica** (per righe): le righe sommano a 1, le colonne no.

Errore tipico da evitare

La confusione più costosa: **le righe sommano a 1, non le colonne**. La riga i elenca le probabilità di *uscire* dallo stato i verso tutti gli stati possibili: partendo da i bisogna pur andare da qualche parte, quindi la riga somma a 1. Se il compito dà una matrice e chiede di verificarne la validità, il controllo è sulle righe.

Distribuzione dello stato al tempo n

La **distribuzione iniziale** è il vettore riga $\pi^{(0)} = (\pi_1^{(0)}, \dots, \pi_k^{(0)})$ con $\pi_i^{(0)} = P(X_0 = i)$ e $\sum_i \pi_i^{(0)} = 1$.

La distribuzione al tempo n si ottiene per moltiplicazione a destra:

$$\pi^{(n)} = \pi^{(0)} P^n, \quad \text{cioè} \quad \pi_j^{(n)} = \sum_i \pi_i^{(0)} p_{ij}^{(n)}.$$

Equazioni di Chapman–Kolmogorov

Le probabilità di transizione in n passi, $p_{ij}^{(n)} = P(X_n = j \mid X_0 = i)$, si ottengono come

$$P^{(n)} = P^n, \quad p_{ij}^{(m+n)} = \sum_{l \in S} p_{il}^{(m)} p_{lj}^{(n)}.$$

In forma matriciale: $P^{(m+n)} = P^{(m)} P^{(n)}$.

Svolgimento. [Perché vale] Per la formula delle probabilità totali, condizionando sullo stato intermedio assunto al tempo m :

$$p_{ij}^{(m+n)} = P(X_{m+n} = j \mid X_0 = i) = \sum_l P(X_{m+n} = j \mid X_m = l) P(X_m = l \mid X_0 = i) = \sum_l p_{lj}^{(n)} p_{il}^{(m)},$$

dove il passaggio chiave usa la proprietà di Markov: noto lo stato al tempo m , la probabilità di arrivare in j dopo altri n passi non dipende da come ci si è arrivati. ■

Cosa scrivere all'esame

Il 27/01/26 ha chiesto *matrice di transizione, proprietà, matrice a m passi, distribuzione di X_t* . Lo schema di risposta:

1. definizione di $P = (p_{ij})$ e proprietà (righe non negative, somma 1);
2. P descrive **un** passo, P^2 due passi, P^m m passi;
3. $\pi^{(t)} = \pi^{(0)} P^t$ (attenzione: *vettore riga a sinistra*);
4. la componente j -esima: $P(X_t = j) = \sum_i \pi_i^{(0)} p_{ij}^{(t)}$.

Nel compito conviene scrivere la matrice esplicitamente con i numeri, non solo in forma simbolica.

9.4 Classi, irriducibilità, ricorrenza

Comunicazione tra stati

Lo stato j è **accessibile** da i (si scrive $i \rightarrow j$) se esiste $n \geq 0$ tale che $p_{ij}^{(n)} > 0$, cioè se esiste una catena di passi di probabilità positiva che porta da i a j .

Due stati i e j **comunicano** ($i \leftrightarrow j$) se $i \rightarrow j$ e $j \rightarrow i$. La comunicazione è una **relazione di equivalenza** (riflessiva, simmetrica, transitiva), quindi partiziona lo spazio degli stati in **classi di comunicazione**.

Classe chiusa

Un sottoinsieme di stati $C \subseteq S$ è una **classe chiusa** se non si può uscirne:

$$p_{ij} = 0 \quad \forall i \in C, \forall j \notin C,$$

equivalentemente $\sum_{j \in C} p_{ij} = 1$ per ogni $i \in C$.

Uno stato i con $p_{ii} = 1$ si dice **assorbente**; in tal caso $\{i\}$ è una classe chiusa.

Catena irriducibile

Una catena di Markov si dice **irriducibile** se lo spazio degli stati costituisce **una sola classe di comunicazione**, cioè se tutti gli stati comunicano tra loro:

$$i \leftrightarrow j \quad \forall i, j \in S.$$

Equivalentemente: non esistono classi chiuse proprie (sottoinsiemi chiusi diversi da S stesso).

Cosa scrivere all'esame

“Classe chiusa” e “catena irriducibile” sono state chieste *insieme* il 28/01/25 e il 29/04/26 (con “classe chiusa e irriducibile”), e “catena irriducibile” anche il 17/06/25. Il legame da scrivere esplicitamente:

una catena è irriducibile quando l'unica classe chiusa è l'intero spazio degli stati.

Questa frase collega le due definizioni ed è esattamente ciò che distingue una risposta completa da due definizioni scollegate. Aggiungi sempre l'esempio opposto: una catena con uno stato assorbente *non* è irriducibile, perché {stato assorbente} è una classe chiusa propria.

Stati ricorrenti e transitori

Sia f_i la probabilità di ritornare prima o poi in i partendo da i .

- i è **ricorrente** se $f_i = 1$ (il ritorno è certo);
- i è **transitorio** se $f_i < 1$ (c'è una probabilità positiva di non tornarci mai).

In una catena finita, se $i \rightarrow j$ e i è ricorrente allora anche j è ricorrente: la ricorrenza è una proprietà di classe.

Periodo

Il **periodo** dello stato i è

$$d(i) = \gcd \{n \geq 1 : p_{ii}^{(n)} > 0\}.$$

Se $d(i) = 1$ lo stato si dice **aperiodico**. Una catena irriducibile in cui tutti gli stati sono

aperiodici si dice **ergodica**.

Un esempio di periodicità

Il *random walk* su $\{0, 1, 2, \dots\}$ con passi ± 1 ha periodo 2: partendo da 0 si può tornare solo dopo un numero pari di passi, quindi $p_{00}^{(n)} > 0$ solo per n pari e $d(0) = 2$. Aggiungendo la possibilità di *restare fermi* ($p_{ii} > 0$) la catena diventa aperiodica. È il caso del random walk su $\{1, \dots, 6\}$ del 17/06/25.

9.5 La distribuzione stazionaria

Distribuzione stazionaria

Un vettore di probabilità $\pi = (\pi_1, \dots, \pi_k)$ è una **distribuzione stazionaria** (o *invariante*) della catena se

$$\pi = \pi P, \quad \sum_{i \in S} \pi_i = 1, \quad \pi_i \geq 0.$$

Esplicitamente, per ogni j : $\pi_j = \sum_{i \in S} \pi_i p_{ij}$.

Le proprietà che l'esame chiede di enunciare

- Se $\pi^{(0)} = \pi$ allora $\pi^{(n)} = \pi$ per ogni n : la distribuzione **non cambia nel tempo**. È il significato del nome “stazionaria”.
- **Esistenza e unicità**: una catena finita e irriducibile ha *sempre* una e una sola distribuzione stazionaria.
- **Convergenza**: se la catena è irriducibile e *aperiodica*, allora $\pi^{(n)} \rightarrow \pi$ per *qualunque* distribuzione iniziale $\pi^{(0)}$. La memoria dello stato di partenza svanisce.
- **Tempo medio di ritorno**: se la catena è ergodica, il tempo medio di ritorno in i partendo da i è $\mu_i = 1/\pi_i$. Stati con π_i grande sono visitati spesso.

Errore tipico da evitare

Stazionaria non significa “distribuzione di equilibrio raggiunta”: una distribuzione stazionaria può esistere anche per catene periodiche, dove $\pi^{(n)}$ *non* converge a π (oscilla). Per avere la convergenza serve anche l'**aperiodicità**. Inoltre in una catena *riducibile* possono esistere *più* distribuzioni stazionarie, una per ogni classe chiusa: la presenza di uno stato assorbente dà $\pi = (0, \dots, 1, \dots, 0)$, concentrata su quello stato.

Come si calcola π in pratica

Si risolve il sistema lineare $\pi = \pi P$, che è

$$\begin{cases} \pi_1 = \pi_1 p_{11} + \pi_2 p_{21} + \dots + \pi_k p_{k1} \\ \vdots \\ \pi_k = \pi_1 p_{1k} + \pi_2 p_{2k} + \dots + \pi_k p_{kk} \\ \pi_1 + \pi_2 + \dots + \pi_k = 1 \end{cases}$$

Un trucco utile: le prime k equazioni sono **linearmente dipendenti** (la matrice $P - I$ ha rango $k - 1$), quindi se ne **scarta una** e si sostituisce con la condizione di normalizzazione. Senza scartarla, il sistema è indeterminato e la soluzione non si trova.

In Python ci sono due strade:

```
# 1) per autovettori: l'autovettore sinistro di P per l'autovalore 1
w, v = np.linalg.eig(P.T)
pi = np.real(v[:, np.isclose(w, 1)]).flatten()
pi = pi / pi.sum()

# 2) per potenza: P^m converge a una matrice con tutte le righe uguali a pi
m = 500
Pm = np.linalg.matrix_power(P, m)
pi = Pm[0]      # ogni riga e' ~ pi
```

La seconda è quella che si usa all'esame (23/06/26, Quesito 2): è concettualmente la più chiara, perché mostra direttamente il significato di “convergenza”.

9.6 Esercizi svolti

Esercizio 1 — Random walk su $\{1, \dots, 6\}$ (17/06/25)

Un segnalino si muove sugli stati $\{1, 2, 3, 4, 5, 6\}$. Da uno stato interno $(2, \dots, 5)$ si va a destra o a sinistra con probabilità $1/2$ ciascuna. Dagli estremi 1 e 6 si torna obbligatoriamente verso l'interno. (a) Scrivere la matrice di transizione. (b) La catena è irriducibile? (c) Calcolare la distribuzione stazionaria.

Svolgimento. (a) Le righe sommano a 1:

$$P = \begin{pmatrix} 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 & 0 \\ 0 & 0 & 1/2 & 0 & 1/2 & 0 \\ 0 & 0 & 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \end{pmatrix}$$

Gli stati interni $2, \dots, 5$ hanno due soli archi uscenti, da $1/2$ ciascuno. Gli estremi hanno invece un **cappio**: da 1 si resta in 1 con probabilità $1/2$, e lo stesso da 6 . È la lettura letterale della traccia (“ho il 50% di probabilità di restare in 1 o di andare in 2 ”).

(b) Sì, è **irriducibile**. Da qualunque stato si raggiunge qualunque altro: gli stati formano una sola classe di comunicazione (per esempio $1 \rightarrow 2 \rightarrow 3 \rightarrow \dots \rightarrow 6$ e $6 \rightarrow 5 \rightarrow \dots \rightarrow 1$). Non ci sono classi chiuse proprie.

(c) La matrice è **doppiamente stocastica**: sommano a 1 non solo le righe ma anche le *colonne*, perché ogni stato riceve esattamente due archi entranti da $1/2$ (per 1 e per 6 uno dei due è il cappio). Per una matrice doppiamente stocastica la distribuzione stazionaria è quella **uniforme**:

$$\pi = \left(\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6} \right).$$

Il sistema $\pi = \pi P$ lo conferma senza bisogno di simmetrie: la prima equazione è $\pi_1 = \frac{1}{2}\pi_1 + \frac{1}{2}\pi_2$, da cui $\pi_1 = \pi_2$; la seconda è $\pi_2 = \frac{1}{2}\pi_1 + \frac{1}{2}\pi_3$, da cui $\pi_3 = 2\pi_2 - \pi_1 = \pi_1$; e così di seguito fino a $\pi_6 = \pi_1$. Tutte le componenti sono uguali, e la normalizzazione $\sum_i \pi_i = 1$ dà $1/6$ ciascuna.

Controprova. Con questa matrice, `np.linalg.matrix_power(P, 500)` restituisce una matrice con *tutte* le righe uguali a $(1/6, \dots, 1/6)$: è la definizione operativa di “ $\pi^{(n)} \rightarrow \pi$ ”.

Verifica: la somma è 1.

Commento. Gli stati centrali sono visitati il doppio delle volte degli estremi: è intuitivo, perché ogni cammino che va da 1 a 6 deve attraversarli tutti. È il vantaggio della distribuzione stazionaria: dice quali stati il sistema “frequenta” nel lungo periodo, senza simulare.

Attenzione alla periodicità: sono i cappi a salvare la convergenza. Senza i cappi agli estremi la catena sarebbe *periodica* di periodo 2: partendo da 1 si tornerebbe in 1 solo dopo un numero pari di passi, π esisterebbe lo stesso ma $\pi^{(n)}$ *oscillerebbe* invece di convergere. La traccia però dice che dagli estremi si *resta fermi* con probabilità $1/2$, e $p_{11} = p_{66} = 1/2 > 0$ rende ogni stato aperiodico. La catena è quindi irriducibile e aperiodica, cioè **ergodica**: P^m converge a una matrice con tutte le righe uguali a π , e il vettore trovato al punto (c) è davvero il limite di $\pi^{(n)}$. Vale la pena scriverlo nel compito, perché è esattamente ciò che distingue “esiste π ” da “ $\pi^{(n)} \rightarrow \pi$ ”.

Esercizio 2 — Matrice a m passi e distribuzione di X_t (27/01/26)

Una catena a due stati $\{1, 2\}$ ha

$$P = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}, \quad \pi^{(0)} = (1, 0).$$

(a) Verificare che P è una matrice stocastica. (b) Calcolare la distribuzione di X_1 e X_2 . (c) Calcolare la distribuzione stazionaria. (d) Cosa succede per $t \rightarrow \infty$?

Svolgimento. (a) Le righe sommano a 1: $0.7 + 0.3 = 1$, $0.4 + 0.6 = 1$. Tutti gli elementi sono non negativi. Quindi P è stocastica.

(b)

$$\pi^{(1)} = \pi^{(0)}P = (1, 0) \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix} = (0.7, 0.3),$$

$$\pi^{(2)} = \pi^{(1)}P = (0.7, 0.3) \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix} = (0.7 \cdot 0.7 + 0.3 \cdot 0.4, 0.7 \cdot 0.3 + 0.3 \cdot 0.6) = (0.61, 0.39).$$

In alternativa $\pi^{(2)} = \pi^{(0)}P^2$, con $P^2 = \begin{pmatrix} 0.61 & 0.39 \\ 0.52 & 0.48 \end{pmatrix}$.

(c) Il sistema $\pi = \pi P$ con $\pi_1 + \pi_2 = 1$:

$$\begin{cases} \pi_1 = 0.7\pi_1 + 0.4\pi_2 \\ \pi_1 + \pi_2 = 1 \end{cases} \implies 0.3\pi_1 = 0.4\pi_2 \implies \pi_2 = 0.75\pi_1.$$

Con $\pi_1 + 0.75\pi_1 = 1$ si ottiene $\pi_1 = \frac{1}{1.75} = \frac{4}{7} \approx 0.5714$ e $\pi_2 = \frac{3}{7} \approx 0.4286$. Quindi $\pi = (4/7, 3/7)$.

(d) La catena è irriducibile (tutti gli elementi positivi $\Rightarrow$ tutti gli stati comunicano) e aperiodica ($p_{11} = 0.7 > 0$). Per il teorema di convergenza:

$$\pi^{(t)} \rightarrow \pi = (4/7, 3/7) \quad \text{per } t \rightarrow \infty,$$

qualunque sia $\pi^{(0)}$. Verifica numerica: $\pi^{(3)} \approx (0.583, 0.417)$, $\pi^{(5)} \approx (0.5729, 0.4271)$, $\pi^{(10)} \approx 0.571429$. La memoria dello stato iniziale svanisce geometricamente.

Tempo medio di ritorno. Per lo stato 1 è $1/\pi_1 = 1.75$ passi; per lo stato 2 è $1/\pi_2 \approx 2.33$ passi.

Esercizio 3 — Leggere una catena da un grafo (28/01/25)

Nel grafo di transizione, lo stato 4 ha una freccia su sé stesso con probabilità 1, e gli stati $\{1, 2, 3\}$ comunicano tra loro con probabilità positive, con una freccia da 3 a 4 di probabilità 0.2. (a) Identificare le classi chiuse. (b) La catena è irriducibile? (c) Classificare gli stati.

Svolgimento. (a) Le classi di comunicazione sono due: $\{1, 2, 3\}$ e $\{4\}$.

- $\{4\}$ è **chiusa**: da 4 si va solo in 4.
- $\{1, 2, 3\}$ **non** è chiusa: da 3 si esce verso 4 con probabilità 0.2.

(b) **No.** Una catena irriducibile ha una sola classe di comunicazione, e qui ce ne sono due. Inoltre $\{4\}$ è una classe chiusa *propria* (diversa da tutto lo spazio degli stati): per definizione, questo esclude l'irriducibilità.

(c) Lo stato 4 è **assorbente** ($p_{44} = 1$) e **ricorrente**. Gli stati 1, 2, 3 sono **transitori**: c'è una probabilità positiva (0.2 per passo, dalla parte giusta del grafo) di finire in 4 e non tornare mai più.

Distribuzione stazionaria. Ce ne sono infinite combinazioni, ma quella “fisica” dipende da dove parte il processo: prima o poi tutti i cammini finiscono in 4, quindi la massa si concentra là, $\pi = (0, 0, 0, 1)$.

Il metodo per leggere un grafo — questo è ciò che l'esercizio 28/01/25 chiedeva:

1. disegna le frecce uscenti da ogni nodo e verifica che sommino a 1;
2. raggruppa i nodi che si raggiungono a vicenda (classi di comunicazione);
3. guarda se da un gruppo si esce: se no, è chiuso;
4. se esiste più di una classe o una classe chiusa propria, la catena **non** è irriducibile.

Esercizio 4 — Catena a 6 stati in Python (23/06/26)

Data la matrice di transizione a 6 stati del compito, calcolare la matrice a 500 passi e la distribuzione stazionaria, e verificare che ogni riga di P^{500} coincide con π indipendentemente dallo stato di partenza.

Svolgimento.

```
import numpy as np

P = np.array([[0.5, 0.5, 0.0, 0.0, 0.0, 0.0],
              [0.2, 0.3, 0.5, 0.0, 0.0, 0.0],
              [0.0, 0.3, 0.4, 0.3, 0.0, 0.0],
              [0.0, 0.0, 0.3, 0.4, 0.3, 0.0],
              [0.0, 0.0, 0.0, 0.3, 0.4, 0.3],
              [0.0, 0.0, 0.0, 0.0, 0.5, 0.5]])

print("righe sommano a 1:", np.allclose(P.sum(axis=1), 1))

Pm = np.linalg.matrix_power(P, 500)
pi = Pm[0]
print("pi      :", np.round(pi, 6))
print("ogni riga ~ pi:", np.allclose(Pm, np.tile(pi, (6, 1)), atol=1e-9))

# verifica diretta dell'equazione pi = pi P
print("pi P ~ pi :", np.allclose(pi @ P, pi, atol=1e-9))
```

Output atteso:

```
righe sommano a 1: True
pi      : [0.054054 0.135135 0.225225 0.225225 0.225225 0.135135]
ogni riga ~ pi: True
pi P ~ pi : True
```

Commento. Tre verifiche in un colpo solo:

1. P^{500} ha *tutte* le righe uguali a π : la memoria dello stato iniziale è scomparsa. È la convergenza $\pi^{(n)} \rightarrow \pi$;
2. $\pi P = \pi$: π è effettivamente stazionaria;
3. la distribuzione non è uniforme: gli stati centrali (3, 4, 5) hanno probabilità doppia degli estremi, perché la catena ci passa più spesso.

Sostituendo 500 con 5 o 20 si vede che la convergenza è già completa molto prima: è il senso di “*m* grande” nel quesito 2.

Parte II

Laboratorio Python

Capitolo 10

Come funziona il Laboratorio

10.1 Il problema: il Python che non ti hanno insegnato

Metà del compito si svolge in Python, ma Python non è nel programma del corso. Questa parte della guida risolve esattamente questo: contiene **il Python che serve**, e nient'altro. Non è un corso di programmazione — non troverai classi, decoratori, generatori o gestione dei file. Troverai le istruzioni che compaiono davvero nei quesiti, spiegate ogni volta che vengono usate.

Cosa devi già sapere

Si assume solo la programmazione di base: variabili, `if`, `for`, funzioni, liste. Chi ha fatto un qualunque corso di programmazione ha già tutto ciò che serve. Il resto lo impari qui.

10.2 Lo schema fisso di ogni quesito di Laboratorio

Analizzando i 18 quesiti di Laboratorio delle nove prove, emerge una struttura che si ripete quasi sempre. Un quesito tipico chiede quattro cose, in quest'ordine:

I quattro passi

1. **Calcolare la quantità teoricamente.** Con una formula: una probabilità, una media, un intervallo. È la parte che si fa con carta e penna e che va scritta *prima* del codice.
2. **Simulare.** Ripetere l'esperimento N volte con `np.random` e stimare la stessa quantità dai risultati.
3. **Confrontare.** Mettere i due risultati uno accanto all'altro, con un grafico (istogramma, overlay, QQ-plot, scatter) e/o con i numeri.
4. **Commentare.** Spiegare la differenza. Quasi sempre la differenza è dovuta alla **fluttuazione campionaria**, che va come $1/\sqrt{N}$ (Capitolo 5): aumentando N la stima simulata si avvicina al valore teorico.

Il passo 4 è quello che vale più punti e quello che si dimentica più spesso. Un quesito risolto correttamente ma senza commento perde punti: il correttore vuole vedere che sai *interpretare* la differenza tra i due numeri, non solo produrli.

Il commento non è “i due valori sono simili”

Dire “i valori sono vicini, quindi va bene” non è un commento. Un commento corretto nomina:

- la **causa** della differenza (il campionamento casuale, non un errore);
- la sua **ampiezza attesa** (l'errore standard, $\sim 1/\sqrt{N}$);
- ciò che accadrebbe **aumentando** N (la differenza si riduce).

Esempio di commento che prende il punteggio pieno: “il valore simulato 0.748 differisce dal valore teorico 0.7468 di circa 0.001, un valore compatibile con l'errore standard stimato $\sqrt{p(1-p)/N} \approx 0.004$ con $N = 10\,000$: la differenza è attribuibile alla fluttuazione campionaria e tende a zero all'aumentare di N .”

10.3 Le quattro cose che si fanno sempre

Ogni capitolo di questa parte è una **ricetta**: un tipo di richiesta che compare nei compiti, con il codice pronto e la spiegazione. Le ricette sono organizzate in questo ordine:

Cap.	Ricetta	Quando serve
11	L'ambiente di lavoro	sempre: sono gli strumenti
12	Simulare una probabilità	“stimare $P(\cdot)$ con una simulazione”
13	Confrontare teoria e simulazione	“confrontare con la distribuzione teorica”
14	Statistica descrittiva	“calcolare media, mediana, quartili”
15	Regressione e correlazione	“stimare la retta, calcolare r ”
16	Test d'ipotesi e IC	“verificare con un test al 5%”
17	Monte Carlo e integrazione	“stimare l'integrale, metodo hit or miss”
18	Catene di Markov	“matrice di transizione, distribuzione stazionaria”

10.4 Consigli pratici per la prova

Come scrivere il codice all'esame

- **Scrivi le import all'inizio**, sempre le stesse tre righe: `numpy`, `scipy.stats`, `matplotlib.pyplot`. Non perdere tempo a ricordare da dove viene una funzione: se serve `norm`, viene da `scipy.stats`.
- **Commenta il codice**. Un codice funzionante ma muto vale meno di un codice funzionante con due righe di commento che spiegano l'idea. Il correttore legge il ragionamento, non esegue il programma.
- **Dichiara N e usa lo stesso N** per tutte le simulazioni confrontabili.
- **Usa `np.random.seed(...)`** solo se vuoi riproducibilità. Non è obbligatorio, ma se metti un seed il risultato è verificabile.
- **Stampa i risultati con `print` e riportali nel testo**. Non basta che il codice “giri”: i numeri vanno scritti, perché il compito è su carta.
- **Se un passaggio non ti riesce, scrivi la formula e commenta**: un quesito a metà con la teoria giusta vale più di un quesito vuoto.

Gli errori di Python che costano più punti

- **Confondere `range` e `np.arange`**: `range(n)` non è un array e non si può usare in operazioni vettoriali. Per generare indici numerici si usa `np.arange`.
- **Dimenticare le parentesi di `size`**: `np.random.uniform(0,1,100)` funziona, ma la forma leggibile è `np.random.uniform(0, 1, size=100)`.
- **Usare `/` con interi** dove serve un float: in Python 3 non è un problema (la divisione è già float), ma `//` tronca.
- **Calcolare la media di una lista di bool**: in NumPy funziona benissimo — `(x > 3).mean()` è il modo più rapido di calcolare una frequenza relativa, e vale la pena

saperlo.

- **Non distinguere pmf da cdf:** $\text{pmf}(2)$ è $P(X = 2)$, $\text{cdf}(2)$ è $P(X \leq 2)$. Confonderli dà errori silenziosi, cioè i peggiori.

Capitolo 11

L'ambiente di lavoro

Questo capitolo è la cassetta degli attrezzi. Tutto il codice dei capitoli successivi usa solo ciò che è spiegato qui. Se hai già programmato, puoi leggerlo in diagonale e tornare quando qualcosa non è chiaro.

11.1 Le tre librerie

```
import numpy as np          # calcolo numerico, array, numeri casuali
import scipy.stats as stats  # distribuzioni, test, regressione
import matplotlib.pyplot as plt # grafici
```

Libreria	Cosa ci si fa
numpy	Generare numeri casuali, fare operazioni su interi vettori in una riga, calcolare medie e somme.
scipy.stats	Tutte le distribuzioni notevoli (norm, binom, poisson, geom, hypergeom, expon, t, chi2) e i test statistici.
matplotlib.pyplot	Istogrammi, scatter plot, curve, QQ-plot.

Perché NumPy e non le liste di Python

Perché le operazioni si scrivono *una volta sola* e valgono per tutti gli elementi. Confronta:

```
# con le liste di Python
somma = 0
for i in range(len(x)):
    somma = somma + x[i]
media = somma / len(x)
```

```
# con NumPy
media = x.mean()
```

All'esame il tempo è poco: la versione NumPy non è solo più corta, è anche più facile da scrivere correttamente sotto pressione.

11.2 Generare numeri casuali

Comando	Risultato	Quando serve
<code>np.random.uniform(0,1,size=n)</code>	n valori uniformi in $[0, 1)$	il più usato
<code>np.random.uniform(a,b,size=n)</code>	n valori uniformi in $[a, b)$	intervalli generici
<code>np.random.randint(a,b,size=n)</code>	n interi in $\{a, \dots, b - 1\}$	dadi, carte, indici
<code>np.random.choice(x,size=n)</code>	n estrazioni da x , con reinserimento	urne, mazzi
<code>np.random.choice(x,size=n,replace=False)</code>	n estrazioni <i>senza</i> reinserimento	ipergeometrica
<code>np.random.choice(x,size=n,p=pr)</code>	estrazioni con probabilità pr	eventi non uniformi
<code>np.random.binomial(n,p,size=N)</code>	N valori $\text{Bin}(n, p)$	binomiale
<code>np.random.poisson(lam,size=N)</code>	N valori $\text{Pois}(\lambda)$	Poisson
<code>np.random.exponential(s,size=N)</code>	N valori $\text{Exp}(1/s)$	esponenziale
<code>np.random.normal(mu,s,size=N)</code>	N valori $N(\mu, \sigma^2)$	normale
<code>np.random.seed(42)</code>	fissa il seme	riproducibilità

Il parametro dell'esponenziale è la *media*, non il tasso

`np.random.exponential(s)` produce valori con **media** s , cioè $\text{Exp}(1/s)$ nella notazione $\text{Exp}(\lambda)$ di questa guida. Se il problema dà $\lambda = 4$ eventi per ora, la media è $1/\lambda = 0.25$ e si scrive `np.random.exponential(1/4, size=N)` oppure `np.random.exponential(1/lam, size=N)`. Sbagliare qui produce un fattore $1/\lambda^2$ di errore, e il grafico confrontato con la teoria non torna. È un errore che si vede subito, ma solo se si fa il confronto (Cap. 13).

Ogni simulazione è un vettore, non un ciclo

Il modo di scrivere una simulazione che si usa sempre:

```
N = 10000                                # numero di esperimenti
x = np.random.uniform(0, 1, size=N)       # N esperimenti tutti insieme
print(x[:5])                             # i primi 5 risultati
print(x.mean())                           # la media su tutti gli N
```

Non serve il `for`: `size=N` già produce N esperimenti. Il ciclo si usa solo quando ogni esperimento ha una durata casuale (es. una catena di Markov che va avanti finché non si ferma). Imparare a pensare “per vettori” è il salto mentale più importante di questa parte.

11.3 Le distribuzioni in `scipy.stats`

Tutte le distribuzioni si usano allo stesso modo. Per una distribuzione `dist` con parametri:

Metodo	Cosa restituisce	Esempio
<code>dist.pmf(k, ...)</code>	$P(X = k)$ (solo discrete)	<code>binom.pmf(3, 10, 0.5)</code>
<code>dist.pdf(x, ...)</code>	densità $f(x)$ (solo continue)	<code>norm.pdf(0, 0, 1)</code>
<code>dist.cdf(x, ...)</code>	$F(x) = P(X \leq x)$	<code>norm.cdf(1.96)</code>
<code>dist.sf(x, ...)</code>	$P(X > x) = 1 - F(x)$	<code>norm.sf(1.96)</code>
<code>dist.ppf(q, ...)</code>	l'inversa: x con $F(x) = q$	<code>norm.ppf(0.975)</code>
<code>dist.rvs(size=N, ...)</code>	N valori simulati	<code>norm.rvs(size=1000)</code>

La distinzione che si sbaglia sempre

$$\text{cdf}(2) = P(X \leq 2) \quad \text{mentre} \quad \text{pmf}(2) = P(X = 2).$$

Per $P(X \geq 2)$ con una discreta: `sf(1)` $= 1 - F(1) = P(X > 1) = P(X \geq 2)$. Attenzione al “ $\geq$ ”: con le discrete `sf(k-1)` dà $P(X \geq k)$, mentre `sf(k)` dà $P(X > k)$. Se il quesito chiede “almeno 67”, si scrive `binom.sf(66, 200, 1/3)`.

I parametri delle distribuzioni che servono

Distribuzione	Chiamata	Nota
Normale $N(\mu, \sigma^2)$	<code>norm(loc=mu, scale=sigma)</code>	scale è σ , non σ^2
Binomiale $\text{Bin}(n, p)$	<code>binom(n, p)</code>	n e p posizionali
Poisson $\text{Pois}(\lambda)$	<code>poisson(mu=lam)</code>	
Geometrica	<code>geom(p)</code>	conta i <i>tentativi</i> fino al 1° successo
Ipergeometrica	<code>hypergeom(M, n, N)</code>	M =totale, n =successi, N =estrazioni
Esponenziale $\text{Exp}(\lambda)$	<code>expon(scale=1/lam)</code>	scale $= 1/\lambda = \text{media}$
Uniforme continua	<code>uniform(loc=a, scale=b-a)</code>	
t di Student	<code>t(df)</code>	df = gradi di libertà
Chi-quadro	<code>chi2(df)</code>	

La normale vuole σ , la t vuole i gradi di libertà

- `norm(0, 1)` $\Rightarrow \mu = 0, \sigma = 1$. Se il problema dà la varianza $= 4$, si scrive `norm(0, 2)` (radice quadrata).
- `t(11)` $\Rightarrow t$ di Student con 11 gradi di libertà, *non* con $\sigma = 11$. Le dovute differenze di sintassi sono una fonte classica di errore sotto esame.
- `expon(scale=1/lam)` $\Rightarrow$ scale è la *media*, non il tasso.

11.4 I grafici

Comando	Cosa produce
<code>plt.hist(x, bins=30, density=True)</code>	istogramma delle frequenze <i>relative</i> (<code>density=True</code> lo rende confrontabile con una densità)
<code>plt.bar(xi, fi)</code>	diagramma a barre per dati discreti già tabulati
<code>plt.plot(x, y)</code>	linea: la curva della densità teorica
<code>plt.scatter(x, y)</code>	nuvola di punti: per la regressione
<code>plt.axvline(v, color='r')</code>	linea verticale: per marcare un valore critico
<code>plt.legend()</code>	mostra la legenda (serve quando ci sono più curve)
<code>plt.xlabel('...') / plt.ylabel('...')</code>	etichette degli assi
<code>plt.title('...')</code>	titolo
<code>plt.show()</code>	mostra il grafico

density=True è ciò che rende possibile il confronto

Senza `density=True`, l'istogramma ha sull'asse y il *numero* di osservazioni in ogni classe, che dipende da N . Con `density=True` l'asse y diventa una **densità**: l'area totale delle barre vale 1, esattamente come l'area sotto una densità teorica.

Solo con `density=True` si possono sovrapporre sullo stesso grafico l'istogramma dei dati simulati e la curva $f(x)$ della teoria: le due cose sono nella stessa unità di misura. **Nel confronto teoria-simulazione `density=True` non è un'opzione, è la condizione per cui il grafico ha senso.**

```
x = np.random.exponential(scale=2.0, size=5000)
xs = np.linspace(0, 15, 300)

plt.hist(x, bins=40, density=True, alpha=0.6,
         label='simulazione', edgecolor='white')
plt.plot(xs, stats.expon(scale=2.0).pdf(xs), 'r-', lw=2, label='teoria Exp(0.5)')
plt.xlabel('valore'); plt.ylabel('densita')
plt.legend(); plt.show()
```

Se la curva rossa segue il profilo delle barre, la simulazione è corretta.

11.5 Un modello completo da cui partire

Questo è lo scheletro di qualunque quesito di Laboratorio. Vale la pena impararlo a memoria e adattarlo.

```
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt

# ---- 1. parametri del problema -----
n = 10          # dimensione di un singolo esperimento
p = 0.5        # probabilita' di successo
N = 10000      # numero di simulazioni

# ---- 2. valore teorico -----
teorico = stats.binom.mean(n, p)
print("valore teorico :", teorico)
```

```
# ---- 3. simulazione -----
sim = np.random.binomial(n, p, size=N)
stimato = sim.mean()
print("valore simulato:", stimato)

# ---- 4. errore standard e confronto -----
se = sim.std(ddof=1) / np.sqrt(N)
print("errore standard:", se)
print("scarto in unita' di se:", (stimato - teorico) / se)

# ---- 5. grafico -----
plt.hist(sim, bins=np.arange(-0.5, n+1.5), density=True,
         alpha=0.6, edgecolor='white', label='simulazione')
ks = np.arange(0, n+1)
plt.plot(ks, stats.binom.pmf(ks, n, p), 'ro-', lw=2, label='teoria')
plt.xlabel('numero di successi'); plt.ylabel('probabilita')
plt.legend(); plt.show()
```

I tre controlli da fare sempre prima di ricopiare

1. **La probabilità sta in $[0, 1]$?** Se no, hai diviso per il numero sbagliato (probabilmente il numero di oggetti invece del numero di simulazioni).
2. **Il valore simulato dista dal teorico meno di 3 errori standard?** Se no, o la simulazione è sbagliata o la formula teorica lo è. Con N grande uno scarto oltre 3σ è quasi sempre un errore, non sfortuna.
3. **Il grafico ha le due curve sovrapposte?** Se l'istogramma è spostato rispetto alla curva teorica, il parametro della simulazione è diverso da quello della formula.

Sono trenta secondi di verifica che salvano un'intera risposta.

Capitolo 12

Probabilità e simulazione in Python

Questo è il tipo di quesito più frequente in Laboratorio: comparire in **6 prove su 9** (28/01/25, 27/01/26, 17/02/26, 01/04/26, 23/06/26 e, in forma ridotta, 24/03/25). Lo schema è sempre lo stesso: *calcolare* una probabilità con la teoria e poi *verificarla* simulando.

12.1 Il trucco che risolve metà dei quesiti

In `numpy` un confronto su un array restituisce un array di `True` e `False`. La media di un array booleano è la **frequenza relativa** dei `True`, cioè la probabilità empirica:

```
1 import numpy as np
2
3 N = 1_000_000
4 dadi = np.random.randint(1, 7, size=N)      # N lanci di un dado a 6 facce
5
6 print("P(esce 6)      =", np.mean(dadi == 6))
7 print("P(esce pari)   =", np.mean(dadi % 2 == 0))
8 print("P(esce 5 o 6)  =", np.mean((dadi == 5) | (dadi == 6)))
```

`np.mean` di un booleano è una frequenza, non una media

Nella legge frequentista la probabilità è $p = k/n$: il numero di casi favorevoli diviso il numero di prove. `np.mean(condizione)` calcola esattamente k/n , dove i casi favorevoli sono contati automaticamente dal confronto. Le tre operazioni logiche si scrivono:

- **unione** (“almeno uno”): `(a) | (b)`
- **intersezione** (“entrambi”): `(a) & (b)`
- **negazione** (“non”): `~(a)`

Tre trappole che costano punti

1. **Mai `and/or/not` di Python su un array**: danno errore o un risultato sbagliato. Servono `&`, `|`, `~`, con le parentesi attorno a ogni confronto.
2. Il confronto è `==` (doppio uguale), non `=`.
3. `np.random.randint(a, b)` esclude `b`: per un dado serve `randint(1, 7)`, non `randint(1, 6)`.

12.2 L'errore standard: quanto bene ho stimato

La simulazione dà sempre una stima, mai il valore esatto. Quanto è affidabile? Per una frequenza su N prove indipendenti, lo stimatore $\hat{p}$ ha

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{N}, \quad \text{quindi} \quad \text{errore standard} = \sqrt{\frac{p(1-p)}{N}}.$$

Questo è il numero che rende “scientifica” la simulazione, e va scritto quando il quesito chiede di confrontare il risultato simulato con quello teorico.

```

1 import numpy as np
2
3 teorico, N = 0.5, 200
4 print(f"errore standard = sqrt(p(1-p)/N) = {np.sqrt(teorico*(1-teorico)/N):.4f}")
5
6 # la regola pratica: con N si riduce l'errore di sqrt(N)
7 for n in [200, 2000, 20000]:
8     print(f" N = {n:>6}: errore standard = {np.sqrt(0.25/n):.4f}")

```

Quando la simulazione “sbaglia”, ha ragione la teoria

Se la stima simulata dista dal valore teorico *meno di due o tre errori standard*, la differenza è pura fluttuazione casuale e la simulazione **conferma** la teoria. Se dista molto di più, allora c'è un errore nel codice o nella formula. È il criterio con cui si risponde a “come cambia il risultato?” quando si aumenta N : la stima si *avvicina* al teorico, e l'errore standard si riduce come $1/\sqrt{N}$ (per migliorare di dieci volte serve cento volte il numero di prove).

12.3 Esercizi svolti

Esercizio 1 — Dieci monete, e l'effetto di N (28/01/25 — Quesito 2)

- Scrivere un programma che simuli $N = 200$ volte il lancio simultaneo di 10 monete equilibrate.
- Stimare dai dati raccolti la probabilità di ottenere 0, 1, 2, ..., 10 volte testa.
- Confrontare in un grafico questo risultato con quello teorico.
- Ripetere la simulazione facendo $N = 2000$ prove. Come cambia il risultato?

Svolgimento. Il modello teorico. Il numero di teste in 10 lanci indipendenti con $p = 1/2$ è una binomiale $X \sim \text{Bin}(10, \frac{1}{2})$, con

$$p(k) = \binom{10}{k} \left(\frac{1}{2}\right)^{10}, \quad \mathbb{E}[X] = np = 5, \quad \text{Var}(X) = np(1-p) = 2.5.$$

(a–c) La simulazione e il confronto.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy import stats
4
5 np.random.seed(42) # per rendere l'output riproducibile
6
7 n_monete, N = 10, 200
8 teste = np.random.binomial(n_monete, 0.5, size=N)
9
10 k = np.arange(0, n_monete + 1)
11 empiriche = np.array([np.mean(teste == i) for i in k]) # frequenze relative
12 teoriche = stats.binom.pmf(k, n_monete, 0.5) # densita' binomiale
13
14 print("testa empirica teorica")
15 for i in k:
16     print(f"{i:5d} {empiriche[i]:8.4f} {teoriche[i]:7.4f}")
17
18 larghezza = 0.38
19 plt.bar(k - larghezza/2, empiriche, larghezza, label='simulazione (N=200)')
20 plt.bar(k + larghezza/2, teoriche, larghezza, label='teoria')
21 plt.xlabel('numero di teste su 10 lanci'); plt.ylabel('probabilita')
22 plt.xticks(k); plt.legend(); plt.grid(alpha=0.3, axis='y'); plt.show()

```

Output (una realizzazione con seed = 42):

testa	empirica	teorica
0	0.0000	0.0010
1	0.0050	0.0098
2	0.0450	0.0439
3	0.1350	0.1172
4	0.1750	0.2051
5	0.2800	0.2461
6	0.2000	0.2051
7	0.1100	0.1172
8	0.0450	0.0439
9	0.0050	0.0098
10	0.0000	0.0010

Le code sono vuote: non è un errore del codice

Con $N = 200$ la probabilità teorica di 0 teste è 0.001, quindi ci si aspetta $200 \times 0.001 = 0.2$ casi: **zero osservazioni è il risultato più probabile**. Lo stesso vale per 10 teste. Se l'output mostra 0.0000 in corrispondenza di $k = 0$ e $k = 10$ *non* si deve concludere che il programma sia sbagliato: va detto che con $N = 200$ quegli esiti sono troppo rari per essere osservati. È esattamente l'aggancio al punto (d).

(d) Con $N = 2000$.

```

1 N2 = 2000
2 teste2 = np.random.binomial(n_monete, 0.5, size=N2)
3 emp2 = np.array([np.mean(teste2 == i) for i in k])
4
5 print("testa  N=200  N=2000  teorica")
6 for i in k:
7     print(f"{i:5d}  {empiriche[i]:7.4f}  {emp2[i]:7.4f}  {teoriche[i]:7.4f}")
8
9 err200 = np.abs(empiriche - teoriche).sum()
10 err2000 = np.abs(emp2 - teoriche).sum()
11 print(f"\nscarto totale  N=200 : {err200:.4f}")
12 print(f"scarto totale  N=2000: {err2000:.4f}")

```

Output:

testa	N=200	N=2000	teorica
0	0.0000	0.0020	0.0010
1	0.0050	0.0085	0.0098
2	0.0450	0.0465	0.0439
3	0.1350	0.1195	0.1172
4	0.1750	0.2070	0.2051
5	0.2800	0.2345	0.2461
6	0.2000	0.1960	0.2051
7	0.1100	0.1180	0.1172
8	0.0450	0.0575	0.0439
9	0.0050	0.0095	0.0098
10	0.0000	0.0010	0.0010

scarto totale N=200 : 0.0720
scarto totale N=2000: 0.0336

Commento — è questo che il punto (d) vuole leggere. Con $N = 2000$ il risultato si avvicina al teorico e **compaiono le code**: $k = 10$ passa da 0.0000 a 0.0010 (il valore teorico esatto). L'oscillazione della stima attorno al valore vero si riduce, coerentemente con l'errore standard $\sqrt{p(1-p)/N}$: moltiplicando N per 10, l'errore si riduce di $\sqrt{10} \approx 3.2$ volte. Non si annulla: la simulazione resta una stima.

La frase da scrivere

“Aumentando N le frequenze empiriche convergono alle probabilità teoriche: è la legge dei grandi numeri (capitolo 5). Con $N = 200$ gli esiti con probabilità dell'ordine di 10^{-3} non vengono osservati, con $N = 2000$ sì. Lo scarto si riduce come $1/\sqrt{N}$, quindi per dimezzarlo servono quattro volte le prove.”

Esercizio 2 — Le carte Magic: ipergeometrica, non binomiale (27/01/26 — Quesito 1)

In un mazzo di Magic ci sono 60 carte, di cui 26 sono *Terre*. Si pescano 7 carte. Una mano si dice **buona** se contiene 3 *oppure* 4 Terre. Simulare $N = 350$ mani e stimare la probabilità che una mano **non** sia buona.

Svolgimento. Quale distribuzione, e perché. Qui il campione si estrae **senza reinserimento**: una volta pescata, una carta non torna nel mazzo, e quindi le estrazioni *non* sono indipendenti. La distribuzione corretta è quindi la **ipergeometrica** (capitolo 4), non la binomiale:

$$\mathbb{P}(X = x) = \frac{\binom{26}{x} \binom{34}{7-x}}{\binom{60}{7}}.$$

Il parametro 26 è il numero di Terre, $34 = 60 - 26$ è il numero di “non Terre”, 7 è la dimensione del campione.

Il calcolo teorico.

```
1 import numpy as np
2 from scipy import stats
3
4 N_CARTE, N_TERRE, PESCALE = 60, 26, 7
5
6 P3 = stats.hypergeom.pmf(3, N_CARTE, N_TERRE, PESCALE)
7 P4 = stats.hypergeom.pmf(4, N_CARTE, N_TERRE, PESCALE)
8 P_buona = P3 + P4
9 P_non_buona = 1 - P_buona
10
11 print(f"P(3 Terre) = {P3:.6f}")
12 print(f"P(4 Terre) = {P4:.6f}")
13 print(f"P(buona) = P(3) + P(4) = {P_buona:.6f}")
14 print(f"P(NON buona) = {P_non_buona:.6f}")
15 print(f"E[Terre] = 7 * 26/60 = {7*N_TERRE/N_CARTE:.4f}")
```

Output:

```
P(3 Terre) = 0.312210
P(4 Terre) = 0.231640
P(buona) = P(3) + P(4) = 0.543849
P(NON buona) = 0.456151
E[Terre] = 7 * 26/60 = 3.0333
```

La simulazione con $N = 350$.

```
1 np.random.seed(7)
2 N = 350
3 mani = np.random.hypergeometric(N_TERRE, N_CARTE - N_TERRE, PESCALE, size=N)
4
5 buona_sim = np.mean((mani == 3) | (mani == 4))
6 non_buona_sim = np.mean(~((mani == 3) | (mani == 4))) # oppure 1 - buona_sim
7
```

```

8 print(f"P(buona)      simulata = {buona_sim:.4f}   (teorica {P_buona:.4f})")
9 print(f"P(NON buona) simulata = {non_buona_sim:.4f} (teorica {P_non_buona:.4f})")
10
11 es = np.sqrt(P_non_buona*(1-P_non_buona)/N)
12 print(f"errore standard = {es:.4f}  -> 2*es = {2*es:.4f}")

```

Output:

```

P(buona)      simulata = 0.5543   (teorica 0.5438)
P(NON buona) simulata = 0.4457   (teorica 0.4562)
errore standard = 0.0266  -> 2*es = 0.0533

```

Commento. La stima simulata 0.4457 dista dal valore teorico 0.4562 di 0.0105, che è *meno di un errore standard* (0.0266): la simulazione conferma il calcolo teorico e la differenza è pura fluttuazione campionaria.

L'errore da non fare: usare la binomiale

Con l'ipergeometrica la probabilità di una mano buona è 0.5438; con una binomiale $\text{Bin}(7, 26/60)$ sarebbe $\mathbb{P}(3) + \mathbb{P}(4) = 0.5182$. La differenza è di 0.0256, ma la scelta della distribuzione è **esattamente ciò che il quesito vuole vedere**. Il discriminante è la presenza o l'assenza del reinserimento:

- **senza** reinserimento (carte da un mazzo, palline da un'urna senza rimetterle, persone da una lista) $\Rightarrow$ **ipergeometrica**;
- **con** reinserimento (lanci di moneta, estrazioni con rimpiazzo) $\Rightarrow$ **binomiale**.

`np.random.hypergeometric(ngood, nbad, nsample, size)` prende il numero di “buoni”, il numero di “cattivi” e quanti se ne pescano.

Esercizio 3 — Tre linee di produzione: probabilità totali e Bayes (17/02/26 — Quesito 1)

In una fabbrica ci sono tre linee di produzione L_1 , L_2 e L_3 che realizzano lo stesso prodotto, con probabilità di ottenere un pezzo difettoso rispettivamente dell'1%, 2% e 0.5%. Le tre linee producono rispettivamente il 30%, 50% e 20% della produzione totale.

- Calcolare la probabilità che dalla fabbrica esca un prodotto difettoso.
- Calcolare la probabilità che un prodotto difettoso scelto a caso provenga dalla linea L_2 .
- Interpretando anche le percentuali di produzione come probabilità, simulare la produzione di 10000 pezzi e confrontare la percentuale di pezzi difettosi prodotti con quanto calcolato al punto (a).
- La simulazione precedente si può realizzare semplicemente contando i pezzi difettosi prodotti: provare a effettuare anche una simulazione che permetta di verificare la probabilità richiesta nel punto (b).

Svolgimento. (a) **Teorema delle probabilità totali.** Le tre linee partizionano lo spazio degli eventi ($\bigcup_i L_i = \Omega$, a due a due incompatibili), quindi si applica direttamente il teorema delle probabilità totali del capitolo 3:

$$\mathbb{P}(D) = \sum_{i=1}^3 \mathbb{P}(D | L_i) \mathbb{P}(L_i) = 0.01 \cdot 0.30 + 0.02 \cdot 0.50 + 0.005 \cdot 0.20.$$

(b) Teorema di Bayes.

$$\mathbb{P}(L_2 | D) = \frac{\mathbb{P}(D | L_2) \mathbb{P}(L_2)}{\mathbb{P}(D)} = \frac{0.02 \cdot 0.50}{\mathbb{P}(D)}.$$

```

1 import numpy as np
2 from scipy import stats
3
4 p_L = np.array([0.30, 0.50, 0.20])      # quota di produzione delle 3 linee
5 p_dif = np.array([0.01, 0.02, 0.005])   # difettosità di ciascuna linea
6
7 P_D = np.sum(p_dif * p_L)               # teorema delle probabilità totali
8 print("a) P(difettoso) = 0.01*0.30 + 0.02*0.50 + 0.005*0.20")
9 print(f"    = {p_dif[0]*p_L[0]:.4f} + {p_dif[1]*p_L[1]:.4f} + {p_dif[2]*p_L[2]:.4f}")
10 print(f"    = {P_D:.4f}    ({P_D*100:.2f}%)")
11
12 P_L2_D = p_dif[1]*p_L[1] / P_D         # Bayes
13 print(f"\nb) P(L2 | difettoso) = 0.02*0.50 / {P_D:.4f} = {P_L2_D:.6f}")
14 print(f"    ({P_L2_D*100:.2f}%)")

```

Output:

```

a) P(difettoso) = 0.01*0.30 + 0.02*0.50 + 0.005*0.20
   = 0.0030 + 0.0100 + 0.0010
   = 0.0140    (1.40%)

b) P(L2 | difettoso) = 0.02*0.50 / 0.0140 = 0.714286
   (71.43%)

```

(c) **La simulazione “contando i difettosi”.** Si estrae per ogni pezzo la linea con probabilità (0.30, 0.50, 0.20), poi si estrae l’esito con la difettosità di quella linea.

```

1 np.random.seed(11)
2 N = 10000
3
4 linea = np.random.choice([1, 2, 3], size=N, p=p_L)      # quale linea produce
5 pd = np.where(linea == 1, 0.01,
6               np.where(linea == 2, 0.02, 0.005))         # la sua difettosità
7 difettoso = np.random.random(N) < pd                     # esito di ogni pezzo
8
9 print(f"c) pezzi difettosi = {difettoso.sum()} / {N} = {difettoso.mean():.4f}")
10 print(f"    (teorico {P_D:.4f}, differenza {abs(difettoso.mean()-P_D):.4f})")

```

Output:

```

c) pezzi difettosi = 133 / 10000 = 0.0133
   (teorico 0.0140, differenza 0.0007)

```

(d) **La simulazione condizionata: verificare Bayes.** Il punto (b) chiede una probabilità *condizionata*. La si stima **filtrando**: fra i pezzi difettosi, quanti provengono dalla linea 2?

```

1 # fra i soli pezzi difettosi, che quota viene dalla linea 2?
2 P_L2_D_sim = np.mean(linea[difettoso] == 2)
3
4 print(f"d) P(L2 | difettoso) simulata = {P_L2_D_sim:.4f} (teorica {P_L2_D:.4f})")
5 print(f"    pezzi difettosi disponibili = {difettoso.sum()}")
6 es = np.sqrt(P_L2_D*(1-P_L2_D)/difettoso.sum())
7 print(f"    errore standard = {es:.4f} -> 2*es = {2*es:.4f}")

```

Output:

```

d) P(L2 | difettoso) simulata = 0.6842 (teorica 0.7143)
   pezzi difettosi disponibili = 133
   errore standard = 0.0392 -> 2*es = 0.0784

```

Perché il punto (b) viene “peggio” del punto (a)

0.6842 contro 0.7143 è uno scarto di 0.030, e a prima vista sembra un errore. Non lo è: la stima è costruita su **133 soli** pezzi difettosi, non su 10000. L'errore standard è $\sqrt{p(1-p)/133} = 0.039$, e lo scarto osservato vale meno di un errore standard. **Il numero di osservazioni utili qui è il numero di difettosi**, non il numero di pezzi prodotti. Questa è la spiegazione da dare quando si commenta il confronto: è il punto concettuale del quesito.

Capitolo 13

Confrontare teoria e simulazione

È la richiesta più frequente del Laboratorio: **8 quesiti su 18** chiedono esplicitamente di confrontare dei dati simulati con la distribuzione teorica prevista. Altri due chiedono comunque gli istogrammi dei dati raccolti. Imparare questo capitolo significa coprire quasi metà del Laboratorio.

Chiesto in: 28/01/25 Q2 (monete); 24/03/25 Q2 (integrale di una gaussiana); 17/06/25 Q1 (gioco dell'oca) e Q2 (vie); 02/09/25 Q2 (funzione bimodale); 27/01/26 Q1 (carte Magic); 17/02/26 Q1 (tre linee); 01/04/26 Q1 (ovetti); 29/04/26 Q1 (coda esponenziale); 23/06/26 Q1 (carta d'identità).

13.1 La ricetta in tre passi

Come si risponde a “simulare e confrontare con la teoria”

1. **Dire la distribuzione teorica e i suoi parametri** *prima* di simulare. “Il numero di teste in 10 lanci indipendenti è $\text{Bin}(10, \frac{1}{2})$: media 5, varianza 2.5.” Questa frase va scritta nel compito, non solo pensata.
2. **Simulare** con `numpy` e calcolare le grandezze empiriche (`mean`, `std`, frequenze relative).
3. **Confrontare** graficamente (sovrapposizione) e numericamente (scarto assoluto, errore standard). Il commento finale deve dire se lo scarto è **compatibile con il rumore campionario**, non se è zero.

Il metro del confronto

Due numeri non saranno *mai* identici. La domanda giusta non è “sono uguali?”, ma “**lo scarto è piccolo rispetto all'errore standard?**”. Per una frequenza relativa $\hat{p}$ su N osservazioni l'errore standard è

$$\text{ES}(\hat{p}) = \sqrt{\frac{p(1-p)}{N}},$$

e lo scarto osservato si misura *in unità di ES*. Se $|\hat{p} - p| \lesssim 2 \text{ES}$ la simulazione conferma la teoria; se $|\hat{p} - p| > 3 \text{ES}$ c'è qualcosa da capire (parametro sbagliato, dipendenza fra le osservazioni, distribuzione sbagliata).

13.2 Caso continuo: istogramma sovrapposto alla densità

```
1 import numpy as np
2 import scipy.stats as stats
3 import matplotlib.pyplot as plt
4
5 lam = 5.0 # tasso dell'esponenziale
6 N = 1000
7 rng = np.random.default_rng(11)
8 x = rng.exponential(1/lam, size=N) # ATTENZIONE: numpy vuole la MEDIA
9
10 xs = np.linspace(0, x.max(), 400)
11 plt.hist(x, bins=40, density=True, alpha=0.6,
12         color='steelblue', edgecolor='white', label='simulazione')
13 plt.plot(xs, stats.expon(scale=1/lam).pdf(xs),
```

```

14         'r-', lw=2, label=f'teoria Exp({lam:g})')
15 plt.xlabel('tempo di attesa (s)'); plt.ylabel('densita')
16 plt.title('Confronto simulazione / teoria'); plt.legend()
17 plt.tight_layout(); plt.show()

```

Le tre condizioni perché il grafico abbia senso

1. `density=True`: senza, l'asse y conta le osservazioni e la curva teorica non è confrontabile (Cap. 11).
2. `scale` della distribuzione teorica **uguale** al parametro usato nella simulazione. `np.random.exponential` e `stats.expon` ragionano entrambi in termini di *media*, non di tasso: con $\lambda = 5$ si scrive `scale=1/5`, **non** `scale=5` e **non** `scale=1/lam` con `lam` interpretato come tasso se si usa `expon`.
3. `bins` fra 30 e 50: con pochi intervalli la forma non si vede, con troppi domina il rumore.

13.3 Caso discreto: barre affiancate

Per le distribuzioni discrete **non si usa l'istogramma** ma un diagramma a barre, perché i valori sono separati. Il modo più leggibile di confrontare due distribuzioni discrete è **affiancare le barre** sfalsandole di ± 0.2 con larghezza 0.4:

```

1 import numpy as np
2 import scipy.stats as stats
3 import matplotlib.pyplot as plt
4
5 n, N = 10, 2000
6 rng = np.random.default_rng(158)
7 sim = rng.binomial(n, 0.5, size=N)
8
9 ks = np.arange(0, n + 1)
10 freq = np.array([(sim == k).mean() for k in ks]) # frequenze relative
11
12 plt.bar(ks - 0.2, freq, width=0.4,
13         label='simulazione', color='steelblue')
14 plt.bar(ks + 0.2, stats.binom.pmf(ks, n, 0.5), width=0.4,
15         label='teoria Bin(10, 0.5)', color='indianred')
16 plt.xlabel('numero di teste'); plt.ylabel('probabilita')
17 plt.legend(); plt.tight_layout(); plt.show()

```

13.4 Quanto deve essere piccolo lo scarto: la legge $1/\sqrt{N}$

È il punto concettualmente più importante del capitolo, e la prova del 28/01/25 lo mette in scena: lo stesso esperimento con $N = 200$ e con $N = 2000$. Lo scarto assoluto totale $\sum_k |\hat{p}_k - p_k|$ **non** tende a zero “perché la simulazione è giusta”, ma **perché l'errore standard decresce come $1/\sqrt{N}$** .

```

1 import numpy as np
2 from scipy import stats
3
4 teo = stats.binom.pmf(np.arange(11), 10, 0.5)
5
6 def scarto_totale(N, seme):
7     rng = np.random.default_rng(seme)
8     sim = rng.binomial(10, 0.5, size=N)

```

```

9     freq = np.array([(sim == k).mean() for k in range(11)])
10    return np.abs(freq - teo).sum()
11
12    for N in (200, 2000):
13        print(f"N = {N:>5}: scarto assoluto totale = {scarto_totale(N, 158):.4f}")
14
15    # il valore ATTESO dello scarto, su molte repliche: e' questo che va come 1/sqrt(N)
16    rng, medie = np.random.default_rng(2024), {}
17    for N in (200, 2000, 20000):
18        errs = []
19        for _ in range(200):
20            sim = rng.binomial(10, 0.5, size=N)
21            freq = np.array([(sim == k).mean() for k in range(11)])
22            errs.append(np.abs(freq - teo).sum())
23        medie[N] = np.mean(errs)
24        print(f"N = {N:>5}: scarto medio su 200 repliche = {medie[N]:.4f}")
25
26    print(f"rapporto 200/2000    = {medie[200]/medie[2000]:.2f}    "
27          f"(atteso sqrt(10) = {np.sqrt(10):.2f})")
28    print(f"rapporto 2000/20000 = {medie[2000]/medie[20000]:.2f}    "
29          f"(atteso sqrt(10) = {np.sqrt(10):.2f})")

```

Output:

```

N = 200: scarto assoluto totale = 0.1457
N = 2000: scarto assoluto totale = 0.0534
N = 200: scarto medio su 200 repliche = 0.1423
N = 2000: scarto medio su 200 repliche = 0.0464
N = 20000: scarto medio su 200 repliche = 0.0142
rapporto 200/2000    = 3.07    (atteso sqrt(10) = 3.16)
rapporto 2000/20000 = 3.26    (atteso sqrt(10) = 3.16)

```

Il commento da scrivere nel compito

Passando da $N = 200$ a $N = 2000$ (dieci volte i dati) lo scarto **non** si divide per dieci: si divide per $\sqrt{10} \approx 3.16$. I rapporti misurati (3.07 e 3.26) confermano la legge $1/\sqrt{N}$. È la stessa legge che regge l'intervallo di confidenza (Cap. 16): **per dimezzare l'errore servono quattro volte i dati**.

Il singolo scarto osservato (0.1457 con $N = 200$) è solo *una* realizzazione: il valore atteso è 0.1423 con deviazione standard ≈ 0.042 , quindi una singola prova può dare qualunque valore fra 0.06 e 0.23. Confrontare due simulazioni singole non dimostra nulla; è il valore *medio* su molte repliche che segue la legge.

13.5 Il Q-Q plot

È lo strumento citato esplicitamente nel quesito 29/04/26 (punto d), dove il testo nomina la funzione `probplot`.

Q-Q plot

Il **Q-Q plot** (quantile-quantile) mette in ascissa i **quantili teorici** $q_i = F^{-1}(\frac{i}{n+1})$ e in ordinata i **quantili osservati** (i dati ordinati $x_{(i)}$). Se i dati seguono la distribuzione teorica, i punti si dispongono su una **retta**. Scostamenti sistematici indicano *dove* il modello non regge: una curvatura alle estremità significa code più pesanti o più leggere del previsto.

```

1 import numpy as np
2 import scipy.stats as stats

```

```

3 import matplotlib.pyplot as plt
4
5 lam = 5.0
6 x = np.random.default_rng(11).exponential(1/lam, size=1000)
7
8 # (A) passo i parametri: la retta di riferimento ha pendenza 1
9 stats.probplot(x, dist=stats.expon, sparams=(0, 1/lam), plot=plt)
10 plt.title('Q-Q plot: dati vs Exp(5)')
11 plt.tight_layout(); plt.show()

```

Come si legge la pendenza della retta

Il comportamento cambia a seconda di cosa si passa a `sparams`, e confondersi qui è l'errore più comune:

- **parametri passati** (`sparams=(0, 1/lam)`): i quantili teorici sono già quelli di `Exp(5)`, quindi se i dati seguono `Exp(5)` i punti stanno sulla **bisettrice**: pendenza attesa ≈ 1 , intercetta ≈ 0 . Misurato: pendenza 1.0086, intercetta -0.0046 , $r = 0.9993$. Il modello è adeguato.
- **parametri non passati** (`dist="expon"`, cioè `Exp(1)`): la retta ha pendenza pari al parametro di scala incognito. Misurato: pendenza 0.2017 contro $1/\lambda = 0.2$ atteso. Anche questo conferma il modello, e in più *stima* $\hat{\lambda} = 1/0.2017 = 4.96$.

Le due letture sono equivalenti; la seconda è quella da usare quando il quesito dice “verificare se i dati seguono una esponenziale” *senza* dire con quale parametro.

Tre errori che si vedono nei compiti

- **Usare `probplot` e non commentare.** Il quesito chiede esplicitamente di commentare: *“i punti sono allineati sulla retta, quindi la distribuzione esponenziale è adeguata; si nota un lieve scostamento nelle code dovuto ai valori estremi campionari”*.
- **Confondere `scale` con λ :** `stats.expon(scale=5)` è `Exp(0.2)`, non `Exp(5)`.
- **Usare `probplot` con `dist="norm"` per dati esponenziali:** i punti si inarcano in modo evidente e sembra che “la simulazione sia sbagliata”. Non lo è: è sbagliata la distribuzione di riferimento.

13.6 Confrontare i momenti, non solo il grafico

Molti quesiti chiedono di *commentare se i dati rispecchiano la teoria*: la risposta più solida confronta media, varianza, asimmetria e curtosi.

```

1 import numpy as np
2 from scipy import stats
3
4 sim = np.random.default_rng(4).binomial(10, 0.5, size=100000)
5
6 print(f"{'grandezza':<12}{ 'teoria':>10}{ 'simulato':>12}")
7 print(f"{'media':<12}{10*0.5:>10.4f}{sim.mean():>12.4f}")
8 print(f"{'varianza':<12}{10*0.25:>10.4f}{sim.var():>12.4f}")
9 print(f"{'asimmetria':<12}{stats.binom.stats(10,0.5,moments='s'):>10.4f}"
10       f"{'stats.skew(sim):>12.4f}")
11 print(f"{'curtosi':<12}{stats.binom.stats(10,0.5,moments='k'):>10.4f}"
12       f"{'stats.kurtosis(sim):>12.4f}")

```

Asimmetria e curtosi: le definizioni degli appunti

$$\text{asimmetria } \gamma_1 = \frac{\mu_3}{\mu_2^{3/2}}, \quad \text{curtosi } \beta_2 = \frac{\mu_4}{\mu_2^2}, \quad \text{coefficiente } \gamma = \beta_2 - 3.$$

con $\mu_k = \mathbb{E}[(X - \mu)^k]$ i momenti centrati. Si legge così:

- $\gamma_1 > 0$: coda **a destra** (asimmetria positiva); $\gamma_1 < 0$: coda a sinistra;
- $\beta_2 > 3$, cioè $\gamma > 0$: code più pesanti e picco più alto della normale (*leptocurtica*);
- $\beta_2 < 3$, cioè $\gamma < 0$: code più leggere (*platicurtica*).

In Python: `scipy.stats.skew(x)` e `scipy.stats.kurtosis(x)`. Attenzione: `kurtosis` restituisce già $\beta_2 - 3$, cioè il *coefficiente* γ , mentre gli appunti chiamano β_2 la curtosi grezza. Se nel compito chiede “la curtosi” e vi serve β_2 , sommate 3.

ddof: l'errore di una riga che costa un punto

`np.var(x)` divide per N (varianza **empirica**, $\bar{\sigma}_n^2$ negli appunti), mentre `np.var(x, ddof=1)` divide per $N - 1$ (varianza **campionaria**, $\bar{S}_n^2$). Per confrontare con la varianza *teorica* di una distribuzione va bene `np.std` senza correzione quando N è grande; per *stimare* il parametro di una popolazione serve `ddof=1`.

Regola pratica: **per descrivere** i dati simulati si divide per N ; **per stimare** si divide per $N - 1$. Le due cose differiscono di un fattore trascurabile quando $N = 100\,000$, ma il correttore guarda la formula, non il numero.

13.7 Esercizi svolti**Esercizio 1 — Coda esponenziale di un processo di Poisson** (29/04/26 — Quesito 1)

Un server web riceve richieste secondo un processo di Poisson con tasso $\lambda = 5$ richieste/secondo. Si può dimostrare che i tempi di attesa tra richieste successive seguono allora una distribuzione esponenziale dello stesso parametro λ .

- Scrivere la formula della densità di probabilità e della funzione di ripartizione associate a questa distribuzione esponenziale.
- Calcolare la probabilità che il tempo di attesa tra due richieste sia superiore a 0.4 secondi e la probabilità che sia compreso tra 0.05 e 0.2 secondi.
- Simulare $N = 1000$ tempi di attesa con questa distribuzione. Visualizzare in un istogramma i tempi di attesa osservati e la distribuzione teorica.
- Confrontare la distribuzione teorica e quella osservata tramite un Q-Q plot (attraverso la funzione Python `probplot`).

Svolgimento. (a) **Densità e ripartizione.** Con $\lambda = 5$:

$$f(x) = 5e^{-5x} \mathbf{1}_{x \geq 0}, \quad F(x) = 1 - e^{-5x} \mathbf{1}_{x \geq 0}.$$

(b) **Le due probabilità.** Si usa $1 - F(x) = e^{-\lambda x}$:

$$\mathbb{P}(X > 0.4) = e^{-5 \cdot 0.4} = e^{-2} = 0.135335,$$

$$\mathbb{P}(0.05 < X < 0.2) = F(0.2) - F(0.05) = e^{-5 \cdot 0.05} - e^{-5 \cdot 0.2} = e^{-0.25} - e^{-1} = 0.410921.$$

```
1 import numpy as np
2 from scipy import stats
3
```

```

4 lam = 5.0
5 print(f"P(X > 0.4)          = {np.exp(-lam*0.4):.6f}")
6 print(f"P(0.05 < X < 0.2) = {np.exp(-lam*0.05) - np.exp(-lam*0.2):.6f}")

```

Output:

```

P(X > 0.4)          = 0.135335
P(0.05 < X < 0.2) = 0.410921

```

(c-d) Simulazione e Q-Q plot.

```

1 import numpy as np
2 from scipy import stats
3 import matplotlib.pyplot as plt
4
5 lam, N = 5.0, 1000
6 x = np.random.default_rng(11).exponential(1/lam, size=N)
7
8 print(f"media simulata = {x.mean():.4f}   (teorica 1/lambda = {1/lam:.4f})")
9 print(f"scarto simulato = {x.std(ddof=1):.4f}   (teorico 1/lambda = {1/lam:.4f})")
10 print(f"P(X>0.4)      : sim = {(x > 0.4).mean():.4f}   teo = {np.exp(-lam*0.4):.6f}")
11 print(f"P(0.05<X<0.2) : sim = {(x>0.05)&(x<0.2).mean():.4f}   "
12       f"teo = {np.exp(-lam*0.05)-np.exp(-lam*0.2):.6f}")
13
14 fig, assi = plt.subplots(1, 2, figsize=(11, 4))
15 xs = np.linspace(0, x.max(), 300)
16 assi[0].hist(x, bins=40, density=True, alpha=0.6, edgecolor='white')
17 assi[0].plot(xs, stats.expon(scale=1/lam).pdf(xs), 'r-', lw=2)
18 assi[0].set_xlabel('tempo di attesa (s)'); assi[0].set_ylabel('densita')
19 assi[0].set_title('Istogramma vs densita teorica')
20
21 _, (pend, interc, r) = stats.probplot(x, dist=stats.expon,
22                                     sparams=(0, 1/lam), plot=assi[1])
23 assi[1].set_title('Q-Q plot')
24 plt.tight_layout(); plt.show()
25
26 print(f"Q-Q: pendenza = {pend:.4f} (attesa 1), intercetta = {interc:.4f}, r = {r:.4f}")

```

Output:

```

media simulata = 0.1968   (teorica 1/lambda = 0.2000)
scarto simulato = 0.2004   (teorico 1/lambda = 0.2000)
P(X>0.4)      : sim = 0.1310   teo = 0.135335
P(0.05<X<0.2) : sim = 0.4100   teo = 0.410921
Q-Q: pendenza = 1.0086 (attesa 1), intercetta = -0.0046, r = 0.9993

```

Il commento (la parte che vale i punti).

- **Media e scarto** simulati (0.1968 e 0.2004) coincidono con i valori teorici $1/\lambda = 0.2$. L'errore standard della media è $\sigma/\sqrt{N} = 0.2/\sqrt{1000} = 0.0063$: lo scarto osservato 0.0032 è meno di *mezzo* ES, quindi perfettamente compatibile.
- **Le due probabilità**: $\hat{p} = 0.1310$ contro $p = 0.1353$, con $ES = \sqrt{0.1353 \cdot 0.8647/1000} = 0.0108$. Lo scarto vale 0.0043, cioè 0.40 ES. E $\hat{p} = 0.4100$ contro $p = 0.4109$: scarto 0.0009, appena 0.06 ES. Entrambe le stime sono ottime.
- **Il Q-Q plot** mostra i punti allineati con pendenza 1.0086 (attesa 1) e $r = 0.9993$: il modello esponenziale è **adeguato**. Si nota solo un lieve scostamento alle estremità, tipico dei valori estremi campionari.

Il “scarto piccolo” non si giudica a occhio

Dire “i valori sono vicini” non è una risposta. Il confronto va **quantificato**: $\hat{p} - p$ diviso per l'errore standard. Nel punto (c) lo scarto grezzo di 0.004 sembra piccolo, ma è informativo solo perché lo si rapporta a $ES = 0.0108$. Senza il denominatore non si sa se 0.004 è tanto o poco: con $N = 1000$ è poco, con $N = 10$ sarebbe enorme.

Esercizio 2 — Dieci monete: da $N = 200$ a $N = 2000$ (28/01/25 — Quesito 2)

- Scrivere un programma che simuli $N = 200$ volte il lancio simultaneo di 10 monete equilibrate.
- Stimare dai dati raccolti la probabilità di ottenere 0, 1, 2, ..., 10 volte testa.
- Confrontare in un grafico questo risultato con quello teorico.

Svolgimento.




Figura 13.1: Il confronto del 28/01/25 Q2 (e del 20) con 10 monete equilibrate. Con $N = 200$ le barre sono vicine ma visibilmente irregolari; con $N = 2000$ si sovrappongono quasi ovunque. Lo scarto assoluto totale passa da 0.1457 a 0.0534, cioè si riduce di un fattore 2.7: aumentando N di 10 volte l'errore scende di circa $\sqrt{10} \approx 3.2$, che è l'andamento $1/\sqrt{N}$ previsto dal Teorema Limite Centrale (Cap. 5).

La distribuzione teorica. Il numero di teste in 10 lanci indipendenti è $X \sim \text{Bin}(10, \frac{1}{2})$, con

$$\mathbb{P}(X = k) = \binom{10}{k} \left(\frac{1}{2}\right)^{10}, \quad \mathbb{E}[X] = 10 \cdot \frac{1}{2} = 5, \quad \text{Var}(X) = 10 \cdot \frac{1}{2} \cdot \frac{1}{2} = 2.5.$$

```

1 import numpy as np
2 from scipy import stats
3 import matplotlib.pyplot as plt
4
5 teo = stats.binom.pmf(np.arange(11), 10, 0.5)
6 print("k : " + " ".join(f"{k:>6}" for k in range(11)))
7 print("teo: " + " ".join(f"{v:6.4f}" for v in teo))
8
9 fig, assi = plt.subplots(1, 2, figsize=(12, 4), sharey=True)
10 for asse, N in zip(assi, (200, 2000)):
11     sim = np.random.default_rng(158).binomial(10, 0.5, size=N)
12     freq = np.array([(sim == k).mean() for k in range(11)])
13     ks = np.arange(11)
14     asse.bar(ks - 0.2, freq, width=0.4, color='steelblue', label='simulazione')
15     asse.bar(ks + 0.2, teo, width=0.4, color='indianred', label='teoria')
16     asse.set_title(f'N = {N} (scarto totale {np.abs(freq-teo).sum():.4f})')
17     asse.set_xlabel('numero di teste'); asse.set_ylabel('probabilità')

```

```

18     asse.legend()
19     plt.tight_layout(); plt.show()

```

Output:

```

k :      0      1      2      3      4      5      6      7      8      9     10
teo: 0.0010 0.0098 0.0439 0.1172 0.2051 0.2461 0.2051 0.1172 0.0439 0.0098 0.0010

```

Le frequenze simulate, da confrontare riga per riga con le teoriche qui sopra:

```

N=200 : 0.0000 0.0000 0.0500 0.1200 0.2350 0.2600 0.2100 0.0650 0.0350 0.0250 0.0000
N=2000: 0.0005 0.0100 0.0420 0.1225 0.2090 0.2605 0.1925 0.1055 0.0445 0.0120 0.0010
scarto assoluto totale: 0.1457 (N=200)   0.0534 (N=2000)

```

Il commento. Tre osservazioni da scrivere:

1. **La forma è giusta:** il massimo è a $k = 5$ e la distribuzione è simmetrica attorno a 5, come $\text{Bin}(10, \frac{1}{2})$.
2. **Le code sono le più difficili da stimare.** Con $N = 200$ le frequenze di $k = 0$ e $k = 10$ valgono $\hat{p} = 0.0000$, mentre la teoria prevede $p = 0.0010$: su 200 lanci ci si aspetta $200 \times 0.0010 = 0.2$ casi, quindi **non vederne nessuno è normale**. Con $N = 2000$ i casi attesi sono 2 e infatti si osservano $\hat{p} = 0.0005$ e 0.0010 : cominciano a comparire.
3. **Lo scarto si riduce come $1/\sqrt{N}$:** da 0.1457 a 0.0534, cioè un fattore 2.73 per dieci volte i dati, contro il $\sqrt{10} = 3.16$ atteso. Il valore *medio* su molte repliche (0.1423 e 0.0464) dà un rapporto 3.07, ancora più vicino all'atteso: la legge $1/\sqrt{N}$ è confermata.

Esercizio 3 — Le carte Magic: confrontare con l'ipergeometrica (27/01/26 — Quesito 1, punti c-d)

Si simuli $N = 350$ volte la prima mano (7 carte pescate da un mazzo di 60, di cui 26 Terre) producendo un istogramma della probabilità empirica associata a ogni numero di Terre, e si confrontino i risultati empirici con quelli teorici commentando le eventuali differenze.

Svolgimento. Un punto che il quesito vuole far sbagliare. Le 7 carte sono pescate *senza reimmissione* da un mazzo finito, quindi il modello corretto è l'**ipergeometrica**, *non* la binomiale. Con la binomiale $\text{Bin}(7, \frac{26}{60})$ si otterrebbe $\mathbb{P}(\text{mano buona}) = 0.5182$ invece del valore esatto 0.5438. In Python si scrive `rng.hypergeometric(26, 34, 7, size=N)`: i parametri sono **successi nella popolazione, fallimenti, numero di estrazioni**.

```

1  import numpy as np
2  from scipy import stats
3  import matplotlib.pyplot as plt
4
5  N, nt, tot, k = 350, 26, 60, 7
6  sim = np.random.default_rng(5).hypergeometric(nt, tot - nt, k, size=N)
7
8  ks, teo = np.arange(0, k + 1), stats.hypergeom.pmf(np.arange(0, k + 1), tot, nt, k)
9  freq = np.array([(sim == j).mean() for j in ks])
10
11 print(f"E[Terre] sim = {sim.mean():.4f}   teo = {k*nt/tot:.4f}")
12 p_buona_teo = stats.hypergeom.pmf(3, tot, nt, k) + stats.hypergeom.pmf(4, tot, nt, k)
13 p_buona_sim = np.mean((sim == 3) | (sim == 4))
14 es = np.sqrt(p_buona_teo*(1-p_buona_teo)/N)
15 print(f"P(buona) sim = {p_buona_sim:.4f}   teo = {p_buona_teo:.6f}")
16 print(f"ES = sqrt(p(1-p)/N) = {es:.4f}   scarto = {p_buona_sim-p_buona_teo:+.4f}")
17     f" = {(p_buona_sim-p_buona_teo)/es:+.2f} ES")
18 print("scarto totale =", round(np.abs(freq-teo).sum(), 4))
19
20 plt.bar(ks - 0.2, freq, width=0.4, color='steelblue', label='simulazione')

```

```

21 plt.bar(ks + 0.2, teo, width=0.4, color='indianred', label='teoria Iper(60,26,7)')
22 plt.xlabel('numero di Terre nella prima mano'); plt.ylabel('probabilita')
23 plt.legend(); plt.tight_layout(); plt.show()

```

Output:

```

E[Terre] sim = 3.0257   teo = 3.0333
P(buona) sim = 0.5886   teo = 0.543849
ES = sqrt(p(1-p)/N) = 0.0266   scarto = +0.0447 = +1.68 ES
scarto totale = 0.0912

```

Il commento. La media empirica (3.0257) coincide con la teorica (3.0333). La probabilità di mano buona è stimata in 0.5886 contro 0.5438 teorica: lo scarto è +1.68 errori standard, **compatibile con il rumore campionario** ($N = 350$ è piccolo). La conclusione corretta è: “*i dati simulati sono coerenti con il modello ipergeometrico; la differenza osservata è attribuibile alla variabilità campionaria, non a un errore di modello*”. Dire “la simulazione è sbagliata perché i valori non coincidono” è l’errore da evitare.

Il segno dello scarto non è un segnale

Lo scarto +1.68 ES è positivo: la simulazione ha prodotto più mani buone del previsto. Con un seme diverso sarebbe potuto essere −1.5 ES. Un *singolo* scarto di questa dimensione non indica nulla di sistematico: per sospettare un errore servirebbe uno scarto oltre 3 ES, oppure uno scarto dello stesso segno ripetuto su più semi diversi.

Esercizio 4 — Le tre linee di produzione (17/02/26 — Quesito 1, punto c)

Nella fabbrica del quesito, le tre linee L_1, L_2, L_3 producono rispettivamente il 30%, 50% e 20% della produzione, con probabilità di difetto 1%, 2% e 0.5%. Interpretando le percentuali di produzione come probabilità, simulare la produzione di 10000 pezzi e confrontare la percentuale di pezzi difettosi con quanto calcolato teoricamente.

Svolgimento. La teoria. Per la formula delle probabilità totali,

$$\mathbb{P}(D) = \sum_{i=1}^3 \mathbb{P}(L_i) \mathbb{P}(D | L_i) = 0.30 \cdot 0.01 + 0.50 \cdot 0.02 + 0.20 \cdot 0.005 = 0.0030 + 0.0100 + 0.0010 = 0.0140.$$

La simulazione. Si estrae prima la linea con `rng.choice` e poi si decide se il pezzo è difettoso, estraendo da una uniforme e confrontandola con la probabilità di difetto di quella linea:

```

1 import numpy as np
2
3 N = 10000
4 p_L = np.array([0.30, 0.50, 0.20]) # prob. di ciascuna linea
5 p_dif = np.array([0.01, 0.02, 0.005]) # prob. di difetto di ciascuna
6
7 rng = np.random.default_rng(11)
8 linea = rng.choice([0, 1, 2], size=N, p=p_L) # quale linea ha prodotto il pezzo
9 dif = rng.random(N) < p_dif[linea] # il pezzo e' difettoso?
10
11 print(f"difettosi simulati = {dif.sum()} / {N} = {dif.mean():.4f} (teorico 0.0140)")
12 print(f"P(L2 | D) simulata = {(linea[dif] == 1).mean():.4f} (teorico 0.714286)")
13 print(f"ES su {dif.sum()} difettosi = {np.sqrt(0.714286*(1-0.714286)/dif.sum()):.4f}")

```

Output:

```

difettosi simulati = 133 / 10000 = 0.0133 (teorico 0.0140)
P(L2 | D) simulata = 0.6842 (teorico 0.714286)
ES su 133 difettosi = 0.0392

```

Il commento.

- $\mathbb{P}(D)$: simulata 0.0133 contro 0.0140 teorica. Con $ES = \sqrt{0.014 \cdot 0.986/10000} = 0.00117$, lo scarto 0.0007 vale 0.6 ES: ottimo accordo.
- $\mathbb{P}(L_2 | D)$: simulata 0.6842 contro 0.7143 teorica. Qui però l'errore standard va calcolato sul numero di difettosi (133), non su N : $ES = \sqrt{0.7143 \cdot 0.2857/133} = 0.0392$, e lo scarto 0.030 vale appena 0.77 ES. Anche questo è compatibile.

L'errore standard si calcola sul campione che stai stimando

Nel punto (d) del compito la domanda è “*provare a effettuare anche una simulazione che permetta di verificare la probabilità richiesta nel punto b)*” — cioè $\mathbb{P}(L_2 | D)$, una probabilità condizionata. La popolazione di riferimento diventa l'insieme dei 133 difettosi, non i 10000 pezzi. Usare $\sqrt{p(1-p)/10000} = 0.0045$ al posto di 0.0392 sottostima l'errore di quasi **nove volte**, e farebbe sembrare significativo uno scarto che non lo è.

Esercizio 5 — Quanto aspetta Giorgino all'anagrafe (23/06/26 — Quesito 1, punto d)

Giorgino è il ventitreesimo del primo gruppo convocato. Per ciascuna persona c'è una probabilità $p = 0.25$ che non si presenti. Simulare $N = 100$ volte la giornata all'ufficio anagrafe e calcolare quante persone deve aspettare Giorgino, confrontando il risultato con la teoria.

Svolgimento. La teoria, prima del codice. Davanti a Giorgino ci sono 22 persone. Ciascuna si presenta con probabilità $1 - p = 0.75$, indipendentemente dalle altre. Quindi il numero di persone *presenti* davanti a lui è

$$X \sim \text{Bin}(22, 0.75), \quad \mathbb{E}[X] = 22 \cdot 0.75 = 16.5, \quad \text{Var}(X) = 22 \cdot 0.75 \cdot 0.25 = 4.125, \quad \sigma_X = 2.0310.$$

```

1 import numpy as np
2
3 N, davanti, p_assente = 100, 22, 0.25
4
5 sim = np.random.default_rng(23).binomial(davanti, 1 - p_assente, size=N)
6
7 print(f"N = {N} giornate simulate")
8 print(f"media   = {sim.mean():.4f}   (teorica 16.5)")
9 print(f"scarto  = {sim.std(ddof=1):.4f} (teorico 2.0310)")
10 print(f"minimo  = {sim.min()}   massimo = {sim.max()}")
11 print(f"ES della media su {N} repliche = {(np.sqrt(22*0.75*0.25)/np.sqrt(N)):.4f}")

```

Output:

```

N = 100 giornate simulate
media   = 16.3800   (teorica 16.5)
scarto  = 2.0537   (teorico 2.0310)
minimo  = 11   massimo = 21
ES della media su 100 repliche = 0.2031

```

Il commento. Qui si confrontano *due* cose, e vanno distinte:

- le **single realizzazioni**: ogni giornata dà un numero diverso di presenti (11 nel caso peggiore, 22 nel migliore), con deviazione standard ≈ 2.03 . Il valore teorico 2.0310 è confermato (2.0537).
- la **media su $N = 100$ repliche**: 16.38 contro 16.5 teorica. Ma attenzione al metro giusto: l'errore standard *della media delle 100 repliche* è $\sigma_X/\sqrt{N} = 2.0310/10 = 0.2031$, e lo scarto 0.12 vale solo 0.59 ES. Con l'errore standard *di una singola* giornata (2.03) lo stesso scarto sembrerebbe piccolissimo, ma sarebbe un confronto sbagliato: la media di 100 repliche è molto meno variabile di una singola giornata.

Il doppio livello di simulazione

È un punto che ricorre in tutto il Laboratorio e che il 17/06/25 (gioco dell'oca) mette in evidenza: quando si *ripete* una simulazione N volte si ottengono N valori di una variabile aleatoria, e quella variabile ha una distribuzione teorica propria (qui $\text{Bin}(22, 0.75)$), con la sua media e la sua varianza. Il confronto va fatto con **quella** distribuzione, e l'errore standard della media campionaria è $\sigma/\sqrt{N}$. Confondere i due livelli — giudicare la media di 100 repliche con l'errore standard di una sola — è l'errore più insidioso di questo tipo di quesito.

Capitolo 14

Statistica descrittiva in Python

Questo capitolo copre i quesiti in cui i dati sono **già dati** (una tabella di numeri o di frequenze) e si chiede di riassumerli: frequenze, media, moda, mediana, quantili, varianza, momenti, grafici. Compare in **3 prove su 9**: 17/06/25 (numero di lettere dei nomi delle vie), 01/04/26 (ovetti) e 27/01/26 (peso dei biscotti).

14.1 Due modi di raggruppare i dati

Gli appunti distinguono due situazioni, e il codice cambia di conseguenza.

Dati con frequenza (raggruppamento per singoli valori)

È il caso in cui il compito dà già la tabella $x_i \mid f_i$. Si costruiscono due array a mano: i valori distinti e le loro frequenze assolute.

```
1 import numpy as np
2
3 # esempio: numero di lettere (x) e quante vie hanno quel numero di lettere (f)
4 x = np.array([ 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15], float)
5 f = np.array([ 2, 20, 59, 89, 62, 15, 14, 21, 48, 72, 61, 28, 9], float)
6
7 N = f.sum()          # numero totale di osservazioni
8 p = f / N           # frequenze relative (= probabilita' empiriche)
9 F = np.cumsum(p)     # frequenze relative cumulate
10
11 print(f"N = {N:.0f}")
12 print("valore  f      p      F")
13 for xi, fi, pi, Fi in zip(x, f, p, F):
14     print(f"{xi:6.0f} {fi:4.0f} {pi:.4f} {Fi:.4f}")
```

Dati grezzi (non raggruppati)

Se il compito dà l'elenco delle osservazioni, è `np.unique` a fare la tabella:

```
1 dati = np.array([3,5,2,3,2,4,3,3,4,4,3,2,4,5,4,4,3,2,4,3])
2 valori, freq = np.unique(dati, return_counts=True)
3 print(valori)          # [2 3 4 5]
4 print(freq)            # [4 7 6 3]
5 print(freq / len(dati)) # frequenze relative
```

`np.unique` è il comando che risolve le tabelle di frequenza

`np.unique(dati, return_counts=True)` restituisce **due** array: i valori distinti ordinati e quante volte compare ciascuno. È la tabella di frequenze in una riga. Da lì:

- frequenza relativa: `freq / N`;
- frequenze cumulate: `np.cumsum(freq)`;
- moda: `valori[freq.argmax()]`.

Se i dati sono *già* raggruppati, si costruiscono i due array a mano e si salta questo passaggio.

14.2 Media e varianza: con e senza frequenze

Gli appunti danno le due coppie di formule. Sono le stesse quantità scritte in due modi, e il compito chiede esplicitamente *entrambi* i casi.

	dati semplici	dati con frequenza
Media	$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$	$\bar{x} = \frac{1}{N} \sum_{i=1}^n x_i f_i = \sum_{i=1}^n p_i x_i$
Varianza empirica	$\bar{\sigma}_n^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$	$\bar{\sigma}_n^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2 f_i$
Momento centrato di ordine r	$\mu_r = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^r$	$\mu_r = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^r f_i$

I due indici di forma

$$\gamma_1 = \frac{\mu_3}{\mu_2^{3/2}} \quad (\text{skewness}), \quad \beta_2 = \frac{\mu_4}{\mu_2^2}, \quad \gamma = \beta_2 - 3 \quad (\text{curtosi}).$$

Skewness: $\gamma_1 = 0$ per una distribuzione simmetrica; $\gamma_1 < 0$ asimmetria a *sinistra*, $\gamma_1 > 0$ asimmetria a *destra*.

Curtosi: la normale ha $\beta_2 = 3$. Si usa quindi $\gamma = \beta_2 - 3$, che vale 0 per la normale, è < 0 se la distribuzione è più piatta (*platycurtica*) e > 0 se è più appuntita (*leptocurtica*).

14.3 Gli indici, in una schermata

```

1 import numpy as np
2 import scipy.stats as stats
3
4 x = np.array([...])                # i dati grezzi
5 N = len(x)
6
7 media    = np.mean(x)
8 mediana  = np.median(x)
9 q1, q3   = np.percentile(x, [25, 75])
10 iqr      = q3 - q1                # distanza interquartile
11 var_emp   = np.var(x)              # divide per N      (empirica)
12 var_cmp   = np.var(x, ddof=1)      # divide per N-1    (campionaria)
13 sd_cmp    = np.std(x, ddof=1)
14
15 print(f"media      = {media:.4f}")
16 print(f"mediana    = {mediana:.4f}")
17 print(f"Q1, Q3     = {q1:.4f}, {q3:.4f}   IQR = {iqr:.4f}")
18 print(f"var. empirica = {var_emp:.4f}")
19 print(f"var. campionaria = {var_cmp:.4f}")
20 print(f"scarto camp. = {sd_cmp:.4f}")
21 print(f"CV         = {sd_cmp/media:.4f}")
22 print(f"skewness    = {stats.skew(x):.4f}")
23 print(f"curtosi     = {stats.kurtosis(x):.4f}")

```

La distinzione che il 17/02/26 chiedeva all'orale

$$\text{np.var}(x) = \frac{1}{N} \sum (x_i - \bar{x})^2 \quad \text{contro} \quad \text{np.var}(x, \text{ddof}=1) = \frac{1}{N-1} \sum (x_i - \bar{x})^2.$$

`ddof` significa *delta degrees of freedom*: i gradi di libertà sottratti. `ddof=0` è il default e dà la varianza **empirica** $\bar{\sigma}_n^2$; `ddof=1` dà quella **campionaria** $\bar{S}_n^2$, che è lo stimatore non distorto (capitolo 6).

Quando usare quale:

- “la varianza dei dati” o “la varianza empirica” $\Rightarrow$ `ddof=0` (default);
- “la varianza campionaria” o “uno stimatore della varianza” $\Rightarrow$ `ddof=1`;
- `scipy.stats.tvar`, `scipy.stats.variation` e le funzioni di `scipy.stats` usano **già** il divisore $N - 1$: se si confrontano i due pacchetti senza saperlo, i numeri non tornano.

14.4 Esercizi svolti

Esercizio 1 — Il numero di lettere dei nomi delle vie (17/06/25 — Quesito 2)

Giorgino conta il numero di lettere dei nomi delle vie della città: non esistono vie con meno di 3 lettere o con più di 15. Dopo aver attraversato le $N = 500$ vie di tutta la città ha registrato:

Numero di lettere	3	4	5	6	7	8	9	10	11	12	13	14	15
Frequenza	2	20	59	89	62	15	14	21	48	72	61	28	9

- Plottare in un istogramma i dati raccolti.
- Calcolare la media e trovare la moda dei dati. C'è corrispondenza tra i due valori?
- Calcolare i momenti empirici centrati di ordine 2, 3 e 4 utilizzando la definizione (*non* è permesso usare le funzioni già scritte in Python).
- Calcolare il coefficiente di skewness e quello di curtosi. Commentare il risultato.

Svolgimento. (a) L'istogramma.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 lettere = np.arange(3, 16)
5 freq = np.array([2, 20, 59, 89, 62, 15, 14, 21, 48, 72, 61, 28, 9], float)
6 N = freq.sum()
7 print(f"N = {N:.0f}")
8
9 plt.bar(lettere, freq / N, edgecolor='white') # frequenze relative
10 plt.xlabel('numero di lettere'); plt.ylabel('frequenza relativa')
11 plt.xticks(lettere); plt.grid(alpha=0.3, axis='y'); plt.show()
```

(b) Media e moda. Con i dati raggruppati la media è $\bar{x} = \frac{1}{N} \sum x_i f_i$:

```
1 xbar = np.sum(lettere * freq) / N
2 moda = lettere[freq.argmax()]
3 print(f"media = {xbar:.4f}")
4 print(f"moda = {moda:.0f} (frequenza {freq.max():.0f})")
```

Output:

```
media = 9.0340
moda = 6 (frequenza 89)
```

Commento (b). Non c'è corrispondenza: la media è 9.03, la moda è 6. In una distribuzione simmetrica e unimodale media e moda coincidono; qui non coincidono, ed è il primo indizio che la distribuzione *non* è simmetrica né tantomeno normale. Guardando le frequenze si vede perché: ci sono *due* gobbe, una a 6 lettere (89 vie) e una a 12 lettere (72 vie), con un avvallamento a 8–9

lettere (15 e 14 vie). La distribuzione è **bimodale**, e la media 9.03 cade proprio nel mezzo, dove i dati scarseggiano.

(c) **I momenti centrati, a mano.** La definizione degli appunti è $\mu_r = \frac{1}{N} \sum_i (x_i - \bar{x})^r f_i$. Serve prima la varianza come “appoggio” per μ_2 , poi le potenze successive:

```

1 # --- punti (c) e (d): tutto a mano, senza funzioni pronte ---
2 mu2 = np.sum(freq * (lettere - xbar)**2) / N
3 mu3 = np.sum(freq * (lettere - xbar)**3) / N
4 mu4 = np.sum(freq * (lettere - xbar)**4) / N
5
6 print(f"mu2 = {mu2:.4f}")
7 print(f"mu3 = {mu3:.4f}")
8 print(f"mu4 = {mu4:.4f}")
9
10 # varianza campionaria (divisore N-1), per confronto
11 var_camp = np.sum(freq * (lettere - xbar)**2) / (N - 1)
12 print(f"varianza campionaria (N-1) = {var_camp:.4f}")

```

Output:

```

mu2 = 10.8808
mu3 = 3.0401
mu4 = 179.1371
varianza campionaria (N-1) = 10.9026

```

(d) **Skewness e curtosi.**

```

1 gamma1 = mu3 / mu2**1.5          # skewness
2 beta2 = mu4 / mu2**2             # curtosi (gaussiana -> 3)
3 gamma = beta2 - 3                # coefficiente di curtosi
4
5 print(f"skewness gamma1 = mu3/mu2^(3/2) = {gamma1:.4f}")
6 print(f"curtosi beta2 = mu4/mu2^2 = {beta2:.4f}")
7 print(f"coefficiente di curtosi gamma = beta2 - 3 = {gamma:.4f}")
8
9 # controllo con scipy (sui dati grezzi)
10 dati = np.repeat(lettere, freq.astype(int))
11 print(f"ncontrollo scipy: skew = {stats.skew(dati):.4f}, "
12       f"kurtosis = {stats.kurtosis(dati):.4f}")

```

Output:

```

skewness gamma1 = mu3/mu2^(3/2) = 0.0847
curtosi beta2 = mu4/mu2^2 = 1.5131
coefficiente di curtosi gamma = beta2 - 3 = -1.4869

controllo scipy: skew = 0.0847, kurtosis = -1.4869

```

Commento (d) — la parte che vale i punti.

- $\gamma_1 = 0.0847$: è un valore **molto vicino a zero**, quindi la distribuzione è **quasi simmetrica**; il segno positivo indica una leggerissima asimmetria a destra. Da solo questo indice suggerirebbe una distribuzione quasi normale.
- $\gamma = \beta_2 - 3 = -1.4869$: è **ben diverso da zero e negativo**, quindi la distribuzione è nettamente **platicurtica**, cioè *più piatta* di una normale, con le code “leggere”.
- **Le due informazioni insieme spiegano la forma reale.** Una distribuzione piatta con skewness nulla è esattamente ciò che ci si aspetta da una **bimodale**: le due gobbe si bilanciano (asimmetria complessivamente quasi zero) ma il “vuoto” centrale abbassa il picco rispetto alla normale (curtosi negativa).

È questo il commento da scrivere: non “la distribuzione è normale perché $\gamma_1 \approx 0$ ”, ma “ $\gamma_1 \approx 0$ da solo non basta a concludere la normalità: la curtosi fortemente negativa rivela che la forma non è gaussiana, e l’istogramma mostra che è bimodale”.

“Skewness = 0 $\Rightarrow$ simmetrica” è un’inferenza a senso unico

Gli appunti lo dicono esplicitamente: l’annullarsi dell’indice di asimmetria è condizione **necessaria** ma **non sufficiente** per la simmetria. Esistono distribuzioni asimmetriche con $\gamma_1 = 0$. Quindi da $\gamma_1 \approx 0$ si può dire “non c’è evidenza di asimmetria”, non “la distribuzione è simmetrica”. Qui l’istogramma è ciò che decide.

Esercizio 2 — Gli ovetti: descrittiva e stimatori (01/04/26 — Quesito 1, punti a–c)

Giorgino ha comprato 20 buste di ovetti assortiti. Ogni busta contiene 10 ovetti, che possono essere al cioccolato al latte, al cioccolato bianco o al cioccolato fondente. Il numero di ovetti per ogni tipo in ciascuna busta è:

busta	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
fondente	3	2	5	4	4	3	2	3	3	4	5	5	2	2	4	3	4	4	3	3
latte	4	3	3	3	4	3	5	4	3	2	2	3	4	3	2	3	3	4	3	4
bianco	3	5	2	3	2	4	3	3	4	4	3	2	4	5	4	4	3	2	4	3

- Fare tre istogrammi, uno per ciascun tipo di ovetto: ogni istogramma deve riportare, al variare di n , il numero di buste con n ovetti del tipo considerato.
- Calcolare la probabilità di aprire una busta e trovare meno di 4 ovetti fondenti. Calcolare la probabilità di trovare esattamente 3 ovetti al latte.
- Calcolare, per ciascun tipo di ovetto, uno stimatore della probabilità di trovare quel tipo di ovetto in una busta.

Svolgimento. Prima osservazione: i dati. I tre array non sono indipendenti, e questo è un controllo che conviene sempre fare: ogni busta ha esattamente 10 ovetti, quindi per ogni colonna la somma dei tre tipi deve dare 10.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 fondente = np.array([3,2,5,4,4,3,2,3,3,4,5,5,2,2,4,3,4,4,3,3], float)
5 latte    = np.array([4,3,3,3,4,3,5,4,3,2,2,3,4,3,2,3,3,4,3,4], float)
6 bianco   = np.array([3,5,2,3,2,4,3,3,4,4,3,2,4,5,4,4,3,2,4,3], float)
7
8 print("controllo: ogni colonna somma a 10 ->",
9       np.all(fondente + latte + bianco == 10))
10 print(f"totali: fondente={fondente.sum():.0f} latte={latte.sum():.0f} "
11       f"bianco={bianco.sum():.0f} (somma {fondente.sum()+latte.sum()+bianco.sum():.0f})")
```

Output:

```
controllo: ogni colonna somma a 10 -> True
totali: fondente=68 latte=65 bianco=67 (somma 200)
```

(a) I tre istogrammi.

```
1 fig, assi = plt.subplots(1, 3, figsize=(14, 4))
2 for asse, (nome, v) in zip(assi, [("fondente", fondente),
3                                   ("latte", latte),
4                                   ("bianco", bianco)]):
5     valori, conteggi = np.unique(v, return_counts=True)
6     asse.bar(valori, conteggi, edgecolor='white')
7     asse.set_title(nome)
```

```

8     asse.set_xlabel("n ovetti nella busta")
9     asse.set_ylabel("numero di buste")
10    asse.set_xticks(valori)
11    for xv, cv in zip(valori, conteggi):          # etichette sopra le barre
12        asse.text(xv, cv + 0.1, str(int(cv)), ha='center')
13    plt.tight_layout(); plt.show()

```

Le frequenze, in tabella (utili per il commento):

tipo	2	3	4	5	media
fondente	4	7	6	3	3.40
latte	3	10	6	1	3.25
bianco	4	7	7	2	3.35

(b) **Le due probabilità empiriche.** Qui la probabilità richiesta è quella *empirica*, cioè la frequenza relativa sul campione delle 20 buste.

```

1  N_buste = 20
2  print(f"P(meno di 4 fondenti) = {np.mean(fondente < 4):.4f} "
3        f"= {np.sum(fondente < 4):.0f}/{N_buste}")
4  print(f"P(esattamente 3 al latte) = {np.mean(latte == 3):.4f} "
5        f"= {np.sum(latte == 3):.0f}/{N_buste}")

```

Output:

```

P(meno di 4 fondenti) = 0.5500 = 11/20
P(esattamente 3 al latte) = 0.5000 = 10/20

```

Nota: è una frequenza, non una probabilità teorica

$\frac{11}{20}$ è la frequenza relativa osservata nel campione. Non serve conoscere una distribuzione: il quesito chiede “la probabilità di aprire una busta e trovare...”, cioè una stima dal campione. Questo è il collegamento con la definizione frequentista di probabilità del capitolo 3.

(c) **Gli stimatori delle tre probabilità.** Lo stimatore è la proporzione campionaria: su 200 ovetti in totale, quanti sono di quel tipo?

```

1  tot_ovetti = 10 * N_buste          # 200
2  for nome, v in [("fondente", fondente), ("latte", latte), ("bianco", bianco)]:
3      p_hat = v.sum() / tot_ovetti
4      print(f"p_hat({nome:9s}) = {v.sum():.0f}/{tot_ovetti} = {p_hat:.4f}")

```

Output:

```

p_hat(fondente ) = 68/200 = 0.3400
p_hat(latte    ) = 65/200 = 0.3250
p_hat(bianco   ) = 67/200 = 0.3350

```

Commento. Le tre stime sono 0.340, 0.325 e 0.335: sono tutte molto vicine a $\frac{1}{3} \approx 0.3333$. Questa è l'osservazione che prepara il punto (d) dello stesso quesito, che chiede se si può affermare con confidenza del 95% che $p_{\text{bianco}} > \frac{1}{3}$: la risposta è **no**, e viene sviluppata nel capitolo 16.

Scarto campionario e coefficiente di variazione

Per completare la descrittiva si aggiungono varianza campionaria e CV:

```

1  for nome, v in [("fondente", fondente), ("latte", latte), ("bianco", bianco)]:

```

```

2   print(f"{nome:9s} media={v.mean():.4f} var(N-1)={v.var(ddof=1):.4f} "
3       f"CV={v.std(ddof=1)/v.mean():.4f}")

```

```

fondente  media=3.4000  var(N-1)=0.9895  CV=0.2926
latte     media=3.2500  var(N-1)=0.6184  CV=0.2420
bianco    media=3.3500  var(N-1)=0.8711  CV=0.2786

```

Il latte è il tipo “più regolare” (CV più basso, varianza minore), il fondente il più variabile. Il CV è l’unico confronto sensato tra grandezze con scale diverse, ed è il numero da citare se il compito chiede “quale tipo è distribuito più uniformemente”.

Esercizio 3 — I biscotti: istogramma, distribuzione e parametri (27/01/26 — Quesito 2, punti a–b)

Un laboratorio ha prodotto $N = 100$ biscotti. I pesi rilevati (in grammi) sono riassunti in tabella:

peso (g)	17	18	19	20	21	22	23	24	25	26	27	28	29	30
numero	1	1	2	5	8	14	17	18	12	9	5	5	2	1

- Calcolare uno stimatore della media e uno della varianza.
- Fare l’istogramma, dire quale distribuzione lo descrive, con quali parametri, e sovrapporre la densità teorica all’istogramma.
- Calcolare la percentuale di biscotti con peso compreso fra 21 e 27 grammi.

Svolgimento. (a) **Gli stimatori.** Il peso è una grandezza continua, quindi lo stimatore della media è la media campionaria $\bar{X}_n$ e quello della varianza è $\bar{S}_n^2$ (con il divisore $n - 1$, perché la media è *non* nota — vedi il capitolo 6).

```

1  import numpy as np
2  import matplotlib.pyplot as plt
3  from scipy import stats
4
5  peso = np.arange(17, 31, dtype=float)
6  num = np.array([1,1,2,5,8,14,17,18,12,9,5,5,2,1], float)
7  N = num.sum()
8  print(f"N = {N:.0f}")
9
10 xbar = np.sum(peso * num) / N          # media campionaria
11 s2 = np.sum(num * (peso - xbar)**2) / (N - 1)  # varianza campionaria
12 s = np.sqrt(s2)
13 var_emp = np.sum(num * (peso - xbar)**2) / N    # varianza empirica
14
15 print(f"media campionaria = {xbar:.4f} g")
16 print(f"varianza campionaria = {s2:.4f} (scarto = {s:.4f})")
17 print(f"varianza empirica = {var_emp:.4f} (per confronto)")

```

Output:

```

N = 100
media campionaria = 23.6900 g
varianza campionaria = 6.1555 (scarto = 2.4810)
varianza empirica = 6.0939 (per confronto)

```

Quale varianza?

Il compito chiede “uno stimatore della varianza”. Uno *stimatore* nel senso del capitolo 6 è $\bar{S}_n^2$, con divisore $N - 1$: 6.1555. Se invece si dà 6.0939 (N) si sta descrivendo il campione, non

stimando la popolazione. La differenza è piccola ($\approx 1\%$) ma la domanda chiede esplicitamente lo stimatore. Se si hanno dubbi, si scrivono entrambi *dicendo quale è quale*.

(b) L'istogramma e la distribuzione.

```
1 larghezza = 0.9
2 plt.bar(peso, num, larghezza, edgecolor='white', label='osservati')
3
4 xs = np.linspace(peso.min() - 2, peso.max() + 2, 400)
5 plt.plot(xs, stats.norm.pdf(xs, xbar, s) * N * 1.0, 'r-', lw=2,
6         label=f'normale({xbar:.2f}, {s:.2f}^2)')
7 plt.xlabel('peso (g)'); plt.ylabel('numero di biscotti')
8 plt.legend(); plt.grid(alpha=0.3, axis='y'); plt.show()
```

Il fattore di scala sull'asse y

L'istogramma qui è in **conteggi** (numero di biscotti), non in densità. La densità normale va quindi moltiplicata per N e per l'ampiezza della classe (qui 1 g), altrimenti la curva risulta 100 volte più bassa delle barre. Se invece si usa `plt.hist(dati, density=True)` la curva va lasciata com'è. È un errore che si vede subito nel grafico e fa perdere il punto del confronto.

Quale distribuzione, e perché. La forma è a campana, simmetrica attorno a 24 g, con code che si assottigliano rapidamente: è una **distribuzione normale**. I suoi parametri si stimano dai dati con gli stimatori appena calcolati:

$$\hat{\mu} = \bar{X}_n = 23.69 \text{ g}, \quad \hat{\sigma}^2 = \bar{S}_n^2 = 6.1555 \text{ (cioè } \hat{\sigma} = 2.481 \text{ g)}.$$

Quindi $X \sim \mathcal{N}(23.69, 2.481^2)$. La scelta va giustificata in una riga: il peso di un biscotto è la somma di molti piccoli contributi indipendenti (quantità di impasto, cottura, umidità), e per il teorema del limite centrale (capitolo 5) una grandezza di questo tipo si distribuisce approssimativamente in modo normale.

(c) La percentuale fra 21 e 27 grammi. Ci sono due letture, e conviene darle entrambe dichiarandole:

```
1 # lettura 1: percentuale OSSERVATA nei dati
2 oss = np.sum(num[(peso >= 21) & (peso <= 27)]) / N
3 print(f"osservata P(21 <= X <= 27) = {oss:.4f} ({oss*100:.2f}%)")
4
5 # lettura 2: dalla normale stimata
6 teo = stats.norm.cdf(27, xbar, s) - stats.norm.cdf(21, xbar, s)
7 print(f"teorica P(21 <= X <= 27) = {teo:.4f} ({teo*100:.2f}%)")
```

Output:

```
osservata P(21 <= X <= 27) = 0.8300 (83.00%)
teorica P(21 <= X <= 27) = 0.7698 (76.98%)
```

Commento. L'83% è la percentuale *osservata nel campione* (83 biscotti su 100); se si usa il modello normale stimato al punto (b) si ottiene il 77.0%. La differenza (6 punti percentuali) è contenuta e accettabile su 100 osservazioni. In sede d'esame conviene riportare la percentuale osservata — è un dato, non una stima — e citare quella teorica come conferma che la normale è un modello adeguato.

Il punto (d), che continua lo stesso quesito

Lo stesso biscotto ha un punto (d): “*si può affermare con confidenza del 95% che i biscotti sono più grandi di 22 g?*”. La risposta si costruisce con un test t unilatero destro su $H_0 : \mu = 22$ contro $H_1 : \mu > 22$:

$$t = \frac{\bar{X}_n - \mu_0}{\bar{S}_n^2 / \sqrt{N}} = \frac{23.69 - 22}{2.4810 / \sqrt{100}} = 6.81, \quad t_{1-\alpha}(N-1) = t_{0.95}(99) = 1.6604.$$

Essendo $6.81 > 1.6604$ si **rigetta** H_0 : sì, si può affermare che i biscotti sono più grandi di 22 g. Lo svolgimento completo è nel capitolo 16.

Capitolo 15

Regressione e correlazione in Python

Il quesito di regressione compare in **3 prove su 9**: 28/01/25 (correlazione tra due variabili, prima su 6 punti poi su 10), 02/09/25 (probabilità di vincita in funzione dell'ora) e 17/02/26 (tempo di calcolo, con l'esplicito divieto di usare `linregress`). È una presenza minoritaria rispetto a Markov e Monte Carlo, ma quando esce vale un intero quesito di laboratorio: conviene arrivarci preparati.

15.1 Le formule, e come si chiamano le cose

Il capitolo 7 ha ricavato le formule. Qui servono i nomi esatti, perché il compito chiede di *calcolare* le quantità e di *commentarle*:

Quantità	Simbolo	Formula (come sugli appunti)
varianza empirica di x	$\bar{\sigma}_x^2$	$\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$
varianza empirica di y	$\bar{\sigma}_y^2$	$\frac{1}{n} \sum_{i=1}^n y_i^2 - \bar{y}^2$
covarianza empirica	$\bar{\sigma}_{xy}$	$\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$
pendenza	β_1	$\beta_1 = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2}$
intercetta	β_0	$\beta_0 = \bar{y} - \beta_1 \bar{x}$
correlazione	ρ	$\rho = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x \bar{\sigma}_y}$
determinazione	R	$R = \rho^2$

Le due cose da dire a voce, sempre

1. La retta si chiama $y = \beta_0 + \beta_1 x$: β_0 è l'**intercetta**, β_1 è la **pendenza**. Negli appunti del corso è questa la notazione; attenzione a non invertirle.
2. Il **coefficiente di determinazione** si indica con R ed è ρ^2 . Il compito lo chiama “coefficiente di determinazione”, non “ R^2 ”, ma è lo stesso numero.

15.2 Il modo rapido: `linregress`

```
1 import numpy as np
2 from scipy.stats import linregress
3
4 x = np.array([1213, 1518, 1550, 1215, 2120, 2207])
5 y = np.array([15474, 16497, 17224, 14459, 22186, 23483])
6
7 ris = linregress(x, y)
8
9 print("beta1 (pendenza) :", round(ris.slope, 4))
10 print("beta0 (intercetta):", round(ris.intercept, 4))
11 print("rho                :", round(ris.rvalue, 4))
12 print("R = rho^2          :", round(ris.rvalue**2, 4))
```

```

13 print("p-value      :", round(ris.pvalue, 6))
14 print("errore std betal :", round(ris.stderr, 4))

```

Attributo	Significato
-----------	-------------

slope	β_1 , la pendenza della retta
intercept	β_0 , l'intercetta
rvalue	il coefficiente di correlazione ρ
pvalue	p -value del test $H_0 : \beta_1 = 0$ (la retta non spiega nulla)
stderr	errore standard di β_1

linregress non restituisce R

`linregress` dà `rvalue`, cioè ρ . Il coefficiente di determinazione lo si ottiene come `rvalue**2`. Dimenticarlo è un errore banale ma frequente. Inoltre `rvalue` può essere *negativo* (correlazione inversa), mentre $R = \rho^2$ è sempre ≥ 0 .

15.3 Il modo “a mano”

Il 17/02/26 il compito dice esplicitamente, in fondo alla pagina:

“NOTA: Non è consentito l’uso della funzione `scipy.stats.linregress`.”

Le formule del capitolo 7 si scrivono in quattro righe, e sono quelle che il correttore si aspetta di vedere:

```

1 import numpy as np
2
3 def regressione(x, y):
4     """beta0, betal, rho, R con le formule degli appunti (divisori = n)."""
5     x, y = np.asarray(x, float), np.asarray(y, float)
6     n = len(x)
7     sxx = np.sum(x**2)/n - x.mean()**2      # varianza empirica di x
8     syy = np.sum(y**2)/n - y.mean()**2      # varianza empirica di y
9     sxy = np.sum(x*y)/n - x.mean()*y.mean() # covarianza empirica
10    betal = sxy / sxx
11    beta0 = y.mean() - betal * x.mean()
12    rho = sxy / np.sqrt(sxx * syy)
13    return beta0, betal, rho, rho**2

```

Scrivere una funzione conviene sempre

Nel 28/01/25 lo stesso quesito va risolto **due volte**: prima sui 6 punti iniziali, poi sui 10 della tabella completa. Definire la funzione una volta sola e richiamarla è molto più sicuro che riscrivere le formule: si eliminano le occasioni di errore di trascrizione, che è il rischio principale quando si scrive a mano sotto esame.

15.4 Il grafico

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 beta0, beta1, rho, R = regressione(x, y)
5
6 plt.figure(figsize=(6, 4))
7 plt.scatter(x, y, s=60, color='steelblue', label='dati', zorder=3)
8
9 xs = np.linspace(x.min(), x.max(), 100)
10 plt.plot(xs, beta0 + beta1*xs, 'r-', lw=2,
11          label=f'y = {beta0:.2f} + {beta1:.2f}x')
12
13 plt.scatter([x.mean()], [y.mean()], marker='x', s=120,
14            color='black', zorder=4, label='baricentro')
15
16 plt.xlabel('x'); plt.ylabel('y')
17 plt.title(f'rho = {rho:.3f}, R = {R:.3f}')
18 plt.legend(); plt.grid(alpha=0.3)
19 plt.show()

```

Due controlli visivi che valgono punti

1. **La retta passa per il baricentro** $(\bar{x}, \bar{y})$: è una conseguenza diretta di $\beta_0 = \bar{y} - \beta_1 \bar{x}$. Segnarlo sul grafico mostra di aver capito da dove viene la formula.
2. **La retta va disegnata solo nell'intervallo dei dati osservati**. Il codice sopra usa `xs = np.linspace(x.min(), x.max(), 100)` proprio per questo.

15.5 La scala di ρ

Gli appunti danno tre gradi di correlazione, e il compito chiede sempre di *commentare* il coefficiente: usare queste soglie è esattamente ciò che il correttore si aspetta di leggere.

Valore di $ \rho $	Interpretazione
$0 < \rho \leq 0.3$	correlazione debole
$0.3 < \rho \leq 0.7$	correlazione moderata
$0.7 < \rho \leq 1$	correlazione forte

Correlazione non implica causalità

È scritto a chiare lettere negli appunti. Se due grandezze risultano correlate *non* si può concludere che una causi l'altra: esistono le *correlazioni spurie*, andamenti paralleli senza alcun legame di causa-effetto. Se il commento contiene una frase causale del tipo “l'ora fa aumentare la probabilità di vincita”, si perde un punto. La forma corretta è “le due grandezze sono legate da una relazione lineare”.

15.6 Esercizi svolti

Esercizio 1 — Correlazione tra due variabili, prima su 6 e poi su 10 punti (28/01/25 — Quesito 1)

Uno studente trova scritti su un foglio i seguenti dati:

X	1213	1518	1550	1215	2120	2207
Y	15474	16497	17224	14459	22186	23483

e vuole capire se sono correlati.

- Stabilire se tra i dati X e i dati Y c'è correlazione.
- Usare il metodo dei minimi quadrati per determinare la retta di regressione. In un plot mostrare i dati e la retta ricavata.
- Calcolare il coefficiente di determinazione e commentare il risultato.

Guardando meglio, lo studente si accorge che mancavano alcuni dati e che la tabella completa era:

X	1213	1518	3050	852	1550	1215	2120	2207	2175	1128
Y	15474	16497	29349	11314	17224	14459	22186	23483	24095	13982

- Usare il metodo dei minimi quadrati per determinare la retta di regressione e confrontarla con la precedente. Com'è cambiato il risultato?

Svolgimento. (a–c) I sei punti.

```
1 import numpy as np
2 from scipy.stats import linregress
3
4 x6 = np.array([1213, 1518, 1550, 1215, 2120, 2207], float)
5 y6 = np.array([15474, 16497, 17224, 14459, 22186, 23483], float)
6
7 ris = linregress(x6, y6)
8 print(f"media x = {x6.mean():.2f}, media y = {y6.mean():.2f}")
9 print(f"retta: y = {ris.intercept:.4f} + {ris.slope:.4f} x")
10 print(f"rho    = {ris.rvalue:.4f}")
11 print(f"R      = {ris.rvalue**2:.4f}")
```

Output:

```
media x = 1637.17, media y = 18220.50
retta: y = 4326.4015 + 8.4867 x
rho    = 0.9888
R      = 0.9778
```

Commento. $\rho = 0.9888$: essendo $|\rho| > 0.7$ la correlazione è **forte** (e positiva, quindi le due grandezze crescono insieme). Il coefficiente di determinazione $R = \rho^2 = 0.9778$ dice che il 97.8% della variabilità di Y è spiegata dalla relazione lineare con X : il modello lineare descrive i dati molto bene.

(d) Il confronto con i dieci punti.

```
1 x10 = np.array([1213, 1518, 3050, 852, 1550, 1215, 2120, 2207, 2175, 1128], float)
2 y10 = np.array([15474, 16497, 29349, 11314, 17224, 14459, 22186, 23483, 24095, 13982], float)
3
4 for etichetta, xx, yy in [("6 punti", x6, y6), ("10 punti", x10, y10)]:
5     ris = linregress(xx, yy)
6     print(f"--- {etichetta} (n={len(xx)}) ---")
7     print(f"retta: y = {ris.intercept:.4f} + {ris.slope:.4f} x")
8     print(f"rho = {ris.rvalue:.4f}, R = {ris.rvalue**2:.4f}")
```

Output:

```

--- 6 punti (n=6) ---
retta: y = 4326.4015 + 8.4867 x
rho = 0.9888, R = 0.9778
--- 10 punti (n=10) ---
retta: y = 4516.0121 + 8.3922 x
rho = 0.9930, R = 0.9861

```

Commento — ed è qui il punto dell'esercizio. Aggiungendo quattro osservazioni il risultato **non cambia in modo sostanziale**:

- la pendenza passa da 8.4867 a 8.3922, cioè varia di poco più dell'1%;
- l'intercetta passa da 4326.40 a 4516.01;
- ρ sale da 0.9888 a 0.9930 e R da 0.9778 a 0.9861.

I nuovi punti sono **coerenti** con la tendenza già osservata, quindi *confermano* la relazione e anzi la rafforzano leggermente. La conclusione da scrivere è che la stima era già **robusta**: con sei punti la retta individuata descriveva bene anche i dati che mancavano.

Il commento “giusto” dipende dai dati, non dalla teoria

Sarebbe sbagliato scrivere d'ufficio “aggiungendo punti la stima cambia molto, perché con pochi dati le stime sono instabili”. Qui i punti aggiunti sono allineati e la stima *regge*. Il commento va costruito sul confronto numerico che si è appena fatto. La frase da evitare è quella copiata a memoria.

Esercizio 2 — Probabilità di vincita in funzione dell'ora (02/09/25 — Quesito 1)

Giorgino vuole vincere un premio del concorso *Frantoio Giallo*: bisogna acquistare un prodotto e caricare lo scontrino. La probabilità di vittoria dipende dall'ora in cui si effettua l'operazione, secondo la tabella:

p	0.08	0.24	0.33	0.35	0.39	0.64	0.70	0.74	0.86
t	7	8	10	12	13	17	19	21	22

- Calcolare il coefficiente di correlazione lineare tra p e t .
- Calcolare la retta di regressione e plottare il risultato.
- Giorgino ha accesso al computer solo alle 14 di ogni giorno. Qual è la probabilità di vittoria a $t = 14$?
- Quanto dovrà aspettare (in media) prima di vincere qualcosa?
(hint: la vittoria sarebbe il primo successo di Giorgino in questo gioco!)

Svolgimento. (a–b) Correlazione e retta.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.stats import linregress
4
5 t = np.array([ 7,  8, 10, 12, 13, 17, 19, 21, 22], float)
6 p = np.array([0.08, 0.24, 0.33, 0.35, 0.39, 0.64, 0.70, 0.74, 0.86], float)
7
8 ris = linregress(t, p)
9 print(f"p = {ris.intercept:.4f} + {ris.slope:.4f} * t")
10 print(f"rho = {ris.rvalue:.4f}, R = {ris.rvalue**2:.4f}")
11
12 plt.scatter(t, p, s=60, zorder=3, label='dati')
13 ts = np.linspace(t.min(), t.max(), 100)
14 plt.plot(ts, ris.intercept + ris.slope*ts, 'r-', lw=2,

```

```

15     label=f'p = {ris.intercept:.2f} + {ris.slope:.3f} t')
16 plt.xlabel('ora t'); plt.ylabel('probabilita di vincita p')
17 plt.legend(); plt.grid(alpha=0.3); plt.show()

```

Output:

```

p = -0.1802 + 0.0461 * t
rho = 0.9866, R = 0.9734

```

Commento. $\rho = 0.9866$: correlazione **forte** e positiva. $R = 0.9734$: il modello lineare spiega il 97.3% della variabilità di p . La pendenza $\beta_1 = 0.0461$ significa che **ogni ora in più la probabilità di vincita cresce di circa 0.046** (cioè di 4.6 punti percentuali). L'intercetta $\beta_0 = -0.1802$ è *priva di significato fisico* (una probabilità negativa non esiste): serve solo a posizionare la retta, e va detto.

(c) La previsione a $t = 14$.

```

1 t0 = 14
2 p14 = ris.intercept + ris.slope*t0
3 print(f"p(14) = {p14:.4f}")

```

Output:

```
p(14) = 0.4657
```

Attenzione: è un'interpolazione, non un'estrapolazione. Il valore $t = 14$ cade *dentro* l'intervallo osservato $[7, 22]$, quindi la previsione è legittima. Lo stesso vale per il 17/02/26, dove si chiedeva il tempo per 200 dati: le dimensioni osservate sono 105, 511, 401, 622, 330, quindi 200 sta *dentro* il range $[105, 622]$ ed è anch'essa un'interpolazione. Dirlo esplicitamente è un punto che i commissari apprezzano, perché mostra che si è controllato il dominio di validità della retta.

(d) Quanto deve aspettare. L'hint dice esattamente cosa usare: la vittoria è il **primo successo** di una sequenza di prove indipendenti, quindi il tempo di attesa T segue una **legge geometrica** di parametro $p = p(14)$ (capitolo 4). Dalla teoria $\mathbb{E}[T] = 1/p$:

```

1 print(f"E[T] = 1/p(14) = {1/p14:.4f} tentativi (giorni)")

```

Output:

```
E[T] = 1/p(14) = 2.1472 tentativi (giorni)
```

Conclusione. A mezzogiorno e mezzo circa, in media, Giorgino deve tentare ≈ 2.15 volte (quindi poco più di due giorni) prima di vincere qualcosa.

Esercizio 3 — Tempo di calcolo, senza `linregress` (17/02/26 — Quesito 2)

Viene osservato il tempo di calcolo in secondi utilizzato da un software nell'elaborazione di diversi insiemi di dati:

dimensione dati	105	511	401	622	330
tempo (s)	44	214	193	299	143

- Determinare la retta di regressione lineare.
- Rappresentare i dati e la retta di regressione in un unico grafico.
- Calcolare il coefficiente di correlazione lineare e il coefficiente di determinazione e commentarli.
- Stimare in base alla retta di regressione il tempo necessario all'elaborazione di un insieme di 200 dati.

NOTA: non è consentito l'uso della funzione `scipy.stats.linregress`.

Svolgimento. (a) **La retta con le formule.** Il divieto di `linregress` non è un problema: si applicano le formule degli appunti.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 dim = np.array([105, 511, 401, 622, 330], float)
5 tmp = np.array([ 44, 214, 193, 299, 143], float)
6
7 n = len(dim)
8 sxx = np.sum(dim**2)/n - dim.mean()*2      # varianza empirica di x
9 syy = np.sum(tmp**2)/n - tmp.mean()*2      # varianza empirica di y
10 sxy = np.sum(dim*tmp)/n - dim.mean()*tmp.mean() # covarianza empirica
11
12 betal = sxy / sxx
13 beta0 = tmp.mean() - betal * dim.mean()
14 rho = sxy / np.sqrt(sxx * syy)
15
16 print(f"media dim = {dim.mean():.4f}, media tempo = {tmp.mean():.4f}")
17 print(f"sxx = {sxx:.4f}, syy = {syy:.4f}, sxy = {sxy:.4f}")
18 print(f"retta: tempo = {beta0:.4f} + {betal:.4f} * dimensione")
19 print(f"rho = {rho:.6f}, R = {rho**2:.6f}")

```

Output:

```

media dim = 393.8000, media tempo = 178.6000
sxx = 30667.7600, syy = 7068.2400, sxy = 14574.3200
retta: tempo = -8.5466 + 0.4752 * dimensione
rho = 0.989901, R = 0.979903

```

Verifica incrociata: il modo per non sbagliare

Quando si ha un dubbio sui conti a mano, si può **sempre** controllare il risultato con `linregress` *per sé*, anche se il compito lo vieta: il divieto riguarda ciò che si scrive nella soluzione, non il fatto di verificare. Confrontare $\beta_1 = 0.4752$ e $\beta_0 = -8.5466$ con `linregress(dim, tmp).slope` e `.intercept` conferma che i conti sono giusti. In sede d'esame questo controllo si fa a mente o su un angolo del foglio.

(b) Il grafico.

```

1 plt.scatter(dim, tmp, s=60, zorder=3, label='dati')
2 xs = np.linspace(dim.min(), dim.max(), 100)
3 plt.plot(xs, beta0 + betal*xs, 'r-', lw=2,
4          label=f'tempo = {beta0:.2f} + {betal:.4f} * dim')
5 plt.xlabel('dimensione dei dati'); plt.ylabel('tempo di calcolo (s)')
6 plt.title(f'rho = {rho:.4f}, R = {rho**2:.4f}')
7 plt.legend(); plt.grid(alpha=0.3); plt.show()

```

(c) Il commento. $\rho = 0.9899$: correlazione **forte** e positiva. $R = 0.9799$: il 98% circa della variabilità del tempo di calcolo è spiegato dalla dimensione dei dati. In parole: il tempo di calcolo cresce in modo praticamente lineare con la dimensione dell'input, e la retta è un modello adeguato. La pendenza $\beta_1 = 0.4752$ va letta con la sua unità di misura: **circa 0.475 secondi in più per ogni unità di dati in più**.

(d) La stima per 200 dati.

```

1 d0 = 200
2 print(f"tempo stimato per {d0} dati = {beta0 + betal*d0:.4f} s")

```

Output:

```
tempo stimato per 200 dati = 86.4999 s
```

Da dichiarare. 200 è fuori dall'intervallo osservato $[105, 622]$? No: 200 sta *dentro* $[105, 622]$, quindi è un'interpolazione. Se la traccia avesse chiesto il tempo per 50 dati, la risposta andrebbe accompagnata dalla parola “estrapolazione”.

Il controllo che distingue chi ha capito

Con un solo grafico in più si mostra di sapere *verificare* il modello: il **grafico dei residui**, $r_i = y_i - \hat{y}_i$ in funzione di x_i . Se i residui sono sparsi a caso attorno allo zero senza struttura, la linearità è plausibile; se mostrano una curva (a U, a campana), la relazione non è lineare e servirebbe un altro modello.

Esercizio 4 — Perché $R = \rho^2$ (dagli appunti, §4.4)

Il compito chiede spesso di calcolare *sia* ρ *sia* R . Non sono due numeri indipendenti: mostrare che R è esattamente ρ^2 , così da poter verificare l'uno con l'altro durante il compito.

Svolgimento. Dalle formule del capitolo 7:

$$\beta_1 = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2} \quad \text{e} \quad \rho = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x \bar{\sigma}_y}.$$

Il coefficiente di determinazione è definito dagli appunti come

$$R = \frac{\bar{\sigma}_{xy}^2}{\bar{\sigma}_x^2 \bar{\sigma}_y^2}.$$

Confrontando:

$$\rho^2 = \left(\frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x \bar{\sigma}_y} \right)^2 = \frac{\bar{\sigma}_{xy}^2}{\bar{\sigma}_x^2 \bar{\sigma}_y^2} = R.$$

Come si scrive in due righe

$\bar{\sigma}_{xy}$ è la covarianza empirica, $\bar{\sigma}_x^2$ e $\bar{\sigma}_y^2$ le varianze empiriche. R è il rapporto tra la varianza “spiegata” dalla retta e la varianza totale di y ; ρ è la stessa quantità ma normalizzata dagli scarti, e il quadrato fa sparire i due scarti. Da qui $R = \rho^2$, sempre compreso tra 0 e 1 mentre ρ può essere negativo.

Capitolo 16

Intervalli di confidenza e test d'ipotesi in Python

Questo capitolo copre i quesiti di statistica inferenziale in Laboratorio: stimare un parametro, costruirne un intervallo di confidenza, verificare un'ipotesi. Compare in **4 prove su 9**: 24/03/25 (due palestre), 29/04/26 (farmaci), 27/01/26 (biscotti) e 01/04/26 (ovetti).

16.1 Le due decisioni da prendere prima di scrivere una riga

Le due domande da farsi

1. La varianza della popolazione σ^2 è nota?

- sì, il testo la dà $\Rightarrow$ distribuzione **normale**, quantile φ , **test** z ;
- no, la stimo dai dati $\Rightarrow$ **t di Student** con $N - 1$ gradi di libertà, **test** t .

2. La domanda è direzionale?

- “diverso da”, “c'è differenza” $\Rightarrow$ **bilaterale**;
- “maggiore di”, “più grande” $\Rightarrow$ **unilaterale destro**;
- “minore di”, “più basso” $\Rightarrow$ **unilaterale sinistro**.

Il criterio in una riga

È la prima domanda che decide tutto: σ^2 **me l'ha data il testo, o la calcolo io?** Se l'ha data $\Rightarrow$ `stats.norm.ppf`. Se la calcolo io $\Rightarrow$ `stats.t.ppf(..., df=N-1)`. Non c'è altro da sapere.

16.2 Gli intervalli di confidenza

Caso

Intervallo di confidenza di livello $1 - \alpha$

media, σ^2 nota	$I_\mu = \left[\bar{X}_n - \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2} \right]$
media, σ^2 non nota	$I_\mu = \left[\bar{X}_n - \frac{\bar{S}_n^2}{\sqrt{N}} t_{1-\alpha/2}, \bar{X}_n + \frac{\bar{S}_n^2}{\sqrt{N}} t_{1-\alpha/2} \right]$
varianza (μ non nota)	$I_{\sigma^2} = \left[\frac{\bar{S}_n^2(N-1)}{\chi_{1-\alpha/2}^2(N-1)}, \frac{\bar{S}_n^2(N-1)}{\chi_{\alpha/2}^2(N-1)} \right]$
proporzione (N grande)	$I_p = \left[\hat{p} - \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \varphi_{1-\alpha/2}, \hat{p} + \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \varphi_{1-\alpha/2} \right]$

La formula della varianza ha le code *scambiate*

Nell'intervallo per σ^2 il quantile di destra $\chi_{1-\alpha/2}^2$ sta al *denominatore* dell'estremo *sinistro*. Non è un refuso: la χ^2 non è simmetrica, e l'inversione della disuguaglianza scambia le code. È l'errore più frequente su questo intervallo.

16.3 I test d'ipotesi

Tutti i test del corso seguono lo stesso scheletro: si calcola una **statistica** Z_n (o T_n , o W_n), si confronta con un **valore critico** che dipende da α e dal tipo di alternativa, e si decide.

	bilatero	unilaterale sinistro	unilaterale destro
	$H_1 : \theta \neq \theta_0$	$H_1 : \theta < \theta_0$	$H_1 : \theta > \theta_0$
si rigetta se	$ Z_n > \varphi$	$Z_n < \varphi_\alpha$	$Z_n > \varphi_{1-\alpha}$
p -value	$2(1 - \Phi(Z_n))$	$\Phi(Z_n)$	$1 - \Phi(Z_n)$

Come si legge il p -value

Il p -value è il più piccolo valore di α per cui si rigetta H_0 (definizione degli appunti). In pratica: si rigetta H_0 se $p < \alpha$. E si può anche rispondere direttamente in termini di p , che è spesso ciò che il compito chiede quando dice “qual è il p -value associato al rigetto?”.

Non rigettare H_0 non significa che H_0 sia vera

È l'asimmetria tra H_0 e H_1 sottolineata negli appunti: se non si trova evidenza per rigettare H_0 , il test è **inconcludente**. Non si può affermare né che H_1 sia vera, né che sia falsa. La forma corretta è: “non c'è evidenza sufficiente per affermare che...”. La frase sbagliata è: “quindi H_0 è vera”.

16.4 Esercizi svolti

Esercizio 1 — Due palestre: stimatore, IC e confronto fra medie (24/03/25 — Quesito 1)

La distribuzione della scelta dei pesi della lat machine segue una distribuzione normale con media 45 kg. Un'indagine in due palestre, “Muscled Mario” e “Weak Luigi”, dà i risultati:

Pesi lat	15	20	25	30	35	40	45	50	55	60	65	70	75	80
Muscled Mario	0	1	2	20	34	50	64	59	40	18	11	1	0	0
Weak Luigi	1	6	19	23	52	75	82	93	63	44	21	10	8	3

- Graficare in due istogrammi i dati raccolti dai due campioni.
- Si suppone che i dati di “Muscle Mario” provengano da una popolazione con varianza $\sigma^2 = 5$, e quelli di “Weak Luigi” da una con varianza $\sigma^2 = 3$. Trovare uno stimatore della media.
- Calcolare l'intervallo di confidenza della media con $\alpha = 0.05$.
- Possiamo affermare con confidenza al 5% che la media dei pesi nella palestra “Muscle Mario” sia più bassa di quella dei pesi nella palestra “Weak Luigi”?

Svolgimento. (a) Gli istogrammi.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 pesi = np.arange(15, 81, 5, dtype=float)
5 mm = np.array([0,1,2,20,34,50,64,59,40,18,11,1,0,0], float) # Muscled Mario
6 wl = np.array([1,6,19,23,52,75,82,93,63,44,21,10,8,3], float) # Weak Luigi
7
8 print(f"N Muscled Mario = {mm.sum():.0f}")

```

```

9 print(f"N Weak Luigi    = {wl.sum():.0f}")
10
11 fig, assi = plt.subplots(1, 2, figsize=(12, 4), sharey=True)
12 for asse, (nome, f) in zip(assi, [("Musclcd Mario", mm), ("Weak Luigi", wl)]):
13     asse.bar(pesi, f, width=4.5, edgecolor='white')
14     asse.set_title(nome); asse.set_xlabel('kg sollevati')
15     asse.set_ylabel('numero di persone')
16 plt.tight_layout(); plt.show()

```

Output:

```

N Musclcd Mario = 300
N Weak Luigi    = 500

```

(b) **Lo stimatore della media.** Con i dati raggruppati in tabella di frequenze, lo stimatore non distorto della media è la media campionaria pesata:

$$\bar{X}_n = \frac{1}{N} \sum_{i=1}^n x_i f_i = \sum_{i=1}^n p_i x_i.$$

```

1 def media_pesata(x, f):
2     return np.sum(x * f) / f.sum()
3
4 for nome, f, s2 in [("Musclcd Mario", mm, 5.0), ("Weak Luigi", wl, 3.0)]:
5     n = f.sum()
6     xbar = media_pesata(pesi, f)
7     var_emp = np.sum(f*(pesi - xbar)**2) / (n - 1)    # varianza campionaria
8     print(f"{nome}: N={n:.0f}")
9     print(f"    media campionaria = {xbar:.4f} kg")
10    print(f"    varianza campionaria (N-1) = {var_emp:.4f}    "
11          f"(il testo assume sigma^2 = {s2})")

```

Output:

```

Musclcd Mario: N=300
    media campionaria = 45.8500 kg
    varianza campionaria (N-1) = 83.3052    (il testo assume sigma^2 = 5.0)
Weak Luigi: N=500
    media campionaria = 46.9400 kg
    varianza campionaria (N-1) = 133.6036    (il testo assume sigma^2 = 3.0)

```

(c) **L'intervallo di confidenza.** La varianza è *data dal testo*, quindi si usa la variabile ausiliaria normale e il quantile $\varphi_{1-\alpha/2} = \varphi_{0.975} = 1.9600$:

$$I_\mu = \left[\bar{X}_n - \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2}, \quad \bar{X}_n + \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2} \right] \quad \text{con } \sigma = \sqrt{\sigma^2}.$$

```

1 from scipy import stats
2 alpha = 0.05
3 z = stats.norm.ppf(1 - alpha/2)
4 print(f"phi_(1-alpha/2) = phi_0.975 = {z:.4f}")
5
6 for nome, f, s2 in [("Musclcd Mario", mm, 5.0), ("Weak Luigi", wl, 3.0)]:
7     n = f.sum(); xbar = media_pesata(pesi, f)
8     se = np.sqrt(s2 / n)    # errore standard della media
9     print(f"{nome}: IC95% = [{xbar - z*se:.4f}, {xbar + z*se:.4f}]")
10    print(f"    (semilarghezza {z*se:.4f})")

```

Output:

```

phi_(1-alpha/2) = phi_0.975 = 1.9600

```

Muscled Mario: IC95% = [45.5970, 46.1030] (semilarghezza 0.2530)
 Weak Luigi: IC95% = [46.7882, 47.0918] (semilarghezza 0.1518)

(d) Il confronto fra le due medie. Il testo chiede se la media di Muscled Mario sia *più bassa*: è un test **unilaterale sinistro**

$$H_0 : \mu_{MM} = \mu_{WL} \quad \text{contro} \quad H_1 : \mu_{MM} < \mu_{WL}.$$

Le due popolazioni sono indipendenti e le varianze sono note, quindi la variabile ausiliaria degli appunti è

$$Z_n = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim \mathcal{N}(0, 1).$$

```

1 n1, n2 = mm.sum(), wl.sum()
2 m1, m2 = media_pesata(pesi, mm), media_pesata(pesi, wl)
3 s1, s2 = 5.0, 3.0 # varianze ASSEGNATE dal testo
4
5 z_stat = (m1 - m2) / np.sqrt(s1/n1 + s2/n2)
6 critico = stats.norm.ppf(alpha) # unilaterale sx -> phi_alpha
7 p_value = stats.norm.cdf(z_stat)
8
9 print(f"z = ({m1:.4f} - {m2:.4f}) / sqrt({s1}/{n1:.0f} + {s2}/{n2:.0f})")
10 print(f"z = {z_stat:.4f}")
11 print(f"valore critico phi_0.05 = {critico:.4f}")
12 print(f"p-value = Phi(z) = {p_value:.3e}")
13 print(f"si rigetta H0? {z_stat < critico}")

```

Output:

```

z = (45.8500 - 46.9400) / sqrt(5.0/300 + 3.0/500)
z = -7.2399
valore critico phi_0.05 = -1.6449
p-value = Phi(z) = 2.245e-13
si rigetta H0? True

```

Conclusione. $z = -7.24$ è molto minore del valore critico -1.6449 (e il p -value è dell'ordine di 10^{-13}): si **rigetta** H_0 . Sì, si può affermare con confidenza al 95% che la media dei pesi di “Muscled Mario” (45.85 kg) è **più bassa** di quella di “Weak Luigi” (46.94 kg). Da aggiungere nel commento: la differenza è statisticamente significativa ma *piccola in pratica* (circa 1.09 kg), quindi il risultato dice che l'effetto è reale, non che sia grande.

La conclusione dipende dalle varianze *assunte*

Se al posto di $\sigma^2 = 5$ e $\sigma^2 = 3$ si usassero le varianze empiriche (83.31 e 133.60, molto più grandi), la statistica diventerebbe $z = -1.48$ con $p = 0.070$ e **non** si rigetterebbe H_0 al 5%. Il testo *impone* le varianze, quindi la risposta corretta è quella sopra (rigettare). Ma vale la pena notarlo: le varianze assunte sono molto più piccole di quelle osservate, ed è questo che rende il test così netto. È anche il motivo per cui l'intervallo del punto (c) risulta strettissimo (± 0.25 kg) pur con dati che hanno scarto ≈ 9 kg.

Esercizio 2 — I farmaci: z -test unilaterale (29/04/26 — Quesito 2)

Una fabbrica produce farmaci con concentrazione di principio attivo (mg/l) che segue una normale di media $\mu = 5.4$ e scarto quadratico medio $\sigma = 1.0$. Su un campione di $N = 25$ flaconi si misura una concentrazione media $m = 5.0$, e si sospetta che la concentrazione attualmente prodotta sia **minore** di quella prevista.

- a) Formulare esplicitamente l'ipotesi nulla e l'ipotesi alternativa.
- b) Fissato un livello di significatività del 5%, possiamo rigettare l'ipotesi nulla?
- c) Qual è il p -value associato al rigetto dell'ipotesi?
- d) Graficare la distribuzione attesa della media di un campione di dimensione $N = 25$, in base a μ e σ dati.

Svolgimento. (a) Le ipotesi. Il sospetto è che la concentrazione sia *calata*, quindi l'alternativa è unilaterale sinistra:

$$H_0 : \mu = 5.4 \quad \text{contro} \quad H_1 : \mu < 5.4.$$

σ è nota (il testo la dà), quindi si usa lo z -test.

(b–c) La statistica e il p -value. La variabile ausiliaria degli appunti è $Z_n = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{N}}$, e qui $\bar{X}_n = m = 5.0$.

```

1 import numpy as np
2 from scipy import stats
3
4 mu0, sigma, N, m = 5.4, 1.0, 25, 5.0
5 alpha = 0.05
6
7 z = (m - mu0) / (sigma / np.sqrt(N))
8 critico = stats.norm.ppf(alpha)      # unilaterale sinistro -> phi_alpha
9 p_value = stats.norm.cdf(z)         # p-value = Phi(z)
10
11 print(f"z = ({m} - {mu0}) / ({sigma}/sqrt({N})) = {z:.4f}")
12 print(f"valore critico phi_0.05 = {critico:.4f}")
13 print(f"si rigetta H0? {z < critico} (z={z:.4f} < {critico:.4f})")
14 print(f"p-value = Phi(z) = {p_value:.5f}")
15 print(f"si rigetta H0 con alpha={alpha}? {p_value < alpha}")

```

Output:

```

z = (5.0 - 5.4) / (1.0/sqrt(25)) = -2.0000
valore critico phi_0.05 = -1.6449
si rigetta H0? True (z=-2.0000 < -1.6449)
p-value = Phi(z) = 0.02275
si rigetta H0 con alpha=0.05? True

```

Conclusione. $z = -2.00$ cade nella zona di rigetto ($z < \varphi_{0.05} = -1.6449$) e il p -value vale $0.0228 < 0.05$. Si **rigetta** H_0 : c'è evidenza che la concentrazione media sia effettivamente **minore** di 5.4 mg/l.

(d) La distribuzione della media campionaria. Poiché $\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{N}\right)$, con $\mu = 5.4$, $\sigma = 1.0$ e $N = 25$ la media dei 25 flaconi ha media 5.4 e scarto $1/\sqrt{25} = 0.2$.

```

1 import matplotlib.pyplot as plt
2
3 se = sigma / np.sqrt(N)      # 0.2
4 xs = np.linspace(mu0 - 3.5*se, mu0 + 3.5*se, 400)
5 plt.plot(xs, stats.norm.pdf(xs, mu0, se), lw=2, label='N(5.4, 0.2^2)')
6 plt.axvline(m, color='r', ls='--', label=f'media osservata m={m}')
7 zona = xs[xs <= mu0 + critico*se]
8 plt.fill_between(zona, 0, stats.norm.pdf(zona, mu0, se), alpha=0.35,
9                 color='r', label='zona di rigetto (5%)')
10 plt.xlabel('media campionaria'); plt.ylabel('densita')
11 plt.legend(); plt.grid(alpha=0.3); plt.show()

```

Perché lo scarto si divide per $\sqrt{N}$

È la conseguenza di $\text{Var}(\bar{X}_n) = \sigma^2/N$ dimostrata negli appunti nell'interludio della legge dei grandi numeri. Il punto concettuale: la distribuzione della *media* è molto più stretta di quella delle singole osservazioni. Con $\sigma = 1$ un singolo flacone varia molto; la media di 25 flaconi ha scarto 0.2. È questo che rende possibile distinguere una media di 5.0 da una di 5.4: la differenza vale 2 scarti *della media*, non 0.4 scarti della popolazione.

Esercizio 3 — I biscotti sono più grandi di 22 g? (27/01/26 — Quesito 2, punto d)

Con i dati del capitolo 14 ($N = 100$ biscotti, media campionaria 23.69 g, varianza campionaria 6.1555): si può affermare con una confidenza del 95% che i biscotti siano più grandi di 22 g?

Svolgimento. Quale test. Il test non dà la varianza: si stima dai dati, quindi *t-test*. La domanda è direzionale (“più grandi”), quindi unilaterale destro:

$$H_0 : \mu = 22 \quad \text{contro} \quad H_1 : \mu > 22.$$

```

1 import numpy as np
2 from scipy import stats
3
4 peso = np.arange(17, 31, dtype=float)
5 num = np.array([1,1,2,5,8,14,17,18,12,9,5,5,2,1], float)
6 N = num.sum()
7 xbar = np.sum(peso*num)/N
8 s2 = np.sum(num*(peso-xbar)**2)/(N-1)
9 s = np.sqrt(s2)
10
11 mu0, alpha = 22.0, 0.05
12 t_stat = (xbar - mu0) / (s/np.sqrt(N))
13 critico = stats.t.ppf(1 - alpha, N - 1)      # unilaterale dx -> t_(1-alpha)
14 p_value = 1 - stats.t.cdf(t_stat, N - 1)
15
16 print(f"media = {xbar:.4f}, scarto campionario = {s:.4f}, N = {N:.0f}")
17 print(f"t = ({xbar:.4f} - {mu0}) / ({s:.4f}/10) = {t_stat:.4f}")
18 print(f"valore critico t_0.95(99) = {critico:.4f}")
19 print(f"p-value = {p_value:.3e}")
20 print(f"si rigetta H0? {t_stat > critico}")

```

Output:

```

media = 23.6900, scarto campionario = 2.4810, N = 100
t = (23.6900 - 22.0) / (2.4810/10) = 6.8117
valore critico t_0.95(99) = 1.6604
p-value = 3.788e-10
si rigetta H0? True

```

Conclusione. $t = 6.81$ supera largamente il valore critico 1.6604 e il p -value è praticamente nullo: si **rigetta** H_0 . Sì, si può affermare con confidenza del 95% che il peso medio dei biscotti è **maggiore** di 22 g.

Per completezza, l'intervallo di confidenza al 95% per μ (varianza non nota, $t(99)$):

$$I_\mu = \left[23.69 - 1.9842 \cdot \frac{2.4810}{10}, \quad 23.69 + 1.9842 \cdot \frac{2.4810}{10} \right] = [23.198, 24.182].$$

L'intervallo **non contiene** 22 ed è interamente sopra 22: coerente con il test. È sempre così quando il test è bilatero; con un test unilaterale la coincidenza non è garantita.

***t* o *z*? Qui la differenza è piccola, ma la scelta va detta**

Con $N - 1 = 99$ gradi di libertà, $t_{0.95}(99) = 1.6604$ contro $\varphi_{0.95} = 1.6449$: quasi identici. Ma **la scelta va comunque giustificata**, scrivendo “ σ non è nota, quindi uso la t con $N - 1$ gradi di libertà”. Il correttore guarda il ragionamento, non solo il numero.

Esercizio 4 — La probabilità di un ovetto bianco è maggiore di $1/3$? (01/04/26 — Quesito 1, punto d)

Con i dati del capitolo 14: su 200 ovetti complessivi, 67 sono bianchi. È possibile affermare con una confidenza del 95% che la probabilità di trovare un ovetto bianco sia maggiore di $\frac{1}{3}$?

Svolgimento. Il modello. Qui il parametro non è una media ma una **proporzione** p . Sotto H_0 il numero totale di ovetti bianchi è $X \sim \text{Bin}(200, \frac{1}{3})$, con

$$\mathbb{E}[X] = 200 \cdot \frac{1}{3} = 66.67, \quad \sigma_X = \sqrt{200 \cdot \frac{1}{3} \cdot \frac{2}{3}} = 6.67.$$

La domanda è direzionale (“maggiore”), quindi unilaterale destro:

$$H_0 : p = \frac{1}{3} \quad \text{contro} \quad H_1 : p > \frac{1}{3}.$$

```

1 import numpy as np
2 from scipy import stats
3
4 bianchi, tot = 67, 200
5 p0, alpha = 1/3, 0.05
6 p_hat = bianchi / tot
7
8 print(f"p_hat = {bianchi}/{tot} = {p_hat:.6f}")
9 print(f"attesi sotto H0 = {tot*p0:.4f}   (osservati {bianchi})")
10
11 # --- (1) test binomiale ESATTO -----
12 p_esatto = stats.binom.sf(bianchi - 1, tot, p0)      # P(X >= 67)
13 print(f"p-value esatto = P(X >= {bianchi}) = {p_esatto:.6f}")
14
15 # --- (2) approssimazione normale (test z per proporzioni) -----
16 z = (p_hat - p0) / np.sqrt(p0*(1-p0)/tot)
17 critico = stats.norm.ppf(1 - alpha)                  # unilaterale dx
18 p_norm = 1 - stats.norm.cdf(z)
19 print(f"z = {z:.4f},   critico phi_0.95 = {critico:.4f}")
20 print(f"p-value normale = {p_norm:.4f}")

```

Output:

```

p_hat = 67/200 = 0.335000
attesi sotto H0 = 66.6667   (osservati 67)
p-value esatto = P(X >= 67) = 0.506637
z = 0.0500,   critico phi_0.95 = 1.6449
p-value normale = 0.4801

```

Conclusione. Il valore osservato 67 è praticamente *sulla media* attesa sotto H_0 (66.67): la statistica z vale appena 0.05. Il p -value è ≈ 0.51 (esatto) o ≈ 0.48 (normale), enormemente maggiore di 0.05: **non si rigetta H_0** . Al livello del 95% **non possiamo affermare** che la probabilità di trovare un ovetto bianco sia maggiore di $\frac{1}{3}$.

Le due versioni del test, e quale scegliere

- Il **test binomiale esatto** (`stats.binom.sf`) è sempre valido e va usato quando N non è grande. Qui $N = 200$, quindi si può usare senza problemi.
- L'**approssimazione normale** è quella che sta negli appunti ($Z_n = \frac{\hat{p}-p_0}{\sqrt{p_0(1-p_0)/N}}$) ed è lecita perché $Np_0 = 66.7 \geq 5$ e $N(1-p_0) = 133.3 \geq 5$: sono esattamente le due condizioni scritte negli appunti.
- I due p -value (0.51 e 0.48) sono vicini e portano alla **stessa conclusione**. Citare entrambi è il modo migliore di rispondere: mostra di sapere che esistono due strade e che coincidono.

La risposta sbagliata

È “no, quindi $p = \frac{1}{3}$ ”. Non rigettare H_0 **non** significa che H_0 sia vera. La forma corretta è: *non c'è evidenza sufficiente per affermare che $p > \frac{1}{3}$* . È il punto (d) del compito, e vale da solo diversi punti.

Collegamento con il resto del quesito

Nello stesso compito il punto (c) chiedeva gli stimatori delle tre probabilità, e si erano ottenute $\hat{p}_{\text{fondente}} = 0.340$, $\hat{p}_{\text{latte}} = 0.325$, $\hat{p}_{\text{bianco}} = 0.335$: tutte vicine a $\frac{1}{3}$. Questa è la conferma numerica della conclusione: le tre frequenze sono così vicine tra loro che non c'è evidenza di uno sbilanciamento verso il bianco.

Esercizio 5 — Come cambia un intervallo di confidenza al variare di N , σ e α

(23/06/26 — Teoria, Quesito 1)

Si consideri l'intervallo di confidenza per la media con varianza nota, $I_\mu = [\bar{X}_n - \varepsilon_\mu, \bar{X}_n + \varepsilon_\mu]$ con $\varepsilon_\mu = \frac{\sigma}{\sqrt{N}}\varphi_{1-\alpha/2}$. Rappresentarlo graficamente e commentare come cambiano i suoi estremi al variare di N , σ e α .

Svolgimento. La semilarghezza. Tutto dipende da un'unica quantità, $\varepsilon_\mu = \frac{\sigma}{\sqrt{N}}\varphi_{1-\alpha/2}$, che è il *marginale di errore*.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy import stats
4
5 mu_hat, se = 10.0, 0.5          # stima e errore standard (sigma/sqrt(N))
6
7 # --- (1) il disegno dell'intervallo -----
8 z = stats.norm.ppf(0.975)
9 xs = np.linspace(mu_hat - 4*se, mu_hat + 4*se, 400)
10 plt.plot(xs, stats.norm.pdf(xs, mu_hat, se), lw=2)
11 plt.fill_between(xs, 0, stats.norm.pdf(xs, mu_hat, se),
12                 where=np.abs(xs - mu_hat) <= z*se, alpha=0.3,
13                 label=f'IC 95% = [{mu_hat - z*se:.2f}, {mu_hat + z*se:.2f}]')
14 plt.axvline(mu_hat, color='k', ls=':', label='stima')
15 plt.xlabel('x'); plt.legend(); plt.grid(alpha=0.3); plt.show()
16
17 # --- (2) al variare di alpha -----
18 print("alpha  phi_(1-a/2)  semilarghezza")
19 for a in [0.10, 0.05, 0.01]:
20     zz = stats.norm.ppf(1 - a/2)
21     print(f"{a:.2f}    {zz:.4f}    {zz*se:.4f}")
22

```

```

23 # --- (3) al variare di N -----
24 print("\nN      sigma/sqrt(N)      semilarghezza (alpha=0.05)")
25 for n in [25, 100, 400]:
26     print(f"{n:>4}      {1/np.sqrt(n):.4f}      {1.96/np.sqrt(n):.4f}")

```

Output:

alpha	phi_(1-a/2)	semilarghezza
0.10	1.6449	0.8224
0.05	1.9600	0.9800
0.01	2.5758	1.2879

N	sigma/sqrt(N)	semilarghezza (alpha=0.05)
25	0.2000	0.3920
100	0.1000	0.1960
400	0.0500	0.0980

Il commento da scrivere. La semilarghezza è $\varphi_{1-\alpha/2}\sigma/\sqrt{N}$, quindi:

- **N cresce** $\Rightarrow$ l'intervallo si *restringe* proporzionalmente a $1/\sqrt{N}$. Quadruplicando N (da 25 a 100) la semilarghezza si **dimezza** ($0.392 \rightarrow 0.196$): più dati danno una stima più precisa, ma con rendimenti decrescenti — per dimezzare ancora l'errore servono altre quattro volte i dati.
- **σ cresce** $\Rightarrow$ l'intervallo si *allarga linearmente*. Più variabilità nella popolazione significa meno informazione in ogni osservazione, quindi più incertezza.
- **α diminuisce** (più confidenza, per esempio dal 95% al 99%) $\Rightarrow \varphi_{1-\alpha/2}$ cresce ($1.9600 \rightarrow 2.5758$) e l'intervallo si *allarga* del 31.4%. Maggiore confidenza si paga con minore precisione: è un compromesso, non un miglioramento.

Il numero che rende concreta la risposta

Passando dal 95% al 99% la semilarghezza va da 0.9800 a 1.2879, cioè cresce del 31.4%. Con la t di Student a 24 gradi di libertà lo stesso passaggio è ancora più caro: da $t_{0.975}(24) = 2.0639$ a $t_{0.995}(24) = 2.7969$, cioè il 35.5% in più. Citare il numero preciso invece della frase generica “l'intervallo si allarga” è ciò che distingue una risposta completa.

Capitolo 17

Monte Carlo e integrazione

Il metodo Monte Carlo compare in **tre prove su nove**, sempre come secondo quesito di Laboratorio: 24/03/25 (integrale di una gaussiana troncata), 02/09/25 (funzione bimodale) e 01/04/26 ($\int_0^1 xe^x dx$, hit or miss e rigetto). Le tre prove chiedono sempre le stesse quattro cose: **(1)** dire se il metodo è applicabile, **(2)** stimare l'integrale, **(3)** plottare la stima al crescere di N , **(4)** commentare la precisione.

Chiesto in: 24/03/25 Q2 (gaussiana troncata, $\sigma = 4$ e $\sigma = 0.5$); 02/09/25 Q2 (funzione bimodale, i due quadrati); 01/04/26 Q2 (xe^x , hit or miss e rigetto). La parte su numeri pseudorandom e metodo dell'inversione è del 02/09/25 *Teoria*, Q2: la teoria sta nel Cap. 8, qui c'è la pratica.

17.1 Hit or miss: quando si può usare

Le tre ipotesi del metodo hit or miss

Per stimare $I = \int_a^b f(x) dx$ con l'hit or miss servono *tutte e tre*:

1. f è **non negativa** su $[a, b]$: $f(x) \geq 0$;
2. $[a, b]$ è **limitato** e f è **limitata** su $[a, b]$;
3. si conosce un **maggiorante** $M \geq \max_{x \in [a, b]} f(x)$, e quindi il rettangolo $[a, b] \times [0, M]$ contiene la regione sotto la curva.

Se f cambia segno, si spezza l'intervallo nelle zone in cui f ha segno costante e si stimano separatamente, cambiando segno alle zone negative.

La risposta da scrivere al punto “è possibile applicarlo?”

Il quesito 01/04/26 comincia esattamente così: “È possibile utilizzare il metodo hit or miss per calcolarlo?”. La risposta completa è:

Sì. $f(x) = xe^x$ è continua e non negativa su $[0, 1]$ (prodotto di $x \geq 0$ e $e^x > 0$), l'intervallo è limitato, e f è crescente su $[0, 1]$ perché $f'(x) = (x+1)e^x > 0$, quindi il massimo è nell'estremo destro: $M = f(1) = e \approx 2.718$. Il rettangolo $[0, 1] \times [0, e]$ contiene la regione sotto la curva e il metodo è applicabile.

Il punto chiave è che va **dimostrato che il massimo sta in $x = 1$** , non affermato. Il compito lo suggerisce (“il massimo della funzione integranda si ha in $x = 1$ ”) ma la derivata va scritta.

17.2 L'errore della stima: la formula che decide tutto

Varianza dello stimatore hit or miss

Sia $A = (b - a)M$ l'area del rettangolo e $p = I/A$ la frazione di esso sotto la curva. Si generano N punti uniformi nel rettangolo e si conta quanti cadono sotto la curva: $\hat{p} = H/N$.

Allora

$$\hat{I} = A\hat{p}, \quad \text{Var}(\hat{I}) = A^2 \frac{p(1-p)}{N} = \frac{I(A-I)}{N}, \quad \text{SE}(\hat{I}) = \sqrt{\frac{I(A-I)}{N}}.$$

La seconda forma è quella da ricordare: la varianza dipende solo dall'integrale I e dall'area A del rettangolo. A parità di I , l'unico modo di ridurre la varianza è **ridurre** A , cioè scegliere il rettangolo più aderente possibile alla curva.

Perché M non va scelto “grande per sicurezza”

Lo stimatore $\hat{I} = A\hat{p}$ resta *non distorto* per qualunque $M \geq \max f$ — quindi non si sbaglia la stima — ma la varianza cresce. Con M troppo grande il rettangolo ha molta area “vuota”, p diventa piccolo, e $p(1-p)$ peggiora. Il caso limite opposto (M troppo piccolo) è peggio: se $M < \max f$ il rettangolo *non contiene* la regione e la stima è **distorta**, non solo imprecisa.

Morale: $M = \max_{[a,b]} f$ **esatto**. Il 24/03/25 dà il suggerimento “il massimo della funzione è in $x = 0$ ”, e nel 01/04/26 “in $x = 1$ ”: servono entrambi.

17.3 Il metodo del rigetto

Serve a una cosa diversa dall'hit or miss: non stimare un integrale, ma **generare numeri casuali** con densità f assegnata.

Metodo del rigetto

Sia g una densità “comoda” da campionare (tipicamente $\mathcal{U}(0,1)$) e M una costante con $f(x) \leq M g(x)$ per ogni x . L'algoritmo è:

1. si genera $Y \sim g$ e $U \sim \mathcal{U}(0,1)$ *indipendenti*;
2. se $U \leq \frac{f(Y)}{M g(Y)}$ si **accetta** Y , altrimenti si **rigetta** e si riprova.

I valori accettati sono una successione di variabili aleatorie con densità f . La probabilità di accettazione vale $1/M$: il numero medio di tentativi per un'accettazione è M .

```

1 import numpy as np
2
3 def rigetto(n, f, M, g_rvs, g_pdf, seme=0):
4     """Genera n valori con densita' f usando la densita' comoda g (f <= M*g)."""
5     rng, out, tentativi = np.random.default_rng(seme), [], 0
6     while len(out) < n:
7         y = g_rvs(rng)
8         tentativi += 1
9         if rng.uniform() <= f(y) / (M * g_pdf(y)):
10             out.append(y)
11     return np.array(out), tentativi
12
13 f = lambda x: x * np.exp(x) # densita' (vedi esercizio 01/04/26)
14 M = np.e # max di xe^x su [0,1]
15 campione, tentativi = rigetto(1000, f, M,
16                               lambda rng: rng.uniform(0, 1), lambda x: 1.0, seme=42)
17 print(f"accettazione = {1000/tentativi:.4f} (teorica 1/M = {1/M:.4f})")

```

```
18 print(f"media campionaria = {campione.mean():.4f}")
```

$f(y)/(M \cdot g(y))$ deve stare in $[0, 1]$

Se il rapporto supera 1 per qualche valore, M è troppo piccolo e la disuguaglianza $f \leq Mg$ è violata: il metodo è *sbagliato*, non solo inefficiente. Va sempre verificato numericamente:

```
1 xs = np.linspace(0, 1, 1000)
2 print("max rapporto:", max(f(x)/(M*1.0) for x in xs)) # deve essere <= 1
```

Il valore ottimale di M è $\max_x f(x)/g(x)$: la probabilità di accettazione è $1/M$, quindi sceglierlo più grande del necessario rende il metodo più lento senza alcun vantaggio. Con $f(x) = xe^x$ su $[0, 1]$ e $g = \mathcal{U}(0, 1)$ si ha $M = e$ e quindi $\mathbb{P}(\text{accettare}) = 1/e \approx 0.368$: si scarta il 63% dei tentativi.

Rigetto e hit or miss sono lo stesso meccanismo

L'hit or miss è il rigetto visto dall'altro lato. Nell'hit or miss si genera (X, Y) uniforme nel rettangolo e si accetta il punto se $Y \leq f(X)$: la distribuzione delle X accettate è proporzionale a f . Nel rigetto si fa la stessa cosa ma si tiene solo la Y (la coordinata "orizzontale"). È il motivo per cui nei due metodi la frazione di accettazione ha la stessa forma I/A e $1/M$.

17.4 Esercizi svolti

Esercizio 1 — La gaussiana troncata, con $\sigma = 4$ e $\sigma = 0.5$ (24/03/25 — Quesito 2)

- Sotto quali ipotesi posso utilizzare il metodo hit or miss per valutare un integrale?
- Se possibile, utilizzare il metodo hit or miss per calcolare

$$I = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-2}^2 e^{-\frac{x^2}{2\sigma^2}} dx.$$

Utilizzare $N = 10000$ e $\sigma = 4$. (hint: il massimo della funzione è in $x = 0$)

- Graficare il valore dell'integrale al crescere di N e confrontarlo con il valore teorico.
- Ripetere la simulazione per $\sigma = 0.5$ e commentare se è cambiato qualcosa.

Svolgimento. (a) Le ipotesi. Le tre del riquadro precedente: $f \geq 0$, intervallo e funzione limitati, maggiorante M noto. Qui $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-x^2/(2\sigma^2)}$ è una densità normale centrata in 0: è positiva, limitata, e sull'intervallo $[-2, 2]$ il massimo è in $x = 0$ (lo dice il suggerimento), con

$$M = f(0) = \frac{1}{\sqrt{2\pi\sigma^2}}.$$

(b–c) Il caso $\sigma = 4$. L'integrale è *esattamente* la probabilità che una normale standard cada in $(-2/\sigma, 2/\sigma)$:

$$I = \mathbb{P}\left(-\frac{2}{\sigma} < Z < \frac{2}{\sigma}\right) = \Phi\left(\frac{2}{\sigma}\right) - \Phi\left(-\frac{2}{\sigma}\right).$$

Con $\sigma = 4$: $2/\sigma = 0.5$, quindi $I = \Phi(0.5) - \Phi(-0.5) = 0.382925$.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy import stats
4
```

```

5 def hit_or_miss_gauss(sigma, N, seme=7):
6     a, b = -2.0, 2.0
7     M = 1/np.sqrt(2*np.pi*sigma**2)          # f(0): il massimo
8     rng = np.random.default_rng(seme)
9     x = rng.uniform(a, b, N)
10    y = rng.uniform(0, M, N)
11    f = np.exp(-x**2/(2*sigma**2))/np.sqrt(2*np.pi*sigma**2)
12    p = (y <= f).mean()
13    return (b - a) * M * p, p
14
15 for sigma in (4.0, 0.5):
16     M = 1/np.sqrt(2*np.pi*sigma**2)
17     esatto = stats.norm.cdf(2/sigma) - stats.norm.cdf(-2/sigma)
18     p_teo = esatto/(4*M)
19     se_teo = np.sqrt((4*M)**2 * p_teo*(1-p_teo)/N)   # N = 10000
20     print(f"--- sigma = {sigma} ---")
21     print(f"M = f(0) = {M:.6f}   I esatto = {esatto:.6f}   p_teorico = {p_teo:.6f}")
22     print(f"SE teorico con N=10000: {se_teo:.6f}")
23     for N in (1000, 10000, 100000):
24         stima, p = hit_or_miss_gauss(sigma, N)
25         print(f"    N={N:>6}: stima={stima:.6f} errore={stima-esatto:+.6f} "
26               f"accettazione={p:.4f}")
27
28 # --- (c) la stima al crescere di N -----
29 rng = np.random.default_rng(1)
30 Nmax = 100000
31 x = rng.uniform(-2, 2, Nmax)
32 y = rng.uniform(0, 1/np.sqrt(2*np.pi*16), Nmax)
33 f = np.exp(-x**2/32)/np.sqrt(2*np.pi*16)
34 dentro = (y <= f)
35 stima_cum = 4*(1/np.sqrt(2*np.pi*16))*np.cumsum(dentro)/np.arange(1, Nmax+1)
36 asse = np.arange(1, Nmax+1)
37 plt.loglog(asse, np.abs(stima_cum - 0.382925), lw=1, label='errore assoluto')
38 plt.loglog(asse, 0.000783*np.sqrt(10000/asse), 'r--', label=r'$1/\sqrt{N}$')
39 plt.xlabel('N'); plt.ylabel('errore'); plt.legend(); plt.grid(alpha=.3, which='both')
40 plt.show()

```

Output:

```

--- sigma = 4.0 ---
M = f(0) = 0.099736   I esatto = 0.382925   p_teorico = 0.959850
SE teorico con N=10000: 0.000783
N= 1000: stima=0.381788 errore=-0.001137 accettazione=0.9570
N= 10000: stima=0.383822 errore=+0.000897 accettazione=0.9621
N=100000: stima=0.383200 errore=+0.000275 accettazione=0.9605
--- sigma = 0.5 ---
M = f(0) = 0.797885   I esatto = 0.999937   p_teorico = 0.313309
SE teorico con N=10000: 0.014804
N= 1000: stima=0.992568 errore=-0.007368 accettazione=0.3110
N= 10000: stima=0.973419 errore=-0.026517 accettazione=0.3050
N=100000: stima=0.995856 errore=-0.004081 accettazione=0.3120

```

(c) **Il commento sulla crescita in N .** La stima oscilla attorno al valore esatto e le oscillazioni si restringono. In scala log-log l'errore assoluto segue una retta di pendenza $-1/2$: l'errore va come $1/\sqrt{N}$. Con $\sigma = 4$ l'errore standard è 0.000783 a $N = 10000$, e gli errori osservati (-0.0011 , $+0.0009$, $+0.0003$) valgono 1.5, 1.1 e 0.35 errori standard: tutti compatibili.

(d) **Che cosa cambia con $\sigma = 0.5$.** Molto, e in peggio. Il confronto numerico:

	$\sigma = 4$	$\sigma = 0.5$
I esatto	0.382925	0.999937
$M = f(0)$	0.099736	0.797885
area del rettangolo $A = 4M$	0.398942	3.191539
$p = I/A$ (accettazione)	0.9599	0.3133
$\text{Var}(\hat{I}) = I(A - I)$ per unità di N	0.006133	2.191463
$\text{SE}(\hat{I})$ con $N = 10\,000$	0.000783	0.014804

Con $\sigma = 0.5$ la varianza è **357 volte** più grande e l'errore standard **18.9 volte** più grande ($\sqrt{357} \approx 18.9$). Per ottenere la stessa precisione del caso $\sigma = 4$ servirebbero circa 357 volte i punti.

La spiegazione, non solo il numero

Il rettangolo ha area $A = 4 \cdot M = 4 \cdot f(0)$. Con $\sigma = 4$ la funzione è **piatta** su $[-2, 2]$: f varia da 0.0997 in 0 a $0.0997 e^{-0.125} = 0.0880$ agli estremi, cioè appena il 12%. Il rettangolo “aderisce” alla curva e $p = 0.96$: quasi tutti i punti cadono sotto. Con $\sigma = 0.5$ la funzione è una **guglia**: a $x = \pm 2$ siamo a 4 scarti standard e f è scesa a $f(0)e^{-8} = 0.00027$, cioè lo 0.03% del massimo. Il rettangolo è quasi tutto vuoto, p crolla a 0.31 e la varianza esplode. **La lezione:** l'hit or miss è efficiente quando il rettangolo *aderisce* alla funzione. Il numero da guardare è $p = I/A$; un p vicino a 1 significa stima precisa, un p piccolo significa spreco di punti.

Il caso $\sigma = 0.5$ ha anche un valore “speciale”

$I = 0.999937$: con $\sigma = 0.5$ l'intervallo $[-2, 2]$ copre ± 4 scarti standard, e la normale standard ha lì dentro praticamente tutta la sua massa. L'integrale richiesto è quindi ≈ 1 *per costruzione*, non per un caso: il quesito lo sceglie proprio per mostrare che un integrale “facile” (vicino a 1) può essere *difficile* da stimare con l'hit or miss.

Esercizio 2 — La funzione bimodale e il trucco dei due quadrati (02/09/25 — Quesito 2)

Si consideri $f(x) = e^{-(x-6)^2} + e^{-(x+6)^2}$.

- Fare il grafico per $x \in [-10, 10]$. Spiegare perché è possibile applicare il metodo hit or miss per calcolare $\int_{-10}^{10} f(x) dx$.
- Calcolare l'integrale e plottare il valore ottenuto in funzione del numero di dati generati.
- Calcolare l'integrale applicando l'hit or miss *nei due quadrati* come in figura, e plottare il valore ottenuto in funzione di N . (hint: ho davvero bisogno di calcolarlo due volte? La figura è simmetrica!)
- Confrontare i due risultati in termini di **precisione** e **velocità** dell'algoritmo.

Svolgimento. (a) Applicabilità. f è somma di due gaussiane non normalizzate, quindi è **positiva**, **continua** e **limitata**. Il massimo globale è in $x = 6$ (e per simmetria anche in $x = -6$), dove il secondo termine è trascurabile (e^{-144}):

$$M = f(6) = e^0 + e^{-144} \approx 1.000000.$$

Il rettangolo $[-10, 10] \times [0, 1]$ contiene la regione sotto la curva: il metodo è applicabile. Da notare che $f(0) = 2e^{-36} \approx 4.6 \times 10^{-16}$, cioè f è *praticamente nulla* al centro: la funzione è **bimodale** e il rettangolo ha una zona morta enorme attorno a $x = 0$.




Figura 17.1: La funzione del 02/09/25. A sinistra il rettangolo unico $[-10, 10] \times [0, 1]$: la zona attorno a $x = 0$ è morta, f vi vale 4.6×10^{-16} , eppure contribuisce alla varianza. A destra i due quadrati “stretti” $[-10, -2]$ e $[2, 10]$ che la traccia richiama con “*come in figura*”: contengono praticamente tutta la massa di f con area 16 invece di 20. È questa riduzione di area — non la simmetria in sé — a far scendere $\text{Var} \cdot N$ da 58.33 a 44.15.

Il valore esatto. Con la sostituzione $u = x - 6$ (e analogamente a sinistra), $\int_{-\infty}^{\infty} e^{-u^2} du = \sqrt{\pi}$, quindi

$$I = \int_{-10}^{10} f(x) dx \approx 2 \int_{-\infty}^{\infty} e^{-u^2} du = 2\sqrt{\pi} = 3.544908.$$

(b–c) Le due strategie.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import quad
4
5 f = lambda x: np.exp(-(x-6)**2) + np.exp(-(x+6)**2)
6 esatto = quad(f, -10, 10)[0]
7 print(f"I esatto = {esatto:.6f}    (2*sqrt(pi) = {2*np.sqrt(np.pi):.6f})")
8
9 def cumulativa(N, seme=4):
10     """Stima cumulativa su TUTTO il rettangolo [-10,10] x [0,1], area 20."""
11     rng = np.random.default_rng(seme)
12     x = rng.uniform(-10, 10, N); y = rng.uniform(0, 1, N)
13     return 20 * np.cumsum(y <= f(x)) / np.arange(1, N + 1)
14
15 def cumulativa_meta(N, seme=4):
16     """Stima cumulativa su UN solo quadrato [2,10] x [0,1] (area 8), raddoppiata.
17
18     Il quadrato e' quello 'stretto' della figura: a sinistra di x=2 la funzione
19     e' dell'ordine di 1e-16, quindi includerla nell'area non aggiunge segnale,
20     aggiunge solo varianza.
21     """
22     rng = np.random.default_rng(seme)
23     x = rng.uniform(2, 10, N); y = rng.uniform(0, 1, N)
24     return 2 * 8 * np.cumsum(y <= f(x)) / np.arange(1, N + 1)
25
26 N = 100000
27 a, c = cumulativa(N), cumulativa_meta(N)
28 print(f"N={N}: un rettangolo [-10,10] -> {a[-1]:.6f}    errore {a[-1]-esatto:+.6f}")
29 print(f"N={N}: un quadrato x2 [2,10] -> {c[-1]:.6f}    errore {c[-1]-esatto:+.6f}")
30 print(f"varianza per punto: rettangolo {esatto*(20-esatto):.4f}"
31       f"    quadrati {4*1.772454*(8-1.772454):.4f}")
32
33 asse = np.arange(1, N + 1)
34 plt.loglog(asse, np.abs(a - esatto), lw=1, label='un rettangolo [-10,10]')
35 plt.loglog(asse, np.abs(c - esatto), lw=1, label='un quadrato [2,10], raddoppiato')
```

```

36 plt.xlabel('N'); plt.ylabel('errore assoluto'); plt.legend()
37 plt.grid(alpha=.3, which='both'); plt.show()

```

Output:

```

I esatto = 3.544908    (2*sqrt(pi) = 3.544908)
N=100000: un rettangolo [-10,10] -> 3.568600    errore +0.023692
N=100000: un quadrato x2  [2,10]  -> 3.530880    errore -0.014028
varianza per punto: rettangolo 58.3318    quadrati 44.1522

```

(d) **Il confronto, che è la parte che vale i punti.** Bisogna distinguere *due* modi di usare la simmetria, e il quesito li confonde apposta.

Strategia	area A	lavoro	$\text{Var}(\hat{I}) \cdot N$
un rettangolo $[-10, 10] \times [0, 1]$, N punti	20	N punti	$I(A - I) = 58.33$
due quadrati stretti, $N/2$ punti ciascuno	$8 + 8$	N punti	$4 \cdot I'(A' - I') = 44.15$
un solo quadrato, N punti, raddoppiato	8	N punti	$4 \cdot I'(A' - I') = \mathbf{44.15}$

dove $I' = I/2 = 1.772454$ è l'integrale su *un* quadrato e $A' = 8$ è la sua area. Il fattore 4 della terza riga è il raddoppio al quadrato: se $\hat{I}'$ ha varianza $I'(A' - I')/N$, allora $2\hat{I}'$ ha varianza $4I'(A' - I')/N$. Le tre righe si leggono così:

- **il guadagno vero viene dall'area, non dalla simmetria.** Il rettangolo $[-10, 10] \times [0, 1]$ ha una zona morta enorme attorno a $x = 0$ ($f(0) \approx 4.6 \times 10^{-16}$): l'area lì vale 20 e non produce mai un "hit". Restrignendo ai due quadrati l'area totale scende da 20 a 16, e $\text{Var} \cdot N$ da 58.33 a 44.15: l'errore standard cala di un fattore $\sqrt{44.15/58.33} \approx 0.87$, cioè circa il 13% in meno;
- **calcolare davvero entrambi i quadrati non aggiunge nulla.** Con $N/2$ punti per quadrato si ottiene $44.15/N$, *esattamente* la stessa varianza di un solo quadrato con tutti gli N punti e raddoppiato. La simmetria serve a questo: a *evitare di scrivere due volte lo stesso ciclo*, non a migliorare la stima. È il senso dell'hint "*ho davvero bisogno di calcolarlo due volte?*".

La frase da scrivere nel compito:

Il guadagno rispetto al rettangolo unico non viene dalla simmetria in sé, ma dal restringere l'area ai due quadrati dove la funzione è effettivamente diversa da zero: $\text{Var} \cdot N$ passa da 58.33 a 44.15 (l'errore standard cala di circa il 13%). La simmetria serve invece a lavorare su un solo quadrato: calcolarne uno con tutti gli N punti e raddoppiare dà la stessa varianza di calcolarne due con $N/2$ punti ciascuno, con metà del codice e senza mai valutare f a sinistra di $x = 2$. In velocità, quindi, la versione simmetrica costa la metà delle valutazioni di f per la stessa precisione.

L'errore concettuale da non scrivere

"La simmetria dimezza la varianza" **non** è una frase corretta. La si verifica subito prendendo come "quadrato" il mezzo rettangolo $[0, 10] \times [0, 1]$ invece di quello stretto $[2, 10] \times [0, 1]$: lì $A' = 10$ e $\text{Var}(2\hat{I}') = 4I'(A' - I')/N = 58.3318/N$, *identica* al rettangolo intero. Con l'area giusta il fattore è $44.15/58.33 \approx 0.76$, non 0.5. La simmetria, da sola, non riduce niente: è la riduzione dell'area che riduce la varianza.

Perché la formula $I(A - I)/N$ è comoda qui

Non serve calcolare p né M : basta conoscere I e A . Per il rettangolo unico $I(A - I) = 3.544908 \times 16.455092 = 58.3318$. Per il singolo quadrato $I'(A' - I') = 1.772454 \times 6.227546 = 11.0380$, e moltiplicando per 4 (perché il raddoppio quadruplica la varianza) si trova 44.1522. È un buon controllo di coerenza da fare a mano.

Esercizio 3 — $\int_0^1 xe^x dx$: **hit or miss e rigetto** (01/04/26 — Quesito 2)

- a) Si consideri l'integrale $I = \int_0^1 xe^x dx$. È possibile utilizzare il metodo hit or miss per calcolarlo?
 b) Calcolare l'integrale con l'hit or miss usando $n = 1000$ e plottare il valore ottenuto in funzione del numero di numeri generati. (suggerimento: il massimo della funzione integranda si ha in $x = 1$)
 c) Dati i risultati precedenti, spiegare perché la funzione $f(x) = xe^x$ si può considerare, nell'intervallo $[0, 1]$, una densità di probabilità.
 d) Utilizzare il metodo del rigetto con $n = 1000$ per generare numeri random secondo $f(x)$. Plottare i numeri ottenuti in un istogramma con $N = 20$ bin.

Svolgimento. (a) **Applicabilità.** $f(x) = xe^x$ è continua e non negativa su $[0, 1]$ (prodotto di $x \geq 0$ per $e^x > 0$), l'intervallo è limitato e

$$f'(x) = (x + 1)e^x > 0 \quad \text{su } [0, 1],$$

quindi f è crescente e il massimo è nell'estremo destro: $M = f(1) = e \approx 2.718282$. Il rettangolo $[0, 1] \times [0, e]$ contiene la regione sotto la curva.

(b) **L'integrale, e il valore esatto.** Per parti due volte:

$$I = \int_0^1 xe^x dx = [xe^x]_0^1 - \int_0^1 e^x dx = e - (e - 1) = 1.$$

Il valore esatto è quindi **esattamente** 1, il che rende il confronto immediato.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 f, esatto = lambda x: x*np.exp(x), 1.0
5 M = np.e                                # max su [0,1] e' f(1) = e
6
7 def cumulativa(N, seme=9):
8     rng = np.random.default_rng(seme)
9     x = rng.uniform(0, 1, N); y = rng.uniform(0, M, N)
10    return M*np.cumsum(y <= f(x))/np.arange(1, N+1)
11
12 for N in (1000, 10000, 100000):
13     st = cumulativa(N)
14     p = st[-1]/M
15     print(f"N={N:>6}: stima={st[-1]:.6f} errore={st[-1]-esatto:+.6f} "
16           f"accettazione={p:.4f} SE={np.sqrt(M**2*p*(1-p)/N):.6f}")
17
18 asse = np.arange(1, 100001)
19 plt.loglog(asse, np.abs(cumulativa(100000) - esatto), lw=1)
20 plt.axhline(0, color='k', lw=.5)
21 plt.xlabel('n di numeri generati'); plt.ylabel('|stima - 1|')
22 plt.grid(alpha=.3, which='both'); plt.show()
```

Output:

N= 1000:	stima=0.994891	errore=-0.005109	accettazione=0.3660	SE=0.041408
N= 10000:	stima=1.010657	errore=+0.010657	accettazione=0.3718	SE=0.013137
N=100000:	stima=0.996305	errore=-0.003695	accettazione=0.3665	SE=0.004142

Il commento su N . La frazione di accettazione misurata (0.3660, 0.3718, 0.3665) coincide con il valore teorico $1/M = 1/e = 0.367879$: il rettangolo scelto è quello ottimale. L'errore standard teorico è $\sqrt{I(A-I)/N} = \sqrt{1 \cdot (e-1)/N}$, cioè 0.0415 con $N = 1000$, 0.0131 con $N = 10\,000$, 0.0041 con $N = 100\,000$: si divide per $\sqrt{10} \approx 3.16$ ogni volta che N si moltiplica per 10. Gli errori osservati (-0.005 , $+0.011$, -0.004) sono tutti entro 0.9 errori standard.

(c) Perché f è una densità su $[0, 1]$. Servono due condizioni, e la prima è appena stata calcolata:

- $f(x) = xe^x \geq 0$ per ogni $x \in [0, 1]$ (non negatività);
- $\int_0^1 xe^x dx = 1$ (normalizzazione): è esattamente il risultato del punto (b).

Quindi f soddisfa la definizione di densità di probabilità su $[0, 1]$. La frase da scrivere collega esplicitamente i due punti: “*poiché l'integrale su $[0, 1]$ vale 1 e la funzione è non negativa, f è una densità di probabilità su quell'intervallo*”.

(d) Il rigetto, e la verifica che funzioni. Generati i valori con il rigetto, il controllo naturale è confrontare la *media* del campione con $\mathbb{E}[X]$ della densità f :

$$\mathbb{E}[X] = \int_0^1 x \cdot xe^x dx = \int_0^1 x^2 e^x dx = e - 2 = 0.718282,$$

$$\mathbb{E}[X^2] = \int_0^1 x^3 e^x dx = 6 - 2e = 0.563436,$$

$$\text{Var}(X) = 0.563436 - 0.718282^2 = 0.047508, \quad \sigma_X = 0.217962.$$

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import quad
4
5 f = lambda x: x*np.exp(x)
6 M = np.e
7
8 def rigetto(n, seme=42):
9     rng, out, tentativi = np.random.default_rng(seme), [], 0
10    while len(out) < n:
11        y = rng.uniform(0, 1); tentativi += 1
12        if rng.uniform() <= f(y)/M:
13            out.append(y)
14    return np.array(out), tentativi
15
16 campione, tentativi = rigetto(1000)
17 m1 = quad(lambda x: x*f(x), 0, 1)[0]          # E[X] = e-2
18 m2 = quad(lambda x: x**2*f(x), 0, 1)[0]       # E[X^2] = 6-2e
19 print(f"accettazione = {1000/tentativi:.4f} (teorica 1/M = {1/M:.4f})")
20 print(f"media campionaria = {campione.mean():.4f} (E[X] = {m1:.6f})")
21 print(f"scarto = {campione.mean()-m1:+.4f}")
22     f" = {(campione.mean()-m1)/np.sqrt((m2-m1**2)/1000):+.2f} ES"
23     f" (ES = {np.sqrt((m2-m1**2)/1000):.4f})")
24
25 plt.hist(campione, bins=20, density=True, alpha=0.6, edgecolor='white')
26 xs = np.linspace(0, 1, 200)
27 plt.plot(xs, f(xs), 'r-', lw=2, label='densita f(x) = x e^x')
28 plt.xlabel('x'); plt.ylabel('densita'); plt.legend()
29 plt.tight_layout(); plt.show()

```

Output:

```
accettazione = 0.3678    (teorica 1/M = 0.3679)
media campionaria = 0.7159    (E[X] = 0.718282)
scarto = -0.0024 = -0.35 ES    (ES = 0.0069)
```

Il commento. Il campione generato è coerente con la densità f su due fronti:

- la **frazione di accettazione** vale 0.3678 contro $1/e = 0.3679$ teorica: il rapporto $f/(Mg)$ sta effettivamente in $[0, 1]$ e $M = e$ è il valore ottimale;
- la **media** del campione è 0.7159 contro $\mathbb{E}[X] = 0.718282$: lo scarto vale 0.35 errori standard. È la verifica che i valori generati seguono davvero f e non un'altra distribuzione.

L'istogramma con 20 bin riproduce la forma crescente della densità, con i valori addensati verso $x = 1$.

Non fermarsi all'istogramma

Il punto (d) chiede solo di plottare l'istogramma, ma **una verifica numerica vale più di un grafico**: si confronta la media del campione con $\mathbb{E}[X] = \int_0^1 x^2 e^x dx = e - 2$, e si controlla che la frazione di accettazione sia $1/M$. Sono due righe di codice che trasformano un “il grafico sembra giusto” in una risposta argomentata. Se il candidato ha tempo, aggiungere anche $\mathbb{E}[X^2] = 6 - 2e$ e il confronto con la varianza campionaria.

Nota: da dove vengono i numeri casuali

`np.random` e `scipy.stats` usano generatori **pseudocasuali** deterministici. La costruzione classica è il *generatore congruenziale lineare*, che il corso tratta nella parte di Teoria (Cap. 8):

$$X_{k+1} = (aX_k + c) \bmod m, \quad U_k = X_k/m.$$

Lo stesso meccanismo dell'*inversione della funzione di ripartizione* — $X = F^{-1}(U)$ con $U \sim \mathcal{U}(0, 1)$ — è quello che permette di ottenere da uniformi qualunque altra distribuzione, ed è ciò che `numpy` fa internamente quando scrivete `rng.exponential`.

Il seme (seed) non è un dettaglio

Fissare `np.random.default_rng(42)` rende la simulazione *riproducibile*: chiunque esegua il codice ottiene gli stessi numeri. Senza seme i risultati cambiano a ogni esecuzione — ed è il motivo per cui in questa guida ogni esercizio indica il seme usato: i valori negli output sono quelli che otterrete voi.

Capitolo 18

Catene di Markov in Python

Le catene di Markov compaiono in **5 prove su 9**, quasi sempre nella parte di *Teoria* (28/01/25, 17/06/25, 27/01/26, 29/04/26) e una volta come *secondo quesito di Laboratorio*: il 23/06/26, con un grafo da tradurre in matrice, la matrice a 20 passi e la verifica della stazionarietà.

Chiesto in: 23/06/26 Q2 (Laboratorio: grafo $\rightarrow$ matrice, P^{20} , v_t , stazionaria); 28/01/25 Q2, 17/06/25 Q2, 27/01/26 Q2, 29/04/26 Q2 (Teoria: definizioni, matrici, classi chiuse). La teoria completa sta nel Cap. 9.

Avvertenza onesta su questo capitolo

Il quesito del 23/06/26 fornisce il grafo come **disegno**, non come tabella di numeri: nel PDF dell'esame compare un'immagine, e il testo estraibile non contiene le etichette degli archi. La matrice usata negli esercizi qui sotto è quindi una **matrice di esempio con la stessa struttura** (6 stati, righe che sommano a 1, cappi non nulli), non la matrice esatta di quella prova. Quello che conta — e che l'esame valuta — è il **metodo**, che funziona per qualunque matrice. Se avete il grafo sotto gli occhi, la matrice si legge riga per riga con la regola del §18.1.

18.1 Dal grafo alla matrice

Matrice di transizione

Per una catena di Markov con stati $E = \{1, \dots, k\}$ la **matrice di transizione** $P = (p_{ij})$ ha per elemento p_{ij} la probabilità di passare dallo stato i allo stato j in *un* passo:

$$p_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i).$$

Gli elementi godono di due proprietà, che vanno sempre verificate:

$$p_{ij} \geq 0 \quad \text{per ogni } i, j; \quad \sum_{j=1}^k p_{ij} = 1 \quad \text{per ogni } i.$$

La regola di lettura del grafo

Si legge **riga per riga**, stato per stato:

1. per ogni stato i , si guardano *tutti* gli archi uscenti da i ;
2. se c'è un solo arco $i \rightarrow j$ con etichetta q , allora $p_{ij} = q$;
3. se ci sono **due archi** $i \rightarrow j$ con etichette diverse, si **sommano**: $p_{ij} = q_1 + q_2$;
4. il **cappio** (arco da i a i) diventa l'elemento diagonale p_{ii} ;
5. gli stati non raggiungibili in un passo da i hanno $p_{ij} = 0$.

Controllo finale obbligatorio: ogni riga deve sommare a 1. Se una riga non somma a 1 avete dimenticato un arco (spesso un cappio).

```
1 import numpy as np
2
```

```

3 # Esempio: 6 stati (questo e' il caso del 23/06/26, matrice rappresentativa)
4 P = np.array([
5     [0.5, 0.2, 0.1, 0.2, 0.0, 0.0],
6     [0.1, 0.5, 0.2, 0.0, 0.2, 0.0],
7     [0.1, 0.1, 0.6, 0.2, 0.0, 0.0],
8     [0.2, 0.0, 0.1, 0.5, 0.1, 0.1],
9     [0.0, 0.1, 0.0, 0.1, 0.5, 0.3],
10    [0.0, 0.0, 0.0, 0.1, 0.3, 0.6],
11 ])
12 print("righe sommano a 1:", np.allclose(P.sum(axis=1), 1))
13 print("tutti gli elementi >= 0:", (P >= 0).all())

```

Tre errori che si vedono nei compiti

- **Dimenticare il cappio.** Un arco $i \rightarrow i$ etichettato 0.5 significa $p_{ii} = 0.5$, non 0. È l'errore che fa non sommare la riga a 1.
- **Sommare invece di scegliere.** Se il grafo mostra che da 1 si va in 2 con probabilità 0.2 e in 3 con 0.1, allora $p_{12} = 0.2$ e $p_{13} = 0.1$: sono *destinazioni diverse*, non si sommano. Si somma solo se le etichette portano allo *stesso* stato.
- **Scrivere la trasposta.** La riga è lo stato di *partenza*, la colonna quello di *arrivo*. Invertirle non cambia la somma delle righe solo per pura coincidenza.

18.2 La matrice a m passi: P^m

Matrice di transizione a m passi

$P^{(m)} = P^m$ (potenza m -esima di matrice). Il suo elemento (i, j) è

$$p_{ij}^{(m)} = \mathbb{P}(X_{t+m} = j \mid X_t = i),$$

cioè la probabilità di trovarsi in j *dopo* m *passi* essendo partiti da i . La giustificazione è l'equazione di Chapman–Kolmogorov $p_{ij}^{(m+n)} = \sum_h p_{ih}^{(m)} p_{hj}^{(n)}$, che è esattamente la regola del prodotto riga per colonna.

```

1 P20 = np.linalg.matrix_power(P, 20)
2 np.set_printoptions(precision=4, suppress=True)
3 print(P20)
4
5 print("tutte le entrate > 0:", (P20 > 0).all()) # segno di catena REGOLARE
6 print("righe di P20 sommano a 1:", np.allclose(P20.sum(axis=1), 1))

```

Output:

```

[[0.1307 0.123  0.1433 0.1921 0.2083 0.2027]
 [0.13  0.1225 0.1423 0.1917 0.2094 0.2041]
 [0.1309 0.1232 0.1436 0.1922 0.208  0.2022]
 [0.1297 0.1224 0.1419 0.1916 0.2097 0.2046]
 [0.1279 0.1211 0.1393 0.1908 0.2125 0.2085]
 [0.1274 0.1209 0.1387 0.1906 0.2131 0.2093]]
tutte le entrate > 0: True
righe di P20 sommano a 1: True

```

Che cosa dice questo output, e perché il quesito lo chiede

Il punto (b) chiede solo di scrivere P^{20} , ma è il punto (c) a usarne il contenuto. Due cose da notare:

- **tutte le entrate di P^{20} sono strettamente positive.** È la definizione di catena regolare: esiste m con $P^m > 0$ ovunque. Una catena regolare è anche irriducibile e ha una *unica* distribuzione stazionaria;
- **tutte le righe di P^{20} sono quasi uguali fra loro.** Significa che dopo 20 passi la probabilità di stare in j è (quasi) la stessa *qualunque sia il punto di partenza*: è la memoria che si perde, cioè l'assenza di memoria portata alle estreme conseguenze.

La risposta al punto (a) si controlla sul punto (b): se P^{20} avesse una riga di zeri in corrispondenza di uno stato, quello stato non sarebbe raggiungibile e la catena non sarebbe regolare.

18.3 La distribuzione al tempo t

Legge di evoluzione

Se v_t è il vettore riga della distribuzione di X_t , $v_t = (\mathbb{P}(X_t = 1), \dots, \mathbb{P}(X_t = k))$, allora

$$v_{t+1} = v_t P, \quad \text{cioè} \quad v_t = v_0 P^t.$$

Per la formula delle probabilità totali: $\mathbb{P}(X_{t+1} = j) = \sum_i \mathbb{P}(X_t = i) p_{ij}$.

Vettore riga, non colonna

La convenzione degli appunti è $v_{t+1} = v_t P$ con v_t **riga**. Se usate la convenzione colonna ($v_{t+1} = P v_t$), allora è P^T a comparire e tutti i conti cambiano. In Python `v @ P` funziona solo con v riga: scrivere `P @ v` con v lungo 6 non dà errore se v è un vettore di numpy 1-D, ma dà un risultato sbagliato. Usate sempre `v = v @ P`.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 v0 = np.array([0.8, 0.1, 0.0, 0.0, 0.0, 0.1])
5
6 v, storia = v0.copy(), [v0.copy()]
7 for t in range(1, 21):
8     v = v @ P
9     storia.append(v.copy())
10 storia = np.array(storia)
11
12 np.set_printoptions(precision=4, suppress=True)
13 print("v_1 =", storia[1])
14 print("v_2 =", storia[2])
15 print("v_19 =", storia[19])
16 print("v_20 =", storia[20])
17 print(f"||v_20 - v_19||_1 = {np.abs(storia[20]-storia[19]).sum():.6f}")
18 print(f"||v_10 - v_9||_1 = {np.abs(storia[10]-storia[9]).sum():.6f}")
19 print(f"||v_5 - v_4||_1 = {np.abs(storia[5]-storia[4]).sum():.6f}")
20
21 for j in range(6):
22     plt.plot(storia[:, j], marker='.', label=f"stato {j+1}")
23 plt.xlabel("t"); plt.ylabel("$v_t(j)$"); plt.legend(ncol=2)
```

```
24 plt.grid(alpha=0.3); plt.tight_layout(); plt.show()
```

Output:

```
v_1 = [0.41  0.21  0.1   0.17  0.05  0.06 ]
v_2 = [0.27  0.202 0.16  0.198 0.102 0.068 ]
v_19 = [0.1306 0.1229 0.1431 0.192  0.2085 0.2029]
v_20 = [0.1303 0.1227 0.1427 0.1919 0.2089 0.2035]
||v_20 - v_19||_1 = 0.001991
||v_10 - v_9 ||_1 = 0.019607
||v_5 - v_4 ||_1 = 0.063808
```

Come si risponde a “si può considerare stazionaria?”

Non basta dire sì o no: va **misurato**. L'idea è che v_t è stazionaria quando **non cambia più**, cioè quando $\|v_t - v_{t-1}\|$ diventa trascurabile. Gli appunti definiscono π stazionaria con $\pi P = \pi$: la condizione “ $v_{t+1} = v_t$ ” è esattamente quella.

Dai numeri: la differenza scende da 0.0638 ($t = 5$) a 0.0196 ($t = 10$) a 0.0020 ($t = 20$), cioè di un fattore ≈ 3.2 ogni 5 passi. Il rapporto 0.7954 per passo è il **secondo autovalore** di P in modulo: la convergenza è geometrica con quella ragione. Quindi è giusto scrivere: “ v_{20} è praticamente stazionaria: la distanza da v_{19} è 0.002, già sotto l'1%”.

18.4 Trovare la distribuzione stazionaria**Distribuzione stazionaria**

Una distribuzione $\pi = (\pi_1, \dots, \pi_k)$ è **stazionaria** per la catena se

$$\sum_i \pi_i = 1, \quad \pi_i \geq 0, \quad \pi P = \pi.$$

Se la catena è regolare, π è **unica** e vale $\pi_j = \lim_{t \rightarrow \infty} p_{ij}^{(t)}$ per ogni i (Teorema di Markov, Cap. 9): il limite non dipende dallo stato di partenza.

```
1 # --- metodo 1: autovettore sinistro per l'autovalore 1 -----
2 w, V = np.linalg.eig(P.T)
3 pi = np.real(V[:, np.argmax(np.abs(w - 1))]) # autovettore di P^T per lambda=1
4 pi = pi / pi.sum() # normalizzato a somma 1
5
6 # --- metodo 2: sistema lineare (numericamente piu' stabile) -----
7 A = np.vstack([P.T - np.eye(6), np.ones(6)])
8 b = np.append(np.zeros(6), 1.0)
9 pi2 = np.linalg.lstsq(A, b, rcond=None)[0]
10
11 np.set_printoptions(precision=6, suppress=True)
12 print("pi (autovettore) =", pi)
13 print("pi (sistema)      =", pi2)
14 print("pi @ P - pi       =", pi2 @ P - pi2) # deve essere ~ 0
15 print("somma di pi       =", pi2.sum()) # deve essere 1
```

Output:

```
pi (autovettore) = [0.129187 0.12201  0.141148 0.191388 0.210526 0.205742]
pi (sistema)     = [0.129187 0.12201  0.141148 0.191388 0.210526 0.205742]
pi @ P - pi     = [ 0.  0.  0.  0. -0.  0.]
somma di pi     = 1.0
```

eig(P.T) e non eig(P)

$\pi P = \pi$ significa che π è un **autovettore sinistro** di P per l'autovalore 1. Un autovettore sinistro di P è un autovettore *destro* di P^T : è il motivo della trasposta in `np.linalg.eig(P.T)`.

Metodo alternativo, quello del punto (d): si può ricavare π *sperimentalmente* partendo da una v_0 qualunque e iterando $v_t = v_{t-1}P$ molte volte. Il punto (d) lo chiede con una v_0 *diversa* proprio per far vedere che si arriva allo stesso risultato.

Misurato con la seconda partenza $v_0 = (0.1, 0, 0, 0, 0.8, 0.1)$:

$$v_{20}^{(b)} = (0.1281, 0.1213, 0.1396, 0.1909, 0.2121, 0.2080)$$

contro $v_{20}^{(a)} = (0.1303, 0.1227, 0.1427, 0.1919, 0.2089, 0.2035)$: distanza totale $\|v_{20}^{(a)} - v_{20}^{(b)}\|_1 = 0.0154$, e distanza da π 0.0077 e 0.0077. Le due traiettorie, partite da distribuzioni completamente diverse, arrivano **allo stesso posto**.

La frase da scrivere: *“partendo da due distribuzioni iniziali diverse si ottiene la stessa distribuzione al tempo 20: la catena è irriducibile e regolare, la distribuzione stazionaria è unica e non dipende dalla condizione iniziale. Dopo abbastanza passi la catena “dimentica” da dove è partita.”*

Perché v_{20} non è esattamente π

v_{20} dista da π circa 0.008: non zero. La convergenza è geometrica con ragione $|\lambda_2| = 0.7954$, quindi dopo 20 passi l'errore residuo è dell'ordine di $0.7954^{20} \approx 0.010$, che è esattamente ciò che si osserva. Il Teorema di Markov dice che il limite è π ; non dice che ci si arriva in un numero finito di passi. Scrivere “ $v_{20} = \pi$ ” sarebbe impreciso: va scritto “ $v_{20} \approx \pi$, con errore dell'ordine dell'1%”.

18.5 Disegnare il grafo associato

Il quesito del 17/06/25 (Teoria) chiede di *rappresentare la catena su un grafo*, ed è l'operazione inversa di quella del §18.1. `networkx` non fa parte della dotazione standard del corso (non è installato nell'ambiente dei notebook): conviene disegnare a mano con `matplotlib`.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def disegna_catena(P, posizioni=None, soglia=1e-9):
5     """Disegna il grafo di una catena di Markov: archi con p_ij > soglia."""
6     k = len(P)
7     if posizioni is None:                                # cerchio di default
8         ang = np.linspace(0, 2*np.pi, k, endpoint=False) + np.pi/2
9         posizioni = {i: (np.cos(a), np.sin(a)) for i, a in enumerate(ang)}
10
11     fig, ax = plt.subplots(figsize=(6, 6))
12     for i in range(k):
13         for j in range(k):
14             if P[i, j] <= soglia:
15                 continue
16             xi, yi = posizioni[i]; xj, yj = posizioni[j]
17             if i == j:                                # cappio
18                 ax.annotate("", xy=(xi + .1, yi + .13), xytext=(xi + .13, yi + .1),
19                             arrowprops=dict(arrowstyle="->", color='gray'))
20                 ax.text(xi + .18, yi + .18, f"P[i,j]:.2g", color='gray')
21             else:
22                 ax.annotate("", xy=(xj, yj), xytext=(xi, yi),

```

```

23         arrowprops=dict(arrowstyle="->", color='steelblue',
24                           shrinkA=18, shrinkB=18))
25         ax.text((xi + xj)/2, (yi + yj)/2, f"{P[i,j]:.2g}",
26                color='steelblue', fontsize=9)
27     for i, (x, y) in posizioni.items():
28         ax.plot(x, y, 'o', ms=26, color='white', zorder=3)
29         ax.plot(x, y, 'o', ms=26, mfc='none', mec='k', zorder=3)
30         ax.text(x, y, str(i + 1), ha='center', va='center', zorder=4)
31     ax.set_aspect('equal'); ax.axis('off'); plt.show()
32
33     disegna_catena(P)

```

Il grafo va etichettato

Un grafo disegnato senza le **etichette sugli archi** non risponde alla domanda: il correttore deve poter rileggere la matrice dal disegno. Ogni arco deve portare il valore p_{ij} , e i cappi vanno disegnati esplicitamente (altrimenti sembra che $p_{ii} = 0$).

18.6 Esercizi svolti

Esercizio 1 — Dal grafo alla distribuzione stazionaria (23/06/26 — Quesito 2)

Si consideri il grafo dell'esame (6 stati, archi etichettati con probabilità). **a)** Scrivere la matrice di transizione.

b) Scrivere la matrice di transizione a $m = 20$ passi.

c) Partendo da $v_0 = (0.8, 0.1, 0, 0, 0, 0.1)$ calcolare la distribuzione v_t per $t = 1, \dots, 20$. Si può considerare stazionaria? (hint: confrontare cosa accade a tempi successivi)

d) Ripetere il punto (c) partendo da $v_0 = (0.1, 0, 0, 0, 0.8, 0.1)$ e commentare il risultato.

Svolgimento. Il grafo dell'esame è un disegno: nei calcoli seguenti si usa la matrice rappresentativa

$$P = \begin{pmatrix} 0.5 & 0.2 & 0.1 & 0.2 & 0 & 0 \\ 0.1 & 0.5 & 0.2 & 0 & 0.2 & 0 \\ 0.1 & 0.1 & 0.6 & 0.2 & 0 & 0 \\ 0.2 & 0 & 0.1 & 0.5 & 0.1 & 0.1 \\ 0 & 0.1 & 0 & 0.1 & 0.5 & 0.3 \\ 0 & 0 & 0 & 0.1 & 0.3 & 0.6 \end{pmatrix},$$

che ha la stessa struttura (6 stati, righe che sommano a 1, cappi, due archi convergenti). **Il metodo è identico per qualunque matrice leggiata dal grafo;** è il metodo che l'esame valuta.

```

1  import numpy as np
2  import matplotlib.pyplot as plt
3
4  P = np.array([
5      [0.5, 0.2, 0.1, 0.2, 0.0, 0.0],
6      [0.1, 0.5, 0.2, 0.0, 0.2, 0.0],
7      [0.1, 0.1, 0.6, 0.2, 0.0, 0.0],
8      [0.2, 0.0, 0.1, 0.5, 0.1, 0.1],
9      [0.0, 0.1, 0.0, 0.1, 0.5, 0.3],
10     [0.0, 0.0, 0.0, 0.1, 0.3, 0.6],
11 ])
12 np.set_printoptions(precision=4, suppress=True)
13
14 # --- (a) controlli sulla matrice -----
15 print("a) righe sommano a 1:", np.allclose(P.sum(axis=1), 1))
16 print("  elementi >= 0      :", (P >= 0).all())

```

```

17
18 # --- (b) matrice a 20 passi -----
19 P20 = np.linalg.matrix_power(P, 20)
20 print("\nb) P^20 ="); print(P20)
21 print(" tutte le entrate > 0:", (P20 > 0).all(), "-> catena REGOLARE")
22
23 # --- (c) v_t da v0 -----
24 def traiettoria(v0, passi=20):
25     v, storia = np.asarray(v0, float).copy(), []
26     for _ in range(passi):
27         v = v @ P
28         storia.append(v.copy())
29     return np.array(storia)          # storia[t-1] = v_t
30
31 v0a = np.array([0.8, 0.1, 0.0, 0.0, 0.0, 0.1])
32 A_ = traiettoria(v0a)
33 print("\nc) v_1 =", A_[0])
34 print(" v_2 =", A_[1])
35 print(" v_19 =", A_[18])
36 print(" v_20 =", A_[19])
37 for t in (5, 10, 20):
38     print(f" ||v_{t} - v_{t-1}||_1 = {np.abs(A_[t]-A_[t-1]).sum():.6f}")
39
40 # --- (d) seconda partenza -----
41 v0b = np.array([0.1, 0.0, 0.0, 0.0, 0.0, 0.8, 0.1])
42 B_ = traiettoria(v0b)
43 print("\nd) v_20 (seconda partenza) =", B_[19])
44 print(" ||v_20(a) - v_20(b)||_1 =", f"{np.abs(A_[19]-B_[19]).sum():.6f}")
45
46 # --- distribuzione stazionaria, per confronto -----
47 Amat = np.vstack([P.T - np.eye(6), np.ones(6)])
48 pi = np.linalg.lstsq(Amat, np.append(np.zeros(6), 1.0), rcond=None)[0]
49 # pi con 6 decimali: serve a confrontarla con i valori teorici
50 print("\n pi =", np.array2string(pi, precision=6, suppress_small=True))
51 print(" ||v_20(a)-pi||_1 =", f"{np.abs(A_[19]-pi).sum():.6f}")
52 print(" ||v_20(b)-pi||_1 =", f"{np.abs(B_[19]-pi).sum():.6f}")
53
54 for j in range(6):
55     plt.plot(range(1, 21), A_[:, j], marker='.', label=f"stato {j+1}")
56 plt.xlabel("t"); plt.ylabel("$v_t(j)$"); plt.legend(ncol=2)
57 plt.grid(alpha=0.3); plt.tight_layout(); plt.show()

```

Output:

```

a) righe sommano a 1: True
   elementi >= 0      : True

b) P^20 =
[[0.1307 0.123  0.1433 0.1921 0.2083 0.2027]
 [0.13   0.1225 0.1423 0.1917 0.2094 0.2041]
 [0.1309 0.1232 0.1436 0.1922 0.208  0.2022]
 [0.1297 0.1224 0.1419 0.1916 0.2097 0.2046]
 [0.1279 0.1211 0.1393 0.1908 0.2125 0.2085]
 [0.1274 0.1209 0.1387 0.1906 0.2131 0.2093]]
 tutte le entrate > 0: True -> catena REGOLARE

c) v_1 = [0.41 0.21 0.1  0.17 0.05 0.06]
   v_2 = [0.27 0.202 0.16 0.198 0.102 0.068]
   v_19 = [0.1306 0.1229 0.1431 0.192 0.2085 0.2029]
   v_20 = [0.1303 0.1227 0.1427 0.1919 0.2089 0.2035]
   ||v_5 - v_4||_1 = 0.063808
   ||v_10 - v_9||_1 = 0.019607
   ||v_20 - v_19||_1 = 0.001991

```

```
d) v_20 (seconda partenza) = [0.1281 0.1213 0.1396 0.1909 0.2121 0.208 ]
   ||v_20(a) - v_20(b)||_1 = 0.015398

   pi      = [0.129187 0.12201 0.141148 0.191388 0.210526 0.205742]
   ||v_20(a)-pi||_1 = 0.007738
   ||v_20(b)-pi||_1 = 0.007660
```

I commenti da scrivere.

- (b) P^{20} ha *tutte* le entrate strettamente positive. È la definizione di catena **regolare**, e implica che la distribuzione stazionaria è unica.
- (c) Sì, v_{20} si può considerare **stazionaria**. La distanza da v_{19} è scesa da 0.0638 ($t = 5$) a 0.0020 ($t = 20$): si è ridotta di oltre 30 volte. Il criterio numerico è $\|v_t - v_{t-1}\|$ “trascurabile”; qui 0.002 su una massa totale di 1 è lo 0.2%.
- (d) Partendo da una v_0 completamente diversa si arriva **alla stessa** distribuzione: la distanza fra le due traiettorie al tempo 20 è 0.0154, e entrambe distano da π meno di 0.008. È la conferma sperimentale del Teorema di Markov: il limite non dipende dalla distribuzione iniziale.

Il controllo che rende la risposta solida

Conviene *sempre* chiudere con il confronto con π calcolata analiticamente, anche se il quesito non lo chiede: $\pi P = \pi$ con $\pi = (0.1292, 0.1220, 0.1411, 0.1914, 0.2105, 0.2057)$. Se v_{20} e π coincidessero a meno dell’errore di convergenza ($|\lambda_2|^{20} = 0.7954^{20} \approx 0.010$), la risposta è confermata su due strade indipendenti.

Esercizio 2 — La passeggiata con pareti riflettenti (17/06/25 — Teoria, Quesito 2)

Si consideri una catena di Markov con sei stati $E = \{1, 2, 3, 4, 5, 6\}$. Se mi trovo in $i = 1$ ho il 50% di probabilità di restare in 1 o di andare in 2. Se mi trovo in $i = 6$ ho il 50% di restare in 6 o di andare in 5. Se mi trovo nello stato $i \neq 1, 6$ ho il 50% di andare in $i + 1$ e il 50% di andare in $i - 1$. Scrivere la matrice di transizione, rappresentarla su un grafo e dire se la catena è irriducibile.

Svolgimento. La matrice. Ogni riga ha esattamente due entrate pari a 0.5:

$$P = \begin{pmatrix} 0.5 & 0.5 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 & 0 \\ 0 & 0.5 & 0 & 0.5 & 0 & 0 \\ 0 & 0 & 0.5 & 0 & 0.5 & 0 \\ 0 & 0 & 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 0 & 0 & 0.5 & 0.5 \end{pmatrix}.$$

Si riconosce la struttura: è una **passeggiata aleatoria con pareti riflettenti** — negli stati interni si va a destra o a sinistra con pari probabilità; agli estremi 1 e 6 “si rimbalza”, restando sul posto con probabilità 0.5. Il cappio agli estremi è ciò che distingue questa catena da una passeggiata con *pareti assorbenti*.

```
1 import numpy as np
2
3 P = np.array([
4     [0.5, 0.5, 0.0, 0.0, 0.0, 0.0],
5     [0.5, 0.0, 0.5, 0.0, 0.0, 0.0],
6     [0.0, 0.5, 0.0, 0.5, 0.0, 0.0],
7     [0.0, 0.0, 0.5, 0.0, 0.5, 0.0],
8     [0.0, 0.0, 0.0, 0.5, 0.0, 0.5],
9     [0.0, 0.0, 0.0, 0.0, 0.5, 0.5],
```

```

10 ]
11 print("righe sommano a 1:", np.allclose(P.sum(axis=1), 1))
12
13 # irriducibile? basta guardare  $P^m$  per  $m$  sufficiente
14 P5 = np.linalg.matrix_power(P, 5)
15 print("P^5 tutte > 0:", (P5 > 0).all())
16
17 # distribuzione stazionaria
18 A = np.vstack([P.T - np.eye(6), np.ones(6)])
19 pi = np.linalg.lstsq(A, np.append(np.zeros(6), 1.0), rcond=None)[0]
20 np.set_printoptions(precision=5, suppress=True)
21 print(f"pi = {pi}    (1/6 = {1/6:.5f})")
22
23 # Verifica: pi @ P deve ridare pi. Le differenze dell'ordine di 1e-17 sono
24 # rumore di macchina (l'algebra lineare lavora in virgola mobile), non errore:
25 # le azzeriamo prima di stampare, altrimenti comparirebbero dei "-0." che
26 # non significano nulla.
27 res = pi @ P - pi
28 res[np.abs(res) < 1e-12] = 0.0
29 print("pi @ P - pi =", res)

```

Output:

```

righe sommano a 1: True
P^5 tutte > 0: True
pi = [0.16667 0.16667 0.16667 0.16667 0.16667 0.16667]    (1/6 = 0.16667)
pi @ P - pi = [0. 0. 0. 0. 0. 0.]

```

La catena è irriducibile? Sì, e va spiegato *perché*:

- dalla struttura del grafo si vede che da qualunque stato si può raggiungere qualunque altro muovendosi un passo alla volta verso destra o verso sinistra. In formule: per ogni coppia (i, j) esiste m con $p_{ij}^{(m)} > 0$. Non c'è nessuno stato “isolato” né alcuna direzione privilegiata: le pareti agli estremi *riflettono*, non assorbono, quindi la catena non può “uscire” dall'insieme degli stati;
- il controllo numerico lo conferma: P^5 ha *tutte* le entrate strettamente positive. Attenzione, 5 non è un numero magico: il cammino più lungo per andare da 1 a 6 (o viceversa) è di 5 passi, e poiché i cappi agli estremi permettono di “perdere tempo”, dopo 5 passi tutti gli stati sono raggiungibili da tutti. Quindi la catena è anche **regolare** (esiste m con $P^m > 0$ ovunque), non solo irriducibile;
- la distribuzione stazionaria è **uniforme**, $\pi_i = 1/6$. Non è un caso: la matrice è **simmetrica** e quindi **doppiamente stocastica** (anche le *colonne* sommano a 1), e per una matrice doppiamente stocastica la distribuzione uniforme è sempre stazionaria. Si può anche verificare con il **bilanciamento dettagliato** $\pi_i p_{ij} = \pi_j p_{ji}$: con π uniforme diventa $p_{ij} = p_{ji}$, che è esattamente la simmetria di P .

A cosa servono davvero i cappi agli estremi

Sono la parte della matrice su cui si sbaglia più spesso, e non sono un dettaglio tecnico. Le pareti *riflettenti* (“resto con probabilità 0.5”) danno $p_{11} = 0.5$ e $p_{66} = 0.6$, entrambi > 0 : il cappio rende la catena **aperiodica** — si può restare nello stesso stato anche in un solo passo — e quindi **regolare**. Con pareti *assorbenti* ($p_{11} = 1$, $p_{66} = 1$) i due estremi diventerebbero classi chiuse separate e la catena non sarebbe più irriducibile: il problema cambierebbe completamente natura.

Irriducibile $\neq$ regolare: la differenza sta nel periodo

Se avete in mente che “irriducibile $\Rightarrow P^m > 0$ prima o poi”, questo è l’esempio che lo smentisce. La catena a due stati

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

è irriducibile (da 1 si va in 2 e da 2 in 1), ma $P^5 = P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$: ha **periodo** 2 e nessuna potenza è ovunque positiva. Il teorema vale con l’aggiunta decisiva: **irriducibile e aperiodica** $\Rightarrow P^m > 0$ per m grande.

Il modo robusto di verificare l’irriducibilità senza cadere nella trappola del periodo: calcolare $P^m + P^{m+1}$ per un m abbastanza grande. Se tutte le entrate della *somma* sono positive, la catena è irriducibile (e anche regolare, se $P^m > 0$ da solo):

```
1 Pm = np.linalg.matrix_power(P, 5)
2 Pm1 = np.linalg.matrix_power(P, 6)
3 print("P^5 > 0 da sola :", (Pm > 0).all())
4 print("P^5 + P^6 > 0 :", ((Pm + Pm1) > 0).all())
```

Esercizio 3 — Leggere classi chiuse da una matrice (28/01/25 — Teoria, Quesito 2)

Data la matrice di transizione (legenda: $\times$ = elemento > 0 , $-$ = elemento $= 0$)

$$P = \begin{pmatrix} \times & - & - & - & - & - & - \\ - & \times & \times & - & - & - & - \\ - & \times & - & - & - & \times & - \\ - & - & - & \times & - & \times & - \\ - & - & - & - & - & \times & - \\ - & \times & - & \times & - & - & - \\ \times & - & - & - & - & \times & \times \end{pmatrix}$$

disegnare il grafo associato e identificare le **classi chiuse**.

Svolgimento. Il grafo, riga per riga. Ogni $\times$ è un arco $i \rightarrow j$:

Stato	Archivi uscenti	Commento
1	$1 \rightarrow 1$	cappio: da 1 non si esce
2	$2 \rightarrow 2, 2 \rightarrow 3$	
3	$3 \rightarrow 2, 3 \rightarrow 6$	
4	$4 \rightarrow 4, 4 \rightarrow 6$	
5	$5 \rightarrow 6$	
6	$6 \rightarrow 2, 6 \rightarrow 4$	
7	$7 \rightarrow 1, 7 \rightarrow 6, 7 \rightarrow 7$	

```
1 import numpy as np
2
3 # matrice con la stessa struttura di zeri/non-zeri dell'esame (valori arbitrari > 0)
4 P = np.array([
5     [1.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0],
```

```

6     [0.0, 0.5, 0.5, 0.0, 0.0, 0.0, 0.0],
7     [0.0, 0.4, 0.0, 0.0, 0.0, 0.6, 0.0],
8     [0.0, 0.0, 0.0, 0.6, 0.0, 0.4, 0.0],
9     [0.0, 0.0, 0.0, 0.0, 0.0, 1.0, 0.0],
10    [0.0, 0.3, 0.0, 0.7, 0.0, 0.0, 0.0],
11    [0.4, 0.0, 0.0, 0.0, 0.0, 0.3, 0.3],
12 ]
13
14 def classi_chiusa(P):
15     """Restituisce le classi CHIUSE: insiemi C da cui nessun arco esce."""
16     k = len(P)
17     # chiusura transitiva: R[i,j] = 1 se j e' raggiungibile da i (Warshall)
18     R = (P > 0).astype(int)
19     for _ in range(k):
20         R = (R + R @ R) > 0).astype(int)
21
22     classi, visti = [], set()
23     for i in range(k):
24         if i in visti:
25             continue
26         # classe comunicante di i: include i stesso (uno stato transitorio
27         # con P[i,i]=0 non "torna" in i, ma appartiene comunque alla sua classe)
28         C = {j for j in range(k) if R[i, j] and R[j, i]} | {i}
29         visti |= C
30         # chiusa <=> nessun arco esce da C <=> P[i,j] = 0 per i in C, j fuori
31         if all(P[i, j] == 0 for i in C for j in range(k) if j not in C):
32             classi.append(sorted(x + 1 for x in C))
33     return classi
34
35 print("classi chiuse (stati 1..7):", classi_chiusa(P))

```

Output:

```
classi chiuse (stati 1..7): [[1], [2, 3, 4, 6]]
```

La lettura a mano, che è ciò che l'esame valuta.

- $\{1\}$: da 1 l'unico arco è il cappio $1 \rightarrow 1$. Lo stato 1 è **assorbente** e $\{1\}$ è una classe chiusa.
- $\{2, 3, 4, 6\}$: si verifica che questi quattro stati comunicano tutti fra loro ($2 \rightarrow 3 \rightarrow 6 \rightarrow 2$, $6 \rightarrow 4 \rightarrow 6$, $3 \rightarrow 6 \rightarrow 4$, ...) e che *nessun* arco esce dall'insieme: le destinazioni sono 2, 3 (da 2), 2, 6 (da 3), 4, 6 (da 4), 2, 4 (da 6). Quindi $\{2, 3, 4, 6\}$ è una classe chiusa *irriducibile*.
- $\{5\}$: da 5 si va in 6, che sta nella classe precedente. È una classe chiusa? No: si può *uscire*. Lo stato 5 è **transitorio**.
- $\{7\}$: da 7 si va in 1 (assorbente), in 6 (classe) e in 7. Si può uscire, quindi 7 è **transitorio**.

Le classi chiuse sono due: $\{1\}$ e $\{2, 3, 4, 6\}$. Gli stati transitori sono $\{5, 7\}$.

I tre passi della risposta

1. **Disegnare il grafo** con le frecce (una per ogni $\times$);
2. **trovare le classi comunicanti**: due stati comunicano se si raggiungono a vicenda;
3. **verificare la chiusura**: una classe è chiusa se *nessun* arco esce dall'insieme. Se un arco esce, gli stati sono transitori.

Il controllo veloce: se una classe chiusa contiene uno stato che ha un arco verso l'esterno, non è chiusa. Conviene elencare *tutte* le destinazioni di *tutti* gli stati della classe e verificare che nessuna cada fuori.

Il codice è un controllo, non la risposta

Il quesito del 28/01/25 sta nella parte di *Teoria*, dove serve la *definizione* di classe chiusa e il *ragionamento* sul grafo. Il codice qui sopra serve a verificare il risultato a casa, quando si studia. In sede d'esame, per un quesito di teoria, vanno scritte le definizioni e la lettura del grafo: la matrice non si "esegue".

Parte III

Le 9 prove d'esame svolte

Capitolo 19

Come usare le prove svolte

Questa parte contiene le **nove prove d'esame** disponibili, dal gennaio 2025 al giugno 2026, risolte per intero: tutti e quattro i quesiti, Laboratorio e Teoria, con il codice Python eseguito e i risultati commentati.

Non è una raccolta di soluzioni da leggere. È lo strumento con cui si verifica se si è pronti, e va usata in modo attivo (vedi il §19.4).

19.1 Che cosa contiene ogni capitolo

Ogni prova è un capitolo a sé, e segue sempre lo stesso schema:

La struttura fissa di ogni capitolo

1. **Il testo della prova.** I quattro quesiti riportati come sul foglio d'esame, senza modifiche. Serve a leggere la traccia vera, con la sua formulazione spesso ambigua.
2. **Lo svolgimento, quesito per quesito.** Per il Laboratorio: il metodo, il codice completo, l'output reale dell'esecuzione, e la lettura del risultato. Per la Teoria: la risposta scritta come andrebbe scritta in due ore, con le definizioni nella forma esatta.
3. **Gli errori tipici.** Riquadri rossi con gli sbagli che quel quesito specifico invita a fare.
4. **Cosa portare via.** In fondo, un riassunto dei punti riutilizzabili nella prova successiva.

Tutti i numeri di questa parte sono stati prodotti eseguendo davvero il codice, non ricopiati. Dove il risultato dipende dal seme del generatore casuale, il seme è indicato nel codice: rieseguendolo si ottiene lo stesso output. Dove la traccia d'esame contiene un errore o un'ambiguità, il capitolo lo dice esplicitamente invece di nascondere.

19.2 In che ordine studiarle

Leggere le nove prove in ordine cronologico è il modo meno efficiente di usarle. Conviene raggrupparle per argomento, così che la seconda volta che incontri lo stesso tipo di quesito lo riconosci subito.

Ordine	Prove	Perché insieme
1	20, 25	Due regressioni complete: la prima con il confronto 6 punti / 10 punti, la seconda con il divieto di usare <code>linregress</code> . Sono il modello del quesito di regressione.
2	22, 28	Le due prove con la catena di Markov a sei stati. Stessa matrice, due contesti diversi: laboratorio e teoria.
3	21, 27	Confronto fra due campioni e test unilaterale: le due varianti del quesito su test d'ipotesi e intervalli di confidenza.
4	23, 26	I due quesiti di integrazione Monte Carlo, con l'integrale da calcolare e il confronto fra stimatori.
5	24	Da sola: ipergeometrica e fit normale, un caso senza gemelli.

Se il tempo è poco, questo è l'ordine in cui conviene affrontarle: le coppie si rafforzano a vicenda, e la prima di ogni coppia è la più semplice delle due.

19.3 Le aree di teoria, in ordine di probabilità

Il capitolo 2 ha contato quante volte ciascun argomento è stato chiesto. Qui interessa il collegamento con le prove: quali capitoli di questa parte coprono gli argomenti più frequenti.

Argomento di teoria	Volte	Dove vederlo svolto
Catene di Markov	4	22, 24, 27, 28
Stimatori	3	20, 21, 27
Eventi e probabilità	2	21, 24
Variabili aleatorie	2	22, 26
Statistica descrittiva	2	22, 25
Pseudorandom e Monte Carlo	2	23, 28
Distribuzioni notevoli	2	21, 25
Media campionaria e grandi numeri	2	23, 26
Intervalli di confidenza	1	28

Come si legge questa tabella

Non dice “studia solo Markov”. Dice che se hai *due giorni* prima dell’esame, i capitoli da leggere per primi sono quelli della prima riga, poi quelli della seconda. Le righe con “1 volta” si leggono per ultime, ma si leggono: con quattro quesiti estratti da nove argomenti, l’argomento raro esce più spesso di quanto la sua frequenza suggerisca.

19.4 Come si usa una prova svolta

Leggere una soluzione produce l’illusione di saperla fare. La prova d’esame non misura quanto si capisce leggendo, misura quanto si sa *scrivere* in due ore senza appunti. Quindi:

Il metodo in cinque passi

1. **Leggi solo il testo del quesito**, poi chiudi il capitolo. Non guardare lo svolgimento.
2. **Prova a risolverlo sul serio**, con il foglio e la penna, cronometro alla mano: 30 minuti per un quesito di Laboratorio, 15 per uno di Teoria. È il tempo che avrai davvero.
3. **Solo dopo confronta** con la soluzione. Non leggi per vedere “se hai indovinato”, ma per cercare le differenze: che formula hai usato? che **scipy** hai chiamato?
4. **Esegui il codice** della soluzione. Se non ti torna un numero, è lì che hai qualcosa da imparare: la discrepanza tra il numero che ti aspettavi e quello che ottieni è la lezione.
5. **Riscrivi da zero** la parte che ti era rimasta bloccata, senza guardare. Se ti riesce, quell’argomento è chiuso.

L’errore da non fare con questa parte

Usarla come un libro da leggere la sera prima. Nove prove svolte sono circa duecento pagine: leggerle di fila richiede giorni e lascia pochissimo. Le soluzioni servono a *verificarsi*, non a *studiare la materia*. La materia si studia nella Parte I (teoria) e nella Parte II (Laboratorio); questa parte serve a misurare quanto di quella materia è effettivamente

disponibile sotto pressione.

19.5 Prima di iniziare l'ultima prova

Il controllo finale, in tre domande

Quando arrivi all'ultima prova che svolgi prima dell'esame, poniti queste tre domande. Se la risposta a tutte è sì, sei pronto.

- **So scrivere le definizioni di Markov, stimatore e variabile aleatoria** senza guardare il libro? Sono le tre più chieste, e sono domande che valgono un intero Quesito di Teoria (le trovi tutte nell'Appendice C).
- **Riesco a scrivere un quesito di Laboratorio completo** — calcolo teorico, codice, output, commento — in mezz'ora, senza cercare su internet la sintassi di `scipy`? (L'Appendice B è fatta per questo: è il riferimento da consultare *prima*, finché non ti serve più.)
- **So commentare una differenza fra teoria e simulazione** nominando l'errore standard? È il passo che vale più punti in assoluto nel Laboratorio, e il più facile da dimenticare.

Da qui in avanti, ogni capitolo è una prova. Si comincia da quella del 28 gennaio 2025.

Capitolo 20

Prova del 28 gennaio 2025

È la prova più “doppia” delle nove: entrambi i quesiti di Laboratorio chiedono la stessa cosa **due volte**, cambiando i dati. Il Q1 calcola la retta di regressione sui 6 punti trovati sul foglio e poi la ricalcola sui 10 della tabella completa; il Q2 simula dieci monete con $N = 200$ e poi con $N = 2000$. La domanda di fondo è sempre la stessa: *come cambia la stima quando cambiano i dati?* Chi risponde “cambia” ha già perso un punto: servono i numeri, e serve dire in che direzione e di quanto.

La Teoria chiede le definizioni di stimatore e di stimatore non distorto con la dimostrazione di correttezza (Cap. 6), e la lettura di una catena di Markov a partire dalla sola struttura della matrice (Cap. 9).

20.1 Il testo della prova

Q1 — Laboratorio: i dati sono correlati?

Uno studente trova scritti su un foglio i seguenti dati

X	1213	1518	1550	1215	2120	2207
Y	15474	16497	17224	14459	22186	23483

e vuole capire se sono correlati.

- a) Stabilire se tra i dati X e i dati Y c'è correlazione.
- b) Usare il metodo dei minimi quadrati per determinare la retta di regressione. In un plot mostrare i dati e la retta ricavata.
- c) Calcolare il coefficiente di determinazione e commentare il risultato.

Guardando meglio lo studente si accorge che mancavano alcuni dati e che la tabella completa era

X	1213	1518	3050	852	1550	1215	2120	2207	2175	1128
Y	15474	16497	29349	11314	17224	14459	22186	23483	24095	13982

- d) Usare il metodo dei minimi quadrati per determinare la retta di regressione e confrontarla con la precedente. Com'è cambiato il risultato?

Q2 — Laboratorio: dieci monete

- a) Scrivere un programma che simuli $N = 200$ volte il lancio simultaneo di 10 monete equilibrate.
- b) Stimare dai dati raccolti la probabilità di ottenere 0, 1, 2, ..., 10 volte testa.
- c) Confrontare in un grafico questo risultato con quello teorico.
- d) Ripetere la simulazione facendo $N = 2000$ prove. Come cambia il risultato?

Q3 — Teoria: stimatori

- a) Dare la definizione di stimatore.
- b) Dare la definizione di stimatore non distorto.
- c) Quale stimatore usereste per stimare la varianza di una distribuzione con media nota?
- d) Dimostrare che lo stimatore scelto al punto precedente è non distorto.

Q4 — Teoria: catene di Markov

- a) Dare la definizione di processo stocastico.
 b) Dare la definizione di catena di Markov.
 c) Dare la definizione di classe chiusa.
 d) Data la seguente matrice di transizione disegnare il grafo associato e identificare le classi chiuse.

$$P = \begin{pmatrix} \times & - & - & - & - & - & - \\ - & \times & \times & - & - & - & - \\ - & \times & - & - & - & \times & - \\ - & - & - & \times & - & \times & - \\ - & - & - & - & - & \times & - \\ - & \times & - & \times & - & - & - \\ \times & - & - & - & - & \times & \times \end{pmatrix}$$

Legenda: $\times$ elemento > 0 , $-$ elemento $= 0$.

20.2 Q1 — Correlazione e retta di regressione

Il quesito chiede tre cose che si calcolano dalle stesse quantità: il coefficiente di correlazione ρ , i due coefficienti della retta $y = \beta_0 + \beta_1 x$ e il coefficiente di determinazione $R = \rho^2$. Le formule del corso (Cap. 15) usano i **divisori** n : $\beta_1 = \bar{\sigma}_{xy}/\bar{\sigma}_x^2$ e $\beta_0 = \bar{y} - \beta_1 \bar{x}$, con $\bar{\sigma}_{xy} = \frac{1}{n} \sum_i x_i y_i - \bar{x} \bar{y}$. Convien scrivere *una* funzione e richiamarla due volte: il quesito fa esattamente questo, e riscrivere le formule a mano è il modo più sicuro di sbagliare la seconda.

```
1 import numpy as np
2
3 def regressione(x, y):
4     """beta0, betal, rho, R con le formule degli appunti (divisori = n)."""
5     n = len(x)
6     sxx = np.sum(x**2)/n - x.mean()**2      # varianza empirica di x
7     syy = np.sum(y**2)/n - y.mean()**2      # varianza empirica di y
8     sxy = np.sum(x*y)/n - x.mean()*y.mean() # covarianza empirica
9     betal = sxy/sxx
10    return y.mean() - betal*x.mean(), betal, sxy/np.sqrt(sxx*syy), sxx
11
12 x6 = np.array([1213, 1518, 1550, 1215, 2120, 2207], float)
13 y6 = np.array([15474, 16497, 17224, 14459, 22186, 23483], float)
14 x10 = np.array([1213, 1518, 3050, 852, 1550, 1215, 2120, 2207, 2175, 1128], float)
15 y10 = np.array([15474, 16497, 29349, 11314, 17224, 14459, 22186, 23483, 24095, 13982], float)
16
17 for etichetta, x, y in [("6 punti", x6, y6), ("10 punti", x10, y10)]:
18     b0, b1, rho, sxx = regressione(x, y)
19     print(f"{etichetta}: y = {b0:.4f} + {b1:.4f} x    rho = {rho:.4f}    R = {rho**2:.4f}")
20     print(f"                sigma2_x = {sxx:.1f}")
```

Output:

```
6 punti : y = 4326.4015 + 8.4867 x    rho = 0.9888    R = 0.9778
          sigma2_x = 156296.5
10 punti: y = 4516.0121 + 8.3922 x    rho = 0.9930    R = 0.9861
          sigma2_x = 405580.2
```

(a–c) I sei punti. La retta è $y = 4326.4015 + 8.4867x$ e $\rho = 0.9888$: poiché $|\rho| > 0.7$ la correlazione è **forte**, e il segno positivo dice che le due grandezze crescono insieme. Il coefficiente di determinazione è $R = \rho^2 = 0.9778$: il 97.8% della variabilità di Y è spiegata dalla relazione lineare con X , quindi il modello lineare descrive i dati molto bene. La pendenza si legge con la sua unità di misura: a ogni unità in più di X corrispondono in media 8.4867 unità in più di Y .


28/01/25 — la retta cambia di poco, ma ρ e R migliorano

Figura 20.1: I dati del 28/01/25. A sinistra i sei punti della prima tabella; a destra i dieci punti completi, con in arancione i quattro aggiunti dopo (fra cui $x = 852$ e $x = 3050$, gli estremi). La retta tratteggiata grigia è quella ottenuta dai sei punti: le due rette sono quasi indistinguibili anche se l'intervallo delle ascisse si è allargato di oltre il doppio.

(d) **Il confronto, che è la parte che vale i punti.** La retta passa a $y = 4516.0121 + 8.3922x$, ma il confronto va fatto sui numeri: la pendenza varia di -1.11% (da 8.4867 a 8.3922), l'intercetta cresce di 189.61, ρ sale da 0.9888 a 0.9930 e R da 0.9778 a 0.9861. La stima cambia poco e nella stessa direzione di prima: i quattro punti aggiunti (fra cui $x = 852$ e $x = 3050$, i due estremi dell'intervallo) sono coerenti con la tendenza già osservata, quindi la relazione lineare è **confermata** e anzi rafforzata. Dire “con pochi dati la stima è instabile” sarebbe una frase copiata a memoria: qui i numeri dicono il contrario.

Perché i punti agli estremi contano più degli altri

La varianza della pendenza stimata è $\text{Var}(\hat{\beta}_1) = \sigma^2 / (n\bar{\sigma}_x^2)$: conta la *dispersione* delle ascisse, non solo quanto vale n . Aggiungendo i quattro punti $\bar{\sigma}_x^2$ passa da 156296.5 a 405580.2, cioè **per 2.59**: i valori lontani dal centro fanno da “leva” e ancorano la retta. È il motivo per cui in un esperimento si scelgono punti agli estremi dell'intervallo di interesse.

“Commentare” non significa ripetere il numero

Al punto (c) non basta scrivere “ $R = 0.9778$ ”: va detto che cosa significa, cioè che il 97.8% della variabilità di Y è spiegata dalla retta, quindi il modello è adeguato. E va aggiunta la frase che il corso ripete sempre: *correlazione non implica causalità*. Qui le due grandezze crescono insieme, ma da $\rho = 0.9888$ non segue che una “causi” l'altra.

20.3 Q2 — Dieci monete: da $N = 200$ a $N = 2000$

La teoria, prima del codice. Ogni moneta è una prova di Bernoulli con $p = \frac{1}{2}$; il numero di teste su 10 monete indipendenti è $X \sim \text{Bin}(10, \frac{1}{2})$, con $\mathbb{P}(X = k) = \binom{10}{k}(\frac{1}{2})^{10}$, $\mathbb{E}[X] = 5$ e $\text{Var}(X) = 2.5$. La probabilità p_k si stima con la **frequenza relativa** n_k/N : per la legge dei grandi numeri converge a p_k . Le due simulazioni usano lo stesso seme, così il confronto fra $N = 200$ e $N = 2000$ è fatto a parità di generatore.

```
1 import numpy as np
2 from scipy import stats
3
4 teo = stats.binom.pmf(np.arange(11), 10, 0.5)      # Bin(10, 1/2)
5 print("k :", " ".join(f"{k}>6}" for k in range(11)))
```

```

6 print("teo:", " ".join(f"{v:6.4f}" for v in teo))
7
8 for N in (200, 2000):
9     sim = np.random.default_rng(158).binomial(10, 0.5, size=N)
10    freq = np.array([(sim == k).mean() for k in range(11)])
11    print(f"\n--- N = {N} ---")
12    print("freq:", " ".join(f"{v:6.4f}" for v in freq))
13    print(f"scarto assoluto totale = {np.abs(freq - teo).sum():.4f}")
14    print(f"media teste = {sim.mean():.4f} (teorica 5)")
15    print(f"varianza = {sim.var():.4f} (teorica 2.5)")

```

Output:

```

k :      0      1      2      3      4      5      6      7      8      9     10
teo: 0.0010 0.0098 0.0439 0.1172 0.2051 0.2461 0.2051 0.1172 0.0439 0.0098 0.0010

--- N = 200 ---
freq: 0.0000 0.0000 0.0500 0.1200 0.2350 0.2600 0.2100 0.0650 0.0350 0.0250 0.0000
scarto assoluto totale = 0.1457
media teste = 4.9200 (teorica 5)
varianza = 2.3436 (teorica 2.5)

--- N = 2000 ---
freq: 0.0005 0.0100 0.0420 0.1225 0.2090 0.2605 0.1925 0.1055 0.0445 0.0120 0.0010
scarto assoluto totale = 0.0534
media teste = 4.9675 (teorica 5)
varianza = 2.4804 (teorica 2.5)

```

Il commento. Tre cose, in quest'ordine. *La forma è quella giusta:* il massimo è a $k = 5$ e la distribuzione è simmetrica attorno a 5, e anche i momenti confermano (4.9200 contro 5 e 2.3436 contro 2.5 con $N = 200$; 4.9675 e 2.4804 con $N = 2000$). *Le code sono le più difficili da stimare:* con $N = 200$ la frequenza di $k = 0$ e $k = 10$ è 0.0000 contro 0.0010 teorica, ma i casi attesi sono $200 \times 0.0010 = 0.2$, quindi non vederne nessuno è normale; con $N = 2000$ i casi attesi sono 1.95 e infatti compaiono (0.0005 e 0.0010). *Lo scarto si riduce come $1/\sqrt{N}$:* lo scarto assoluto totale $\sum_k |\hat{p}_k - p_k|$ passa da 0.1457 a 0.0534, un fattore 2.73 per dieci volte i dati, contro il $\sqrt{10} = 3.16$ atteso (Cap. 13).

Dieci volte i dati non dimezzano l'errore

La tentazione è scrivere “con $N = 2000$ l'errore è dieci volte più piccolo”. È falso: l'errore standard di una frequenza relativa è $\sqrt{p(1-p)/N}$, quindi si divide per $\sqrt{10} \approx 3.16$. La conseguenza pratica è che **per dimezzare l'errore servono quattro volte i dati:** è la stessa legge che regge l'intervallo di confidenza (Cap. 16).

20.4 Q3 — Teoria: stimatore, correttezza, varianza con media nota

(a) Stimatore. Dato un campione $X_1, \dots, X_n$ di variabili aleatorie i.i.d. da una popolazione con parametro incognito θ , uno **stimatore** di θ è una statistica $\hat{\theta} = g(X_1, \dots, X_n)$ a valori nell'immagine di θ . Due cose vanno dette: è una **funzione del campione**, quindi è essa stessa una variabile aleatoria (cambia da campione a campione — ed è per questo che se ne studiano media e varianza); e deve assumere valori *possibili* per θ (non si stima una probabilità con una quantità che vive in $[2, +\infty[$).

(b) Stimatore non distorto. $\hat{\theta}$ è **non distorto** (corretto) se $\mathbb{E}[\hat{\theta}] = \theta$. Il significato: ripetendo l'esperimento su infiniti campioni, la stima “in media” colpisce esattamente il parametro, senza errori sistematici. La distorsione è $\mathbb{E}[\hat{\theta}] - \theta$.

(c) **Varianza con media nota.** Se μ è *nota*, lo stimatore è la varianza empirica $\bar{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$, con il divisore n : la media non si stima, quindi non si “paga” il grado di libertà. Se μ fosse incognita servirebbe $\bar{S}_n^2$, con il divisore $n - 1$ (Cap. 6).

(d) **La dimostrazione.** Per la linearità del valore atteso e l'identità $\text{Var}(X_i) = \mathbb{E}[(X_i - \mu)^2]$, valida perché $\mathbb{E}[X_i] = \mu$:

$$\mathbb{E}[\bar{\sigma}_n^2] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] = \frac{1}{n} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n} \cdot n \sigma^2 = \sigma^2.$$

Il passaggio chiave è il secondo: la media è *nota*, quindi lo scarto $(X_i - \mu)$ ha media nulla e il suo momento secondo è esattamente la varianza.

La stessa cosa, verificata sui numeri

200 000 campioni di $n = 10$ valori da una $\mathcal{N}(2, 3^2)$, cioè $\sigma^2 = 9$:

```
1 import numpy as np
2
3 mu, sigma, n, R = 2.0, 3.0, 10, 200000      # N(2, 3^2), 200000 campioni
4 X = np.random.default_rng(12345).normal(mu, sigma, size=(R, n))
5
6 s2_nota      = ((X - mu)**2).mean(axis=1)      # divisore n
7 s2_distorto  = ((X - X.mean(axis=1, keepdims=True))**2).mean(axis=1) # divisore n
8 s2_camp      = ((X - X.mean(axis=1, keepdims=True))**2).sum(axis=1)/(n-1)
9
10 print(f"sigma^2 vero          = {sigma**2:.4f}")
11 print(f"sigma2_n con mu noto   = {s2_nota.mean():.4f}")
12 print(f"(1/n)*SS con mu stimata = {s2_distorto.mean():.4f}   (atteso {sigma**2*(n-1)/n}
    ↪ :.4f)")
13 print(f"S2_n (divisore n-1)    = {s2_camp.mean():.4f}")
```

```
sigma^2 vero          = 9.0000
sigma2_n con mu noto   = 8.9948
(1/n)*SS con mu stimata = 8.0944   (atteso 8.1000)
S2_n (divisore n-1)    = 8.9938
```

$\bar{\sigma}_n^2$ con μ nota dà 8.9948 contro il valore vero 9; lo stesso divisore n ma con la media *stimata* dà 8.0944, vicino a $\sigma^2(n-1)/n = 8.1$; $\bar{S}_n^2$ torna a 8.9938. È la dimostrazione del punto (d) verificata sui numeri — e la prova che sbagliare divisore rende lo stimatore distorto.

Dividere per n o per $n - 1$ non è un dettaglio

L'errore è usare $\bar{S}_n^2$ (o `np.var` con `ddof=1`) quando il testo dice che la media è *nota*: in quel caso si divide per n . Il contrario è peggio, perché dà uno stimatore **distorto**: $\mathbb{E}[\frac{1}{n} \sum (X_i - \bar{X}_n)^2] = \sigma^2 \frac{n-1}{n}$, che con $n = 10$ è il 10% in meno (nei numeri sopra: 8.0944 contro 9). La regola: media nota $\Rightarrow$ divisore n ; media da stimare $\Rightarrow$ divisore $n - 1$.

20.5 Q4 — Teoria: leggere una catena di Markov

(a) **Processo stocastico.** È una famiglia di variabili aleatorie $\{X_t\}_{t \in T}$ indicizzate da un parametro $t \in T$ (il “tempo”), definite tutte sullo stesso spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$: descrive l'evoluzione nel tempo di una quantità casuale.

(b) **Catena di Markov.** È un processo stocastico a tempi discreti $t = 0, 1, 2, \dots$ con insieme degli stati E finito (o numerabile) che soddisfa la **proprietà di Markov**:

$$\mathbb{P}(X_{t+1} = j \mid X_t = i, X_{t-1} = i_{t-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{t+1} = j \mid X_t = i) = p_{ij}.$$

Il futuro dipende **solo dal presente**, non dalla storia. Le probabilità p_{ij} non dipendono da t (catena omogenea) e formano la matrice di transizione, con $p_{ij} \geq 0$ e $\sum_j p_{ij} = 1$ per ogni riga.

(c) Classe chiusa. Un sottoinsieme $C \subseteq E$ è una **classe chiusa** se gli stati di C non comunicano con quelli di $E \setminus C$, cioè se $p_{ij} = 0$ per ogni $i \in C$ e $j \notin C$: da C non si esce. Se la classe chiusa ha un solo stato, lo stato si dice **assorbente**.

(d) Il grafo e le classi. Un $\times$ in posizione (i, j) significa $p_{ij} > 0$, quindi è un arco $i \rightarrow j$; si legge **riga per riga**. Lo stato 1 ha il solo cappio $1 \rightarrow 1$ (da 1 non si esce). Gli stati 2 e 4 hanno un cappio e un arco verso 3 e 6. Lo stato 3 va in 2 e in 6; lo stato 6 va in 2 e in 4; lo stato 5 va *solo* in 6; lo stato 7 va in 1, in 6 e in sé stesso.

La verifica numerica si fa con la funzione `classi_chiuse` del Cap. 18, applicata alla matrice con la stessa struttura di zeri/non-zeri dell'esame (i valori delle entrate non contano: conta solo quali sono nulle). Il risultato è `[[1], [2, 3, 4, 6]]`. Essendo un quesito di *Teoria*, in sede d'esame contano la definizione e la lettura del grafo: la matrice non si "esegue".

La lettura a mano, che è ciò che l'esame valuta.

- $\{1\}$: l'unico arco uscente è il cappio $1 \rightarrow 1$, quindi da 1 non si esce. È una classe chiusa e lo stato 1 è **assorbente**.
- $\{2, 3, 4, 6\}$: comunicano tutti fra loro ($2 \rightarrow 3 \rightarrow 6 \rightarrow 2$, $6 \rightarrow 4 \rightarrow 6$) e le destinazioni di ciascuno (2, 3 da 2; 2, 6 da 3; 4, 6 da 4; 2, 4 da 6) restano tutte dentro l'insieme: nessun arco esce. È una classe chiusa *irriducibile*.
- $\{5\}$: da 5 si va in 6, che sta nella classe precedente. Si può uscire, quindi **non** è chiusa: 5 è **transitorio**.
- $\{7\}$: da 7 si va in 1 (assorbente), in 6 (classe) e in 7. Si esce, quindi anche 7 è **transitorio**: torna in sé stesso solo con probabilità minore di 1.

Le classi chiuse sono due: $\{1\}$ e $\{2, 3, 4, 6\}$; gli stati transitori sono $\{5, 7\}$.

Classe comunicante $\neq$ classe chiusa

L'errore tipico è fermarsi alle "classi" intese come insiemi di stati che comunicano fra loro e dimenticare la verifica di **chiusura**. Sono due condizioni diverse: $\{5\}$ è banalmente una classe comunicante (un solo stato), ma *non* è chiusa, perché esiste l'arco $5 \rightarrow 6$ verso l'esterno. Il controllo da fare sempre: elencare **tutte** le destinazioni di **tutti** gli stati della classe e verificare che nessuna cada fuori.

20.6 Cosa portare via da questa prova

1. **Una funzione, due chiamate.** Il Q1 va risolto due volte sugli stessi dati: definire `regressione(x, y)` una volta sola è la differenza fra consegnare e non consegnare (Cap. 15).
2. **Il commento del punto (d) si costruisce sui numeri**, non su una frase preconfezionata: la pendenza varia dell'1.11%, R sale da 0.9778 a 0.9861, $\bar{\sigma}_x^2$ quasi triplica. Punti aggiunti coerenti *rafforzano* la stima.
3. **Il metro dell'errore è $1/\sqrt{N}$** , non $1/N$: dieci volte i dati riducono lo scarto di $\sqrt{10} \approx 3.16$, e il rapporto misurato (2.73) lo conferma (Cap. 13).
4. **Stimatore non distorto: la dimostrazione si fa in due righe** con la linearità del valore atteso, ma il compito chiede di *dimostrare* e va scritta per intero (Cap. 6).
5. **Media nota $\Rightarrow$ divisore n ; media incognita $\Rightarrow$ divisore $n - 1$** : sbagliarlo rende lo stimatore distorto del 10% con $n = 10$.

6. **Una classe chiusa va verificata, non indovinata:** si elencano le destinazioni di tutti i suoi stati e si controlla che nessuna esca (Cap. 18).

Capitolo 21

Prova del 24 marzo 2025 (primo turno)

Questa prova è il “pacchetto statistico” del corso: il Q1 di Laboratorio confronta due campioni con varianze *assegnate dal testo*, costruisce un intervallo di confidenza e chiude con un test d’ipotesi unilaterale; il Q2 applica l’hit or miss a un integrale e mostra che cosa succede quando il rettangolo non aderisce più alla funzione. La Teoria chiede la probabilità assiomatica degli eventi e la distribuzione geometrica con la dimostrazione dell’assenza di memoria.

È la prova in cui si vedono meglio le due decisioni che governano tutta la statistica inferenziale del corso: σ^2 **me l’ha data il testo o la stimano i dati?** e la domanda è **direzionale o bilaterale?** (Cap. 16).

21.1 Il testo della prova

Q1 — Laboratorio: due palestre

Uno studente ha notato che la distribuzione della scelta dei pesi della lat machine segue una distribuzione normale con media 45 kg. Fa un’indagine tra i frequentatori della palestra “Muscle Mario” e della palestra “Weak Luigi”. Nella tabella la prima riga è l’elenco dei chili sollevati alla lat, le altre due il numero di persone che ha dichiarato di sollevare quel peso:

Pesi lat	15	20	25	30	35	40	45	50	55	60	65	70	75	80
Muscle Mario	0	1	2	20	34	50	64	59	40	18	11	1	0	0
Weak Luigi	1	6	19	23	52	75	82	93	63	44	21	10	8	3

- Graficare in due istogrammi i dati raccolti dai due campioni.
- Ci si aspetta che i dati provenienti dalla palestra “Muscle Mario” siano estratti da una popolazione con varianza $\sigma^2 = 5$, e quelli della palestra “Weak Luigi” con varianza $\sigma^2 = 3$. Trovare uno stimatore della media.
- Calcolare l’intervallo di confidenza della media con $\alpha = 0.05$.
- Possiamo affermare con confidenza al 5% che la media dei pesi nella palestra “Muscle Mario” sia più bassa di quella dei pesi nella palestra “Weak Luigi”?

Q2 — Laboratorio: hit or miss

- Sotto quali ipotesi posso utilizzare il metodo hit or miss per valutare un integrale?
- Se possibile, utilizzare il metodo hit or miss per calcolare

$$I = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-2}^2 e^{-\frac{x^2}{2\sigma^2}} dx,$$

con $N = 10000$ e $\sigma = 4$. (hint: il massimo della funzione è in $x = 0$)

- Graficare il valore dell’integrale al crescere di N e confrontarlo con il valore teorico.
- Ripetere la simulazione per $\sigma = 0.5$ e commentare se è cambiato qualcosa.

Q3 — Teoria: eventi

- Dare la definizione di evento.
- Dare la definizione di evento incompatibile.
- Dati i due eventi $A = \text{“Giorgino ha studiato”}$ e $B = \text{“Giorgino ha passato l’esame”}$,

esprimere in termini di A e B l'evento composto $E = \text{"Giorgino non ha passato l'esame e ha studiato"}$.

d) Sapendo che A e B sono indipendenti e che $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.5$, calcolare la probabilità dell'evento E .

Q4 — Teoria: la geometrica

- a) Descrivere la distribuzione geometrica e il suo legame con la distribuzione binomiale.
- b) Giorgino ha comprato una confezione di caramelle tre gusti: limone, arancia e menta. Sapendo che ci sono 10 caramelle al limone, 7 all'arancia e 13 alla menta, calcolare la probabilità che, pescando a caso dalla confezione, Giorgino debba pescare sei caramelle prima di trovarne una alla menta.
- c) Di quale proprietà gode questa distribuzione?
- d) Dimostrare questa proprietà.

21.2 Q1 — Le due palestre

Il modello, e la scelta che decide tutto. Le varianze sono **assegnate dal testo** ($\sigma^2 = 5$ e $\sigma^2 = 3$): questo esclude la t di Student e impone i quantili della normale. In più i due campioni hanno varianze *diverse*, quindi il modo corretto di combinare le due medie non è la media semplice ma la **media pesata con pesi inversamente proporzionali alle varianze**:

$$\hat{\mu} = \frac{\frac{n_1 m_1}{\sigma_1^2} + \frac{n_2 m_2}{\sigma_2^2}}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}}, \quad \text{Var}(\hat{\mu}) = \frac{1}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}}.$$

Il campione più grande e più preciso merita più fiducia: sono i pesi $w_i = n_i/\sigma_i^2$ che *minimizzano* la varianza dello stimatore combinato.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 pesi = np.arange(15, 85, 5, dtype=float)
5 mario = np.array([0,1,2,20,34,50,64,59,40,18,11,1,0,0], float)
6 luigi = np.array([1,6,19,23,52,75,82,93,63,44,21,10,8,3], float)
7 n1, n2 = mario.sum(), luigi.sum()
8
9 fig, assi = plt.subplots(1, 2, figsize=(11, 4), sharey=True)
10 for asse, (nome, f) in zip(assi, [("Muscle Mario", mario), ("Weak Luigi", luigi)]):
11     asse.bar(pesi, f/f.sum(), width=4, edgecolor='white')
12     asse.set_title(nome); asse.set_xlabel('kg sollevati')
13     asse.set_ylabel('frequenza relativa')
14 plt.tight_layout(); plt.show()
15
16 m1 = np.sum(pesi*mario)/n1 # media campionaria pesata per le frequenze
17 m2 = np.sum(pesi*luigi)/n2
18 print(f"n1 = {n1:.0f}   n2 = {n2:.0f}")
19 print(f"media Mario = {m1:.4f}   media Luigi = {m2:.4f}")
20
21 # (b) varianze NOTE e diverse -> pesi inversamente proporzionali alle varianze
22 s1sq, s2sq = 5.0, 3.0
23 w1, w2 = n1/s1sq, n2/s2sq
24 mu_hat = (w1*m1 + w2*m2)/(w1 + w2)
25 print(f"w1 = n1/sigma1^2 = {w1:.4f}   w2 = n2/sigma2^2 = {w2:.4f}")
26 print(f"mu_hat = {mu_hat:.4f}   Var(mu_hat) = {1/(w1 + w2):.6f}")

```

Output:

```
n1 = 300    n2 = 500
media Mario = 45.8500    media Luigi = 46.9400
w1 = n1/sigma1^2 = 60.0000    w2 = n2/sigma2^2 = 166.6667
mu_hat = 46.6515    Var(mu_hat) = 0.004412
```

(a–b) I commenti. I dati sono già raggruppati in classi di frequenza, quindi l'istogramma è un bar plot delle frequenze *relative* (non *hist*, che tratterebbe i valori come dati grezzi), e le medie sono pesate: $\bar{X}_n = 45.8500$ kg per Muscled Mario e 46.9400 kg per Weak Luigi. Con $w_1 = 300/5 = 60$ e $w_2 = 500/3 = 166.6667$ lo stimatore combinato vale $\hat{\mu} = 46.6515$, con $\text{Var}(\hat{\mu}) = 0.004412$ (errore standard $\sqrt{0.004412} = 0.0664$): l'errore standard è piccolo perché il testo *assegna* varianze molto minori di quelle osservate nei dati (le varianze campionarie valgono 83.3052 e 133.6036, ma il punto (b) non le usa).

```
1 import numpy as np
2 from scipy import stats
3
4 pesi = np.arange(15, 85, 5, dtype=float)
5 mario = np.array([0,1,2,20,34,50,64,59,40,18,11,1,0,0], float)
6 luigi = np.array([1,6,19,23,52,75,82,93,63,44,21,10,8,3], float)
7 n1, n2 = mario.sum(), luigi.sum()
8 m1 = np.sum(pesi*mario)/n1
9 m2 = np.sum(pesi*luigi)/n2
10 s1sq, s2sq = 5.0, 3.0
11
12 # (c) intervallo di confidenza al 95% per la media comune
13 alpha = 0.05
14 z = stats.norm.ppf(1 - alpha/2)
15 se_mu = np.sqrt(1/(n1/s1sq + n2/s2sq))
16 mu_hat = (n1*m1/s1sq + n2*m2/s2sq)/(n1/s1sq + n2/s2sq)
17 print(f"phi_0.975 = {z:.4f}")
18 print(f"IC 95% (stimatore combinato) = [{mu_hat - z*se_mu:.4f}, {mu_hat + z*se_mu:.4f}]")
19     f"    semilarghezza {z*se_mu:.4f}")
20
21 # (d) test unilaterale sinistro, varianze ASSEGNATE dal testo
22 se_d = np.sqrt(s1sq/n1 + s2sq/n2)
23 z_oss = (m1 - m2)/se_d
24 print(f"\nse = sqrt(5/300 + 3/500) = {se_d:.6f}")
25 print(f"z = (45.8500 - 46.9400)/se = {z_oss:.4f}")
26 print(f"critico phi_0.05 = {stats.norm.ppf(alpha):.4f}    p-value = {stats.norm.cdf(z_oss):.3e}"
27     ↪ )
28
29 # controprova: con le varianze EMPIRICHE il test non rigetta piu'
30 v1 = np.sum(mario*(pesi-m1)**2)/(n1-1)
31 v2 = np.sum(luigi*(pesi-m2)**2)/(n2-1)
32 z_emp = (m1 - m2)/np.sqrt(v1/n1 + v2/n2)
33 print(f"\nvarianze empiriche: {v1:.4f} e {v2:.4f}")
34 print(f"z = {z_emp:.4f}    p-value = {stats.norm.cdf(z_emp):.4f}")
```

Output:

```
phi_0.975 = 1.9600
IC 95% (stimatore combinato) = [46.5213, 46.7817]    semilarghezza 0.1302

se = sqrt(5/300 + 3/500) = 0.150555
z = (45.8500 - 46.9400)/se = -7.2399
critico phi_0.05 = -1.6449    p-value = 2.245e-13

varianze empiriche: 83.3052 e 133.6036
z = -1.4766    p-value = 0.0699
```

(c) **L'intervallo di confidenza.** Con $\alpha = 0.05$ si ha $\varphi_{0.975} = 1.9600$ e

$$I_\mu = [46.6515 - 1.96 \cdot 0.0664, 46.6515 + 1.96 \cdot 0.0664] = [46.5213, 46.7817],$$

con semilarghezza 0.1302 kg. L'intervallo è strettissimo, ed è l'indicazione che le varianze *assunte* (5 e 3) sono molto più piccole di quelle osservate nei dati: rifacendo l'intervallo con la varianza campionaria di Weak Luigi (133.6036) la semilarghezza salirebbe a 1.0132, quasi otto volte tanto.

(d) **Il test.** La domanda è direzionale (“più bassa”), quindi unilaterale sinistro:

$$H_0 : \mu_{MM} \geq \mu_{WL} \quad \text{contro} \quad H_1 : \mu_{MM} < \mu_{WL}, \quad Z_n = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}}.$$

La statistica vale $z = -7.2399$ contro il valore critico $\varphi_{0.05} = -1.6449$, e il p -value è 2.245×10^{-13} : si **rigetta** H_0 . Sì, si può affermare con confidenza al 95% che la media dei pesi di “Muscle Mario” (45.85 kg) è **più bassa** di quella di “Weak Luigi” (46.94 kg). La differenza però è piccola in pratica (1.09 kg): il test dice che l'effetto è reale, non che sia grande.

“L'intervallo della media”: due letture, entrambe legittime

Il punto (c) dice “della media” senza specificare quale. La lettura coerente con il punto (b) è quella dello **stimatore combinato** $\hat{\mu}$, ed è quella usata sopra. Se invece si vuole l'intervallo della media di *ciascuna* palestra, si costruisce con la varianza assegnata alla palestra:

$$MM = [45.5970, 46.1030], \quad WL = [46.7882, 47.0918],$$

con semilarghezze 0.2530 e 0.1518. Il secondo è più stretto del primo perché Weak Luigi ha più dati (500 contro 300) e varianza più piccola (3 contro 5). In sede d'esame conviene dichiarare quale delle due letture si sta usando; i due intervalli sono sviluppati nel Cap. 16.

La conclusione dipende dalle varianze *assunte*

Se al posto di $\sigma^2 = 5$ e $\sigma^2 = 3$ si usassero le varianze empiriche (83.3052 e 133.6036), la statistica diventerebbe $z = -1.4766$ con $p = 0.0699$: **non** si rigetterebbe H_0 al 5%. Il testo *impone* le varianze, quindi la risposta corretta è quella che rigetta; ma vale la pena notarlo, perché spiega perché il test è così netto. Da non scrivere: “non c'è differenza fra le due palestre” — al più, con le varianze empiriche, *non c'è evidenza sufficiente* per affermare che la media di Muscle Mario sia più bassa.

21.3 Q2 — Hit or miss su una gaussiana troncata

(a) **Le ipotesi.** Servono tutte e tre: $f \geq 0$ sull'intervallo, intervallo e funzione **limitati**, e un maggiorante M noto. Qui $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-x^2/(2\sigma^2)}$ è una densità normale centrata in 0: è positiva, limitata, e su $[-2, 2]$ il massimo è in $x = 0$ (lo dice l'hint), con $M = f(0)$. Il valore *esatto* si ricava dalla funzione di ripartizione:

$$I = \mathbb{P}\left(-\frac{2}{\sigma} < Z < \frac{2}{\sigma}\right) = \Phi\left(\frac{2}{\sigma}\right) - \Phi\left(-\frac{2}{\sigma}\right).$$

Il codice qui sotto calcola prima le costanti teoriche (che servono per il commento) e poi esegue davvero l'hit or miss con $N = 10000$.

```
1 import numpy as np
2 from scipy import stats
3
4 a, b, N = -2.0, 2.0, 10000
```

```

5 print("sigma  M = f(0)  I esatto  p = I/(4M)  Var*N      SE(N=10000)")
6 for sigma in (4.0, 0.5):
7     M = 1/np.sqrt(2*np.pi*sigma**2)
8     esatto = stats.norm.cdf(b/sigma) - stats.norm.cdf(a/sigma)
9     A = (b - a)*M
10    print(f"sigma:<7} {M:.6f} {esatto:.6f} {esatto/A:11.6f} {esatto*(A-esatto):10.6f}"
11          f" {np.sqrt(esatto*(A-esatto)/N):10.6f}")
12
13 def hit_or_miss(sigma, N, seme=7):
14     """Stima hit or miss su [-2,2] x [0, M], M = f(0)."""
15     M = 1/np.sqrt(2*np.pi*sigma**2)
16     rng = np.random.default_rng(seme)
17     x = rng.uniform(a, b, N)
18     y = rng.uniform(0.0, M, N)
19     f = np.exp(-x**2/(2*sigma**2))/np.sqrt(2*np.pi*sigma**2)
20     hit = (y <= f)
21     return (b - a)*M*hit.mean(), hit.mean()
22
23 for sigma in (4.0, 0.5):
24     stima, p = hit_or_miss(sigma, N)
25     esatto = stats.norm.cdf(b/sigma) - stats.norm.cdf(a/sigma)
26     print(f"sigma={sigma}: stima={stima:.6f} errore={stima-esatto:+.6f}"
27           f"  accettazione={p:.4f}")

```

Output:

```

sigma  M = f(0)  I esatto  p = I/(4M)  Var*N      SE(N=10000)
4.0    0.099736 0.382925  0.959850  0.006133  0.000783
0.5    0.797885 0.999937  0.313309  2.191463  0.014804
sigma=4.0: stima=0.383822 errore=+0.000897  accettazione=0.9621
sigma=0.5: stima=0.973419 errore=-0.026517  accettazione=0.3050

```

(b–c) Il caso $\sigma = 4$, e la lettura dell’output. La stima vale 0.383822 contro il valore esatto 0.382925: l’errore è +0.000897, cioè 1.1 errori standard teorici ($SE = 0.000783$), perfettamente compatibile. La frazione di accettazione misurata (0.9621) coincide con il valore teorico $p = I/A = 0.959850$: il rettangolo scelto è quello ottimale, e quasi tutti i punti cadono sotto la curva. Plottando la stima cumulata $\hat{I}_n = 4M \frac{1}{n} \sum_{i \leq n} \text{hit}_i$ in funzione di n , le oscillazioni si restringono come $1/\sqrt{n}$ attorno al valore esatto: è il punto (c) del quesito (Cap. 17).

(d) Che cosa cambia con $\sigma = 0.5$. Cambia la *precisione*, non l’applicabilità del metodo. Con $\sigma = 0.5$ la funzione è un picco stretto: a $x = \pm 2$ siamo a 4 scarti standard e f è scesa allo 0.03% del massimo, quindi il rettangolo $[-2, 2] \times [0, 0.797885]$ è quasi tutto vuoto e la frazione di accettazione crolla a 0.313309. La varianza dello stimatore $\text{Var}(\hat{I}) = I(A - I)/N$ passa da $0.006133/N$ a $2.191463/N$: è 357.3 **volte** più grande, e l’errore standard $\sqrt{357.3} = 18.90$ volte più grande (0.014804 contro 0.000783). Nella simulazione l’errore osservato è infatti -0.026517 , circa 1.8 errori standard. Per ottenere la stessa precisione del caso $\sigma = 4$ servirebbero circa 357 volte i punti.

Il rettangolo va scelto aderente, non “grande per sicurezza”

Lo stimatore $\hat{I} = A\hat{p}$ resta non distorto per qualunque $M \geq \max f$, ma la varianza vale $I(A - I)/N$: allargare il rettangolo non sbaglia la stima, la rende solo inutilmente rumorosa. Il caso limite opposto è peggio: se $M < \max f$ il rettangolo *non contiene* la regione sotto la curva e la stima diventa **distorta**. Qui il massimo è $x = 0$ e $M = f(0)$ va preso esatto: con $\sigma = 4$ vale 0.099736, con $\sigma = 0.5$ vale 0.797885 (Cap. 17).

21.4 Q3 — Teoria: evento, evento incompatibile, indipendenza

(a) **Evento.** Fissato lo spazio campionario Ω (l'insieme di tutti i risultati possibili dell'esperimento), un **evento** è un sottoinsieme $A \subseteq \Omega$. L'evento si realizza se il risultato dell'esperimento appartiene ad A .

(b) **Eventi incompatibili.** A e B sono **incompatibili** (disgiunti) se $A \cap B = \emptyset$: non possono verificarsi insieme, quindi $\mathbb{P}(A \cap B) = 0$ e $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$.

(c) **L'evento composto.** Con A = “ha studiato” e B = “ha passato l'esame”, l'evento “non ha passato l'esame e ha studiato” è l'intersezione di A con il complementare di B :

$$E = A \cap \bar{B}.$$

Il punto d'esame è il *non*: “non ha passato” è $\bar{B}$, e la congiunzione “e” diventa un'intersezione. Scrivere $E = \bar{B}$ (dimenticando che ha anche studiato) oppure $E = A \cup \bar{B}$ sono gli errori tipici.

(d) **La probabilità.** A e B sono indipendenti, e l'indipendenza si conserva passando ai complementari: anche A e $\bar{B}$ sono indipendenti. Quindi

$$\mathbb{P}(E) = \mathbb{P}(A \cap \bar{B}) = \mathbb{P}(A) \mathbb{P}(\bar{B}) = \mathbb{P}(A)(1 - \mathbb{P}(B)) = 0.3 \cdot 0.5 = 0.15.$$

Il valore 0.15 è la risposta richiesta.

Perché A e $\bar{B}$ sono indipendenti

È il passaggio su cui si perde il punto. Se $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$, allora

$$\mathbb{P}(A \cap \bar{B}) = \mathbb{P}(A) - \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A)\mathbb{P}(B) = \mathbb{P}(A)(1 - \mathbb{P}(B)),$$

che è esattamente $\mathbb{P}(A)\mathbb{P}(\bar{B})$. L'indipendenza “sopravvive” al complementare, e questa verifica va scritta: affermarla senza giustificarla è mezzo punto in meno.

21.5 Q4 — Teoria: la distribuzione geometrica

(a) **La distribuzione, e il legame con la binomiale.** La **geometrica** conta il numero di prove di Bernoulli necessarie per ottenere il *primo* successo, in una successione di prove i.i.d. con probabilità di successo p :

$$\text{Geom}(p) : \quad \mathbb{P}(X = k) = (1 - p)^{k-1}p, \quad k = 1, 2, 3, \dots$$

Il **legame con la binomiale** è nello schema: entrambe descrivono prove di Bernoulli i.i.d., ma la *binomiale* fissa il numero di prove n e conta i successi, mentre la *geometrica* fissa il numero di successi (uno) e conta le prove necessarie. Sono la stessa moneta guardata da due lati.

(b) **L'esempio delle caramelle.** Nella confezione ci sono $10 + 7 + 13 = 30$ caramelle, di cui 13 alla menta: se si pesca “a caso” con restituzione, $p = \mathbb{P}(\text{menta}) = 13/30 = 0.433333$. “Dover pescare sei caramelle prima di trovarne una alla menta” si legge come *il primo successo alla sesta prova*:

$$\mathbb{P}(X = 6) = (1 - p)^5 p = \left(\frac{17}{30}\right)^5 \cdot \frac{13}{30} = 0.025320.$$

```

1 import numpy as np
2 from scipy import stats
3
4 p = 13/30                                # P(menta) = 13 caramelle su 30
5 print(f"p = 13/30 = {p:.6f}    1-p = 17/30 = {1-p:.6f}")
6 for k in (6, 7):
7     print(f"P(X = {k}) = (17/30)^(k-1) * 13/30 = {(1-p)**(k-1)*p:.6f}")
8

```

```

9 # assenza di memoria:  $P(X > s+t \mid X > s) = P(X > t)$ 
10 print(f"P(X > 5)/P(X > 3) = {(1-p)**5:.6f}/{(1-p)**3:.6f} = {(1-p)**5/(1-p)**3:.6f}")
11 print(f"P(X > 2) = {(1-p)**2:.6f}")
12
13 rng = np.random.default_rng(2025)
14 X = rng.geometric(p, size=200000) # prove fino al primo successo
15 print(f"\nsimulazione (200000 repliche): media di X = {X.mean():.4f} (1/p = {1/p:.4f})")
16 print(f"P(X = 6) simulata = {(X == 6).mean():.6f}")
17 print(f"P(X > 5 | X > 3) simulata = {(X > 5).sum()/(X > 3).sum():.6f}")

```

Output:

```

p = 13/30 = 0.433333 1-p = 17/30 = 0.566667
P(X = 6) = (17/30)^5 * 13/30 = 0.025320
P(X = 7) = (17/30)^6 * 13/30 = 0.014348
P(X > 5)/P(X > 3) = 0.058430/0.181963 = 0.321111
P(X > 2) = 0.321111

simulazione (200000 repliche): media di X = 2.3067 (1/p = 2.3077)
P(X = 6) simulata = 0.025020
P(X > 5 | X > 3) simulata = 0.318951

```

(c) **La proprietà: l'assenza di memoria.** Per ogni $s, t \geq 1$,

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

Se finora non ho avuto successo, la legge del tempo *rimanente* è identica a quella di partenza: la variabile “non invecchia”. Nel codice la si vede in azione: $\mathbb{P}(X > 5)/\mathbb{P}(X > 3) = 0.321111$ coincide con $\mathbb{P}(X > 2) = 0.321111$.

(d) **La dimostrazione.** Serve prima il calcolo di $\mathbb{P}(X > k)$, che si ottiene sommando una serie geometrica:

$$\mathbb{P}(X > k) = \sum_{j=k+1}^{\infty} (1-p)^{j-1}p = (1-p)^k.$$

Allora

$$\mathbb{P}(X > s + t \mid X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{(1-p)^{s+t}}{(1-p)^s} = (1-p)^t = \mathbb{P}(X > t). \quad \blacksquare$$

Il passaggio chiave è l'ultimo: l'esponente s si semplifica, ed è *quello* a far sparire il passato dalla formula.

“Sei caramelle prima”: due letture, e le due risposte

La formula “sei caramelle prima di trovarne una alla menta” ammette due letture, e conviene dichiarare quella scelta. Se significa *il primo successo alla sesta prova* (ed è la lettura usata qui, coerente con la definizione della geometrica) la risposta è $\mathbb{P}(X = 6) = 0.025320$. Se invece significa *sei insuccessi prima del successo*, cioè primo successo alla settima prova, la risposta è $\mathbb{P}(X = 7) = (17/30)^6 \cdot 13/30 = 0.014348$. Nel compito conviene scrivere la formula e il valore, aggiungendo in una riga quale lettura si è adottata. Da notare anche l'ipotesi di fondo: si pesca “con restituzione”, altrimenti le prove non sarebbero indipendenti e la geometrica non varrebbe.

La semplificazione va mostrata, non solo il risultato

Alla domanda “dimostrare questa proprietà” non basta scrivere $\frac{(1-p)^{s+t}}{(1-p)^s} = (1-p)^t$ senza dire da dove viene $(1-p)^k$: serve il passaggio $\mathbb{P}(X > k) = \sum_{j>k} (1-p)^{j-1}p = (1-p)^k$. Il correttore cerca la serie geometrica, che è il punto matematico della dimostrazione. E

attenzione al verso della condizionata: $\mathbb{P}(X > s + t \mid X > s)$, non $\mathbb{P}(X > s \mid X > s + t)$ — confonderle porta a un rapporto invertito.

21.6 Cosa portare via da questa prova

1. **Varianze assegnate $\Rightarrow$ normale, non t :** è la prima decisione del Q1, e la si dichiara in una riga (Cap. 16).
2. **Due campioni con varianze diverse si combinano con i pesi n_i/σ_i^2 ,** non con la media semplice: lo stimatore a varianza minima ha $\text{Var}(\hat{\mu}) = 1/(w_1 + w_2)$ (Cap. 16).
3. **La direzione dell'ipotesi decide il quantile:** “più bassa” $\Rightarrow$ unilaterale sinistro, valore critico $\varphi_{0.05} = -1.6449$, $p\text{-value} = \Phi(z)$.
4. **Hit or miss: la varianza è $I(A-I)/N$,** quindi dipende dall'area del rettangolo. Con $\sigma = 0.5$ la varianza è 357 volte quella con $\sigma = 4$: stesso integrale quasi 1, difficoltà completamente diverse (Cap. 17).
5. $\mathbb{P}(A \cap \bar{B}) = \mathbb{P}(A)\mathbb{P}(\bar{B})$ **va giustificato** con l'indipendenza dei complementari, e “non ha passato l'esame e ha studiato” è un'intersezione, non un'unione.
6. **Assenza di memoria:** $\mathbb{P}(X > k) = (1 - p)^k$ è il passaggio che regge tutta la dimostrazione; la lettura di “sei caramelle prima” va dichiarata (Cap. 4).

Capitolo 22

Prova del 17 giugno 2025

Prova “mista”: il Q1 di Laboratorio è una simulazione (il gioco dell’oca, con una sola uniforme discreta dietro), il Q2 è statistica descrittiva pura su dati già raggruppati. Sono due modi opposti di lavorare — nel primo i dati li *produciamo*, nel secondo ci sono già dati — e in entrambi il punto non è il calcolo ma il **confronto con la teoria**: la media di un dado deve venire 3.5, il numero di lanci per finire deve venire $\approx 100/3.5$, la skewness e la curtosi devono raccontare la forma della distribuzione.

La Teoria chiede la probabilità assiomatica con le variabili aleatorie (Cap. 3, 4) e una catena di Markov con pareti riflettenti, da scrivere e commentare (Cap. 9).

22.1 Il testo della prova

Q1 — Laboratorio: il gioco dell’oca

Giorgino sta giocando da solo al Gioco dell’oca. Ad ogni turno lancia un dado a sei facce e si muove di tante caselle quante indicate dal dado. Il gioco finisce quando Giorgino ritorna al via dopo aver attraversato tutto il tabellone.

- a) Sia X la variabile aleatoria che descrive l’evento “lancio del dado”. Che distribuzione segue X ?
- b) Assumendo che il dado sia equilibrato e che il tabellone abbia 100 caselle, simulare una partita al gioco dell’oca. Plottare i risultati ottenuti ad ogni lancio in funzione del numero del lancio. (hint: ricordate che il gioco si arresta quando si supera la linea del via!)
- c) Qual è il risultato più frequente? Qual è il risultato meno frequente? Qual è la media? Commentare se i dati rispecchiano i risultati che ci aspettiamo dalla teoria.
- d) Quanti lanci ha impiegato Giorgino per completare la prima partita? Ripetere la simulazione per 100 partite e calcolare il numero medio di lanci necessario per finire il gioco. (hint: ogni partita si concluderà in un numero diverso di mosse. Il numero di mosse è una v.a.: posso calcolarne la media!)

Q2 — Laboratorio: i nomi delle vie

Vagando per le vie della città Giorgino si è messo a contare il numero di lettere dei nomi delle vie che ha attraversato. Non esistono vie con nomi con meno di 3 lettere o con più di 15 lettere. Dopo aver attraversato le $N = 500$ vie di tutta la città ha registrato:

Numero di lettere	3	4	5	6	7	8	9	10	11	12	13	14	15
Frequenza	2	20	59	89	62	15	14	21	48	72	61	28	9

- a) Plottare in un istogramma i dati raccolti.
- b) Calcolare la media e trovare la moda dei dati. C’è corrispondenza tra i due valori?
- c) Calcolare i momenti empirici centrati di ordine 2, 3 e 4 utilizzando la definizione (ovvero, per questo punto, non è permesso utilizzare le funzioni già scritte in Python).
- d) Calcolare il coefficiente di skewness e quello di curtosi. Commentare il risultato.

Q3 — Teoria: probabilità e variabili aleatorie

- a) Dare la definizione assiomatica di probabilità, avendo cura di definire anche gli spazi di probabilità.
- b) Dare la definizione di variabile aleatoria. Qual è la differenza tra variabile aleatoria discreta e continua?
- c) Sia X una variabile aleatoria discreta. Dare la definizione di legge di X e di densità discreta.
- d) Di che proprietà gode la densità discreta?

Q4 — Teoria: una passeggiata con pareti riflettenti

- a) Sia data una catena di Markov. Dare la definizione di matrice di transizione.
- b) Dare la definizione di catena di Markov irriducibile.
- c) Si consideri una catena di Markov con sei stati, per cui $E = \{1, 2, 3, 4, 5, 6\}$. Se mi trovo in $i = 1$ ho il 50% di probabilità di restare in 1 o di andare in 2. Se mi trovo in $i = 6$ ho il 50% di probabilità di restare in 6 o di andare in 5. Se mi trovo nello stato $i \neq 1, 6$ ho il 50% di probabilità di andare nello stato $i + 1$ e il 50% di andare nello stato $i - 1$. Scrivere la matrice di transizione associata a questa catena e rappresentarla su un grafo.
- d) Questa catena è irriducibile? Spiegare perché.

22.2 Q1 — Il gioco dell'oca

(a) La distribuzione del dado. Un dado equilibrato assume i valori $\{1, \dots, 6\}$ tutti con la stessa probabilità $1/6$: è una **uniforme discreta** su $\{1, \dots, 6\}$, con

$$E[X] = 3.5, \quad \text{Var}(X) = \frac{6^2 - 1}{12} = \frac{35}{12} \approx 2.917.$$

Non è una binomiale: le prove non sono “successo/insuccesso” e i valori non sono conteggi, ma etichette equiprobabili.

(b) La simulazione. Si accumula la posizione lancio dopo lancio e ci si ferma quando si *supera* la casella 100 (“si torna al via”). Il plot della posizione in funzione del numero di lancio è una scala crescente che termina sopra la linea del via.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 TABELLONE = 100
5 rng = np.random.default_rng(42)
6
7 # --- (b) una partita -----
8 pos, rolls = 0, []
9 while pos <= TABELLONE:                # finche' non supero la linea del via
10     r = rng.integers(1, 7)            # dado equilibrato: {1,...,6}
11     rolls.append(r)
12     pos += r
13 rolls = np.array(rolls)
14 posizioni = np.cumsum(rolls)
15
16 plt.plot(np.arange(1, len(rolls) + 1), posizioni, 'o-')
17 plt.axhline(TABELLONE, color='r', ls='--', label="linea del via (100)")
18 plt.xlabel("numero di lancio"); plt.ylabel("posizione sul tabellone")
19 plt.legend(); plt.show()
20
21 print(f"prima partita: {len(rolls)} lanci, ultima posizione {posizioni[-1]}")
22

```

```

23 # --- (c) frequenze degli esiti di quella partita -----
24 valori, conteggi = np.unique(rolls, return_counts=True)
25 print("esito piu' frequente :", valori[conteggi.argmax()], f"({conteggi.max()} volte)")
26 print("esito meno frequente:", valori[conteggi.argmin()], f"({conteggi.min()} volte)")
27 print(f"media degli esiti      : {rolls.mean():.3f}      (teorica 3.5)")
28
29 # --- (d) 100 partite -----
30 def partita(rng):
31     pos, n = 0, 0
32     while pos <= TABELLONE:
33         pos += rng.integers(1, 7)
34         n += 1
35     return n
36
37 lanci = np.array([partita(rng) for _ in range(100)])
38 print(f"\n100 partite: media lanci = {lanci.mean():.2f}, scarto = {lanci.std(ddof=1):.2f}")
39 print(f"minimo = {lanci.min()}, massimo = {lanci.max()}")
40 print(f"attesa teorica 100/3.5 = {100/3.5:.2f}")

```

Output:

```

prima partita: 27 lanci, ultima posizione 102
esito piu' frequente : 5 (7 volte)
esito meno frequente: 2 (2 volte)
media degli esiti      : 3.778      (teorica 3.5)

100 partite: media lanci = 29.40, scarto = 2.63
minimo = 24, massimo = 36
attesa teorica 100/3.5 = 28.57

```

(c) Il commento sui dati di una partita. Con 27 lanci ci si aspetta circa $27/6 = 4.5$ occorrenze per faccia: le frequenze osservate ($1 \rightarrow 4, 2 \rightarrow 2, 3 \rightarrow 5, 4 \rightarrow 5, 5 \rightarrow 7, 6 \rightarrow 4$) oscillano attorno a questo valore e la faccia “più frequente” cambia da simulazione a simulazione — qui è il 5 con 7 occorrenze, la meno frequente è il 2 con 2. La **media** invece è molto più stabile: 3.778 contro il valore teorico 3.5. La lettura corretta è quindi: *le frequenze di un singolo valore sono rumorose, la media no*. E non c’è contraddizione con la teoria: lo scarto di 0.278 sulla media di 27 lanci vale $0.278/0.329 = 0.85$ errori standard, dove $\sigma_X/\sqrt{n} = \sqrt{35/12}/\sqrt{27} = 0.3287$ è l’errore standard *della media* (e $\sigma_X = \sqrt{35/12} = 1.7078$ quello del singolo lancio).

(d) Il numero di lanci, che è anch’esso una v.a. Ogni partita dura un numero diverso di mosse: su 100 partite la media è 29.40 lanci, con minimo 24 e massimo 36. Il valore indicato dall’hint — ad ogni lancio si avanza in media di 3.5 caselle, quindi circa $100/3.5 = 28.57$ lanci — è un’approssimazione per *difetto*: l’ultimo lancio può *superare* la linea del via, quindi il numero atteso di lanci è un po’ più grande. Il valore vero si misura su molte partite:

```

1 import numpy as np
2
3 # il valore vero di E[N], su 300000 partite (vettorizzato)
4 rng = np.random.default_rng(7)
5 passi = rng.integers(1, 7, size=(300000, 200))
6 N = (np.cumsum(passi, axis=1) > 100).argmax(axis=1) + 1
7 print(f"E[N] su 300000 partite = {N.mean():.4f}      scarto = {N.std(ddof=1):.4f}")
8 print(f"100/3.5                      = {100/3.5:.4f}")

```

Output:

```

E[N] su 300000 partite = 29.3289      scarto = 2.6352
100/3.5                      = 28.5714

```

Il valore atteso vero è quindi $E[N] \approx 29.3289$, cioè 0.76 lanci sopra l’approssimazione dell’hint, e lo scarto del numero di lanci per partita vale 2.6352 (le 100 partite di prima davano 2.63: coincidono). Confrontata con il valore vero, la media simulata (29.40) dista 0.07 lanci, cioè $0.07/0.2635 = 0.27$

errori standard: l'accordo è ottimo, non “un valore un po' alto”. Il commento da scrivere è che l'hint dà l'ordine di grandezza giusto (≈ 29 lanci) ma non il valore esatto, perché trascura l'ultimo lancio che scavalca la linea.

Due livelli di casualità in un solo quesito

Il punto (d) nasconde il passaggio concettuale più fine della prova. Il numero di lanci di una partita è una variabile aleatoria (con la sua media e la sua varianza, stimate da 24–36 e 2.63); la *media* di 100 partite è un'altra variabile aleatoria, con errore standard $\sigma/\sqrt{100}$. Sono due livelli diversi, e vanno giudicati con due metri diversi: confrontare la media di 100 partite con l'errore standard di una partita farebbe sembrare tutto perfettamente centrato, ed è l'errore più insidioso di questo tipo di quesito (Cap. 13).

22.3 Q2 — Il numero di lettere dei nomi delle vie

I momenti “dalla definizione”. Il testo vieta le funzioni pronte, quindi si usa $\mu_r = \frac{1}{N} \sum_i (x_i - \bar{x})^r f_i$ con i dati raggruppati. La media $\bar{x} = \frac{1}{N} \sum_i x_i f_i = 9.0340$ cade *in mezzo* alle due gobbe dell'istogramma: la frequenza massima è a 6 lettere (89 vie) e c'è un secondo picco a 12 lettere (72 vie), con un avvallamento a 8–9 (15 e 14 vie). È già l'indizio che la distribuzione non è né simmetrica né normale.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 import scipy.stats as stats
4
5 lettere = np.arange(3, 16)
6 freq = np.array([2,20,59,89,62,15,14,21,48,72,61,28,9], float)
7 N = freq.sum()
8 print(f"N = {N:.0f}")
9
10 plt.bar(lettere, freq/N, edgecolor='white')
11 plt.xlabel("numero di lettere"); plt.ylabel("frequenza relativa")
12 plt.xticks(lettere); plt.show()
13
14 media = np.sum(lettere*freq)/N
15 moda = lettere[freq.argmax()]
16 print(f"media = {media:.4f}   moda = {moda:.0f} (frequenza {freq.max():.0f})")
17
18 # (c) momenti centrati empirici, dalla definizione
19 mu2 = np.sum(freq*(lettere - media)**2)/N
20 mu3 = np.sum(freq*(lettere - media)**3)/N
21 mu4 = np.sum(freq*(lettere - media)**4)/N
22 print(f"mu2 = {mu2:.4f}   mu3 = {mu3:.4f}   mu4 = {mu4:.4f}")
23
24 # (d) skewness e curtosi
25 gammal = mu3/mu2**1.5
26 beta2 = mu4/mu2**2
27 print(f"skewness gammal = {gammal:.4f}")
28 print(f"curtosi beta2 = {beta2:.4f} (normale: 3)")
29 print(f"coefficiente gamma = beta2 - 3 = {beta2 - 3:.4f}")
30
31 dati = np.repeat(lettere, freq.astype(int))
32 print(f"controllo scipy: skew = {stats.skew(dati):.4f}, kurtosis = {stats.kurtosis(dati):.4f}")

```

Output:

```

N = 500
media = 9.0340   moda = 6 (frequenza 89)
mu2 = 10.8808   mu3 = 3.0401   mu4 = 179.1371

```

```
skewness gamma1 = 0.0847
curtosi beta2    = 1.5131 (normale: 3)
coefficiente gamma = beta2 - 3 = -1.4869
controllo scipy: skew = 0.0847, kurtosis = -1.4869
```

(b) **Media e moda: c'è corrispondenza? No.** La media è 9.0340, la moda è 6: in una distribuzione simmetrica e unimodale coinciderebbero, qui non coincidono. Il motivo è la **bimodalità**: le due gobbe si trovano a 6 e a 12 lettere, e la media cade proprio nel mezzo, in una zona dove i dati scarseggiano. È la risposta da scrivere, con il riferimento all'istogramma.

(c) **I momenti.** $\mu_2 = 10.8808$, $\mu_3 = 3.0401$, $\mu_4 = 179.1371$. Il controllo di coerenza: μ_2 è la varianza *empirica* (divisore N), quindi deve essere un po' minore della varianza campionaria $\bar{S}_n^2$ con divisore $N - 1$, che vale 10.9026 — e infatti lo è, di un fattore $499/500 = 0.998$. Il controllo con `scipy` sui dati espansi conferma gli stessi valori (0.0847 e -1.4869).

(d) **Skewness e curtosi — il commento che vale i punti.**

$$\gamma_1 = \frac{\mu_3}{\mu_2^{3/2}} = 0.0847, \quad \beta_2 = \frac{\mu_4}{\mu_2^2} = 1.5131, \quad \gamma = \beta_2 - 3 = -1.4869.$$

γ_1 è **molto vicino a zero**: non c'è evidenza di asimmetria (il segno positivo indica una leggerissima coda a destra). Da solo, questo indice suggerirebbe una distribuzione quasi normale. Ma $\beta_2 = 1.5131$ è *molto* minore di 3: la distribuzione è nettamente **platicurtica**, cioè più piatta di una normale, con code leggere. Le due informazioni insieme descrivono esattamente ciò che si vede: le due gobbe si bilanciano (asimmetria complessivamente nulla) ma il “vuoto” centrale abbassa il picco rispetto alla normale (curtosi negativa).

“Skewness ≈ 0 ” non significa “normale”

È l'inferenza sbagliata da evitare. L'annullarsi dell'asimmetria è condizione *necessaria* ma **non sufficiente** per la simmetria (esistono distribuzioni asimmetriche con $\gamma_1 = 0$), e comunque non dice nulla sulla forma delle code. Qui è la **curtosi** a smentire la normalità ($\beta_2 = 1.5131$ contro 3), e l'istogramma a mostrarne la ragione: la distribuzione è bimodale. La frase corretta è “ $\gamma_1 \approx 0$ da solo non basta a concludere la normalità”.

22.4 Q3 — Teoria: probabilità assiomatica e variabili aleatorie

(a) **Probabilità assiomatica.** Uno **spazio di probabilità** è una terna $(\Omega, \mathcal{F}, \mathbb{P})$ dove Ω è lo *spazio campionario* (l'insieme di tutti i risultati possibili), $\mathcal{F}$ è una σ -algebra su Ω (la famiglia degli eventi, chiusa per complemento e unioni numerabili) e $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ soddisfa gli **assiomi di Kolmogorov**:

1. $\mathbb{P}(A) \geq 0$ per ogni $A \in \mathcal{F}$ (non negatività);
2. $\mathbb{P}(\Omega) = 1$ (normalizzazione);
3. per una famiglia numerabile di eventi incompatibili a due a due, $\mathbb{P}(\bigcup_i A_i) = \sum_i \mathbb{P}(A_i)$ (additività numerabile).

(b) **Variabile aleatoria.** È una funzione $X : \Omega \rightarrow \mathbb{R}$ (misurabile) che associa un numero reale a ogni risultato dell'esperimento. È **discreta** se prende un insieme finito o numerabile di valori, **continua** se assume valori in un intervallo di $\mathbb{R}$. La differenza operativa: per una discreta le probabilità sono concentrate sui punti ($\mathbb{P}(X = x_k) > 0$ e si sommano), per una continua $\mathbb{P}(X = a) = 0$ per ogni a e le probabilità si calcolano con integrali della densità.

(c) **Legge e densità discreta.** La **legge** di X è la funzione $\mathbb{P}_X(B) = \mathbb{P}(X \in B)$ per $B \subseteq \mathbb{R}$: dice come si distribuisce la probabilità sui valori di X . Per una v.a. discreta la legge è descritta dalla **densità discreta** (funzione di probabilità)

$$p(x_k) = \mathbb{P}(X = x_k), \quad k = 1, 2, \dots$$

(d) **Le proprietà della densità discreta.** Due, e vanno entrambe scritte:

$$p(x_k) \geq 0 \quad \forall k, \quad \sum_k p(x_k) = 1.$$

Da esse segue la regola di calcolo: per ogni insieme di valori A , $\mathbb{P}(X \in A) = \sum_{x_k \in A} p(x_k)$.

Tre definizioni, tre cose da non confondere

- **legge $\neq$ densità:** la legge è la funzione d'insieme $\mathbb{P}_X(B)$ e serve a calcolare $\mathbb{P}(X \in B)$; la densità discreta è la funzione $p(x_k) = \mathbb{P}(X = x_k)$ e serve a calcolare $\mathbb{P}(X = x_k)$. Per una discreta, dalla densità si risale alla legge sommando.
- **lo spazio di probabilità è una terna**, non un insieme: dimenticare la σ -algebra $\mathcal{F}$ o la funzione $\mathbb{P}$ è un punto perso, perché il quesito chiede esplicitamente di “definire anche gli spazi di probabilità”.
- **discreta $\neq$ continua:** ciò che cambia non è “quanti valori” ma come si calcolano le probabilità — somme contro integrali, e $\mathbb{P}(X = a) = 0$ per ogni a nel caso continuo.

22.5 Q4 — Teoria: la passeggiata con pareti riflettenti

(a) **Matrice di transizione.** Per una catena di Markov a stati finiti $E = \{1, \dots, k\}$ è la matrice $P = (p_{ij})$ con

$$p_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i),$$

cioè la probabilità di passare da i a j in un passo. Due proprietà da verificare sempre: $p_{ij} \geq 0$ per ogni i, j e $\sum_j p_{ij} = 1$ per ogni riga. La riga è lo stato di *partenza*, la colonna quello di *arrivo*.

(b) **Catena irriducibile.** È irriducibile se tutti gli stati **comunicano**: per ogni coppia (i, j) esiste m con $p_{ij}^{(m)} > 0$, cioè da ogni stato si raggiunge ogni altro con probabilità positiva.

(c) **La matrice.** Ogni riga ha esattamente due entrate pari a 0.5: nei 4 stati interni si va a destra o a sinistra, agli estremi 1 e 6 si “rimbalza” restando sul posto con probabilità 0.5.

$$P = \begin{pmatrix} 0.5 & 0.5 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 & 0 \\ 0 & 0.5 & 0 & 0.5 & 0 & 0 \\ 0 & 0 & 0.5 & 0 & 0.5 & 0 \\ 0 & 0 & 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 0 & 0 & 0.5 & 0.5 \end{pmatrix}$$

Sul grafo: sei nodi in fila, frecce avanti e indietro fra stati adiacenti, e un **cappio** su 1 e su 6.

```

1 import numpy as np
2
3 P = np.array([
4     [0.5, 0.5, 0.0, 0.0, 0.0, 0.0],
5     [0.5, 0.0, 0.5, 0.0, 0.0, 0.0],
6     [0.0, 0.5, 0.0, 0.5, 0.0, 0.0],
7     [0.0, 0.0, 0.5, 0.0, 0.5, 0.0],
8     [0.0, 0.0, 0.0, 0.5, 0.0, 0.5],
9     [0.0, 0.0, 0.0, 0.0, 0.5, 0.5],
10 ])
11 print("righe sommano a 1 :", np.allclose(P.sum(axis=1), 1))
12 print("colonne sommano a 1:", np.allclose(P.sum(axis=0), 1))
13 print("matrice simmetrica :", np.allclose(P, P.T))
14
15 for m in (2, 3, 4, 5):

```

```

16 Pm = np.linalg.matrix_power(P, m)
17 print(f"P^{m} tutte > 0: {(Pm > 0).all()}")
18
19 A = np.vstack([P.T - np.eye(6), np.ones(6)])
20 pi = np.linalg.lstsq(A, np.append(np.zeros(6), 1.0), rcond=None)[0]
21 np.set_printoptions(precision=5, suppress=True)
22 print("pi =", pi)
23 print("1/6 =", round(1/6, 5))
24 print("pi @ P - pi =", pi @ P - pi)

```

Output:

```

righe sommano a 1 : True
colonne sommano a 1: True
matrice simmetrica : True
P^2 tutte > 0: False
P^3 tutte > 0: False
P^4 tutte > 0: False
P^5 tutte > 0: True
pi = [0.16667 0.16667 0.16667 0.16667 0.16667 0.16667]
1/6 = 0.16667
pi @ P - pi = [-0. -0. -0.  0.  0.  0.]

```

(d) È irriducibile? Sì, e va spiegato perché.

- **L'argomento strutturale.** Da qualunque stato si raggiunge qualunque altro camminando un passo alla volta lungo la fila: per andare da i a j basta muoversi sempre nella direzione giusta, e i cappi agli estremi non intrappolano nessuno. In formule: per ogni coppia (i, j) esiste m con $p_{ij}^{(m)} > 0$.
- **Il controllo numerico.** P^5 ha tutte le entrate strettamente positive. Il valore 5 non è magico: è il cammino più lungo possibile nella fila ($1 \rightarrow 2 \rightarrow 3 \rightarrow 4 \rightarrow 5 \rightarrow 6$), e poiché i cappi permettono di “perdere tempo” dopo 5 passi tutti gli stati sono raggiungibili da tutti. Quindi la catena è anche **regolare** — esiste m con $P^m > 0$ ovunque — e non solo irriducibile.
- **Perché è regolare: il criterio del corso.** Se E è finito e la catena è irriducibile, condizione *sufficiente* perché P sia regolare è che esista uno stato h con $p_{hh} > 0$ (Cap. 9). Qui $p_{11} = p_{66} = 0.5 > 0$: i cappi agli estremi bastano a garantirlo. Sono esattamente ciò che distingue le pareti *riflettenti* da quelle *assorbenti*: con $p_{11} = p_{66} = 1$ i due estremi diventerebbero classi chiuse separate e la catena non sarebbe più irriducibile.
- **La distribuzione stazionaria è uniforme**, $\pi_i = 1/6$. Non è un caso: la matrice è **simmetrica**, quindi anche le colonne sommano a 1 (doppiamente stocastica), e per una matrice doppiamente stocastica la distribuzione uniforme è sempre stazionaria. Il codice lo conferma con $\pi P - \pi = 0$ e $\pi_i = 0.16667 = 1/6$.

Irriducibile non vuol dire “ P^m subito tutta positiva”

Dal fatto che la catena sia irriducibile *non* segue che $P^m > 0$ per ogni m : qui P^2 , P^3 e P^4 hanno ancora degli zeri, e solo da $m = 5$ in poi tutte le entrate sono positive. Il motivo è semplicemente che nella fila servono 5 passi per andare da un estremo all'altro — non c'è nessuna periodicità nascosta: i cappi su 1 e su 6 rendono la catena aperiodica (contiene un $p_{hh} > 0$), ed è proprio per questo che alla fine P^m diventa tutta positiva. L'errore da evitare è scrivere “la catena ha periodo 2” guardando gli zeri di P^2 : il vero esempio di periodo 2 è la catena a due stati con

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix},$$

dove *nessuna* potenza è ovunque positiva (Cap. 18).

22.6 Cosa portare via da questa prova

1. **Il dado è un'uniforme discreta**, non una binomiale: valori equiprobabili $\{1, \dots, 6\}$, media 3.5 e varianza 35/12. La frase va scritta al punto (a), prima di simulare (Cap. 4).
2. **Con una sola partita le frequenze sono rumore, la media no**: 27 lanci danno da 2 a 7 occorrenze per faccia (attese 4.5), ma la media resta vicina a 3.5 (Cap. 13).
3. **Il secondo livello di simulazione**: il numero di lanci per partita è una v.a. e la sua media su 100 partite si giudica con $\sigma/\sqrt{100}$, non con σ .
4. **Dati raggruppati $\Rightarrow$ tutto si pesa per le frequenze**, e i momenti si calcolano *dalla definizione* quando il testo lo impone (Cap. 14).
5. **Skewness e curtosi vanno lette insieme**: $\gamma_1 \approx 0$ e $\beta_2 = 1.51$ descrivono una distribuzione *bimodale e piatta*, non una normale.
6. **I cappi agli estremi** rendono la catena regolare e la distribuzione stazionaria uniforme (1/6, matrice simmetrica e doppiamente stocastica): è il punto su cui il quesito di Markov insiste (Cap. 9, 18).

Capitolo 23

Prova del 2 settembre 2025

È la prova del primo appello d'autunno del 2025, con lo schema classico del corso: due quesiti di Laboratorio e due di Teoria. Il Laboratorio chiede un'analisi di regressione su nove coppie ora-probabilità, con una coda di **distribuzione geometrica** (quanto si aspetta il primo successo), e la **stima hit or miss** dell'integrale di una funzione **bimodale**, dove il punto che vale davvero i punti è il confronto fra i due modi di sfruttare la simmetria. La Teoria chiede la distinzione fra statistica descrittiva e inferenziale con la **legge dei grandi numeri** dimostrata via Chebyshev, e i **numeri pseudorandom** con il metodo dell'inversione della funzione di ripartizione. Le ricette di Laboratorio sono svolte per esteso nei Capp. 15 e 17; la teoria nei Capp. 6, 5 e 8.

23.1 Il testo della prova

Q1 — Laboratorio: il concorso “Frantoio Giallo”

Per vincere un premio bisogna acquistare un prodotto e caricare lo scontrino su una piattaforma. La probabilità di vittoria dipende dall'ora t in cui si effettua l'operazione, secondo la tabella:

Probabilità (p)	0.08	0.24	0.33	0.35	0.39	0.64	0.70	0.74	0.86
Ora (t)	7	8	10	12	13	17	19	21	22

- a) Calcolare il coefficiente di correlazione lineare tra p e t .
- b) Calcolare la retta di regressione e plottare il risultato.
- c) Giorgino ha accesso al computer solo alle 14 di ogni giorno. Qual è la probabilità di vittoria a $t = 14$?
- d) Quanto dovrà aspettare (in media) prima di vincere qualcosa? (*hint: la vittoria sarebbe il primo successo di Giorgino in questo gioco!*)

Q2 — Laboratorio: hit or miss su una funzione bimodale

Si consideri la funzione

$$f(x) = e^{-(x-6)^2} + e^{-(x+6)^2}.$$

- a) Fare il grafico di questa funzione per $x \in [-10, 10]$. Spiegare perché è possibile applicare il metodo hit or miss per calcolare l'integrale $\int_{-10}^{10} f(x) dx$.
- b) Calcolare l'integrale e plottare il valore ottenuto in funzione del numero di dati generati.
- c) Calcolare l'integrale applicando il metodo hit or miss *nei due quadrati* come in figura, e plottare il valore ottenuto in funzione del numero di dati generati. (*hint: ho davvero bisogno di calcolarlo due volte? La figura è simmetrica!*)
- d) Confrontare i due risultati in termini di precisione e velocità dell'algoritmo.

Q1 — Teoria

- a) Dare la definizione di statistica descrittiva e statistica inferenziale.
- b) Che stimatore utilizzereste per stimare la media? Calcolarne media e varianza.
- c) Quale legge ci garantisce che ripetere tante volte un esperimento è un modo furbo per ottenere informazioni sui parametri che descrivono la popolazione?
- d) Dimostrare tale legge partendo dalla conoscenza della disuguaglianza di Chebyshev.

Q2 — Teoria

- a) Che cos'è un numero pseudorandom?
- b) A cosa serve il metodo delle congruenze lineari?
- c) Si illustri il metodo di inversione della funzione di ripartizione per generare numeri random distribuiti secondo una densità data.
- d) Si illustri il caso specifico della generazione di numeri distribuiti secondo una distribuzione esponenziale.

23.2 Q1 (Laboratorio) — Correlazione, regressione, tempo di attesa

Il metodo. Con la notazione del corso, dette $\bar{\sigma}_x$ e $\bar{\sigma}_y$ le deviazioni standard empiriche e $\bar{\sigma}_{xy}$ la covarianza empirica,

$$\rho = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x \bar{\sigma}_y}, \quad \beta_1 = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}, \quad R = \rho^2.$$

I conti si fanno **a mano** (nel 17/02/26 `linregress` era addirittura vietata: vedi il Cap. 15). Il punto (c) è una *interpolazione*: $t = 14$ cade dentro l'intervallo osservato $[7, 22]$. Il punto (d) è una **geometrica**: se ogni tentativo ha probabilità p di successo e i tentativi sono indipendenti, il numero T di tentativi fino al primo successo ha $\mathbb{P}(T = k) = (1 - p)^{k-1}p$ e quindi $\mathbb{E}[T] = 1/p$ (Cap. 4).

```

1 import numpy as np
2
3 t = np.array([ 7,  8, 10, 12, 13, 17, 19, 21, 22], float)
4 p = np.array([0.08, 0.24, 0.33, 0.35, 0.39, 0.64, 0.70, 0.74, 0.86], float)
5
6 tb, pb = t.mean(), p.mean()
7 Stt = np.sum((t - tb)**2)           # S_tt
8 Spp = np.sum((p - pb)**2)           # S_pp
9 Stp = np.sum((t - tb) * (p - pb))   # S_tp
10
11 rho = Stp / np.sqrt(Stt * Spp)       # coefficiente di correlazione
12 betal = Stt / Spp                   # pendenza
13 beta0 = pb - betal * tb              # intercetta
14
15 print(f"tbar = {tb:.4f}, pbar = {pb:.4f}")
16 print(f"S_tt = {Stt:.4f}, S_pp = {Spp:.6f}, S_tp = {Stp:.6f}")
17 print(f"rho = {rho:.4f}, R = rho^2 = {rho**2:.4f}")
18 print(f"retta: p = {beta0:.4f} + {betal:.4f} t")
19
20 p14 = beta0 + betal * 14
21 print(f"p(14) = {p14:.4f}")
22 print(f"E[T] = 1/p(14) = {1/p14:.4f} tentativi")
23 print(f"P(T <= 7) = 1-(1-p)^7 = {1-(1-p14)**7:.4f}")

```

Output:

```

tbar = 14.3333, pbar = 0.4811
S_tt = 252.0000, S_pp = 0.551089, S_tp = 11.626667
rho = 0.9866, R = rho^2 = 0.9734
retta: p = -0.1802 + 0.0461 t
p(14) = 0.4657
E[T] = 1/p(14) = 2.1472 tentativi
P(T <= 7) = 1-(1-p)^7 = 0.9876

```

Lettura dei risultati. $\rho = 0.9866$ è una correlazione **forte e positiva**: più tardi si carica lo scontrino, più alta è la probabilità di vincere. $R = 0.9734$ dice che il modello lineare spiega il

97.3% della variabilità di p . La pendenza $\beta_1 = 0.0461$ va letta con la sua unità di misura: *ogni ora in più la probabilità di vittoria cresce di 4.6 punti percentuali*. L'intercetta $\beta_0 = -0.1802$ è invece priva di significato fisico (una probabilità negativa non esiste): serve solo a posizionare la retta. Alle 14 la retta prevede $p(14) = 0.4657$, quindi il tempo medio di attesa è $\mathbb{E}[T] = 1/p(14) = 2.1472$ tentativi, cioè poco più di due giorni. Il numero $1/p$ è il *numero* di tentativi, non la data: per convincersene basta notare che in una settimana la probabilità di aver vinto è $1 - (1 - p)^7 = 0.9876$ (e non 1, perché la geometrica non ha memoria).

Le tre trappole di questo quesito

1. **Scambiare x e y nella retta.** La traccia vuole p in funzione di t (“la retta di regressione” fra le due), e la previsione si fa valutando la retta in $t = 14$: $\hat{p} = \beta_0 + \beta_1 t$. Invertendo i ruoli si otterrebbe una retta diversa, che *non* è quella richiesta.
2. **Usare la geometrica dei fallimenti.** Se T conta i fallimenti *prima* del primo successo, $\mathbb{E}[T] = (1 - p)/p = 1.147$; la traccia dice “primo successo”, quindi si conta anche il tentativo vincente e $\mathbb{E}[T] = 1/p = 2.1472$. Le due convenzioni differiscono esattamente di 1.
3. **Commentare β_0 .** Va detto che non ha significato: una probabilità non può essere negativa. È il tipo di osservazione che distingue una risposta completa.

23.3 Q2 (Laboratorio) — Hit or miss e il trucco della simmetria

(a) **Perché il metodo è applicabile.** Servono le tre ipotesi del Cap. 17: $f \geq 0$, f limitata su un intervallo limitato, e un maggiorante M noto. Qui f è somma di due campane non normalizzate, positive e continue, e il massimo globale è in $x = \pm 6$ (nell'altro estremo la seconda campana vale e^{-144} , che in virgola mobile è zero):

```

1 import numpy as np
2 from scipy.integrate import quad
3
4 f = lambda x: np.exp(-(x-6)**2) + np.exp(-(x+6)**2)
5
6 I = 2*np.sqrt(np.pi)          # ogni campana integra sqrt(pi); il troncamento a +-10 vale e^-16
7 M = f(6.0)                   # massimo globale: in x = 6 (e in x = -6) f vale 1 + e^-144
8 print(f"I = 2*sqrt(pi) = {I:.6f}      (quad: {quad(f, -10, 10)[0]:.6f})")
9 print(f"M = f(6) = {M:.6f}      f(0) = {f(0.0):.3e}      f(10) = {f(10.0):.3e}")
10
11 A = 20.0                     # area del rettangolo [-10,10] x [0,1]
12 p = I / A                    # frazione di hit
13 print(f"A = {A:.0f}, p = I/A = {p:.6f}, p(1-p) = {p*(1-p):.6f}")
14 print(f"Var*N un rettangolo      = I(A-I)      = {I*(A-I):.4f}")
15 print(f"Var*N un quadrato raddoppiato = 4*I'(A'-I') = {4*(I/2)*(10-I/2):.4f}")
16 print(f"Var*N un quadrato con N/2 punti = 2*I'(A'-I') = {2*(I/2)*(10-I/2):.4f}")

```

Output:

```

I = 2*sqrt(pi) = 3.544908      (quad: 3.544908)
M = f(6) = 1.000000      f(0) = 4.639e-16      f(10) = 1.125e-07
A = 20, p = I/A = 0.177245, p(1-p) = 0.145829
Var*N un rettangolo      = I(A-I)      = 58.3318
Var*N un quadrato raddoppiato = 4*I'(A'-I') = 58.3318
Var*N un quadrato con N/2 punti = 2*I'(A'-I') = 29.1659

```

Il valore esatto si ricava con la sostituzione $u = x - 6$: ogni campana è una gaussiana non normalizzata, $\int_{-\infty}^{\infty} e^{-u^2} du = \sqrt{\pi}$, e il troncamento a ± 10 taglia una massa dell'ordine di $e^{-16} \approx 10^{-7}$. Quindi $I = 2\sqrt{\pi} = 3.544908$, esattamente il valore che restituisce `quad`. Da notare $f(0) = 4.6 \times 10^{-16}$:

al centro la funzione è *nulla* in virgola mobile, e il rettangolo $[-10, 10] \times [0, 1]$ ha una zona morta enorme.

(b–c) Le due stime.

```

1 import numpy as np
2
3 f = lambda x: np.exp(-(x-6)**2) + np.exp(-(x+6)**2)
4 N = 100000
5
6 def cumulativa(N, seme=4):
7     """(b) hit or miss su tutto [-10,10] x [0,1], stima cumulativa."""
8     rng = np.random.default_rng(seme)
9     x = rng.uniform(-10, 10, N); y = rng.uniform(0, 1, N)
10    return 20 * np.cumsum(y <= f(x)) / np.arange(1, N + 1)
11
12 def cumulativa_meta(N, seme=4):
13     """(c) un solo quadrato [0,10] x [0,1] con N punti, poi raddoppiato."""
14     rng = np.random.default_rng(seme)
15     x = rng.uniform(0, 10, N); y = rng.uniform(0, 1, N)
16    return 2 * 10 * np.cumsum(y <= f(x)) / np.arange(1, N + 1)
17
18 esatto = 2*np.sqrt(np.pi)
19 a, c = cumulativa(N), cumulativa_meta(N)
20 print(f"esatto = {esatto:.6f}")
21 print(f"N={N}: un rettangolo [-10,10] = {a[-1]:.6f} errore {a[-1]-esatto:+.6f}")
22 print(f"N={N}: una meta', raddoppiata = {c[-1]:.6f} errore {c[-1]-esatto:+.6f}")
23 print(f"SE teorico con N={N} = {np.sqrt(esatto*(20-esatto)/N):.4f}")

```

Output:

```

esatto = 3.544908
N=100000: un rettangolo [-10,10] = 3.568600 errore +0.023692
N=100000: una meta', raddoppiata = 3.526000 errore -0.018908
SE teorico con N=100000 = 0.0242

```

I due errori (+0.0237 e −0.0189) valgono circa 1 e 0.8 errori standard (0.0242): entrambe le stime sono compatibili con il valore esatto, e il grafico cumulativo in funzione di N mostra le oscillazioni restringersi come $1/\sqrt{N}$ (Cap. 17).

(d) Il confronto: che cosa compra davvero la simmetria. L’hint del compito (“ho davvero bisogno di calcolarlo due volte?”) invita a non ripetere il calcolo, e la risposta corretta si ottiene confrontando le varianze *a parità di punti generati*. La varianza dello stimatore hit or miss è $\text{Var}(\hat{I}) = A^2 p(1-p)/N = I(A-I)/N$, con A area del rettangolo e $p = I/A$: qui $p = 0.177245$ è lo stesso in ogni configurazione, perché dimezzando il dominio si dimezza sia I sia A .

Strategia	punti	area	$\text{Var}(\hat{I}) \cdot N$
un rettangolo $[-10, 10] \times [0, 1]$	N	20	$I(A - I) = 58.3318$
un solo quadrato $[0, 10] \times [0, 1]$, raddoppiato	N	10	$4I'(A' - I') = 58.3318$
due quadrati, $N/2$ punti ciascuno, sommati	N	10 + 10	$4I'(A' - I') = 58.3318$

Le tre righe danno lo stesso numero: la simmetria non cambia l’errore statistico per punto generato. Il guadagno è di *codice e di punti*: la seconda metà del dominio non aggiunge informazione (il suo integrale è uguale a quello della prima, per simmetria), quindi non serve né generare punti in $[-10, 0]$ né scrivere due volte l’hit or miss. È esattamente ciò che dice l’hint: “la figura è simmetrica”, quindi il secondo calcolo è puro spreco.

```

1 import numpy as np

```

```

2
3 f = lambda x: np.exp(-(x-6)**2) + np.exp(-(x+6)**2)
4 esatto, N, R = 2*np.sqrt(np.pi), 10000, 400
5
6 def grande(rng, N):
7     x = rng.uniform(-10, 10, N); y = rng.uniform(0, 1, N)
8     return 20 * np.mean(y <= f(x))
9
10 def meta_raddoppiata(rng, N):
11     x = rng.uniform(0, 10, N); y = rng.uniform(0, 1, N)
12     return 2 * 10 * np.mean(y <= f(x))
13
14 def due_quadrati(rng, N):                # N/2 punti per quadrato, poi somma
15     n = N // 2
16     x1 = rng.uniform(-10, 0, n); y1 = rng.uniform(0, 1, n)
17     x2 = rng.uniform(0, 10, n); y2 = rng.uniform(0, 1, n)
18     return 10*np.mean(y1 <= f(x1)) + 10*np.mean(y2 <= f(x2))
19
20 rng = np.random.default_rng(3)
21 A = np.array([grande(rng, N) for _ in range(R)])
22 B = np.array([meta_raddoppiata(rng, N) for _ in range(R)])
23 C = np.array([due_quadrati(rng, N) for _ in range(R)])
24
25 se_teo = np.sqrt(esatto*(20-esatto)/N)
26 print(f"SE teorico di tutte e tre = sqrt(I(A-I)/N) = {se_teo:.4f}")
27 for nome, v in [("un rettangolo", A), ("una meta' x2", B), ("due quadrati N/2", C)]:
28     print(f"{nome}: media = {v.mean():.4f}    sd empirica = {v.std(ddof=1):.4f}")
29         f"    sd/SE = {v.std(ddof=1)/se_teo:.2f}")
30 print(f"SE se la varianza fosse 29.1659/N : {np.sqrt(29.1659/N):.4f}")

```

Output:

```

SE teorico di tutte e tre = sqrt(I(A-I)/N) = 0.0764
un rettangolo    : media = 3.5389    sd empirica = 0.0768    sd/SE = 1.01
una meta' x2     : media = 3.5503    sd empirica = 0.0752    sd/SE = 0.99
due quadrati N/2: media = 3.5461    sd empirica = 0.0829    sd/SE = 1.08
SE se la varianza fosse 29.1659/N : 0.0540

```

“La simmetria dimezza la varianza”: la frase da non scrivere

Con 400 repliche da $N = 10\,000$ punti le tre deviazioni standard empiriche valgono 0.0768, 0.0752 e 0.0829, tutte vicine al valore teorico comune 0.0764 — e **non** a 0.0540, che è il valore che si otterrebbe se la varianza fosse davvero dimezzata ($29.1659/N$ invece di $58.3318/N$). Il numero 29.1659 ha un'altra origine: è la varianza di *una singola* stima su un quadrato fatta con $N/2$ punti, ed è la metà del totale perché le due stime si sommano. Confrontare la versione simmetrica con la versione “due quadrati” *raddoppiando i punti* di quest'ultima non è un confronto a parità di lavoro: per punto generato le due versioni sono identiche. Se il correttore chiede “quanto si guadagna?”, la risposta onesta è: *in precisione nulla, in lavoro metà*, perché la seconda metà non va calcolata.

Dove si guadagna davvero in precisione

Se si vuole *diminuire* la varianza a parità di N , l'unica leva è **ridurre l'area del rettangolo**, cioè aumentare $p = I/A$. Le due campane sono praticamente nulle fuori da $[2, 10]$ e $[-10, -2]$: usando i due rettangoli $[2, 10] \times [0, 1]$ e $[-10, -2] \times [0, 1]$ (area totale 16 invece di 20) si ha $p = 3.544908/16 = 0.221557$ e

$$\text{Var}(\hat{I}) \cdot N = 4 \cdot 8^2 p(1-p) = 44.15 \quad \text{contro} \quad 58.33,$$

cioè un errore standard ridotto del 13% ($\sqrt{44.15/58.33} = 0.870$), al prezzo di trascurare una

massa dell'ordine di $e^{-16} \approx 10^{-7}$. È il senso della regola generale del Cap. 17: il rettangolo va scelto il più aderente possibile alla curva, e il numero da guardare è p .

23.4 Q1 (Teoria) — Descrittiva, inferenziale e legge dei grandi numeri

(a) **Le due statistiche.** La **statistica descrittiva** riassume e visualizza i dati raccolti (medie, varianze, istogrammi, quantili): parla *solo del campione*. La **statistica inferenziale** usa il campione per trarre conclusioni sulla **popolazione** che lo ha generato: stima dei parametri, intervalli di confidenza, test d'ipotesi (Cap. 6).

(b) **Lo stimatore della media.** È la media campionaria $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, ed è lo stimatore *non distorto* della media μ : $\mathbb{E}[\bar{X}_n] = \mu$ per linearità della media. Per l'indipendenza delle osservazioni la varianza è

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n},$$

e si dimezza ogni volta che si quadruplica il campione.

(c) **La legge.** È la **legge dei grandi numeri** in forma debole: al crescere di n la media campionaria converge in probabilità a μ , $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$ (Cap. 5). È ciò che rende “furbo” ripetere l'esperimento: tante più istanze si osservano, tanto più la media campionaria assomiglia alla media della distribuzione, qualunque essa sia.

(d) **La dimostrazione via Chebyshev.** Per una v.a. Y con media e varianza finite,

$$\mathbb{P}(|Y - \mathbb{E}[Y]| \geq \eta) \leq \frac{\text{Var}(Y)}{\eta^2}.$$

Applicandola a $Y = \bar{X}_n$, che ha media μ e varianza σ^2/n :

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \eta) \leq \frac{\sigma^2}{n\eta^2} \xrightarrow{n \rightarrow \infty} 0 \quad \forall \eta > 0,$$

cioè esattamente $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$. ■

Il bound è vero ma pessimista: un numero per capirlo

Con $\sigma = 1$ e $\eta = 0.5$ la disuguaglianza dice $\mathbb{P}(|\bar{X}_n - \mu| \geq 0.5) \leq 1/(0.25n)$, cioè ≤ 0.0400 con $n = 100$ e ≤ 0.0004 con $n = 10\,000$. Per una normale, con $n = 100$, la probabilità esatta dello stesso evento è 5.7×10^{-7} : Chebyshev è *cieca* rispetto alla forma della distribuzione, e paga questo con un bound molto largo. Va citato come stima di comodo, non come valore attendibile.

23.5 Q2 (Teoria) — Numeri pseudorandom e inversione

(a) **Che cos'è un numero pseudorandom.** È il numero prodotto da un **algoritmo deterministico** a partire da un valore iniziale detto *seed*, che però si comporta come un'estrazione casuale: passa i test statistici di casualità per un tempo abbastanza lungo. Quel tempo è il **periodo**, l'iterazione alla quale la sequenza torna al punto di partenza e si ripete identica. Sono preferiti ai generatori fisici per leggerezza e velocità, e sono **riproducibili**: stesso seed, stessa sequenza (ed è il motivo per cui in questa guida ogni simulazione dichiara il proprio).

(b) **Il metodo delle congruenze lineari.** Serve a *generare* numeri pseudorandom in $[0, 1)$:

$$X_{n+1} = (aX_n + b) \bmod m, \quad U_n = \frac{X_n}{m},$$

con a moltiplicatore, b incremento e m modulo scelti ad hoc per allungare il periodo. L'esempio degli appunti, $X_0 = 1$, $a = 3$, $b = 1$, $m = 5$, dà 4, 3, 0, 1, 4, ...: periodo $T = 4$, ottimo per un esercizio ma inadatto all'uso reale. Il generatore usato oggi da `numpy` è il Mersenne Twister, con periodo $2^{19937} - 1$.

(c) Il metodo dell'inversione. Se F è la funzione di ripartizione target, strettamente crescente e quindi invertibile, e $U \sim \mathcal{U}(0, 1)$, allora

$$X = F^{-1}(U)$$

ha esattamente funzione di ripartizione F . La verifica è di una riga: $\mathbb{P}(X \leq x) = \mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)) = F(x)$, perché per l'uniforme $\mathbb{P}(U \leq u) = u$.

(d) Il caso esponenziale. Per $X \sim \text{Exp}(\lambda)$ si ha $F(x) = 1 - e^{-\lambda x}$ per $x \geq 0$; invertendo,

$$u = 1 - e^{-\lambda x} \implies x = -\frac{\ln(1-u)}{\lambda}, \quad \text{quindi} \quad X = -\frac{\ln(1-U)}{\lambda} = -\frac{\ln U}{\lambda},$$

dove l'ultimo passaggio usa il fatto che U e $1 - U$ hanno la stessa legge.

```

1 import numpy as np
2
3 lam, n = 2.0, 100000
4 rng = np.random.default_rng(1)
5
6 U = rng.random(n)                # uniformi in [0,1]: e' il "motore" di tutto
7 Y = -np.log(1 - U) / lam          # inversione della f.d.r. esponenziale
8 Z = rng.exponential(1/lam, n)     # stessa legge generata da numpy
9
10 print(f"media per inversione = {Y.mean():.4f}    (1/lambda = {1/lam:.4f})")
11 print(f"media per exponential = {Z.mean():.4f}")
12 print(f"P(Y > 0.4) = {np.mean(Y > 0.4):.4f}    (e^-0.8 = {np.exp(-0.8):.4f})")

```

Output:

```

media per inversione = 0.4997    (1/lambda = 0.5000)
media per exponential = 0.4976
P(Y > 0.4) = 0.4492    (e^-0.8 = 0.4493)

```

La media campionaria (0.4997) e la probabilità di coda (0.4492 contro $e^{-0.8} = 0.4493$) confermano che $Y = -\ln(1 - U)/\lambda$ segue davvero la legge esponenziale: è la verifica da aggiungere quando il compito chiede di “illustrare” il metodo.

23.6 Cosa portare via da questa prova

- **La retta di regressione si calcola a mano**, con $\beta_1 = \bar{\sigma}_{xy}/\bar{\sigma}_x^2$ e $\beta_0 = \bar{y} - \beta_1\bar{x}$: `linregress` serve solo come controllo personale. E l'ordine delle variabili conta: qui p è la variabile dipendente e t quella indipendente.
- **Il tempo di attesa al primo successo è una geometrica**, $\mathbb{E}[T] = 1/p$: si riconosce dalla parola “primo successo” nell'hint. Le verifiche di coerenza ($\mathbb{P}(T \leq 7) = 0.9876$; il caso dei “fallimenti prima del successo” che vale $1/p - 1$) sono il modo di mostrare di aver capito quale convenzione si sta usando.
- **Hit or miss: le tre ipotesi**, il massimo esatto M , e la formula $\text{Var}(\hat{I}) = I(A - I)/N$ che dipende solo da I e dall'area del rettangolo. Sono i tre punti che il quesito 02/09/25 chiede esplicitamente.
- **La simmetria non compra precisione**, compra lavoro: calcolare entrambi i quadrati non migliora la stima a parità di punti ($\text{Var} \cdot N = 58.3318$ in ogni configurazione). Si guadagna solo restringendo il rettangolo, cioè alzando p .

- **La legge dei grandi numeri si dimostra in tre righe** applicando Chebyshev alla media campionaria, con $\text{Var}(\bar{X}_n) = \sigma^2/n$. Il bound è vero ma pessimista: saperlo dire vale quanto saperlo scrivere.
- **Pseudorandom e inversione**: definizione, ruolo del seed e del periodo, $(aX_n + b) \bmod m$, e $X = F^{-1}(U)$. Il caso esponenziale $-\ln(1 - U)/\lambda$ è la versione da ricordare a memoria, con la verifica numerica su media e probabilità di coda.

Capitolo 24

Prova del 27 gennaio 2026

Appello con due quesiti di Laboratorio molto “da esame”: il primo è la classica estrazione **senza reimmissione** (le carte Magic), dove la scelta della distribuzione è la domanda vera; il secondo è un’**analisi descrittiva** di dati con frequenze che finisce in un **test t** sulla media. La Teoria chiede gli **eventi** e le leggi di De Morgan da un lato, le **catene di Markov** dall’altro. Nel primo quesito c’è la trappola più istruttiva della prova: la mano di carte *non* è una binomiale. Le ricette sono nei Capp. 12 (simulazione e confronto con la teoria), 14 (dati con frequenze) e 16 (il test t).

24.1 Il testo della prova

Q1 — Laboratorio: le carte Magic

Molti studenti, in corridoio, giocano a Magic. Per giocare si utilizza un mazzo da 60 carte di cui alcune sono delle carte dette Terre. All’inizio del gioco si pescano $k = 7$ carte. Assumendo che in questo mazzo ci siano $n = 26$ Terre, rispondere alle seguenti domande.

- a) Quante Terre ci aspettiamo, in media, di trovare nelle prime sette carte pescate? Che tipo di distribuzione e che parametri sono stati utilizzati per rispondere alla precedente domanda?
- b) Una mano è considerata “buona” se ci sono o tre o quattro Terre. Qual è la probabilità di pescare una mano “non buona”?
- c) Scrivere un codice che simuli $N = 350$ fasi iniziali di gioco, ovvero $N = 350$ volte la prima mano con le sette carte pescate, producendo un istogramma che mostri la probabilità empirica associata ad ogni numero di Terre nella prima mano.
- d) Utilizzare i risultati del punto precedente per ricavare le stesse quantità richieste in a) e b). Confrontare i risultati empirici con quelli teorici, commentando le eventuali differenze.

Q2 — Laboratorio: i biscotti di Giorgino

Giorgino si segna sempre il peso in grammi di ogni biscotto. Questa volta ha preparato $N = 100$ biscotti con i seguenti pesi:

peso in grammi	17	18	19	20	21	22	23	24	25	26	27	28	29	30
numero di biscotti	1	1	2	5	8	14	17	18	12	9	5	5	2	1

- a) Calcolare uno stimatore della media e della varianza.
- b) Plottare questi dati in un istogramma. Che distribuzione ricordano? E con che parametri? Plottare questa distribuzione sull’istogramma.
- c) Qual è la percentuale di biscotti con peso tra i 21 e i 27 grammi?
- d) Osservando i suoi biscotti, Giorgino ha la sensazione che siano più grandi di quelli di martedì scorso, che in media pesavano $\mu = 22$ g. È possibile affermare ciò con una confidenza al 95%?

Q1 — Teoria

- a) Dare la definizione di evento.
- b) Dare la definizione di evento incompatibile.
- c) Quando lavora al computer Giorgino utilizza tastiera, mouse e monitor. Non sempre questi tre elementi funzionano. Giorgino riesce a lavorare soltanto se il monitor funziona e

se uno tra tastiera e mouse funziona. Dati gli eventi elementari

$$A = \text{"la tastiera non funziona"}, \quad B = \text{"il mouse non funziona"}, \\ C = \text{"il monitor non funziona"},$$

scrivere l'evento $G = \text{"Giorgino non può lavorare al computer"}$.

d) Sapendo che le probabilità di guasto sono $P(A) = 0.45$, $P(B) = 0.35$ e $P(C) = 0.2$, e sapendo che gli eventi A , B e C sono indipendenti, calcolare la probabilità che Giorgino non riesca a lavorare al computer.

Q2 — Teoria

Si consideri una catena di Markov a stati finiti, omogenea.

a) Dare la definizione di matrice di transizione ed elencare le due proprietà di cui godono gli elementi di tale matrice.

b) Dare la definizione di matrice di transizione a m passi e spiegarne il significato.

c) Dare la definizione di distribuzione di X_t , dove X è il processo stocastico associato alla catena di Markov.

d) Dare la definizione di distribuzione stazionaria. Spiegarne il significato in maniera intuitiva, eventualmente anche fornendo un esempio.

24.2 Q1 (Laboratorio) — Le carte Magic

Il modello, prima di ogni conto. Le sette carte si pescano **senza reimmissione**: una carta pescata non torna nel mazzo, quindi le estrazioni *non* sono indipendenti e la probabilità di Terra cambia da carta a carta. La variabile $X = \text{"numero di Terre in 7 carte"}$ segue quindi la **ipergeometrica** $\text{Iper}(N, K, n)$ con $N = 60$, $K = 26$ e $n = 7$:

$$\mathbb{P}(X = x) = \frac{\binom{26}{x} \binom{34}{7-x}}{\binom{60}{7}}, \quad \mathbb{E}[X] = n \frac{K}{N} = 3.0333, \\ \text{Var}(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1} = 1.5441.$$

L'ultimo fattore $\frac{N-n}{N-1}$ è la *correzione per popolazione finita*: è ciò che distingue l'ipergeometrica dalla binomiale, e manca se si modella la pescata *con* reimmissione (Cap. 4).

```
1 import numpy as np
2 from scipy import stats
3
4 tot, nt, k, N = 60, 26, 7, 350      # carte, Terre, carte pescate, mani simulate
5
6 # --- (a) il modello: ipergeometrica, NON binomiale -----
7 print(f"E[X] = k*K/N = 7*26/60 = {k*nt/tot:.4f}")
8 print(f"Var(X) = {stats.hypergeom.var(tot, nt, k):.4f}    (sd {np.sqrt(stats.hypergeom.var(tot,
9     ↪ nt, k)):.4f})")
10
11 # --- (b) P(mano non buona) = 1 - [P(3) + P(4)] -----
12 p3, p4 = stats.hypergeom.pmf(3, tot, nt, k), stats.hypergeom.pmf(4, tot, nt, k)
13 p_buona, p_non = p3 + p4, 1 - (p3 + p4)
14 print(f"P(3 Terre) = {p3:.6f}    P(4 Terre) = {p4:.6f}")
15 print(f"P(buona) = P(3)+P(4) = {p_buona:.6f}    P(non buona) = {p_non:.6f}")
16 p_bin = stats.binom.pmf(3, k, nt/tot) + stats.binom.pmf(4, k, nt/tot)
```

```

16 print(f"se fosse Bin(7, 26/60): P(buona) = {p_bin:.6f} (differenza {p_buona-p_bin:+.6f})")
17
18 # --- (c)-(d) simulazione di N = 350 mani -----
19 sim = np.random.default_rng(5).hypergeometric(nt, tot - nt, k, size=N)
20 ks, teo = np.arange(0, k + 1), stats.hypergeom.pmf(np.arange(0, k + 1), tot, nt, k)
21 freq = np.array([(sim == j).mean() for j in ks])
22
23 p_sim = np.mean((sim == 3) | (sim == 4))
24 es = np.sqrt(p_buona*(1-p_buona)/N)
25 print(f"E[Terre] sim = {sim.mean():.4f} teo = {k*nt/tot:.4f}")
26 print(f"P(buona) sim = {p_sim:.4f} teo = {p_buona:.6f}")
27 print(f"ES = sqrt(p(1-p)/N) = {es:.4f} scarto = {p_sim-p_buona:+.4f} = {(p_sim-p_buona)/es}
    ↪ :+.2f} ES")
28 print("scarto totale =", round(np.abs(freq-teo).sum(), 4))
29 print("P(non buona) sim = %.4f teo = %.6f" % (1-p_sim, p_non))

```

Output:

```

E[X] = k*K/N = 7*26/60 = 3.0333
Var(X) = 1.5441 (sd 1.2426)
P(3 Terre) = 0.312210 P(4 Terre) = 0.231640
P(buona) = P(3)+P(4) = 0.543849 P(non buona) = 0.456151
se fosse Bin(7, 26/60): P(buona) = 0.518224 (differenza +0.025626)
E[Terre] sim = 3.0257 teo = 3.0333
P(buona) sim = 0.5886 teo = 0.543849
ES = sqrt(p(1-p)/N) = 0.0266 scarto = +0.0447 = +1.68 ES
scarto totale = 0.0912
P(non buona) sim = 0.4114 teo = 0.456151

```

Lettura dei risultati. La media empirica (3.0257) coincide con la teorica (3.0333) e la probabilità di mano buona stimata è 0.5886 contro 0.5438: lo scarto è +1.68 errori standard, quindi **compatibile con il rumore campionario** di 350 prove. Lo “scarto totale” $\sum_x |f_x^{\text{sim}} - p_x^{\text{teo}}| = 0.0912$ riassume in un solo numero la distanza fra istogramma empirico e distribuzione teorica: con $N = 350$ un valore dell’ordine di 0.1 è normale, e tende a zero come $1/\sqrt{N}$ aumentando le mani simulate. La conclusione da scrivere è: *i dati simulati sono coerenti con il modello ipergeometrico; la differenza osservata è variabilità campionaria, non un errore di modello.*

Le due trappole: la distribuzione e il denominatore

1. **La binomiale è la distribuzione sbagliata.** Modellando la mano come 7 prove indipendenti con $p = 26/60$ si otterrebbe $\mathbb{P}(\text{buona}) = 0.518224$ invece di 0.543849: una differenza di 0.026, cioè circa un errore standard. La differenza è proprio la correzione per popolazione finita $\frac{N-n}{N-1} = \frac{53}{59} = 0.898$, che vale 10% sulla varianza. Il discriminante è sempre lo stesso: **senza** reimmissione $\Rightarrow$ ipergeometrica, **con** reimmissione $\Rightarrow$ binomiale.
2. **Il denominatore delle frequenze.** Le probabilità empiriche sono *frequenze relative*: si dividono per il numero di **mani simulate** (350), non per le carte del mazzo (60) né per le carte pescate (7). Dividere per 60 produce numeri come “3.18”: una probabilità maggiore di 1, che è il modo più rapido di accorgersi dell’errore.

Con un altro seme i numeri cambiano, la conclusione no

Il seme usato qui è 5 e va **dichiarato**: senza di esso la simulazione non è riproducibile. Cambiandolo, la stima oscilla dentro il rumore previsto, come mostra questa prova su cinque semi diversi (stesso $N = 350$):

```

teoria: P(buona) = 0.5438, ES = 0.0266 -> 2*ES = 0.0532
seme    5: E[Terre] = 3.0257 P(buona) = 0.5886 scarto = +1.68 ES

```

seme 7:	E[Terre] = 2.9543	P(buona) = 0.5543	scarto = +0.39 ES
seme 11:	E[Terre] = 3.0714	P(buona) = 0.5486	scarto = +0.18 ES
seme 13:	E[Terre] = 3.0571	P(buona) = 0.5686	scarto = +0.93 ES
seme 2026:	E[Terre] = 2.9600	P(buona) = 0.5257	scarto = -0.68 ES

Tutti gli scarti stanno entro 2 errori standard. È il motivo per cui non si commenta mai una simulazione guardando *un solo* seme, e per cui “il valore non coincide” non è una conclusione ammissibile.

24.3 Q2 (Laboratorio) — I biscotti: descrittiva, normale e test t

(a) **Gli stimatori.** I dati sono **con frequenze** (il valore z_i compare n_i volte), quindi

$$\bar{X}_n = \frac{1}{N} \sum_i z_i n_i, \quad \bar{S}_n^2 = \frac{1}{N-1} \sum_i n_i (z_i - \bar{X}_n)^2.$$

Il divisore è $N - 1$ perché la domanda chiede uno *stimatore*: $\bar{S}_n^2$ è non distorto, mentre la varianza empirica $\bar{\sigma}_n^2$ con divisore N descrive solo il campione (Cap. 6).

```

1 import numpy as np
2 from scipy import stats
3
4 peso = np.arange(17, 31, dtype=float)
5 num = np.array([1,1,2,5,8,14,17,18,12,9,5,5,2,1], dtype=float)
6 N = int(num.sum())
7
8 xbar = np.sum(peso*num)/N
9 s2 = np.sum(num*(peso-xbar)**2)/(N-1)
10 s = np.sqrt(s2)
11 print(f"N = {N}")
12 print(f"media campionaria = {xbar:.4f} g")
13 print(f"varianza campionaria = {s2:.4f} (scarto {s:.4f} g)")
14 print(f"varianza empirica = {np.sum(num*(peso-xbar)**2)/N:.4f} (divisore N)")
15
16 sel = (peso >= 21) & (peso <= 27)
17 print(f"percentuale in [21,27] g = {num[sel].sum()/N*100:.0f}% ({num[sel].sum():.0f} biscotti
    ↪ su {N})")
18
19 mu0 = 22.0
20 t_stat = (xbar - mu0)/(s/np.sqrt(N))
21 crit = stats.t.ppf(0.95, N-1)
22 print(f"t = ({xbar:.4f} - {mu0}) / ({s:.4f}/10) = {t_stat:.4f}")
23 print(f"t_0.95(99) = {crit:.4f} p-value = {1-stats.t.cdf(t_stat, N-1):.3e}")
24 tc = stats.t.ppf(0.975, N-1)
25 print(f"IC 95%: t_0.975(99) = {tc:.4f} -> [{xbar-tc*s/10:.4f}, {xbar+tc*s/10:.4f}]")

```

Output:

```

N = 100
media campionaria = 23.6900 g
varianza campionaria = 6.1555 (scarto 2.4810 g)
varianza empirica = 6.0939 (divisore N)
percentuale in [21,27] g = 83% (83 biscotti su 100)
t = (23.6900 - 22.0) / (2.4810/10) = 6.8117
t_0.95(99) = 1.6604 p-value = 3.788e-10
IC 95%: t_0.975(99) = 1.9842 -> [23.1977, 24.1823]

```

(b) **Che distribuzione è.** L'istogramma è campanulato e simmetrico attorno a 24 g, con code che si assottigliano in fretta: è una **normale** di parametri stimati $\hat{\mu} = 23.69$ g e $\hat{\sigma} = 2.481$ g. La sovrapposizione della densità si fa in *densità* (o moltiplicando per N se l'istogramma è in conteggi):

è l'errore di scala più frequente, ed è spiegato nel Cap. 14, dove questo stesso esercizio è svolto nel dettaglio. La giustificazione teorica è il teorema del limite centrale: il peso è la somma di molti piccoli contributi indipendenti.

(c) **La percentuale.** I biscotti con peso in $[21, 27]$ g sono $8 + 14 + 17 + 18 + 12 + 9 + 5 = 83$ su 100: l'83%.

(d) **Il test.** La varianza *non* è nota (si stima dai dati) e la domanda è direzionale (“più grandi”), quindi il test è la t di Student unilaterale destra:

$$H_0 : \mu = 22 \quad \text{contro} \quad H_1 : \mu > 22, \quad T_n = \frac{\bar{X}_n - \mu_0}{\sqrt{\hat{S}_n^2/N}} \sim t(99).$$

$t = 6.8117$ supera largamente il valore critico $t_{0.95}(99) = 1.6604$ e il p -value vale $3.788 \times 10^{-10} \ll 0.05$: si **rigetta** H_0 . Sì, si può affermare con confidenza del 95% che i biscotti sono mediamente più pesanti di 22 g. L'intervallo di confidenza al 95%, calcolato con $t_{0.975}(99) = 1.9842$, è $[23.1977, 24.1823]$: non contiene 22 ed è interamente sopra, coerente con il test.

Tre errori che costano il punto

1. **Usare z al posto di t .** σ non è nota: va stimata con S e i gradi di libertà sono $N - 1 = 99$. Qui i due quantili sono quasi uguali (1.6604 contro $\varphi_{0.95} = 1.6449$) e il rigetto non cambia, ma la *scelta va dichiarata*.
2. **Sbagliare l'ipotesi alternativa.** “Più grandi di 22 g” è $H_1 : \mu > 22$, quindi il test è **unilaterale destro** e il p -value si legge nella coda destra. Un test bilaterale darebbe un p -value doppio.
3. **Confondere la confidenza con la probabilità.** Al 95% si rigetta H_0 ; non si “dimostra” che μ valga 23.69 g. La conclusione corretta riguarda l'ipotesi $\mu = 22$, non il valore puntuale stimato.

24.4 Q1 (Teoria) — Eventi, incompatibilità e De Morgan

(a) **Evento.** Dato lo spazio campionario Ω (l'insieme di tutti i risultati possibili dell'esperimento), un **evento** è un sottoinsieme $A \subseteq \Omega$: si realizza se il risultato dell'esperimento appartiene ad A . In particolare Ω è l'evento certo e $\emptyset$ quello impossibile.

(b) **Eventi incompatibili.** A e B sono **incompatibili** se $A \cap B = \emptyset$: non possono verificarsi insieme, e allora $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$ (Cap. 3). Se invece sono indipendenti vale $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$: sono due nozioni diverse, e confonderle è l'errore classico di questo quesito.

(c) **L'evento G .** “Giorgino lavora” significa: il monitor funziona *e* almeno uno tra tastiera e mouse funziona, cioè $\bar{C} \cap (\bar{A} \cup \bar{B})$. L'evento richiesto è il suo complementare, e per la legge di De Morgan

$$G = \overline{\bar{C} \cap (\bar{A} \cup \bar{B})} = C \cup (A \cap B).$$

A parole: Giorgino **non** può lavorare se il monitor è rotto *oppure* se sono rotti sia tastiera che mouse.

(d) **La probabilità.** Con l'indipendenza e la formula di inclusione-esclusione per l'unione:

$$\mathbb{P}(G) = \mathbb{P}(C) + \mathbb{P}(A \cap B) - \mathbb{P}(C \cap A \cap B) = 0.2 + 0.45 \cdot 0.35 - 0.2 \cdot 0.45 \cdot 0.35 = 0.3260.$$

```
1 pA, pB, pC = 0.45, 0.35, 0.20
2 print(f"P(A)*P(B) = {pA*pB:.4f}   P(A)*P(B)*P(C) = {pC*pA*pB:.4f}")
3 print(f"P(G) = {pC} + {pA*pB:.4f} - {pC*pA*pB:.4f} = {pC + pA*pB - pC*pA*pB:.4f}")
```

Output:

$$\begin{aligned} P(A)*P(B) &= 0.1575 & P(A)*P(B)*P(C) &= 0.0315 \\ P(G) &= 0.2 + 0.1575 - 0.0315 & &= 0.3260 \end{aligned}$$

Il termine da non dimenticare

$A \cap B$ e C non sono incompatibili: “monitor rotto e tastiera e mouse rotti” è un caso che sta in entrambi gli eventi, e va sottratto una volta (-0.0315). Senza la sottrazione si otterrebbe 0.3575 invece di 0.3260. Il modo sicuro di procedere è passare dal complementare: $\mathbb{P}(G) = 1 - \mathbb{P}(\text{lavora})$, e “lavora” è un’intersezione di eventi indipendenti.

24.5 Q2 (Teoria) — Catene di Markov: le quattro definizioni

Le definizioni sono svolte per esteso, con gli esempi numerici, nel Cap. 9 (teoria) e nel Cap. 18 (simulazione). Qui la forma sintetica da scrivere sul foglio.

(a) Matrice di transizione. Per una catena di Markov omogenea a stati finiti E , la matrice di transizione è $P = (p_{ij})$ con

$$p_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i)$$

(probabilità di andare da i a j in un passo; “omogenea” significa che non dipende da t). I suoi elementi godono di due proprietà:

1. $p_{ij} \geq 0$ per ogni i, j (sono probabilità);
2. $\sum_{j \in E} p_{ij} = 1$ per ogni riga i : da i si va da qualche parte con probabilità 1. Si dice che P è **stocastica per righe**.

(b) Matrice a m passi. È $P^{(m)} = (p_{ij}^{(m)})$ con $p_{ij}^{(m)} = \mathbb{P}(X_{t+m} = j \mid X_t = i)$: la probabilità di trovarsi in j dopo m passi partendo da i . Per le equazioni di Chapman–Kolmogorov $P^{(m)} = P^m$, la potenza m -esima della matrice di transizione: è il motivo per cui la distribuzione dopo m passi si calcola moltiplicando il vettore iniziale per P^m .

(c) Distribuzione di X_t . È il vettore riga $v_t = (v_t(1), \dots, v_t(|E|))$ con $v_t(j) = \mathbb{P}(X_t = j)$: la legge della catena al tempo t . Si evolve con

$$v_t = v_0 P^t.$$

(d) Distribuzione stazionaria. È un vettore di probabilità π ($\pi_j \geq 0$, $\sum_j \pi_j = 1$) tale che

$$\pi P = \pi.$$

Significato intuitivo: se la catena parte da π , la sua distribuzione non cambia più nel tempo; inoltre, per catene irriducibili, *qualunque* distribuzione iniziale converge a π : dopo abbastanza passi la probabilità di trovarsi in ciascuno stato si stabilizza, indipendentemente dal punto di partenza. *Esempio:* la frazione di tempo che un navigatore casuale passa su ciascuna pagina web — è l’idea alla base del PageRank. La stazionaria si trova risolvendo il sistema lineare $\pi(P - I) = 0$ con il vincolo $\sum_j \pi_j = 1$.

24.6 Cosa portare via da questa prova

- **Senza reimmissione $\Rightarrow$ ipergeometrica**, con la correzione per popolazione finita $\frac{N-n}{N-1}$. La binomiale qui darebbe 0.518224 invece di 0.543849: il quesito vuole vedere che la differenza è nota e giustificata, non che il risultato “somiglia”.
- **Si simula estraendo davvero le carte** (`rng.hypergeometric(K, N-K, n, size=N)`), e il seme va dichiarato. Le frequenze relative si dividono per il numero di *prove*, mai per altri numeri.

- **Confrontare empirico e teorico si fa con l'errore standard:** $ES = \sqrt{p(1-p)/N}$, scarto in unità di ES, e lo “scarto totale” $\sum_x |f_x - p_x|$ come riassunto dell'istogramma. Uno scarto entro 2 ES non è un errore.
- **Dati con frequenze:** media $\sum z_i n_i / N$, varianza campionaria con $N - 1$. Il test sulla media, con σ incognita, è la t di Student con $N - 1$ gradi di libertà, e l'ipotesi “più grandi” impone la coda destra.
- **Eventi composti:** si scrive l'evento con i connettivi ($G = C \cup (A \cap B)$), poi si calcola con inclusione-esclusione usando l'indipendenza per i prodotti. Il termine di intersezione tripla si dimentica sempre.
- **Markov:** matrice di transizione (righe non negative che sommano a 1), $P^{(m)} = P^m$, $v_t = v_0 P^t$, e $\pi P = \pi$ con la sua lettura intuitiva. Sono quattro definizioni da sapere a memoria.

Capitolo 25

Prova del 17 febbraio 2026

Prova “da manuale” sulle due anime del corso. Il Laboratorio chiede **probabilità totali** e **teorema di Bayes** su tre linee di produzione, con due simulazioni di verifica, e una **regressione lineare** con il divieto esplicito di usare `scipy.stats.linregress`: le formule vanno scritte a mano. La Teoria chiede le definizioni di **frequenza**, media, **quantili** e varianza empirica/campionaria (dati semplici e con frequenze), e la **distribuzione binomiale** con la derivazione di media e varianza. Le ricette sono nei Capp. 12, 15 e 14; le definizioni nei Capp. 6 e 4.

25.1 Il testo della prova

Q1 — Laboratorio: le tre linee di produzione

In una fabbrica sono presenti tre linee di produzione, L_1 , L_2 e L_3 , che realizzano lo stesso prodotto, con una probabilità di ottenere un prodotto difettoso rispettivamente del 1%, 2% e 0.5%. Sapendo che le tre linee producono rispettivamente il 30%, 50% e 20% della produzione totale:

- a) Calcolare la probabilità che dalla fabbrica esca un prodotto difettoso.
- b) Calcolare la probabilità che un prodotto difettoso scelto a caso provenga dalla linea L_2 .
- c) Interpretando anche le percentuali di produzione come una probabilità, simulare la produzione di 10000 pezzi e confrontare la percentuale di pezzi difettosi prodotti con quanto calcolato al punto a).
- d) La simulazione precedente si può realizzare semplicemente contando i pezzi difettosi prodotti, provare a effettuare anche una simulazione che permetta di verificare la probabilità richiesta nel punto b).

Q2 — Laboratorio: tempo di calcolo e dimensione dei dati

Viene osservato il tempo di calcolo in secondi utilizzato da un software nell’elaborazione di diversi insiemi di dati, ottenendo le quantità riportate in tabella:

dimensione dati	105	511	401	622	330
tempo (s)	44	214	193	299	143

- a) Determinare la retta di regressione lineare.
- b) Rappresentare i dati e la retta di regressione in un unico grafico.
- c) Calcolare il coefficiente di correlazione lineare e il coefficiente di determinazione e commentarli.
- d) Stimare in base alla retta di regressione il tempo necessario all’elaborazione di un insieme di 200 dati.

NOTA: Non è consentito l’uso della funzione `scipy.stats.linregress`.

Q1 — Teoria

- a) Dare la definizione di frequenza assoluta, frequenza relativa, frequenza accumulata (assoluta e relativa) di un insieme di dati.
- b) Dare la formula matematica di media aritmetica nel caso di dati semplici e di dati con frequenza.

- c) Definire i quantili di un insieme di dati. Definire la mediana e i quartili. Definire la distanza interquartile.
- d) Dare la formula matematica di varianza empirica e campionaria nel caso di dati semplici e di dati con frequenza.

Q2 — Teoria

- a) Definire la distribuzione binomiale, e darne la formula definendo le quantità coinvolte.
- b) Dare un esempio di applicazione della distribuzione binomiale, calcolando esplicitamente delle probabilità.
- c) Dare il valore atteso e la varianza di una variabile aleatoria che segue una distribuzione binomiale.
- d) Ricavare le formule del punto precedente.

25.2 Q1 (Laboratorio) — Probabilità totali, Bayes e simulazione

La teoria, prima del codice. Gli eventi “il pezzo viene da L_i ” partizionano lo spazio campionario (ogni pezzo viene da esattamente una linea, $\bigcup_i L_i = \Omega$ e $L_i \cap L_j = \emptyset$ per $i \neq j$), quindi si applica il **teorema delle probabilità totali** (Cap. 3):

$$\mathbb{P}(D) = \sum_{i=1}^3 \mathbb{P}(D | L_i) \mathbb{P}(L_i) = 0.01 \cdot 0.30 + 0.02 \cdot 0.50 + 0.005 \cdot 0.20 = 0.0030 + 0.0100 + 0.0010 = 0.0140.$$

Il punto (b) chiede la probabilità “a ritroso” della causa, noto l’effetto: è il **teorema di Bayes**,

$$\mathbb{P}(L_2 | D) = \frac{\mathbb{P}(D | L_2) \mathbb{P}(L_2)}{\mathbb{P}(D)} = \frac{0.02 \cdot 0.50}{0.0140} = 0.714286.$$

```

1 import numpy as np
2
3 # --- (a) probabilita' totali (b) Bayes -----
4 p_L = np.array([0.30, 0.50, 0.20]) # P(L1), P(L2), P(L3)
5 p_dif = np.array([0.01, 0.02, 0.005]) # P(D | L1), P(D | L2), P(D | L3)
6
7 P_D = np.sum(p_L * p_dif)
8 print(f"P(D) = 0.30*0.01 + 0.50*0.02 + 0.20*0.005 = {P_D:.4f}")
9 print(f"P(L2|D) = 0.50*0.02 / {P_D:.4f} = {p_L[1]*p_dif[1]/P_D:.6f}")
10
11 # --- (c) simulazione della produzione di 10000 pezzi -----
12 N = 10000
13 rng = np.random.default_rng(11)
14 linea = rng.choice([1, 2, 3], size=N, p=p_L) # quale linea produce il pezzo
15 pd = np.where(linea == 1, 0.01, np.where(linea == 2, 0.02, 0.005))
16 dif = rng.random(N) < pd # il pezzo e' difettoso?
17 print(f"difettosi simulati = {dif.sum()} / {N} = {dif.mean():.4f} (teorico {P_D:.4f})")
18 es_PD = np.sqrt(P_D*(1-P_D)/N)
19 print(f"ES su P(D) = sqrt(p(1-p)/N) = {es_PD:.5f} scarto = {(dif.mean()-P_D)/es_PD:+.2f} ES")
20
21 # --- (d) verifica di Bayes: fra i SOLI difettosi, quanti da L2? -----
22 n_dif = int(dif.sum())
23 p_L2_D_sim = np.mean(linea[dif] == 2)
24 es = np.sqrt((p_L[1]*p_dif[1]/P_D)*(1 - p_L[1]*p_dif[1]/P_D)/n_dif)
25 print(f"difettosi disponibili = {n_dif}")
26 print(f"P(L2|D) simulata = {p_L2_D_sim:.4f} (teorico {p_L[1]*p_dif[1]/P_D:.6f})")
27 print(f"ES sui {n_dif} difettosi = {es:.4f} scarto = {(p_L2_D_sim - p_L[1]*p_dif[1]/P_D)/es
    ↪ :+.2f} ES")

```

```
28 print(f"ES sbagliato (su 10000) = {np.sqrt((p_L[1]*p_dif[1]/P_D)*(1-p_L[1]*p_dif[1]/P_D)/N):.4f
    ↪ }")
```

Output:

```
P(D) = 0.30*0.01 + 0.50*0.02 + 0.20*0.005 = 0.0140
P(L2|D) = 0.50*0.02 / 0.0140 = 0.714286
difettosi simulati = 133 / 10000 = 0.0133 (teorico 0.0140)
ES su P(D) = sqrt(p(1-p)/N) = 0.00117 scarto = -0.60 ES
difettosi disponibili = 133
P(L2|D) simulata = 0.6842 (teorico 0.714286)
ES sui 133 difettosi = 0.0392 scarto = -0.77 ES
ES sbagliato (su 10000) = 0.0045
```

Lettura dei risultati. La percentuale di difettosi simulata (1.33%) dista dal valore teorico (1.40%) di 0.60 errori standard: ottimo accordo. La frazione di difettosi provenienti da L_2 è 0.6842 contro 0.714286 teorica, e lo scarto vale -0.77 errori standard. Entrambe le simulazioni “verificano” la teoria entro il rumore campionario — che per il punto (d) va però misurato sul campione giusto.

Il punto (d): l'errore standard si calcola su 133, non su 10000

La probabilità richiesta in (b) è *condizionata*: “dato che il pezzo è difettoso, quanto vale la probabilità che venga da L_2 ?”. La popolazione di riferimento è quindi l'insieme dei pezzi difettosi — 133 — non i 10000 prodotti. Da qui

$$ES = \sqrt{\frac{0.714286 \cdot 0.285714}{133}} = 0.0392,$$

mentre $\sqrt{p(1-p)/10000} = 0.0045$ sottostima l'errore di quasi **nove volte** ($0.0392/0.0045 = 8.7$). Con l'errore sbagliato lo scarto di -0.030 sembrerebbe di -6.7 errori standard, cioè un fallimento clamoroso della simulazione, mentre è un normalissimo scarto di -0.77 . **Regola: l'errore standard si calcola sul numero di osservazioni che stai effettivamente usando.**

Che cosa dimostrano davvero le due simulazioni

Il punto (c) è una verifica del teorema delle probabilità totali: si “costruisce” la produzione estraendo prima la linea (con probabilità 0.30, 0.50, 0.20) e poi l'esito (con la difettosità di quella linea), e la frequenza relativa dei difettosi converge a $\mathbb{P}(D)$. Il punto (d) è una verifica di Bayes, e la differenza concettuale è che si **condiziona** la simulazione: si guardano solo i pezzi difettosi e si conta la frazione di quelli venuti da L_2 . È esattamente la definizione di probabilità condizionata $\mathbb{P}(L_2 | D) = \mathbb{P}(L_2 \cap D)/\mathbb{P}(D)$: il “/” si realizza filtrando i dati, non moltiplicando numeri.

25.3 Q2 (Laboratorio) — Regressione con le formule, senza `linregress`

Le formule da scrivere. Con $S_{xx} = \sum_i (x_i - \bar{x})^2$, $S_{yy} = \sum_i (y_i - \bar{y})^2$ e $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$:

$$\beta_1 = \frac{S_{xy}}{S_{xx}} = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}, \quad \rho = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}}, \quad R = \rho^2.$$

Notare che dividere S_{xx} , S_{yy} e S_{xy} per n non cambia né β_1 né ρ : sono le *varianze e covarianze empiriche* del corso, e a mano conviene usarle per tenere i numeri piccoli.

```
1 import numpy as np
2
3 # NOTA: niente scipy.stats.linregress, le formule si scrivono a mano
```

```

4 x = np.array([105, 511, 401, 622, 330], dtype=float) # dimensione dei dati
5 y = np.array([ 44, 214, 193, 299, 143], dtype=float) # tempo (s)
6 n = len(x)
7
8 xb, yb = x.mean(), y.mean()
9 Sxx = np.sum((x - xb)**2) # somma degli scarti al quadrato
10 Syy = np.sum((y - yb)**2)
11 Sxy = np.sum((x - xb) * (y - yb))
12
13 betal = Sxy / Sxx # pendenza = sigma_xy / sigma_x^2
14 beta0 = yb - betal * xb # intercetta
15 rho = Sxy / np.sqrt(Sxx * Syy) # coefficiente di correlazione
16 R = rho**2 # coefficiente di determinazione
17
18 print(f"media x = {xb:.4f}, media y = {yb:.4f}")
19 print(f"S_xx = {Sxx:.2f} -> varianza empirica di x = S_xx/n = {Sxx/n:.2f}")
20 print(f"S_yy = {Syy:.2f} -> varianza empirica di y = S_yy/n = {Syy/n:.2f}")
21 print(f"S_xy = {Sxy:.2f} -> covarianza empirica = S_xy/n = {Sxy/n:.2f}")
22 print(f"retta: tempo = {beta0:.4f} + {betal:.4f} * dimensione")
23 print(f"rho = {rho:.6f}, R = rho^2 = {R:.6f}")
24 print(f"previsione per 200 dati: {beta0 + betal*200:.4f} s")
25
26 res = y - (beta0 + betal*x)
27 print("residui (s):", np.round(res, 3).tolist())
28 print(f"somma dei residui = {res.sum():.2e}")

```

Output:

```

media x = 393.8000, media y = 178.6000
S_xx = 153338.80 -> varianza empirica di x = S_xx/n = 30667.76
S_yy = 35341.20 -> varianza empirica di y = S_yy/n = 7068.24
S_xy = 72871.60 -> covarianza empirica = S_xy/n = 14574.32
retta: tempo = -8.5466 + 0.4752 * dimensione
rho = 0.989901, R = rho^2 = 0.979903
previsione per 200 dati: 86.4999 s
residui (s): [2.647, -20.297, 10.978, 11.952, -5.28]
somma dei residui = 2.13e-14

```

Lettura dei risultati. $\rho = 0.989901$: correlazione lineare **quasi perfetta** e positiva. $R = 0.979903$: il 98% della variabilità dei tempi è spiegata dalla dimensione dei dati. La pendenza vale $\beta_1 = 0.4752$ **secondi in più per ogni unità di dati in più**, l'intercetta $\beta_0 = -8.5466$ s è priva di significato fisico (un tempo negativo per 0 dati) e serve solo a posizionare la retta. La previsione per 200 dati è 86.4999 s: 200 sta dentro l'intervallo osservato [105, 622], quindi è un'**interpolazione** e non richiede cautele. Il controllo dei residui chiude il ragionamento: sono sparsi attorno allo zero (+2.6, -20.3, +11.0, +12.0, -5.3) e sommano a zero (2.1×10^{-14} , cioè zero a meno dell'errore di macchina): la verifica che il modello lineare non lascia struttura non spiegata.

Le trappole della regressione “a mano”

1. **Usare la pendenza al posto dell'intercetta** (o scambiare x e y). La variabile dipendente è il tempo, quindi la retta predice **tempo** in funzione di **dimensione**.
2. **Sbagliare i denominatori.** $\beta_1 = S_{xy}/S_{xx}$ (non S_{xy}/S_{yy}): al numeratore la covarianza, al denominatore la varianza della variabile *indipendente*.
3. **Confondere R con ρ .** Il corso chiama R il coefficiente di determinazione, e vale $R = \rho^2 = 0.979903$: è un numero, non un'operazione da fare. Chi lo eleva di nuovo al quadrato “perché nella notazione anglosassone si scrive r^2 ” ottiene $\rho^4 = 0.960212$, che non è il coefficiente di determinazione. Si calcola ρ e lo si eleva al quadrato *una volta sola*.

4. **Fidarsi di linregress in sede d'esame.** Il divieto non è un dettaglio formale: usarla quando è vietata azzerà il punteggio del quesito. Serve solo come controllo mentale, e il confronto $\beta_1 = 0.4752$, $\beta_0 = -8.5466$ conferma i conti.

25.4 Q1 (Teoria) — Frequenze, media, quantili, varianza

(a) **Le frequenze.** Dato un insieme di N dati in cui il valore x_i compare n_i volte:

- **frequenza assoluta:** n_i , il numero di volte che il valore compare;
- **frequenza relativa:** $f_i = n_i/N$, con $\sum_i f_i = 1$;
- **frequenza accumulata assoluta:** $N_i = n_1 + \dots + n_i$, quanti dati sono $\leq x_i$;
- **frequenza accumulata relativa:** $F_i = N_i/N$.

(b) **La media aritmetica.**

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \quad (\text{dati semplici}), \quad \bar{x} = \frac{1}{N} \sum_i x_i n_i = \sum_i x_i f_i \quad (\text{dati con frequenze}).$$

(c) **I quantili.** Il **quantile** di ordine $p \in [0, 1]$, Q_p , è il valore che lascia a sinistra (almeno) una frazione p dei dati ordinati in senso crescente; in notazione del corso $q_\alpha = \sup\{r : F_X(r) = \alpha\}$. Casi notevoli: la **mediana** $Q_{0.5}$ (divide i dati a metà), i **quartili** $Q_{0.25} = Q_1$ e $Q_{0.75} = Q_3$, e la **distanza interquartile** $IQR = Q_3 - Q_1$, che misura l'ampiezza del “cuore” dei dati e serve a individuare gli outlier (Cap. 6).

(d) **Le varianze.**

$$\text{empirica: } \bar{\sigma}_n^2 = \frac{1}{N} \sum_i (x_i - \bar{x})^2, \quad \text{campionaria: } \bar{S}_n^2 = \frac{1}{N-1} \sum_i (x_i - \bar{x})^2,$$

e con le frequenze $\bar{\sigma}_n^2 = \frac{1}{N} \sum_i n_i (x_i - \bar{x})^2$ e $\bar{S}_n^2 = \frac{1}{N-1} \sum_i n_i (x_i - \bar{x})^2$. Il divisore $N-1$ serve a rendere lo stimatore *non distorto*: con N al denominatore si sottostima sistematicamente la varianza della popolazione (Cap. 6).

Le stesse definizioni sui dati del 27/01/26, per fissarle

Sui 100 biscotti (pesi da 17 a 30 g, tabella del Cap. 14):

$$\bar{x} = 23.6900 \text{ g}, \quad \text{mediana} = 24.00 \text{ g}, \quad Q_1 = 22.00 \text{ g}, \quad Q_3 = 25.00 \text{ g}, \quad IQR = 3.00 \text{ g},$$

$$\bar{\sigma}_n^2 = 6.0939 \text{ (divisore } N), \quad \bar{S}_n^2 = 6.1555 \text{ (divisore } N-1), \quad \sqrt{\bar{S}_n^2} = 2.4810 \text{ g}.$$

Le frequenze accumulate relative crescono da 0.01 (primo valore, 17 g) a 1.00: $F(22) = 0.31$ significa che il 31% dei biscotti pesa al più 22 g, ed è il numero da cui si legge la mediana (F supera 0.5 per la prima volta a 24 g). È il modo di controllare a mano i quantili che `np.quantile` restituisce.

25.5 Q2 (Teoria) — La distribuzione binomiale

(a) **Definizione.** Sia X il numero di successi in n prove di Bernoulli indipendenti e identiche, ciascuna con probabilità di successo p . Allora $X \sim \text{Bin}(n, p)$ con

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

Le quantità coinvolte: n è il numero di prove; p è la probabilità di successo in *ogni* prova, costante perché le prove sono indipendenti; $\binom{n}{k}$ conta in quanti modi i k successi possono posizionarsi fra le n prove. La condizione di indipendenza è essenziale: se le estrazioni fossero *senza* reimmissione il modello corretto sarebbe l'ipergeometrica (il caso delle carte Magic, prova del 27/01/26, Cap. 4).

(b) Esempio con i conti espliciti. Lancio 10 monete equilibrate e conto le teste: $X \sim \text{Bin}(10, \frac{1}{2})$. La probabilità di esattamente 3 teste è

$$\mathbb{P}(X = 3) = \binom{10}{3} \left(\frac{1}{2}\right)^3 \left(\frac{1}{2}\right)^7 = \frac{120}{1024} = 0.117188.$$

(c) Media e varianza.

$$\mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p).$$

(d) La derivazione. Si scrive $X = Y_1 + \dots + Y_n$ dove $Y_i \sim \text{Ber}(p)$ vale 1 se la prova i -esima ha successo, e le Y_i sono indipendenti.

- **Media:** per *linearità* della media, $\mathbb{E}[X] = \sum_i \mathbb{E}[Y_i] = \sum_i p = np$.
- **Varianza:** per una Bernoulli $\mathbb{E}[Y_i^2] = p$, quindi $\text{Var}(Y_i) = p - p^2 = p(1-p)$; poiché le Y_i sono *indipendenti*, la varianza della somma è la somma delle varianze: $\text{Var}(X) = \sum_i \text{Var}(Y_i) = \sum_i p(1-p) = np(1-p)$. ■

```

1 import numpy as np
2 from scipy import stats
3 from math import comb
4
5 n, p = 10, 0.5
6 print(f"P(X=3) = C(10,3)*(1/2)^3*(1/2)^7 = {comb(10,3)/1024 = {comb(10,3)/1024:.6f}}")
7 print(f"controllo scipy: {stats.binom.pmf(3, n, p):.6f}")
8 print(f"E[X] = n*p = {n*p:.4f}    Var(X) = n*p*(1-p) = {n*p*(1-p):.4f}")
9
10 rng = np.random.default_rng(2)
11 sim = rng.binomial(n, p, size=100000)
12 print(f"simulazione: media = {sim.mean():.4f}    varianza = {sim.var():.4f}")

```

Output:

```

P(X=3) = C(10,3)*(1/2)^3*(1/2)^7 = 120/1024 = 0.117188
controllo scipy: 0.117188
E[X] = n*p = 5.0000    Var(X) = n*p*(1-p) = 2.5000
simulazione: media = 5.0024    varianza = 2.5047

```

La simulazione conferma le due formule: media 5.0024 contro $np = 5$ e varianza 2.5047 contro $np(1-p) = 2.5$. È la verifica da citare quando il compito chiede di “ricavare” media e varianza: la derivazione analitica sta sopra, il controllo numerico la rende concreta.

Un dettaglio che vale un punto: n grande e p piccola

Per il teorema del limite centrale la binomiale si approssima con una normale quando $np \geq 5$ e $n(1-p) \geq 5$ (soglia indicata negli appunti), e con una Poisson di parametro $\lambda = np$ quando n è grande e p piccolo (Cap. 4). Qui $n = 10$ e $np = 5$: l'approssimazione normale è al limite, e conviene usare la formula esatta. Dichiarare *quale* strumento si sta usando, e perché, è parte della risposta.

25.6 Cosa portare via da questa prova

- **Probabilità totali e Bayes sono due domande diverse:** la prima guarda in avanti (dalla causa all'effetto), la seconda all'indietro (dall'effetto alla causa). Nel compito sono i punti (a) e (b), e il discriminante è la partizione $\{L_1, L_2, L_3\}$ dello spazio campionario.
- **L'errore standard si calcola sul campione che si sta stimando:** 133 difettosi, non 10000 pezzi. Sbagliarlo di un fattore 9 trasforma uno scarto normale (-0.77 ES) in un presunto fallimento (-6.7 ES).
- **Simulare una probabilità condizionata significa filtrare i dati,** non riscaldare i numeri: si guardano solo i difettosi e si conta la frazione che viene da L_2 . È il punto (d), il più “concettuale” del quesito.
- **La regressione si fa con le formule** ($\beta_1 = S_{xy}/S_{xx}$, $\beta_0 = \bar{y} - \beta_1 \bar{x}$, $R = \rho^2$): il divieto di `linregress` va rispettato nella soluzione, e i residui che sommano a zero sono il controllo di coerenza da citare.
- **Le quattro definizioni descrittive** (frequenze, media, quantili con mediana/quartili/IQR, varianza empirica e campionaria) vanno sapute sia per dati semplici sia per dati con frequenze: la differenza è solo il fattore n_i nei numeratori e il divisore N o $N - 1$.
- **La binomiale: definizione, esempio, media, varianza e derivazione.** La derivazione si fa scrivendo X come somma di n Bernoulli indipendenti: linearità per la media, indipendenza per la varianza.

Capitolo 26

Prova del 1 aprile 2026

Prova del **1 aprile 2026**: quattro quesiti (due di Laboratorio, due di Teoria), due ore di tempo. È una prova “da manuale”, nel senso che ogni quesito ricalca un tipo già visto: il primo quesito di Laboratorio è un problema di **statistica descrittiva con test** sui dati degli ovetti di Pasqua (20 buste da 10 ovetti), il secondo è un quesito di **Monte Carlo** sull'integrale $\int_0^1 xe^x dx$ (hit or miss, rigetto e riconoscimento di una densità nascosta). La Teoria chiede le **variabili aleatorie** e la **media campionaria** con la legge dei grandi numeri.

Le quattro tecniche sono sviluppate nei capitoli 14 (istogrammi e stimatori), 16 (test sulla proporzione), 17 (hit or miss e rigetto), 4 e 5 (teoria). Qui le vediamo applicate tutte insieme, come all'esame.

26.1 Il testo della prova

Laboratorio — Quesito 1: gli ovetti di Pasqua

Si avvicina Pasqua. Per l'occasione Giorgino ha comprato 20 buste di ovetti assortiti. Ogni busta contiene 10 ovetti, che possono essere al cioccolato al latte, al cioccolato bianco o al cioccolato fondente. Giorgino ha raccolto il numero di ovetti per ogni tipo in ciascuna busta:

busta	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
fondente	3	2	5	4	4	3	2	3	3	4	5	5	2	2	4	3	4	4	3	3
latte	4	3	3	3	4	3	5	4	3	2	2	3	4	3	2	3	3	4	3	4
bianco	3	5	2	3	2	4	3	3	4	4	3	2	4	5	4	4	3	2	4	3

- a) Fare tre istogrammi, uno per ciascun tipo di ovetto. Ogni istogramma deve riportare, al variare di n , il numero di buste con n ovetti del tipo considerato.
- b) Calcolare la probabilità di aprire una busta e trovare meno di 4 ovetti fondenti. Calcolare la probabilità di trovare esattamente 3 ovetti al latte.
- c) Calcolare, per ciascun tipo di ovetto, uno stimatore della probabilità di trovare quel tipo di ovetto in una busta.
- d) A Giorgino è venuto il dubbio che i tre tipi di ovetti non siano distribuiti in maniera uniforme. È possibile affermare con una confidenza del 95% che la probabilità di trovare un ovetto bianco sia maggiore di $\frac{1}{3}$?

Laboratorio — Quesito 2: hit or miss e rigetto

- a) Si consideri il seguente integrale $I = \int_0^1 xe^x dx$. È possibile utilizzare il metodo hit or miss per calcolarlo?
- b) Calcolare l'integrale utilizzando il metodo hit or miss con $n = 1000$ e plottare il valore ottenuto in funzione del numero di numeri generati. (suggerimento: il massimo della funzione integranda si ha in $x = 1$)
- c) Dati i risultati precedenti spiegare perché la funzione $f(x) = xe^x$ si può considerare, nell'intervallo $[0, 1]$, una densità di probabilità.
- d) Utilizzare il metodo del rigetto con $n = 1000$ per generare numeri random secondo $f(x)$. Plottare i numeri ottenuti in un istogramma, scegliendo come numero di bin $N = 20$.

Teoria — Quesito 1: variabili aleatorie

- a) Dare la definizione di variabile aleatoria.
- b) Dare un esempio di evento e di variabile aleatoria ad esso associata.
- c) Qual è la differenza tra variabili aleatorie discrete e continue? E tra densità discreta e densità continua?
- d) Dare la definizione di momento centrato di ordine k sia per variabili aleatorie discrete che per quelle continue e fare un esempio di un momento centrato noto.

Teoria — Quesito 2: media campionaria e legge dei grandi numeri

Sia X_n una successione di variabili aleatorie indipendenti definite tutte nello stesso spazio di probabilità. Assumiamo che le X_n abbiano media μ e varianza σ^2 .

- a) Dare la definizione di media campionaria. È ancora una variabile aleatoria? Argomentare.
- b) Calcolare media e varianza della media campionaria.
- c) Enunciare la legge dei grandi numeri. Assumendo vera la disuguaglianza di Chebyshev, dimostrare tale legge.
- d) Spiegare intuitivamente il significato della legge dei grandi numeri e spiegare come viene utilizzata in statistica.

26.2 Laboratorio, Q1 — gli ovetti

Il quesito mescola tre cose: le **frequenze** (punti a–b), uno **stimatore** (punto c) e un **test** (punto d). Lo svolgimento esteso dei primi tre punti, con gli istogrammi e il commento descrittivo, è nel capitolo 14; qui ne riprendiamo i numeri per arrivare al test.

Le tre idee, in ordine

(b) Le probabilità richieste sono frequenze relative sul campione: non c'è una distribuzione teorica da cui calcolarle, quindi $P(\text{fondente} < 4)$ è la frazione di buste con meno di 4 fondenti. (c) Ogni ovetto è una prova di Bernoulli (“è di questo tipo?”): su 200 ovetti lo stimatore naturale è $\hat{p} = \frac{\text{\#ovetti di quel tipo}}{200}$, non distorto e consistente. (d) Il test è sulla *proporzione*: sotto $H_0 : p = \frac{1}{3}$ il numero di ovetti bianchi è $\text{Bin}(200, \frac{1}{3})$.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 fondente = np.array([3,2,5,4,4,3,2,3,3,4,5,5,2,2,4,3,4,4,3,3])
5 latte    = np.array([4,3,3,3,4,3,5,4,3,2,2,3,4,3,2,3,3,4,3,4])
6 bianco   = np.array([3,5,2,3,2,4,3,3,4,4,3,2,4,5,4,4,3,2,4,3])
7
8 # a) un istogramma per tipo: quante buste contengono n = 0,1,...,5 ovetti di quel tipo
9 fig, assi = plt.subplots(1, 3, figsize=(13, 4), sharey=True)
10 for asse, (nome, dati) in zip(assi, [("fondente", fondente), ("latte", latte), ("bianco",
    ↪ bianco)]):
11     asse.bar(np.arange(6), np.bincount(dati, minlength=6), edgecolor='k')
12     asse.set_title(nome); asse.set_xlabel("n ovetti nella busta"); asse.set_ylabel("numero di
    ↪ buste")
13 plt.tight_layout(); plt.show()
14
15 # b) probabilità empiriche sulle 20 buste
16 print("P(fondente < 4) =", (fondente < 4).mean())
17 print("P(latte == 3)   =", (latte == 3).mean())
18
19 # c) stimatore per tipo: frequenza relativa sugli ovetti totali
20 totale = fondente.sum() + latte.sum() + bianco.sum()

```

```

21 for nome, dati in [("fondente", fondente), ("latte", latte), ("bianco", bianco)]:
22     print("p_hat(%-8s) = %d/%d = %.4f" % (nome, dati.sum(), totale, dati.sum()/totale))

```

Output:

```

P(fondente < 4) = 0.55
P(latte == 3)   = 0.5
p_hat(fondente) = 68/200 = 0.3400
p_hat(latte    ) = 65/200 = 0.3250
p_hat(bianco   ) = 67/200 = 0.3350

```

I conteggi degli istogrammi sono, per $n = 0, \dots, 5$: fondente $[0, 0, 4, 7, 6, 3]$, latte $[0, 0, 3, 10, 6, 1]$, bianco $[0, 0, 4, 7, 7, 2]$. Le tre stime 0.340, 0.325 e 0.335 sono tutte vicinissime a $\frac{1}{3} \approx 0.3333$: è esattamente questa vicinanza che prepara la risposta (negativa) del punto (d).

(d) Il test. Il sospetto è direzionale (“maggiore di $\frac{1}{3}$ ”), quindi unilaterale destro:

$$H_0 : p = \frac{1}{3} \quad \text{contro} \quad H_1 : p > \frac{1}{3}.$$

Sotto H_0 si ha $X \sim \text{Bin}(200, \frac{1}{3})$, con $\mathbb{E}[X] = 66.67$ e $\sigma_X = \sqrt{200 \cdot \frac{1}{3} \cdot \frac{2}{3}} = 6.67$; il valore osservato è $k = 67$, praticamente *sulla media*.

```

1 import numpy as np
2 from scipy import stats
3
4 bianchi, tot = 67, 200
5 p0, alpha = 1/3, 0.05
6
7 print("p_hat = %d/%d = %.6f" % (bianchi, tot, bianchi/tot))
8 print("attesi sotto H0 = %.4f   (osservati %d)" % (tot*p0, bianchi))
9
10 # (1) test binomiale esatto: H0: p = 1/3 vs H1: p > 1/3
11 print("p-value esatto = P(X >= %d) = %.6f" % (bianchi, stats.binom.sf(bianchi-1, tot, p0)))
12
13 # (2) approssimazione normale (la variabile ausiliaria degli appunti)
14 p_hat = bianchi/tot
15 z = (p_hat - p0)/np.sqrt(p0*(1-p0)/tot)
16 critico = stats.norm.ppf(1-alpha) # unilaterale destro -> phi_(1-alpha)
17 print("z = %.4f, critico phi_0.95 = %.4f" % (z, critico))
18 print("p-value normale = %.4f" % (1 - stats.norm.cdf(z)))

```

Output:

```

p_hat = 67/200 = 0.335000
attesi sotto H0 = 66.6667   (osservati 67)
p-value esatto = P(X >= 67) = 0.506637
z = 0.0500, critico phi_0.95 = 1.6449
p-value normale = 0.4801

```

La conclusione. La statistica vale $z = 0.05$: il valore osservato è praticamente indistinguibile dall’atteso sotto H_0 . Il p -value è ≈ 0.51 (esatto) o ≈ 0.48 (normale), enormemente più grande di 0.05: **non si rigetta** H_0 . La risposta da scrivere è quindi: *con una confidenza del 95% non è possibile affermare che la probabilità di trovare un ovetto bianco sia maggiore di $\frac{1}{3}$.*

“Non rigetto” non significa “ H_0 è vera”

La risposta sbagliata è “no, quindi $p = \frac{1}{3}$ ”. Non rigettare H_0 rende il test **inconcludente**: non c’è evidenza per affermare H_1 , ma non c’è nemmeno una prova che H_1 sia falsa. È l’asimmetria fra H_0 e H_1 scritta negli appunti (Cap. 6). Il punto (d) vale da solo diversi punti, e si perde tutto con una frase del tipo “quindi la distribuzione è uniforme”.

26.3 Laboratorio, Q2 — hit or miss e rigetto

(a) Si può applicare l'hit or miss? Servono le tre ipotesi: $f \geq 0$, intervallo e funzione limitati, maggiorante M noto. Qui $f(x) = xe^x$ è continua e non negativa su $[0, 1]$ (prodotto di $x \geq 0$ e $e^x > 0$) e

$$f'(x) = (x+1)e^x > 0 \quad \text{su } [0, 1],$$

quindi è crescente e il massimo è nell'estremo destro: $M = f(1) = e \approx 2.718282$. Il rettangolo $[0, 1] \times [0, e]$ contiene la regione sotto la curva: **sì, il metodo è applicabile**. La derivata va scritta: il suggerimento del testo dice dove sta il massimo, non perché.

(b) L'integrale, e il suo valore esatto. Per parti,

$$I = \int_0^1 xe^x dx = [xe^x]_0^1 - \int_0^1 e^x dx = e - (e - 1) = 1,$$

quindi il valore esatto è **esattamente** 1. Lo stimatore hit or miss è $\hat{I} = M \cdot \frac{\#_{\text{hit}}}{N}$ (l'area del rettangolo è $1 \cdot M$), e la sua varianza è $\text{Var}(\hat{I}) = \frac{I(A-I)}{N} = \frac{e-1}{N}$, cioè $1.718282/N$ (Cap. 17).

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 f = lambda x: x*np.exp(x)
5 M = np.e                                # massimo su [0,1]: f è crescente, f(1) = e
6
7 def cumulativa(N, seme=9):
8     rng = np.random.default_rng(seme)
9     x = rng.uniform(0, 1, N); y = rng.uniform(0, M, N)
10    return M*np.cumsum(y <= f(x))/np.arange(1, N+1)
11
12 for N in (1000, 10000, 100000):
13     st = cumulativa(N)
14     se = np.sqrt((M-1)/N)                # SE = sqrt(I(A-I)/N) con I = 1, A = M
15     print("N=%6d: stima=%.6f errore=%+.6f accettazione=%.4f SE=%.6f errore in ES=%+.2f"
16           % (N, st[-1], st[-1]-1, st[-1]/M, se, (st[-1]-1)/se))
17
18 plt.plot(np.arange(1, 100001), cumulativa(100000), lw=1)
19 plt.axhline(1.0, color='r', ls='--', label='valore esatto = 1')
20 plt.xlabel("numero di numeri generati"); plt.ylabel("stima di I"); plt.legend()
21 plt.show()

```

Output:

N= 1000:	stima=0.994891	errore=-0.005109	accettazione=0.3660	SE=0.041452	errore in ES=-0.12
N= 10000:	stima=1.010657	errore=+0.010657	accettazione=0.3718	SE=0.013108	errore in ES=+0.81
N=100000:	stima=0.996305	errore=-0.003695	accettazione=0.3665	SE=0.004145	errore in ES=-0.89

Il commento. Le tre stime oscillano attorno a 1 e gli errori (-0.005 , $+0.011$, -0.004) valgono -0.12 , $+0.81$ e -0.89 errori standard: tutti compatibili con il rumore campionario. La frazione di accettazione misurata (0.3660, 0.3718, 0.3665) coincide con $1/M = 1/e = 0.367879$: il rettangolo scelto è quello ottimale. L'errore standard si divide per $\sqrt{10} \approx 3.16$ ogni volta che N si moltiplica per 10, come deve essere.

(c) Perché f è una densità su $[0, 1]$. Per definizione servono $f \geq 0$ su $[0, 1]$ e $\int_0^1 f = 1$. La prima è ovvia, la seconda è esattamente il calcolo del punto (b): f soddisfa entrambe le condizioni, quindi è una densità di probabilità su quell'intervallo. È il punto in cui i due quesiti si saldano: l'integrale "da calcolare" è la costante di normalizzazione di una densità.

(d) Il rigetto. L'algoritmo del corso: si genera $\xi \sim \mathcal{U}(0, 1)$ e $\eta \sim \mathcal{U}(0, M)$ e si accetta ξ se $\eta \leq f(\xi)$; i valori accettati hanno densità f , e la probabilità di accettazione è $1/M$ (Cap. 8). Qui il controllo che rende solida la risposta non è l'istogramma ma il confronto della **media** del campione

con $\mathbb{E}[X]$:

$$\mathbb{E}[X] = \int_0^1 x^2 e^x dx = e - 2 = 0.718282, \quad \mathbb{E}[X^2] = \int_0^1 x^3 e^x dx = 6 - 2e = 0.563436,$$

$$\text{Var}(X) = 0.563436 - 0.718282^2 = 0.047508, \quad \sigma_X = 0.217962.$$

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 f = lambda x: x*np.exp(x)
5 M = np.e
6
7 def rigetto(n, seme=42):
8     rng, out, tentativi = np.random.default_rng(seme), [], 0
9     while len(out) < n:
10         y = rng.uniform(0, 1); tentativi += 1
11         if rng.uniform() <= f(y)/M:
12             out.append(y)
13     return np.array(out), tentativi
14
15 campione, tentativi = rigetto(1000)
16 m1, m2 = np.e - 2, 6 - 2*np.e          # E[X] e E[X^2], calcolati per parti
17 es = np.sqrt((m2 - m1**2)/1000)
18
19 print("accettazione = %.4f   (teorica 1/M = %.4f)" % (1000/tentativi, 1/M))
20 print("media campionaria = %.4f   (E[X] = %.6f)" % (campione.mean(), m1))
21 print("scarto = %+.4f = %+.2f ES   (ES = %.4f)" % (campione.mean()-m1, (campione.mean()-m1)/es,
22     ↪ es))
23 print("E[X^2] = %.6f   Var(X) = %.6f   sd = %.6f" % (m2, m2-m1**2, np.sqrt(m2-m1**2)))
24
25 plt.hist(campione, bins=20, density=True, alpha=0.6, edgecolor='white')
26 xs = np.linspace(0, 1, 200)
27 plt.plot(xs, f(xs), 'r-', lw=2, label='densità f(x) = x e^x')
28 plt.xlabel('x'); plt.ylabel('densità'); plt.legend(); plt.tight_layout(); plt.show()

```

Output:

```

accettazione = 0.3678   (teorica 1/M = 0.3679)
media campionaria = 0.7159   (E[X] = 0.718282)
scarto = -0.0024 = -0.35 ES   (ES = 0.0069)
E[X^2] = 0.563436   Var(X) = 0.047508   sd = 0.217962

```

La media del campione (0.7159) dista da $\mathbb{E}[X] = 0.718282$ solo 0.35 errori standard: i valori generati seguono davvero f . L'istogramma con 20 bin ne riproduce la forma crescente, con i valori addensati verso $x = 1$.

Le due trappole di questo quesito

- $M = f(1) = e$ e non un numero “grande a caso”. Se M fosse minore del massimo il rettangolo non conterrebbe la regione e la stima sarebbe *distorta*; se fosse più grande del necessario la stima resterebbe corretta ma la varianza crescerebbe. Il valore ottimale è il massimo esatto.
- Hit or miss e rigetto **non sono due modi per fare la stessa cosa**: il primo *stima* I , il secondo *genera* numeri con densità f . Sono lo stesso meccanismo visto da due lati — la frazione di accettazione vale I/A nel primo caso e $1/M$ nel secondo — ma le due domande restano distinte.

26.4 Teoria, Q1 — variabili aleatorie

(a) **Definizione.** Dato uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, una **variabile aleatoria** è un'applicazione $X : \Omega \rightarrow \mathbb{R}$ tale che per ogni $t \in \mathbb{R}$ l'insieme $\{\omega : X(\omega) \leq t\}$ appartenga a $\mathcal{A}$, cioè sia un evento. In parole povere: è una funzione che a ogni esito dell'esperimento associa un numero reale. Serve perché sui numeri si sa fare matematica (somme, medie, integrali), sugli esiti no (Cap. 4).

(b) **Esempio.** Lancio di un dado: l'evento è $A = \text{"esce un numero pari"}$, la variabile aleatoria associata è $X = \text{"risultato del lancio"}$. Allora $A = \{X \in \{2, 4, 6\}\}$, cioè l'evento si riscrive come condizione sulla variabile, e $\mathbb{P}(A) = \mathbb{P}(X \in \{2, 4, 6\}) = \frac{1}{2}$.

(c) **Discreta contro continua.** Una v.a. è **discreta** se l'insieme dei valori possibili è finito o numerabile (il dado), **continua** se i valori riempiono un intervallo di $\mathbb{R}$ (il tempo di decadimento di una sostanza radioattiva). La differenza si porta dietro la descrizione:

- **densità discreta** (pmf) $p(x_k) = \mathbb{P}(X = x_k)$, con $p_k \geq 0$ e $\sum_k p_k = 1$; le probabilità stanno *sui punti* e si sommano;
- **densità continua** $f(x)$, con $f(x) \geq 0$ e $\int_{\mathbb{R}} f(x) dx = 1$; le probabilità stanno *sugli intervalli*, $\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx$, e per un singolo punto $\mathbb{P}(X = a) = 0$.

È la distinzione da cui discende tutto il resto: somme al posto di integrali, e l'integrale della densità al posto della somma delle probabilità puntuali.

(d) **Momento centrato.** Il **momento centrato di ordine k** è

$$\mu_k = \mathbb{E}[(X - \mathbb{E}[X])^k] = \begin{cases} \sum_j (x_j - \mathbb{E}[X])^k p(x_j), & X \text{ discreta,} \\ \int_{\mathbb{R}} (x - \mathbb{E}[X])^k f(x) dx, & X \text{ continua.} \end{cases}$$

L'esempio noto è $k = 2$: $\mu_2 = \mathbb{E}[(X - \mathbb{E}[X])^2] = \text{Var}(X)$, la varianza, cioè la dispersione attorno alla media. Gli altri due che il corso nomina sono $k = 3$ (asimmetria) e $k = 4$ (curtosi).

26.5 Teoria, Q2 — media campionaria e legge dei grandi numeri

(a) **Definizione, e perché è ancora una v.a.** La **media campionaria** di $X_1, \dots, X_N$ è

$$\bar{X}_n = \frac{1}{N} \sum_{n=1}^N X_n.$$

È ancora una variabile aleatoria: è una funzione (somma e divisione) di variabili aleatorie, quindi resta una funzione da Ω a $\mathbb{R}$. Il punto concettuale da argomentare è che $\bar{X}_n$ **cambia da campione a campione**: solo dopo aver osservato i dati diventa un numero. Prima è una v.a., con una sua distribuzione (la "distribuzione campionaria" dello stimatore).

(b) **Media e varianza.** Per la linearità del valore atteso,

$$\mathbb{E}[\bar{X}_n] = \frac{1}{N} \sum_{n=1}^N \mathbb{E}[X_n] = \frac{1}{N} \cdot N\mu = \mu,$$

e usando l'indipendenza (la varianza della somma è la somma delle varianze):

$$\text{Var}(\bar{X}_n) = \frac{1}{N^2} \text{Var}\left(\sum_{n=1}^N X_n\right) = \frac{1}{N^2} \cdot N\sigma^2 = \frac{\sigma^2}{N}.$$

Due conseguenze da citare: $\bar{X}_n$ è uno stimatore **non distorto** di μ , e la sua varianza **decresce come** $1/N$ (lo scarto come $1/\sqrt{N}$).

(c) **La legge dei grandi numeri, con la dimostrazione.** Enunciato: per $X_1, X_2, \dots$ indipendenti con media μ e varianza σ^2 finita, per ogni $\varepsilon > 0$

$$\lim_{N \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) = 0,$$

cioè $\bar{X}_n$ converge in probabilità a μ : $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$. Dimostrazione (assumendo Chebyshev): si applica la disuguaglianza $\mathbb{P}(|Y - \mathbb{E}[Y]| \geq \varepsilon) \leq \frac{\text{Var}(Y)}{\varepsilon^2}$ alla variabile $Y = \bar{X}_n$, che ha media μ e varianza σ^2/N :

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{N\varepsilon^2} \xrightarrow{N \rightarrow \infty} 0,$$

perché σ^2 ed ε sono fissati e il denominatore cresce indefinitamente. ■

(d) **Significato e uso in statistica.** Ripetendo l'esperimento molte volte, la media dei risultati **si stabilizza** sulla media teorica: la casualità si cancella, e lo fa a velocità $1/\sqrt{N}$. È il fondamento del metodo frequentista ($\mathbb{P}(E) \approx$ frequenza relativa per N grande), della definizione di stimatore consistente e di tutto il Laboratorio: perché la media campionaria di 1000 tempi di attesa “assomiglia” a $1/\lambda$, perché l'hit or miss converge all'integrale, perché una simulazione si può usare come prova.

26.6 Cosa portare via da questa prova

1. **Le probabilità empiriche sono frequenze relative**, non probabilità teoriche: se il testo non dà una distribuzione, si contano i casi favorevoli sul totale (Cap. 14).
2. **Su una proporzione si usano due strade**: il test binomiale esatto `stats.binom.sf` e l'approssimazione normale con $Z_n = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/N}}$. Qui danno 0.51 e 0.48: citarle entrambe mostra di sapere che esistono (Cap. 16).
3. **“Non si rigetta” non è “è vera”**: la formula corretta della risposta è “*non c'è evidenza sufficiente per affermare che...*”.
4. **Hit or miss**: va dimostrato che M è il massimo, e l'accettazione vale I/A . Con $I = 1$ e $A = e$ la varianza per unità di punti è $I(A - I) = e - 1 = 1.718282$ (Cap. 17).
5. **Il rigetto si verifica con i momenti**: media campionaria contro $\mathbb{E}[X] = e - 2$ e frazione di accettazione contro $1/M$, non solo con l'istogramma.
6. **Teoria**: la definizione di v.a. richiede la misurabilità; la dimostrazione della legge dei grandi numeri è di tre righe (Chebyshev + $\text{Var}(\bar{X}_n) = \sigma^2/N$) e va scritta per esteso (Capp. 4, 5).

Capitolo 27

Prova del 29 aprile 2026

Prova del **29 aprile 2026**: quattro quesiti, due di Laboratorio e due di Teoria. Il filo conduttore è il **tempo** (e il rumore) di un sistema che produce eventi: il primo quesito di Laboratorio simula i tempi di attesa di un server web modellati da una **esponenziale**, il secondo fa un **test z** sulla concentrazione media di un farmaco. La Teoria chiede gli **stimatori** (e in particolare lo stimatore della varianza nei due casi, media nota e non nota) e le definizioni delle **catene di Markov**.

È la prova più “inferenziale” delle nove: entrambi i quesiti di Laboratorio richiedono di *decidere* qualcosa (se il modello è adeguato, se si rigetta H_0), e la Teoria chiede le definizioni esatte. I due quesiti sono sviluppati per esteso nei capitoli 13 e 16; qui li riprendiamo con i numeri di questa prova.

27.1 Il testo della prova

Laboratorio — Quesito 1: i tempi di attesa di un server

Un server web riceve richieste secondo un processo di Poisson con tasso $\lambda = 5$ richieste/secondo. Si può dimostrare che i tempi di attesa tra richieste successive seguono allora una distribuzione esponenziale dello stesso parametro λ .

- a) Scrivere la formula della densità di probabilità e della funzione di ripartizione associate a questa distribuzione esponenziale.
- b) Calcolare la probabilità che il tempo di attesa tra due richieste sia superiore a 0.4 secondi e la probabilità che sia compreso tra 0.05 e 0.2 secondi.
- c) Simulare $N = 1000$ tempi di attesa con questa distribuzione. Visualizzare in un istogramma i tempi di attesa osservati e la distribuzione teorica.
- d) Confrontare la distribuzione teorica e quella osservata tramite un Q-Q plot (attraverso la funzione Python `probplot`).

Laboratorio — Quesito 2: la concentrazione dei farmaci

Una fabbrica produce dei farmaci contenenti un dato principio attivo, con una concentrazione in mg per litro che segue una distribuzione normale di media $\mu = 5.4$, con scarto quadratico medio $\sigma = 1.0$. Per un test produttivo viene esaminato un campione di $N = 25$ flaconi su cui viene misurata una concentrazione media $m = 5.0$ e si sospetta quindi che la concentrazione della sostanza attualmente prodotta sia minore di quella prevista.

- a) Formulare esplicitamente l'ipotesi nulla e l'ipotesi alternativa da indagare.
- b) Fissato un livello di significatività del 5%, possiamo rigettare l'ipotesi nulla?
- c) Qual è il p -value associato al rigetto dell'ipotesi?
- d) Graficare la distribuzione attesa della media di un campione di dimensione $N = 25$, in base a μ e σ date.

Teoria — Quesito 1: stimatori

- a) Dare la definizione di stimatore.
- b) Dare la definizione di stimatore non distorto.
- c) Quale stimatore usereste per stimare la varianza di una distribuzione con media nota? Dire se si tratta di uno stimatore distorto o no.
- d) Quale stimatore usereste per stimare la varianza di una distribuzione con media non nota? Dire se si tratta di uno stimatore distorto o no.

Teoria — Quesito 2: catene di Markov

- a) Dare la definizione di processo stocastico.
- b) Dare la definizione di catena di Markov.
- c) Dare la definizione di classe chiusa e di classe irriducibile.
- d) Dare la definizione di catena di Markov irriducibile.

27.2 Laboratorio, Q1 — la coda esponenziale

(a) **Densità e ripartizione.** Con $\lambda = 5$ e $t \geq 0$:

$$f(t) = \lambda e^{-\lambda t} = 5e^{-5t}, \quad F(t) = \mathbb{P}(T \leq t) = 1 - e^{-\lambda t} = 1 - e^{-5t}.$$

(b) **Le due probabilità, senza integrali.** Basta la ripartizione, usando $\mathbb{P}(T > t) = 1 - F(t) = e^{-\lambda t}$ e $\mathbb{P}(a < T < b) = F(b) - F(a)$:

$$\mathbb{P}(T > 0.4) = e^{-5 \cdot 0.4} = e^{-2} = 0.135335,$$

$$\mathbb{P}(0.05 < T < 0.2) = F(0.2) - F(0.05) = e^{-5 \cdot 0.05} - e^{-5 \cdot 0.2} = e^{-0.25} - e^{-1} = 0.410921.$$

```
1 import numpy as np
2 from scipy import stats
3
4 lam = 5.0 # richieste al secondo
5 print("P(T > 0.4) = e^-2 = %.6f" % np.exp(-lam*0.4))
6 print("P(0.05 < T < 0.2) = e^-0.25 - e^-1 = %.6f" % (np.exp(-lam*0.05) - np.exp(-lam*0.2)))
```

Output:

```
P(T > 0.4) = e^-2 = 0.135335
P(0.05 < T < 0.2) = e^-0.25 - e^-1 = 0.410921
```

(c–d) **Simulazione e Q-Q plot.** Attenzione al parametro: numpy vuole la *media* della distribuzione, cioè $\text{scale}=1/\text{lambda}$, non il tasso. Il confronto con la teoria si fa su tre fronti: i due momenti, le due probabilità del punto (b) e l'allineamento del Q-Q plot.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy import stats
4
5 lam, N = 5.0, 1000
6 attese = np.random.default_rng(42).exponential(1/lam, size=N) # numpy vuole la MEDIA 1/lambda
7
8 print("media = %.4f (teorica 1/lambda = %.4f)" % (attese.mean(), 1/lam))
9 print("scarto = %.4f (teorico 1/lambda = %.4f)" % (attese.std(ddof=1), 1/lam))
10 print("P(T>0.4) : sim %.4f teo %.6f" % ((attese > 0.4).mean(), np.exp(-lam*0.4)))
11 print("P(0.05<T<0.2) : sim %.4f teo %.6f" % (((attese > 0.05) & (attese < 0.2)).mean(),
12                                             np.exp(-lam*0.05) - np.exp(-lam*0.2)))
13
14 fig, assi = plt.subplots(1, 2, figsize=(11, 4))
15 xs = np.linspace(0, attese.max(), 300)
16 assi[0].hist(attese, bins=30, density=True, alpha=0.6, edgecolor='white')
17 assi[0].plot(xs, lam*np.exp(-lam*xs), 'r-', lw=2, label='densità teorica Exp(5)')
18 assi[0].set_xlabel('tempo di attesa (s)'); assi[0].set_ylabel('densità'); assi[0].legend()
19
20 _, (pend, interc, r) = stats.probplot(attese, dist=stats.expon, sparams=(0, 1/lam), plot=assi
21                                     ↪ [1])
22 assi[1].set_title('Q-Q plot')
23 plt.tight_layout(); plt.show()
24 print("Q-Q: pendenza = %.4f (attesa 1), intercetta = %.4f, r = %.4f" % (pend, interc, r))
```

Output:

```
media = 0.2029    (teorica 1/lambda = 0.2000)
scarto = 0.2055   (teorico 1/lambda = 0.2000)
P(T>0.4)        : sim 0.1500    teo 0.135335
P(0.05<T<0.2)   : sim 0.3980    teo 0.410921
Q-Q: pendenza = 1.0345 (attesa 1), intercetta = -0.0037, r = 0.9993
```

Il commento, in unità di errore standard. Il confronto va quantificato, altrimenti “i valori sono vicini” non è una risposta:

- **media:** 0.2029 contro $1/\lambda = 0.2$. L'errore standard della media è $\sigma/\sqrt{N} = 0.2/\sqrt{1000} = 0.0063$, quindi lo scarto $+0.0029$ vale $+0.45$ ES: perfettamente compatibile.
- **scarto quadratico:** 0.2055 contro 0.2000 (teorico $1/\lambda$, perché per l'esponenziale media e scarto coincidono).
- $\mathbb{P}(T > 0.4)$: $\hat{p} = 0.1500$ contro $p = 0.135335$, con $ES = \sqrt{p(1-p)/N} = 0.0108$: scarto $+1.36$ ES.
- $\mathbb{P}(0.05 < T < 0.2)$: $\hat{p} = 0.3980$ contro $p = 0.410921$, con $ES = 0.0156$: scarto -0.83 ES. Tutti gli scarti stanno entro due errori standard.
- **Q-Q plot:** pendenza 1.0345 contro 1 attesa, intercetta -0.0037 , $r = 0.9993$: i punti stanno sulla retta, il modello esponenziale è **adeguato**. Le piccole deviazioni alle estremità sono normali (lì i quantili sono stimati con pochissimi dati).

Il seme cambia i numeri, non le conclusioni

Questo esercizio è svolto anche nel capitolo 13 con `default_rng(11)`: là la media simulata è 0.1968, qui (seme 42) è 0.2029. Sono due realizzazioni diverse della *stessa* simulazione, ed entrambe stanno entro un errore standard dal valore teorico 0.2. È il motivo per cui in tutta la guida il **seme va sempre dichiarato** (Cap. 11): senza seme i numeri non sono riproducibili, ma nessun seme “giusto” esiste — solo risultati compatibili con la teoria.

scale non è λ

`np.random.exponential(scale)` e `stats.expon(scale)` ragionano entrambi in termini di **media**, non di tasso: con $\lambda = 5$ si scrive `scale=1/5`. Scrivere `scale=5` simula una $\text{Exp}(0.2)$, cioè tempi di attesa *cinque volte più lunghi* del previsto: la media verrebbe 5.0 invece di 0.2, e il confronto con la teoria fallirebbe in modo plateale. È l'errore più frequente su questo quesito.

27.3 Laboratorio, Q2 — il test sui farmaci

Il sospetto è *direzionale* (“la concentrazione è **minore** di quella prevista”), quindi l'alternativa è unilaterale sinistra:

$$H_0 : \mu = 5.4 \quad \text{contro} \quad H_1 : \mu < 5.4.$$

σ è **nota** (il testo la dà), quindi si usa lo z -test e non la t : la variabile ausiliaria è $Z_n = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{N}} \sim \mathcal{N}(0, 1)$, e la media campionaria di 25 flaconi ha scarto $\sigma/\sqrt{N} = 1/5 = 0.2$ (Cap. 16).

```
1 import numpy as np
2 from scipy import stats
3
4 mu0, sigma, N, m, alpha = 5.4, 1.0, 25, 5.0, 0.05
5 z = (m - mu0)/(sigma/np.sqrt(N))
6 critico = stats.norm.ppf(alpha)      # unilaterale sinistro -> phi_alpha
```

```

7 print("z = (%.1f - %.1f)/(.1f/sqrt(%d)) = %.4f" % (m, mu0, sigma, N, z))
8 print("valore critico phi_0.05 = %.4f" % critico)
9 print("p-value = Phi(z) = %.5f" % stats.norm.cdf(z))
10 print("si rigetta H0? %s" % (z < critico))
11 print("scarto della media campionaria = sigma/sqrt(N) = %.4f" % (sigma/np.sqrt(N)))

```

Output:

```

z = (5.0 - 5.4)/(1.0/sqrt(25)) = -2.0000
valore critico phi_0.05 = -1.6449
p-value = Phi(z) = 0.02275
si rigetta H0? True
scarto della media campionaria = sigma/sqrt(N) = 0.2000

```

La conclusione. $z = -2.00$ cade nella zona di rigetto ($z < \varphi_{0.05} = -1.6449$) e il p -value vale $0.0228 < 0.05$: si **rigetta** H_0 . C'è evidenza che la concentrazione media prodotta sia effettivamente *minore* di 5.4 mg/l. Il punto (d) chiede infine di disegnare la distribuzione della media campionaria sotto H_0 , cioè $\mathcal{N}(5.4, 0.2^2)$, con la zona di rigetto e il valore osservato $m = 5.0$.

Le tre trappole di questo quesito

- **Usare la t invece della z :** qui σ è data, quindi la scelta è obbligata. La t servirebbe se σ fosse stimata dai dati (come nel 27/01/26, Cap. 16).
- **Confrontare con il valore critico bilatero ± 1.96 invece che con $\varphi_{0.05} = -1.6449$.** Con $z = -2$ la conclusione non cambierebbe, ma il ragionamento sì: la domanda è unilaterale, e la soglia va presa tutta da una parte.
- **Confondere lo scarto della media con quello della popolazione:** 0.4 mg/l è la differenza grezza, ma la media di 25 flaconi ha scarto 0.2: la differenza vale due scarti della media, non 0.4 scarti della popolazione. È questo che rende il test significativo.

27.4 Teoria, Q1 — stimatori

(a) Stimatore. Si chiama **statistica** una funzione delle variabili aleatorie del campione. Uno **stimatore puntuale** di un parametro θ è una statistica $\hat{\theta} = g(X_1, \dots, X_N)$ a valori nell'immagine di θ , usata per stimare θ . Essendo una funzione di variabili aleatorie, è a sua volta una variabile aleatoria: ha una distribuzione (la *distribuzione campionaria dello stimatore*), con la sua media e la sua varianza (Cap. 6).

(b) Stimatore non distorto. $\hat{\theta}$ è **non distorto** (o corretto) se

$$\mathbb{E}[\hat{\theta}] = \theta.$$

Il significato: ripetendo l'estrazione di molti campioni, le stime oscillano attorno al valore vero *senza errori sistematici* (né per eccesso né per difetto).

(c) Varianza con media nota. Se μ è nota si può usare direttamente lo scarto da μ :

$$\bar{\sigma}_n^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2.$$

È **non distorto**: per la linearità del valore atteso,

$$\mathbb{E}[\bar{\sigma}_n^2] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[(X_i - \mu)^2] = \frac{1}{N} \cdot N\sigma^2 = \sigma^2.$$

Qui il divisore è N e va bene così: non c'è nessuna stima della media da “pagare”.

(d) **Varianza con media non nota.** Se μ non è nota si sostituisce con la media campionaria e si corregge il divisore:

$$\bar{S}_n^2 = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X}_n)^2.$$

È **non distorto**, $\mathbb{E}[\bar{S}_n^2] = \sigma^2$. Il perché del divisore $N-1$ va scritto: gli scarti $(X_i - \bar{X}_n)$ non sono indipendenti (la loro somma è zero, quindi solo $N-1$ sono liberi — i “gradi di libertà”), e inoltre gli scarti sono calcolati rispetto a $\bar{X}_n$, che è *più vicino* agli X_i di quanto lo sia μ . Con il divisore N lo stimatore sarebbe quindi **distorto per difetto**: $\mathbb{E}[\frac{1}{N} \sum (X_i - \bar{X}_n)^2] = \frac{N-1}{N} \sigma^2 < \sigma^2$.

La distinzione da non sbagliare

La **varianza empirica** $\bar{\sigma}_n^2$ (divisore N) descrive i dati e si usa quando la media è nota; la **varianza campionaria** $\bar{S}_n^2$ (divisore $N-1$) stima σ^2 e si usa quando la media è stimata dai dati. In Python: `np.var(x)` divide per N , `np.var(x, ddof=1)` divide per $N-1$; `scipy.stats` e `pandas` usano per default $N-1$. La distinzione è la stessa che decide fra z e t nel capitolo 16.

27.5 Teoria, Q2 — catene di Markov: le definizioni

(a) **Processo stocastico.** È una famiglia di variabili aleatorie $\{X_t\}_{t \in T}$ indicizzate da un insieme T (il tempo), tutte definite sullo stesso spazio di probabilità. Descrive l’evoluzione casuale di un sistema: a ogni istante t la variabile X_t rappresenta lo stato del sistema, e la famiglia ne descrive la storia possibile (Cap. 9). Se $T = \{0, 1, 2, \dots\}$ il processo è a *tempi discreti*; l’insieme dei valori possibili E è lo *spazio degli stati*.

(b) **Catena di Markov.** È un processo stocastico a tempi discreti, con spazio degli stati E finito o numerabile, che gode della **proprietà di Markov** (assenza di memoria):

$$\mathbb{P}(X_{t+1} = j \mid X_t = i, X_{t-1} = i_{t-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{t+1} = j \mid X_t = i) = p_{ij}.$$

Il futuro dipende solo dallo stato presente, non da come ci si è arrivati. La matrice $P = (p_{ij})$ è la matrice di transizione, con $p_{ij} \geq 0$ e $\sum_j p_{ij} = 1$ per ogni riga.

(c) **Classe chiusa e classe irriducibile.** Due stati i, j **comunicano** se i raggiunge j e j raggiunge i in un numero finito di passi ($p_{ij}^{(m)} > 0$ e $p_{ji}^{(n)} > 0$ per opportuni m, n).

- Un sottoinsieme $C \subseteq E$ è **chiuso** se da C non si esce: $p_{ij} = 0$ per ogni $i \in C$ e $j \notin C$. Una volta entrati in C , non se ne esce più.
- C è una **classe irriducibile** (classe di comunicazione) se tutti i suoi stati comunicano fra loro: per ogni $i, j \in C$ esiste m con $p_{ij}^{(m)} > 0$ e $p_{ji}^{(m)} > 0$.

(d) **Catena irriducibile.** Una catena di Markov è **irriducibile** se *tutto* lo spazio degli stati forma un’unica classe di comunicazione: ogni stato raggiunge ogni altro stato (in un numero finito di passi) con probabilità positiva. Il controllo pratico su una matrice è guardare una potenza sufficientemente alta (Cap. 18): se P^m (o $P^m + P^{m+1}$) ha tutte le entrate positive, la catena è irriducibile. Se la catena è anche **regolare**, la distribuzione stazionaria esiste, è unica e non dipende dallo stato iniziale (teorema di Markov).

Come si risponde a un quesito “tutto definizioni”

Qui non c’è niente da calcolare: il punteggio sta tutto nelle **parole esatte**. Le tre cose da non dimenticare mai:

1. nella definizione di processo stocastico va detta l’*indicizzazione* temporale e il fatto che le variabili sono definite sullo stesso spazio di probabilità;

2. nella proprietà di Markov va scritta la catena completa delle condizionamenti, mostrando che si riduce al solo stato presente;
3. tra “chiusa” e “irriducibile” non c’è gerarchia: la prima riguarda gli archi che *escono* da C , la seconda le comunicazioni *interne* a C .

27.6 Cosa portare via da questa prova

1. **La scelta z contro t dipende solo dalla varianza:** σ data dal testo $\Rightarrow$ normale; σ stimata dai dati $\Rightarrow t$ con $N - 1$ gradi di libertà (Cap. 16).
2. **Il confronto simulazione/teoria va misurato in errori standard**, non a occhio: media, scarto, probabilità e quantili, ciascuno con il suo ES (Cap. 13).
3. **scale è la media, non il tasso:** $\text{scale}=1/\text{lambda}$ per l’esponenziale. Vale anche per `stats.expon`.
4. **Il Q-Q plot si commenta:** pendenza attesa 1 quando si passano i parametri in `sparams`, e scostamenti solo alle estremità.
5. **I due stimatori della varianza:** divisore N con media nota, divisore $N - 1$ con media stimata. La differenza non è un dettaglio di notazione: è ciò che rende lo stimatore non distorto.
6. **Le definizioni di Markov vanno sapute a memoria**, incluse classe chiusa e classe irriducibile: sono state chieste in *cinque* prove su nove (Cap. 9).

Capitolo 28

Prova del 23 giugno 2026

Prova del **23 giugno 2026**: quattro quesiti, due di Laboratorio e due di Teoria. Il primo quesito di Laboratorio è un problema di **probabilità empiriche e binomiale** sui dati dell'ufficio anagrafe (le carte d'identità in scadenza); il secondo è la **catena di Markov** su un grafo a sei stati (matrice di transizione, matrice a 20 passi, distribuzione stazionaria). La Teoria chiede gli **intervalli di confidenza** (definizione, esempio grafico, dipendenza da N , σ e α) e i **numeri pseudorandom** con il metodo Monte Carlo.

È la prova con il maggiore squilibrio fra i due lati: il Laboratorio è veloce (una binomiale e una potenza di matrice), mentre la Teoria chiede due discorsi lunghi e precisi. Le tecniche sono nei capitoli 13 (probabilità empiriche e simulazione), 18 (catene), 16 e 6 (intervalli), 8 (pseudorandom e Monte Carlo).

28.1 Il testo della prova

Laboratorio — Quesito 1: le carte d'identità

Giorgino ha ancora la vecchia carta d'identità cartacea. Entro giorno 3 agosto dovrà provvedere a sostituirla con quella elettronica. Nel suo comune, altre 200 persone si trovano nella stessa situazione. L'impiegato dell'ufficio anagrafe ha raggruppato il numero di persone che devono rinnovare la carta d'identità per data di scadenza:

Data di scadenza	22/06–28/06	29/06–5/07	6/07–12/07	13/07–19/07	20/07–26/07	27/07–2/08
Numero di persone	45	47	36	37	20	15

- a) Calcolare la probabilità di avere la carta in scadenza in una determinata settimana e plottare il risultato in un istogramma.
- b) Calcolare la probabilità che la carta d'identità scada dopo il 5 luglio.
- c) L'impiegato all'anagrafe ha convocato i primi 45 cittadini. Sa che, per ciascuno, c'è una probabilità pari a $p = 0.25$ che non venga. Qual è la probabilità che riesca a sbrigare almeno 32 persone? (hint: per sbrigare almeno 32 persone, almeno 32 persone devono essere presenti!)
- d) Giorgino è il ventitreesimo del primo gruppo. Simulare $N = 100$ volte la giornata all'ufficio anagrafe e calcolare quante persone dovrà aspettare Giorgino per rinnovare la carta d'identità.

Laboratorio — Quesito 2: la catena di Markov sul grafo

Si consideri il seguente grafo (sei stati, archi etichettati con probabilità).

- a) Scrivere la matrice di transizione.
- b) Scrivere la matrice di transizione a $m = 20$ passi.
- c) Partendo dalla distribuzione iniziale $v_0 = (0.8, 0.1, 0, 0, 0, 0.1)$ calcolare la distribuzione v_t a tempi $t = 1, \dots, 20$. Si può considerare stazionaria? (hint: confrontare cosa accade a tempi successivi!)
- d) Ripetere il punto (c) partendo da $v_0 = (0.1, 0, 0, 0, 0.8, 0.1)$ e commentare il risultato.

Teoria — Quesito 1: intervalli di confidenza

- a) Dare la definizione di stimatore puntuale.
- b) Dare la definizione di intervallo di confidenza con livello di confidenza $1 - \alpha$.
- c) Scegliere un particolare intervallo di confidenza e darne una rappresentazione grafica.
- d) Commentare come cambiano gli estremi dell'intervallo di confidenza scelto al variare di N , σ e α .

Teoria — Quesito 2: pseudorandom e Monte Carlo

- a) Dare la definizione di numero pseudorandom.
- b) Dare la definizione di metodo Monte Carlo.
- c) Spiegare quali sono i vantaggi e gli svantaggi dell'utilizzo del metodo Monte Carlo.
- d) Illustrare a parole il funzionamento del metodo hit or miss per il calcolo degli integrali.

28.2 Laboratorio, Q1 — l'ufficio anagrafe

(a) **Le probabilità settimanali.** Le 200 persone sono il campione, e la probabilità empirica di ciascuna settimana è la frequenza relativa $n_i/200$: la somma delle sei probabilità fa 1, come deve essere.

(b) **“Dopo il 5 luglio”** è l'unione di quattro eventi incompatibili (le ultime quattro settimane): le probabilità si sommano.

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 persone = np.array([45, 47, 36, 37, 20, 15], dtype=float)
5 settimane = ["22-28/06", "29/06-5/07", "6-12/07", "13-19/07", "20-26/07", "27/07-2/08"]
6
7 # a) probabilità empirica di ciascuna settimana = frequenza relativa su 200 persone
8 p_sett = persone/persone.sum()
9 plt.bar(settimane, p_sett, edgecolor='k')
10 plt.ylabel("probabilità"); plt.xticks(rotation=30); plt.tight_layout(); plt.show()
11
12 for s, p in zip(settimane, p_sett):
13     print("%-12s %.3f" % (s, p))
14 print("P(scade dopo il 5/7) = %.2f" % p_sett[2:].sum())

```

Output:

```

22-28/06    0.225
29/06-5/07  0.235
6-12/07     0.180
13-19/07    0.185
20-26/07    0.100
27/07-2/08  0.075
P(scade dopo il 5/7) = 0.54

```

La settimana più affollata è la seconda (0.235) e la meno affollata l'ultima (0.075): la scadenza di Giorgino (3 agosto, ultima settimana) cade nella fascia con meno persone. Il punto (b) si poteva leggere anche direttamente in tabella: $36 + 37 + 20 + 15 = 108$ persone su 200, cioè 0.54.

(c) **Almeno 32 persone sbrigate.** Convocate 45 persone, ciascuna indipendente con probabilità $p_{\text{pres}} = 0.75$ di presentarsi: il numero di presenti è $X \sim \text{Bin}(45, 0.75)$, e “sbrigare almeno 32 persone” accade esattamente quando $X \geq 32$ (lo dice l'hint).

```

1 import numpy as np
2 from scipy import stats
3

```

```

4 p_pres = 0.75 # probabilità che il cittadino convocato si presenti
5 print("presenti ~ Bin(45, 0.75): E = %.2f sd = %.4f"
6       % (45*p_pres, np.sqrt(45*p_pres*(1-p_pres))))
7
8 P_almeno32 = 1 - stats.binom.cdf(31, 45, p_pres)
9 print("P(almeno 32 presenti) = 1 - P(X <= 31) = %.4f" % P_almeno32)

```

Output:

```

presenti ~ Bin(45, 0.75): E = 33.75 sd = 2.9047
P(almeno 32 presenti) = 1 - P(X <= 31) = 0.7841

```

Il valore atteso dei presenti è 33.75 e la soglia 32 è a meno di uno scarto dalla media: la probabilità di superarla è alta, 0.7841.

(d) Quanto aspetta Giorgino. Giorgino è il ventitreesimo: davanti a lui ci sono 22 persone, ciascuna presente con probabilità 0.75 e indipendente dalle altre. Le persone *da aspettare* sono quindi $X \sim \text{Bin}(22, 0.75)$, con $\mathbb{E}[X] = 16.5$ e $\sigma_X = \sqrt{22 \cdot 0.75 \cdot 0.25} = 2.0310$. Il punto delicato è il *metro* del confronto: la media di 100 repliche ha errore standard $\sigma_X/\sqrt{100}$, non σ_X .

```

1 import numpy as np
2
3 # d) Giorgino è il 23-esimo: davanti a lui ci sono 22 persone
4 N, davanti, p_pres = 100, 22, 0.75
5 sim = np.random.default_rng(23).binomial(davanti, p_pres, size=N)
6 es = np.sqrt(davanti*p_pres*(1-p_pres))/np.sqrt(N)
7
8 print("media = %.4f (teorica 22*0.75 = %.1f)" % (sim.mean(), davanti*p_pres))
9 print("scarto = %.4f (teorico %.4f)" % (sim.std(ddof=1), np.sqrt(davanti*p_pres*(1-p_pres))))
10 print("minimo = %d massimo = %d" % (sim.min(), sim.max()))
11 print("ES della media su %d repliche = %.4f scarto = %+.2f ES" % (N, es, (sim.mean()-davanti*
    ↪ p_pres)/es))

```

Output:

```

media = 16.3800 (teorica 22*0.75 = 16.5)
scarto = 2.0537 (teorico 2.0310)
minimo = 11 massimo = 21
ES della media su 100 repliche = 0.2031 scarto = -0.59 ES

```

Il commento. Lo scarto di una singola giornata vale 2.0537 contro il teorico 2.0310: la variabilità è quella prevista, e nei 100 giorni simulati Giorgino ha aspettato da 11 a 21 persone. La *media* delle 100 repliche è 16.38 contro 16.5: lo scarto 0.12 vale 0.59 errori standard *della media* (0.2031). Confrontarlo con lo scarto di una singola giornata (2.03) sarebbe un errore: la media di 100 repliche è molto meno variabile di una giornata sola (Cap. 13).

Due errori simmetrici, e tutti e due gravi

- **Contare Giorgino fra i presenti:** davanti a lui ci sono 22 persone, non 23. Usare $\text{Bin}(23, 0.75)$ sposta la media a 17.25 e falsa tutto il confronto.
- **Giudicare la media delle 100 repliche con l'errore standard di una sola:** $\sigma_X = 2.0310$ invece di $\sigma_X/\sqrt{100} = 0.2031$ farebbe sembrare lo scarto di 0.12 piccolissimo (appena 0.06 ES). Il numero giusto è 0.59 ES, ed è comunque compatibile.

28.3 Laboratorio, Q2 — la catena di Markov

Avvertenza: il grafo dell'esame è un disegno

Il quesito fornisce il grafo come **immagine**: nel testo estraibile dal PDF non compaiono le etichette degli archi. Nei calcoli che seguono si usa quindi la matrice rappresentativa già impiegata nel capitolo 18, con la stessa struttura (sei stati, righe che sommano a 1, cappi non nulli). **Il metodo è identico per qualunque matrice**, e la regola per leggere il grafo riga per riga (sommando le etichette degli archi che portano allo stesso stato) è nel Cap. 18. Con il grafo sotto gli occhi, i numeri cambiano; i passi no.

$$P = \begin{pmatrix} 0.5 & 0.2 & 0.1 & 0.2 & 0 & 0 \\ 0.1 & 0.5 & 0.2 & 0 & 0.2 & 0 \\ 0.1 & 0.1 & 0.6 & 0.2 & 0 & 0 \\ 0.2 & 0 & 0.1 & 0.5 & 0.1 & 0.1 \\ 0 & 0.1 & 0 & 0.1 & 0.5 & 0.3 \\ 0 & 0 & 0 & 0.1 & 0.3 & 0.6 \end{pmatrix}$$

```

1 import numpy as np
2
3 # matrice rappresentativa del grafo dell'esame (6 stati, righe che sommano a 1)
4 P = np.array([
5     [0.5, 0.2, 0.1, 0.2, 0.0, 0.0],
6     [0.1, 0.5, 0.2, 0.0, 0.2, 0.0],
7     [0.1, 0.1, 0.6, 0.2, 0.0, 0.0],
8     [0.2, 0.0, 0.1, 0.5, 0.1, 0.1],
9     [0.0, 0.1, 0.0, 0.1, 0.5, 0.3],
10    [0.0, 0.0, 0.0, 0.1, 0.3, 0.6]])
11 np.set_printoptions(precision=4, suppress=True)
12
13 print("a) righe sommano a 1:", np.allclose(P.sum(axis=1), 1))
14
15 # b) matrice di transizione a m = 20 passi
16 P20 = np.linalg.matrix_power(P, 20)
17 print("b) tutte le entrate di P^20 sono > 0:", (P20 > 0).all(), "-> catena regolare")
18
19 # c) traiettoria da v0 = (0.8, 0.1, 0, 0, 0, 0.1)
20 def traiettoria(v0, passi=20):
21     v, storia = np.asarray(v0, float), []
22     for _ in range(passi):
23         v = v @ P; storia.append(v.copy())
24     return np.array(storia)
25
26 A_ = traiettoria([0.8, 0.1, 0, 0, 0, 0.1])
27 print("c) v_1 =", A_[0]); print("    v_2 =", A_[1])
28 print("    v_19 =", A_[18]); print("    v_20 =", A_[19])
29 for t in (5, 10, 20):
30     print("    ||v_%d - v_%d||_1 = %.6f" % (t, t-1, np.abs(A_[t-1]-A_[t-2]).sum()))
31
32 # d) stessa cosa partendo da un'altra distribuzione iniziale
33 B_ = traiettoria([0.1, 0, 0, 0, 0.8, 0.1])
34 print("d) v_20 (seconda partenza) =", B_[19])
35 print("    ||v_20(a) - v_20(b)||_1 = %.6f" % np.abs(A_[19]-B_[19]).sum())
36
37 # distribuzione stazionaria, per il confronto finale
38 pi = np.linalg.lstsq(np.vstack([P.T - np.eye(6), np.ones(6)]),
39                     np.zeros(6), 1.0, rcond=None)[0]
40 aut = np.sort(np.abs(np.linalg.eigvals(P)))[::-1]
41 print("pi =", pi)

```

```

42 print("||v_20(a) - pi||_1 = %.6f    ||v_20(b) - pi||_1 = %.6f"
43       % (np.abs(A_[19]-pi).sum(), np.abs(B_[19]-pi).sum()))
44 print("lambda_2 = %.4f    |lambda_2|^20 = %.4f" % (aut[1], aut[1]**20))

```

Output:

```

a) righe sommano a 1: True
b) tutte le entrate di P^20 sono > 0: True -> catena regolare
c) v_1 = [0.41 0.21 0.1  0.17 0.05 0.06]
   v_2 = [0.27  0.202 0.16  0.198 0.102 0.068]
   v_19 = [0.1306 0.1229 0.1431 0.192  0.2085 0.2029]
   v_20 = [0.1303 0.1227 0.1427 0.1919 0.2089 0.2035]
   ||v_5 - v_4||_1 = 0.063808
   ||v_10 - v_9||_1 = 0.019607
   ||v_20 - v_19||_1 = 0.001991
d) v_20 (seconda partenza) = [0.1281 0.1213 0.1396 0.1909 0.2121 0.208 ]
   ||v_20(a) - v_20(b)||_1 = 0.015398
pi = [0.1292 0.122  0.1411 0.1914 0.2105 0.2057]
||v_20(a) - pi||_1 = 0.007738    ||v_20(b) - pi||_1 = 0.007660
lambda_2 = 0.7954    |lambda_2|^20 = 0.0103

```

Le risposte ai quattro punti.

- **(b)** P^{20} ha *tutte* le entrate strettamente positive: la catena è **regolare**, quindi la distribuzione stazionaria è unica.
- **(c)** Sì, v_{20} si può considerare **stazionaria**: la distanza da v_{19} è scesa da 0.0638 ($t = 5$) a 0.0196 ($t = 10$) a 0.0020 ($t = 20$), cioè lo 0.2% della massa totale. La convergenza è geometrica con ragione $|\lambda_2| = 0.7954$, il secondo autovalore di P : $0.7954^{20} = 0.0103$ è l'ordine di grandezza dell'errore residuo.
- **(d)** Partendo da una distribuzione iniziale completamente diversa si arriva **allo stesso** risultato: $\|v_{20}^{(a)} - v_{20}^{(b)}\|_1 = 0.0154$ e le due traiettorie distano da π meno di 0.008. È la conferma sperimentale del teorema di Markov: il limite non dipende dalla condizione iniziale, la catena “dimentica” da dove è partita.
- **Il controllo finale**: la distribuzione stazionaria calcolata analiticamente ($\pi P = \pi$, autovettore sinistro per l'autovalore 1) è $\pi = (0.1292, 0.1220, 0.1411, 0.1914, 0.2105, 0.2057)$, e v_{20} ne dista 0.0077. È esattamente l'errore che ci si aspetta da $|\lambda_2|^{20} = 0.0103$: v_{20} *non* è π , ne è una approssimazione con errore dell'1%.

Il vettore è una riga, e i cappi vanno letti

Due errori che si vedono nei compiti: usare la convenzione *colonna* ($P @ v$ invece di $v @ P$) — con un vettore di numpy 1-D il codice non dà errore ma il risultato è sbagliato — e dimenticare i **cappi** nel leggere il grafo, che sono la causa numero uno delle righe che non sommano a 1. Il controllo `np.allclose(P.sum(axis=1), 1)` va scritto sempre, prima di qualunque altro conto (Cap. 18).

28.4 Teoria, Q1 — intervalli di confidenza

(a) Stimatore puntuale. È una statistica $\hat{\theta} = g(X_1, \dots, X_N)$, cioè una funzione (variabile aleatoria) del campione, che fornisce un **singolo valore** come stima del parametro θ : per esempio $\bar{X}_n$ per la media, $\bar{S}_n^2$ per la varianza.

(b) Intervallo di confidenza. Un intervallo di confidenza di livello $1 - \alpha$ è una coppia di statistiche $L(X_1, \dots, X_N) \leq U(X_1, \dots, X_N)$ tali che

$$\mathbb{P}(L \leq \theta \leq U) = 1 - \alpha.$$

Il punto da scrivere subito dopo: è l'**intervallo** (la procedura) a essere casuale, non θ , che è un numero fisso e incognito. Su 100 campioni diversi, circa $(1 - \alpha) \cdot 100$ intervalli conterranno il vero θ ; il singolo intervallo osservato o contiene θ o non lo contiene, e non lo si può sapere.

(c) **Un esempio e la sua rappresentazione grafica.** Il caso più semplice è la media di una popolazione normale con varianza **nota**:

$$I_\mu = \left[\bar{X}_n - \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2} \right],$$

dove $\varphi_{1-\alpha/2} = \varphi_{1-\alpha/2}$ è il quantile della normale standard. Per $\alpha = 0.05$: $\varphi_{0.975} = 1.9600$. Il disegno da fare è la **campana gaussiana centrata su $\bar{X}_n$** , con il segmento orizzontale $[\bar{X}_n \pm 1.96 \sigma / \sqrt{N}]$ che copre il 95% dell'area (Cap. 16).

(d) **Come cambiano gli estremi.** Tutto dipende dalla semilarghezza $\varepsilon_\mu = \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2}$:

```
1 from scipy import stats
2
3 print("alpha    phi_(1-a/2)    t_(1-a/2)(24)")
4 for a in (0.10, 0.05, 0.01):
5     print("%.2f    %.4f    %.4f" % (a, stats.norm.ppf(1-a/2), stats.t.ppf(1-a/2, 24)))
6
7 z90, z95, z99 = (stats.norm.ppf(1-a/2) for a in (0.10, 0.05, 0.01))
8 t90, t95, t99 = (stats.t.ppf(1-a/2, 24) for a in (0.10, 0.05, 0.01))
9 print("95% -> 99%:  normale +%.1f%%    t(24) +%.1f%%" % ((z99/z95-1)*100, (t99/t95-1)*100))
10 print("90% -> 99%:  normale +%.1f%%    t(24) +%.1f%%" % ((z99/z90-1)*100, (t99/t90-1)*100))
```

Output:

```
alpha    phi_(1-a/2)    t_(1-a/2)(24)
0.10     1.6449       1.7109
0.05     1.9600       2.0639
0.01     2.5758       2.7969
95% -> 99%:  normale +31.4%    t(24) +35.5%
90% -> 99%:  normale +56.6%    t(24) +63.5%
```

- N **cresce** $\Rightarrow$ l'intervallo si **restringe** come $1/\sqrt{N}$: quadruplicando N la semilarghezza si dimezza. Più dati, stima più precisa, ma con rendimenti decrescenti.
- σ **cresce** $\Rightarrow$ l'intervallo si **allarga linearmente**: più variabilità nella popolazione significa meno informazione in ogni osservazione.
- α **diminuisce** (più confidenza, per esempio dal 95% al 99%) $\Rightarrow$ il quantile cresce da 1.9600 a 2.5758 e l'intervallo si allarga del **+31.4%**. Con la t di Student a 24 gradi di libertà — il caso in cui σ è stimata dai dati — lo stesso passaggio costa ancora di più: da $t_{0.975}(24) = 2.0639$ a $t_{0.995}(24) = 2.7969$, cioè il **+35.5%**.

Il numero che rende concreta la risposta

La frase “l'intervallo si allarga” vale poco; il numero vale molto. I tre quantili per $\alpha = 0.10, 0.05, 0.01$ sono 1.6449, 1.9600, 2.5758 (normale) e 1.7109, 2.0639, 2.7969 ($t(24)$): citarli dà la misura dello scambio fra confidenza e precisione. Da notare anche che la t è sempre più “caro” della normale (+5.3% a $\alpha = 0.05$, +8.6% a $\alpha = 0.01$), e che il divario si assottiglia al crescere dei gradi di libertà.

28.5 Teoria, Q2 — numeri pseudorandom e Monte Carlo

(a) **Numero pseudorandom.** È un numero prodotto da un **algoritmo deterministico** a partire da un valore iniziale detto *seed*, ma costruito in modo da risultare statisticamente indistinguibile da

un'estrazione casuale uniforme. Il generatore classico del corso è quello delle **congruenze lineari**,

$$X_{n+1} = (aX_n + b) \bmod m, \quad U_n = X_n/m,$$

che partendo da X_0 (il seme) produce una sequenza *periodica*: il **periodo** è il numero di passi dopo il quale la sequenza si ripete (per $a = 3$, $b = 1$, $m = 5$ e $X_0 = 1$ il periodo è appena $T = 4$). Da qui due proprietà da citare: la sequenza è **riproducibile** (stesso seme $\Rightarrow$ stessi numeri, ed è il motivo per cui in questa guida il seme è sempre dichiarato) e la qualità di un generatore si misura sulla lunghezza del periodo — il Mersenne Twister usato da `numpy` ha periodo $2^{19937} - 1$. Da uniformi su $[0, 1]$ si genera tutto il resto: con l'**inversione della funzione di ripartizione** $Y = F^{-1}(U)$, per esempio $Y = -\frac{\log(1-U)}{\lambda} \sim \text{Exp}(\lambda)$, oppure con il metodo del rigetto (Cap. 8).

(b) Metodo Monte Carlo. È una tecnica che stima grandezze *deterministiche* (integrali, probabilità, valori attesi) attraverso **medie di campioni casuali**, seguendo quattro passi: si definisce un dominio di input, si generano numeri casuali nel dominio, si esegue un calcolo deterministico su ciascuno e si aggregano i risultati (media, frequenza). Il fondamento è la legge dei grandi numeri: la media empirica converge al valore atteso, e l'errore va come $1/\sqrt{N}$ (Cap. 5).

(c) Vantaggi e svantaggi.

- **Vantaggi:** è semplicissimo da implementare e facilmente parallelizzabile; l'errore $1/\sqrt{N}$ *non dipende dalla dimensionalità* del problema, mentre il costo delle griglie deterministiche esplode al crescere della dimensione; si applica a funzioni e domini di forma arbitraria.
- **Svantaggi:** la convergenza è **lenta** ($1/\sqrt{N}$: per guadagnare una cifra decimale servono 100 volte i punti); il risultato è affetto da errore statistico, quindi va sempre accompagnato da un errore standard; richiede un generatore di numeri casuali di buona qualità e, per l'hit or miss, un maggiorante M della funzione.

(d) L'hit or miss a parole. Per stimare $I = \int_a^b f(x) dx$ con $f \geq 0$: si **incornicia** il grafico di f nel rettangolo $[a, b] \times [0, M]$, dove $M = \max_{[a, b]} f$; si generano N punti uniformi nel rettangolo e si contano quelli che cadono *sotto* la curva ("hit"). La probabilità che un punto caso sotto la curva è il rapporto fra le aree, $p = \frac{I}{(b-a)M}$, quindi per la legge dei grandi numeri $\hat{p} = \frac{\#hit}{N}$ stima p e

$$\hat{I} = (b-a)M \frac{\#hit}{N}.$$

Il metodo si può usare solo se $f \geq 0$, se l'intervallo e la funzione sono limitati e se si conosce un maggiorante M ; la sua efficienza si misura con p , e la varianza dello stimatore è $\text{Var}(\hat{I}) = \frac{I(A-I)}{N}$ con $A = (b-a)M$ (Cap. 17).

28.6 Cosa portare via da questa prova

1. **Le probabilità da una tabella sono frequenze relative**, e la probabilità di un evento composto da eventi incompatibili è la *somma* delle frequenze (0.54 per "dopo il 5 luglio").
2. **La soglia di una binomiale si calcola con `1 - stats.binom.cdf(...)`**: qui $P(X \geq 32) = 1 - P(X \leq 31) = 0.7841$; `binom.sf(31, 45, 0.75)` dà lo stesso numero, e il complemento è la forma che si scrive nel compito.
3. **Prima di simulare si dice qual è la variabile aleatoria**: "davanti a Giorgino ci sono 22 persone, ognuna presente con probabilità 0.75, quindi le persone da aspettare sono $\text{Bin}(22, 0.75)$, con media 16.5 e scarto 2.0310". Il confronto con la teoria viene da sé (Cap. 13).
4. **Sul grafo delle catene**: righe che sommano a 1, cappi compresi, e vettori *riga* ($\mathbf{v} = \mathbf{v} @ \mathbf{P}$). La stazionarietà si *misura* ($\|v_{20} - v_{19}\|_1 = 0.002$), non si dichiara, e si controlla con π e con $|\lambda_2|^{20}$ (Cap. 18).

5. **La semilarghezza di un intervallo di confidenza** è $\varphi_{1-\alpha/2}\sigma/\sqrt{N}$: cresce linearmente con σ , diminuisce come $1/\sqrt{N}$, e passando dal 95% al 99% cresce del 31.4% (normale) o del 35.5% con $t(24)$.
6. **Per la teoria** servono due definizioni pulite: numero pseudorandom (deterministico ma statisticamente indistinguibile dal casuale, con seme e periodo) e metodo Monte Carlo (media di campioni per stimare una quantità deterministica, errore $1/\sqrt{N}$).

Appendici

Appendice A

Formulario

Come usare questo formulario

È pensato per la consultazione dell'ultimo minuto: ogni formula è scritta nella **notazione degli appunti del corso**, non in quella di un libro di testo qualsiasi. In particolare, tenete presente che qui

- la retta di regressione è $y = \beta_0 + \beta_1 x$ (non $\alpha + \beta x$);
- il coefficiente di correlazione si chiama ρ (non r);
- il coefficiente di determinazione si chiama $R = \rho^2$ (non R^2);
- $\bar{\sigma}_x^2$ è la *varianza empirica* (divisore n) e $\bar{S}_n^2$ la *varianza campionaria* (divisore $n - 1$);
- il quantile di ordine α è $q_\alpha = \sup\{r \in \mathbb{R} : F_X(r) = \alpha\}$; per la normale si scrive φ_α , per la t di Student t_α .

I riferimenti incrociati rimandano ai capitoli di teoria, dove ogni voce è spiegata e dimostrata.

A.1 Probabilità

Assiomi di Kolmogorov

Uno **spazio di probabilità** è una terna $(\Omega, \mathcal{A}, \mathbb{P})$ con Ω spazio campionario, $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ una σ -algebra di eventi e $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ una misura con

$$\mathbb{P}(\Omega) = 1, \quad \mathbb{P}\left(\bigcup_i A_i\right) = \sum_i \mathbb{P}(A_i) \quad \text{se } A_i \cap A_j = \emptyset \quad \forall i \neq j.$$

Da qui si dimostrano:

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \quad A \subseteq B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B), \quad \mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B),$$

e in generale la formula di inclusione-esclusione:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_i \mathbb{P}(A_i) - \sum_{i < j} \mathbb{P}(A_i \cap A_j) + \sum_{i < j < k} \mathbb{P}(A_i \cap A_j \cap A_k) - \dots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^n A_i\right).$$

Probabilità condizionata, indipendenza

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (\mathbb{P}(B) > 0),$$

$$A, B \text{ indipendenti} \iff \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \iff \mathbb{P}(A \mid B) = \mathbb{P}(A).$$

Indipendenti $\neq$ incompatibili

$A \cap B = \emptyset$ dà $\mathbb{P}(A \cap B) = 0$, che è uguale a $\mathbb{P}(A)\mathbb{P}(B)$ solo se uno dei due ha probabilità nulla. Due eventi incompatibili con probabilità positiva sono quindi *dependenti*. Tre eventi sono **a due a due indipendenti** se il prodotto vale per tutte le coppie; formano una **famiglia di**

eventi indipendenti se vale anche il prodotto delle tre probabilità,

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

Le due condizioni *non* sono equivalenti.

Probabilità totali e Bayes

Se $A_1, \dots, A_n$ è una **partizione** di Ω (unione Ω , a due a due incompatibili, $\mathbb{P}(A_i) > 0$):

$$\mathbb{P}(B) = \sum_{i=1}^n \mathbb{P}(B | A_i) \mathbb{P}(A_i)$$

$$\mathbb{P}(A_i | B) = \frac{\mathbb{P}(B | A_i) \mathbb{P}(A_i)}{\sum_j \mathbb{P}(B | A_j) \mathbb{P}(A_j)}$$

La seconda è il **teorema di Bayes**; il denominatore è $\mathbb{P}(B)$ calcolato con le probabilità totali.

Calcolo combinatorio

Tipo	Numero	Quando
r -disposizioni	n^r	r elementi ordinati da n , con ripetizione
r -disposizioni semplici	$D_{n,r} = \frac{n!}{(n-r)!}$	ordinati, senza ripetizione
r -combinazioni	$\binom{n+r-1}{r}$	non ordinati, con ripetizione
r -combinazioni semplici	$C_{n,r} = \binom{n}{r} = \frac{n!}{r!(n-r)!}$	non ordinati, senza ripetizione

Permutazioni: $D_{n,n} = n!$. Partizioni in gruppi di taglia $n_1, \dots, n_k$: $C_{n_1, \dots, n_k}^n = \frac{n!}{n_1! \dots n_k!}$.

A.2 Variabili aleatorie

Definizioni

$X : \Omega \rightarrow \mathbb{R}$ è una v.a. se $\{X \leq t\} \in \mathcal{A}$ per ogni $t \in \mathbb{R}$. X è **discreta** se $X(\Omega)$ è finito o numerabile, **continua** se ammette densità f con $F_X(t) = \int_{-\infty}^t f(x) dx$.

	discreta	continua
densità	$p(x) = \mathbb{P}(X = x)$	$f(x) = F'_X(x)$
condizioni	$p(x) \geq 0, \sum_x p(x) = 1$	$f(x) \geq 0, \int_{\mathbb{R}} f(x) dx = 1$
f. di ripartizione	$F_X(t) = \sum_{x \leq t} p(x)$	$F_X(t) = \int_{-\infty}^t f(x) dx$
$\mathbb{P}(a \leq X \leq b)$	$\sum_{a \leq x \leq b} p(x)$	$F_X(b) - F_X(a)$

Proprietà di F_X : $0 \leq F_X \leq 1$, non decrescente, continua a destra, $F_X(-\infty) = 0$, $F_X(+\infty) = 1$; nel continuo $\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X < b)$ perché $\mathbb{P}(X = t) = 0$. Per una v.a. discreta $\mathbb{P}(X = t) = F_X(t^+) - F_X(t^-)$.

Quantile

$$q_\alpha = \sup\{r \in \mathbb{R} : F_X(r) = \alpha\}, \quad \text{equivalentemente } F_X(q_\alpha) = \alpha.$$

φ_α è il quantile della normale standard, t_α quello della t di Student: entrambe le distribuzioni sono simmetriche, quindi $\varphi_\alpha = -\varphi_{1-\alpha}$ e $t_\alpha = -t_{1-\alpha}$. La χ^2 invece *non* è simmetrica.

Momenti, media, varianza

$$\mathbb{E}[X] = \sum_i x_i p(x_i) \quad \text{oppure} \quad \int_{\mathbb{R}} x f(x) dx, \quad \mathbb{E}[X^k] = \sum_i x_i^k p(x_i) \quad \text{oppure} \quad \int_{\mathbb{R}} x^k f(x) dx,$$

$$\mathbb{E}[(X - \mathbb{E}[X])^k] \quad \text{momento centrato di ordine } k,$$

$$\sigma_X^2 = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2, \quad \sigma_X = \sqrt{\sigma_X^2}.$$

Proprietà: $\mathbb{E}[cX] = c \mathbb{E}[X]$, $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$, $\text{Var}(aX) = a^2 \text{Var}(X)$, $\text{Var}(a + X) = \text{Var}(X)$. Per la varianza di una somma serve l'indipendenza:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y], \\ \text{Var}(X + Y) &= \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y). \end{aligned}$$

Il coefficiente di correlazione lineare è

$$\rho = \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \in [-1, 1],$$

con $|\rho| \leq 0.3$ correlazione debole, $0.3 < |\rho| \leq 0.7$ moderata, $0.7 < |\rho| \leq 1$ forte. **Correlazione non implica causalità.**

A.3 Distribuzioni notevoli discrete

Distribuzione	Densità discreta $p(x)$	$\mathbb{E}[X]$	$\text{Var}(X)$	scipy.stats
Ber(p)	p se $x = 1$, $1 - p$ se $x = 0$	p	$p(1 - p)$	binom(1, p)
Bin(n, p)	$\binom{n}{x} p^x (1 - p)^{n-x}$, $x = 0, \dots, n$	np	$np(1 - p)$	binom(n, p)
Pois(λ)	$\frac{\lambda^x}{x!} e^{-\lambda}$, $x = 0, 1, 2, \dots$	λ	λ	poisson(λ)
Geom(p)	$p(1 - p)^{x-1}$, $x = 1, 2, \dots$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$	geom(p)
Iper(b, r, n)	$\frac{\binom{b}{x} \binom{r}{n-x}}{\binom{b+r}{n}}$, $x = 0, \dots, n$	$n \frac{b}{b+r}$	$\frac{nbr}{(b+r)^2} \cdot \frac{b+r-n}{b+r-1}$	hypergeom($b+r, b, n$)
$\mathcal{U}\{1, \dots, n\}$	$\frac{1}{n}$, $x = 1, \dots, n$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$	randint(1, $n+1$)

Promemoria sulle convenzioni

- Bin(n, p): n prove *indipendenti*, stessa p , X = numero di successi. Ber(p) è il caso $n = 1$; $X \sim \text{Bin}(n, p)$ si scrive come $\sum_{i=1}^n X_i$ con $X_i \sim \text{Ber}(p)$ indipendenti.

- $\text{Pois}(\lambda)$ approssima $\text{Bin}(n, p)$ per $n \gg 1$, $p \ll 1$, con $\lambda = np$. Se $X \sim \text{Pois}(\lambda)$ e $Y \sim \text{Pois}(\mu)$ indipendenti, $X + Y \sim \text{Pois}(\lambda + \mu)$.
- $\text{Geom}(p)$ conta il **numero di prove fino al primo successo** (supporto $1, 2, \dots$: la densità *non* è definita in $x = 0$). Legame con la binomiale: $\mathbb{P}(T > n) = \mathbb{P}(X(n) = 0) = (1 - p)^n$ con $X(n) \sim \text{Bin}(n, p)$, da cui $\mathbb{P}(T = n) = p(1 - p)^{n-1}$.
- Iper: estrazioni **senza reinserimento**. b oggetti con la proprietà, r senza, $b + r$ totali, se ne estraggono n . Attenzione: nell'ordine dei parametri di `scipy` il primo è la *popolazione totale*.
- Geom ed Exp sono le uniche due distribuzioni notevoli **senza memoria**.

A.4 Distribuzioni notevoli continue

Distribuzione	Densità $f(x)$	$\mathbb{E}[X]$	$\text{Var}(X)$	<code>scipy.stats</code>
$\mathcal{U}([a, b])$	$\frac{1}{b-a}$ su $[a, b]$, 0 altrove	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	<code>uniform(a, b-a)</code>
$\text{Exp}(\lambda)$	$\lambda e^{-\lambda x}$, $x > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	<code>expon(1/λ)</code>
$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2	<code>norm(μ, σ)</code>
$\chi^2(n)$	$\frac{x^{\frac{n}{2}-1} e^{-x/2}}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})}$, $x > 0$	n	$2n$	<code>chi2(n)</code>
$T(n)$	$A_0 \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$	0	$\frac{n}{n-2}$	<code>t(n)</code>

Funzioni di ripartizione e sopravvivenza

$$\mathcal{U}([a, b]): \quad F_X(t) = \frac{t-a}{b-a} \quad (t \in [a, b]); \quad \text{Exp}(\lambda): \quad F_X(t) = 1 - e^{-\lambda t} \quad (t > 0).$$

Per l'esponenziale si usa spesso la **funzione di sopravvivenza**

$$S(t) = 1 - F_X(t) = e^{-\lambda t} = \mathbb{P}(X > t).$$

Per la normale standard $F = \Phi$, e per $Y \sim N(\mu, \sigma^2)$ vale la **standardizzazione** $Z = \frac{Y - \mu}{\sigma} \sim N(0, 1)$, ossia

$$Y = \sigma Z + \mu, \quad q_\alpha = \sigma \varphi_\alpha + \mu.$$

Quantili e valori che tornano sempre

	normale	t di Student, $n - 1$ gradi
$1 - \alpha = 0.90$	$\varphi_{0.95} = 1.6449$	$t_{0.95}(24) = 1.7109$
$1 - \alpha = 0.95$	$\varphi_{0.975} = 1.9600$	$t_{0.975}(24) = 2.0639$
$1 - \alpha = 0.99$	$\varphi_{0.995} = 2.5758$	$t_{0.995}(24) = 2.7969$

Legge dei tre sigma: per una normale $f(x) \approx 0$ quando $|x - \mu| > 3\sigma$. **Somma:** se $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ sono indipendenti, $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. **Proprietà χ^2 :** $Z \sim N(0, 1) \Rightarrow Z^2 \sim \chi^2(1)$; $X_1, \dots, X_n \sim N(0, 1)$ indipendenti $\Rightarrow \sum_i X_i^2 \sim \chi^2(n)$; $\chi^2(n) + \chi^2(m) \sim \chi^2(n + m)$. **t di Student:** per $n \rightarrow \infty$ $T(n) \rightarrow N(0, 1)$, e già per $n > 30$ la differenza è trascurabile.

Assenza di memoria

$$\text{Geom}(p) : \mathbb{P}(T = m + n \mid T > n) = \mathbb{P}(T = m),$$

$$\text{Exp}(\lambda) : \mathbb{P}(X \geq x + t \mid X \geq x) = S(t) = e^{-\lambda t}.$$

Non serve ricalcolare nulla: il tempo già trascorso non cambia la distribuzione del tempo rimanente. È la proprietà che l'esame del 24/03/25 chiedeva di dimostrare per la geometrica.

A.5 Legge dei grandi numeri e teorema del limite centrale**Le disuguaglianze**

$$\text{Markov: } \mathbb{P}(X \geq \alpha) \leq \frac{\mathbb{E}[X]}{\alpha} \quad (X \geq 0, \alpha > 0), \quad \text{Čebyšëv: } \mathbb{P}(|X - \mathbb{E}[X]| \geq \eta) \leq \frac{\text{Var}(X)}{\eta^2}.$$

Media campionaria e legge dei grandi numeri

Per $X_1, \dots, X_n$ indipendenti e identicamente distribuite con media μ e varianza σ^2 , la **media campionaria** è

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad \mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{errore standard} = \frac{\sigma}{\sqrt{n}}.$$

Legge dei grandi numeri (debole): per ogni $\eta > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \eta) = 0, \quad \text{cioè} \quad \bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

Dimostrazione in due righe: per Čebyšëv applicata a $\bar{X}_n$, $\mathbb{P}(|\bar{X}_n - \mu| \geq \eta) \leq \frac{\text{Var}(\bar{X}_n)}{\eta^2} = \frac{\sigma^2}{\eta^2 n} \rightarrow 0$.

Che cosa dice e che cosa *non* dice

Dice che, prendendo molte istanze di un fenomeno di distribuzione ignota, la media dei valori osservati si avvicina alla media teorica μ : è ciò che giustifica la definizione frequentista di probabilità e tutte le simulazioni. *Non* dice che $\bar{X}_n$ diventa *esattamente* uguale a μ : per ogni n finito c'è probabilità positiva di uno scostamento. È la differenza tra “converge in probabilità” e “è uguale”.

Teorema del limite centrale

$$S_n = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1),$$

cioè per n grande $\bar{X}_n \approx N(\mu, \frac{\sigma^2}{n})$, *qualunque* sia la distribuzione delle X_i .

Quando valgono, in pratica

Sia la legge dei grandi numeri sia il TLC sono giustificati se $n \geq 30$; nel caso di distribuzioni binomiali se $np \geq 5$ e $n(1-p) \geq 5$. L'errore degli stimatori Monte Carlo va come $1/\sqrt{N}$: per *dimezzare* l'errore servono *quattro volte* le simulazioni, per guadagnare una cifra decimale cento volte tante.

La correzione di continuità

Quando si approssima una **binomiale** (o una Poisson) con la normale, la variabile è discreta e la normale è continua: per il calcolo di $\mathbb{P}(X \leq k)$ conviene usare $\mathbb{P}(X \leq k + 0.5)$ e per $\mathbb{P}(X \geq k)$ usare $\mathbb{P}(X \geq k - 0.5)$. È la **correzione di continuità** di mezzo punto, e migliora l'approssimazione. Nei test sulla proporzione l'esame non la richiede, ma citarla mostra di sapere *perché* l'approssimazione non è esatta.

A.6 Statistica descrittiva

Dati N valori, di cui n distinti $x_1, \dots, x_n$ con frequenze assolute f_i :

Quantità	Formula
frequenza assoluta f_i	molteplicità del valore x_i ; $\sum_i f_i = N$
frequenza relativa p_i	$p_i = \frac{f_i}{N}$; $\sum_i p_i = 1$
frequenza relativa cumulata F_i	$F_i = \sum_{k \leq i} p_k$ (approssimazione costante a tratti della f. di ripartizione)
media aritmetica	$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{N} \sum_{i=1}^n x_i f_i = \sum_{i=1}^n p_i x_i$
moda	il valore più frequente (unimodale / multimodale)
mediana m_e	valore che divide i dati in due gruppi di uguale numerosità; se N è pari, media dei due centrali. Minimizza $S(a) = \sum_i x_i - a $
quantili di ordine k	i $k - 1$ valori che dividono i dati in k gruppi di uguale numerosità
varianza empirica $\bar{\sigma}_x^2$	$\bar{\sigma}_x^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2 f_i = \sum_i (x_i - \bar{x})^2 p_i$
scarto empirico $\bar{\sigma}_x$	$\bar{\sigma}_x = \sqrt{\bar{\sigma}_x^2}$
momento empirico centrato μ_r	$\mu_r = \frac{1}{N} \sum_i (x_i - \bar{x})^r f_i$ ($\mu_2 = \bar{\sigma}_x^2$)
asimmetria γ_1	$\gamma_1 = \frac{\mu_3}{\mu_2^{3/2}}$: > 0 asimmetria a destra, < 0 a sinistra, $= 0$ per la normale
curtosi β_2	$\beta_2 = \frac{\mu_4}{\mu_2^2}$, e $\gamma = \beta_2 - 3$: $\gamma = 0$ normocurtica, < 0 platicurtica, > 0 leptocurtica

Empirica contro campionaria

$$\bar{\sigma}_x^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

|—————{Z—————}|
empirica, divisore N

$$\bar{S}_n^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

|—————{Z—————}|
campionaria, divisore $N-1$

La prima è un indice *descrittivo* del campione; la seconda è lo *stimatore non distorto* di σ^2 . Differiscono del fattore $\frac{N-1}{N}$, trascurabile per N grande. È l'errore più frequente del capitolo, sia a mano sia in Python (**ddof**).

A.7 Stimatori

Un **campione** di rango n è una n -upla $(X_1, \dots, X_n)$ di variabili indipendenti con la stessa distribuzione. Una **statistica** è una funzione del campione; uno **stimatore puntuale** di θ è una statistica $\hat{\theta}$ a valori nell'immagine di θ . È **non distorto** se

$$\mathbb{E}[\hat{\theta}] = \theta.$$

Parametro	Stimatore	Media e varianza
media μ	$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$	$\mathbb{E}[\bar{X}_n] = \mu, \text{ Var}(\bar{X}_n) = \frac{\sigma^2}{n}$
varianza σ^2 , μ nota	$\bar{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$	$\mathbb{E}[\bar{\sigma}_n^2] = \sigma^2$: non distorto
varianza σ^2 , μ non nota	$\bar{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$	$\mathbb{E}[\bar{S}_n^2] = \sigma^2$: non distorto
varianza σ^2 , μ non nota, divisore n	$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$	$\mathbb{E}[S^2] = \frac{n-1}{n} \sigma^2$: distorto , sottostima
proporzione p	$\hat{p} = \bar{X}_n$ (media di Bernoulli)	$\mathbb{E}[\hat{p}] = p, \text{ Var}(\hat{p}) = \frac{p(1-p)}{n}$

Il filo da tenere a mente

Con μ nota si divide per n ; con μ non nota si divide per $n-1$. Il “prezzo” della stima di μ è un **grado di libertà**: gli n scarti $X_i - \bar{X}_n$ hanno somma nulla, quindi noti $n-1$ di essi l'ultimo è determinato. Per una dimostrazione per esteso si veda il Capitolo 6.

Errore quadratico medio: $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{bias}(\hat{\theta})^2$; per uno stimatore non distorto $\text{MSE} = \text{Var}$.

A.8 Intervalli di confidenza

$[I_1, I_2]$ è un intervallo di confidenza di livello $1-\alpha$ per θ se $\mathbb{P}(I_1 \leq \theta \leq I_2) = 1-\alpha$. L'interpretazione è *del procedimento*: il 95% dei campioni produce un intervallo che contiene θ .

Caso	Intervallo di livello $1-\alpha$
media, σ^2 nota	$I_\mu = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}} \varphi_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{n}} \varphi_{1-\alpha/2} \right]$, variabile ausiliaria $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
media, σ^2 non nota	$I_\mu^{\bar{S}_n^2} = \left[\bar{X}_n - \frac{\bar{S}_n^2}{\sqrt{n}} t_{1-\alpha/2}, \bar{X}_n + \frac{\bar{S}_n^2}{\sqrt{n}} t_{1-\alpha/2} \right]$, variabile ausiliaria $T_n = \frac{\bar{X}_n - \mu}{\bar{S}_n^2/\sqrt{n}} \sim t(n-1)$
varianza σ^2 (μ non nota)	$I_{\sigma^2} = \left[\frac{\bar{S}_n^2(n-1)}{\chi_{1-\alpha/2}^2(n-1)}, \frac{\bar{S}_n^2(n-1)}{\chi_{\alpha/2}^2(n-1)} \right]$, variabile ausiliaria $W_n = \frac{\bar{S}_n^2}{\sigma^2}(n-1) \sim \chi^2(n-1)$
proporzione (n grande)	$I_p = \left[\hat{p} - \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \varphi_{1-\alpha/2}, \hat{p} + \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \varphi_{1-\alpha/2} \right]$

Le tre trappole di questa tabella

1. Nei primi due intervalli la semilarghezza si chiama **margin** di errore ε e l'intervallo è *simmetrico* rispetto a $\bar{X}_n$. Nel terzo **no**: la χ^2 non è simmetrica.
2. Nel terzo intervallo il quantile di destra $\chi^2_{1-\alpha/2}$ sta al **denominatore dell'estremo sinistro**: non è un refuso, l'inversione della disuguaglianza scambia le code. È l'errore più frequente su questo intervallo.
3. Nell'intervallo per σ^2 serve un campione **strettamente gaussiano**: è l'unica delle quattro variabili ausiliarie che non si giustifica con il TLC.

Come cambiano gli estremi

Con $\varepsilon = \varphi_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$: se N cresce l'ampiezza diminuisce come $1/\sqrt{N}$ (per dimezzarla servono quattro volte i dati); se σ cresce l'ampiezza cresce *linearmente*; se α diminuisce (più confidenza) $\varphi_{1-\alpha/2}$ cresce e l'ampiezza aumenta. Numero minimo di dati per un margine E : $n \geq (\varphi_{1-\alpha/2} \sigma / E)^2$.

A.9 Test d'ipotesi

Si fissa $H_0 : \theta = \theta_0$, l'alternativa H_1 e il livello α ; si calcola una variabile ausiliaria Z_n , T_n o W_n la cui distribuzione sotto H_0 è nota, e si rigetta H_0 se la statistica cade nella zona di rigetto CR .

	bilatero	unilaterale sinistro	unilaterale destro
	$H_1 : \theta \neq \theta_0$	$H_1 : \theta < \theta_0$	$H_1 : \theta > \theta_0$
Zona di rigetto	$ Z_n > \varphi_{1-\alpha/2}$	$Z_n < \varphi_\alpha$	$Z_n > \varphi_{1-\alpha}$
p -value (con Φ)	$2(1 - \Phi(Z_n))$	$\Phi(Z_n)$	$1 - \Phi(Z_n)$

Per il t -test le zone di rigetto sono le stesse con t al posto di φ e $n - 1$ gradi di libertà; per il p -value si sostituisce Φ con la funzione di ripartizione della $t(n - 1)$ (in Python `stats.t.cdf`, `stats.t.sf`).

Situazione	Variabile ausiliaria sotto H_0	Distribuzione
Media, σ^2 nota	$Z_n = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$	$N(0, 1)$
Media, σ^2 non nota	$T_n = \frac{\bar{X}_n - \mu_0}{\bar{S}_n^2/\sqrt{n}}$	$t(n-1)$
Proporzione, n grande	$Z_n = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	$N(0, 1)$
Proporzione, n piccolo o test esatto	$X \sim \text{Bin}(n, p_0)$ sotto H_0	binomiale esatta
Due popolazioni indipendenti, varianze note	$Z_n = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}}$	$N(0, 1)$
Popolazioni accoppiate ($D_i = X_i - Y_i$)	$T_n = \frac{\bar{D}_n}{\bar{S}_n^2/\sqrt{n}}, H_0: \mu_D = 0$	$t(n-1)$
Varianza	$W_n = \frac{\bar{S}_n^2(n-1)}{\sigma_0^2}$	$\chi^2(n-1)$
Multinomiale, test di Pearson	$W_n = n \sum_{k=1}^m \frac{(\hat{p}_k - p_k^0)^2}{p_k^0}$	$\chi^2(m-1)$

L'asimmetria tra H_0 e H_1

Se si rigetta H_0 si può affermare H_1 . Se **non** si rigetta, il test è **inconcludente**: non si può dire né che H_1 è vera né che è falsa, e *mai* che H_0 è vera. La forma corretta è: “*non c'è evidenza sufficiente, al livello α , per rifiutare H_0* ”. Il p -value è il più piccolo valore di α per cui si rigetta H_0 (dunque si rigetta se $p < \alpha$), e **non** è la probabilità che H_0 sia vera.

A.10 Regressione lineare

Modello: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, con residui $d_i = y_i - \hat{y}_i$ e funzione da minimizzare

$$S^2(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Annullando le derivate parziali si ottiene il **metodo dei minimi quadrati**:

$$\hat{\beta}_1 = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

dove le quantità empiriche sono

$$\bar{x} = \frac{1}{n} \sum_i x_i, \quad \bar{y} = \frac{1}{n} \sum_i y_i, \quad \bar{\sigma}_{xy} = \frac{1}{n} \sum_i x_i y_i - \bar{x} \bar{y}, \quad \bar{\sigma}_x^2 = \frac{1}{n} \sum_i x_i^2 - \bar{x}^2, \quad \bar{\sigma}_y^2 = \frac{1}{n} \sum_i y_i^2 - \bar{y}^2.$$

La retta passa **sempre** per il baricentro $(\bar{x}, \bar{y})$.

$$\rho = \frac{\bar{\sigma}_{xy}}{\bar{\sigma}_x \bar{\sigma}_y} = \frac{\sum_i x_i y_i - \bar{x} \bar{y}}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}, \quad -1 \leq \rho \leq 1, \quad R = \rho^2 = \frac{\bar{\sigma}_{xy}^2}{\bar{\sigma}_x^2 \bar{\sigma}_y^2}.$$

Che cosa significano i tre numeri

$\hat{\beta}_1$ è di quanto cambia y per un'unità in più di x ; $\hat{\beta}_0$ è il valore previsto per $x = 0$ (spesso è un'**estrapolazione**, da commentare come intercetta matematica). ρ misura la *forza* del

legame lineare ed è simmetrico; $R = \rho^2$ è la frazione di variabilità di y **spiegata** dalla retta, e vale $0 \leq R \leq 1$. Le previsioni sono affidabili solo *dentro* l'intervallo degli x osservati.

A.11 Monte Carlo e numeri pseudorandom

Generatori

Un **numero pseudorandom** è prodotto da una sequenza deterministica a partire da un **seme** (*seed*): stesso seme $\Rightarrow$ stessa sequenza (riproducibilità), e le proprietà statistiche imitano quelle di variabili uniformi indipendenti su $(0, 1)$. Il generatore didattico è quello a **congruenze lineari**

$$X_{n+1} = (aX_n + b) \bmod m, \quad U_n = \frac{X_n}{m} \in [0, 1),$$

con *modulo* m , *moltiplicatore* a , *incremento* b , seme X_0 . Il **periodo** è il più piccolo T con $X_{n+T} = X_n$; il generatore in uso in `np.random` è il **Mersenne Twister**, con periodo $2^{19937} - 1$.

Inversione e rigetto

Metodo dell'inversione: se $U \sim \mathcal{U}([0, 1])$ e F è invertibile, allora $Y = F^{-1}(U)$ ha funzione di ripartizione F . Casi espliciti:

$$\mathcal{U}([a, b]) : Y = a + (b - a)U, \quad \text{Exp}(\lambda) : Y = -\frac{\log(1 - U)}{\lambda} = -\frac{\log U}{\lambda}.$$

Metodo del rigetto per una densità f su $[a, b]$ con $M = \max_{[a, b]} f$: si genera (ξ, η) con $\xi \sim \mathcal{U}([a, b])$ e $\eta \sim \mathcal{U}([0, M])$; se $0 \leq \eta \leq f(\xi)$ si accetta $X = \xi$, altrimenti si ripete. Allora $\mathbb{P}(X \leq t) = \int_{-\infty}^t f(x) dx$.

Hit or miss

Per $I = \int_a^b f(x) dx$ con $f \geq 0$ continua su $[a, b]$, sia $M = \max_{[a, b]} f$ e $R = [a, b] \times [0, M]$. Detto N il numero di coppie estratte in R e N_s quelle “andate a segno” ($\eta \leq f(\xi)$):

$$p = \frac{I}{(b-a)M} \approx \frac{N_s}{N} \quad \Rightarrow \quad \boxed{I \approx \frac{N_s}{N}(b-a)M}$$

Lo stimatore $\hat{p} = N_s/N$ è una media di N Bernoulli di parametro p , quindi è **non distorto** e

$$\mathbb{E}[\hat{p}] = p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{N}, \quad \text{errore standard} = \sqrt{\frac{p(1-p)}{N}}.$$

Per f non limitata in modo comodo si usa lo stimatore alternativo $\hat{I} = (b-a)\overline{f(X_1), \dots, f(X_N)}$ con $X_i \sim \mathcal{U}([a, b])$, che ha varianza minore.

Monte Carlo in quattro passi

1. definire il dominio di input;
2. generare numeri random nel dominio;
3. eseguire un calcolo deterministico;
4. aggregare i risultati.

Vantaggi: generalità (nessuna primitiva, qualunque dimensione), semplicità, errore $1/\sqrt{N}$

indipendente dalla dimensione, errore stimabile dai dati. **Svantaggi:** convergenza lenta ($1/\sqrt{N}$), errore mai certezza, dipendenza dalla qualità del generatore, costo elevato per alta precisione.

A.12 Catene di Markov

Un **processo stocastico** è una famiglia di variabili aleatorie $\{X_t\}_{t \in T}$ sullo stesso spazio di probabilità, indicizzate da un parametro temporale t (discreto o continuo); i valori assunti formano lo **spazio degli stati**. Un processo a tempo discreto e stati discreti è una **catena di Markov** se vale la **proprietà di Markov**

$$\mathbb{P}(X_{t+1} = j \mid X_t = i, X_{t-1} = i_{t-1}, \dots, X_1 = i_1) = \mathbb{P}(X_{t+1} = j \mid X_t = i) = p_{ij}(t),$$

e la catena si dice **omogenea** se $p_{ij}(t) \equiv p_{ij}$ non dipende da t . A parole: *il futuro dipende dal presente, e solo dal presente*.

Matrice di transizione

$P = (p_{ij})$ con $i, j \in E$, dove p_{ij} è la probabilità di passare da i a j in un passo. Proprietà caratterizzanti:

$$p_{ij} \geq 0 \quad \forall i, j \in E, \quad \sum_{j \in E} p_{ij} = 1 \quad \forall i \in E.$$

Sono le **righe** a sommare a 1, non le colonne: la riga i elenca dove si può andare partendo da i .

Legge del processo e m passi

Detta $\pi^{(t)}$ la legge di X_t e $\pi^{(0)}$ la distribuzione iniziale,

$$\pi^{(t)} = \pi^{(0)} P^t, \quad \text{cioè} \quad \mathbb{P}(X_t = j) = \sum_{i \in E} \pi_i^{(0)} p_{ij}^{(t)},$$

dove $p_{ij}^{(t)} = \mathbb{P}(X_t = j \mid X_0 = i)$. Per il **teorema di Chapman–Kolmogorov** la matrice a m passi è

$$P^{(m)} = P^m \quad (\text{prodotto riga per colonna}).$$

Classificazione degli stati

Nozione	Definizione
i comunica con j ($i \rightarrow j$)	$\exists m > 0$ t.c. $p_{ij}^{(m)} > 0$. La relazione è transitiva ma <i>non</i> simmetrica
classe chiusa $C \subseteq E$	gli stati di C non comunicano con quelli di $E \setminus C$, cioè $\sum_{j \in C} p_{ij} = 1$ per ogni $i \in C$
classe irriducibile	una classe chiusa i cui stati comunicano tutti tra loro
catena irriducibile	tutti gli stati comunicano: $i \leftrightarrow j$ per ogni $i, j \in E$ (l'unica classe chiusa è E stesso)
stato assorbente	$p_{ii} = 1$: la classe chiusa $\{i\}$ ha un solo stato
stato ricorrente	la probabilità di ritornarci prima o poi è 1
stato transitorio	non ricorrente
catena regolare	$\exists m$ t.c. $p_{ij}^{(m)} > 0$ per ogni i, j

In una catena **finita**: i è transitorio se e solo se $i \rightarrow j$ ma $j \not\rightarrow i$; se la catena è irriducibile gli stati sono tutti transitori o tutti ricorrenti, e se è finita sono tutti ricorrenti. Criterio di regolarità: se E è finito e la catena è irriducibile, condizione sufficiente perché P sia regolare è che esista $h \in E$ con $p_{hh} > 0$.

Distribuzione stazionaria

$\pi = (\pi_1, \dots, \pi_n)$ è **stazionaria** se

$$\boxed{\pi = \pi P} \quad \text{cioè} \quad \pi_j = \sum_{i \in E} \pi_i p_{ij} \quad \forall j, \quad \text{con} \quad \sum_{i \in E} \pi_i = 1, \quad \pi_i \geq 0.$$

Una distribuzione stazionaria è un **autovettore sinistro** di P con autovalore 1. π è **reversibile** se $\pi_i p_{ij} = \pi_j p_{ji}$ per ogni i, j : se è reversibile allora è stazionaria.

I tre teoremi da citare

- **Markov–Kakutani**: se E è finito, esiste almeno una distribuzione stazionaria.
- **Markov**: se P è regolare e E è finito, la distribuzione stazionaria è *unica* e $\pi_j = \lim_{t \rightarrow \infty} p_{ij}^{(t)}$ per ogni j (il limite non dipende dallo stato di partenza).
- **Convergenza**: se la catena è irriducibile e *aperiodica*, $\pi^{(t)} \rightarrow \pi$ per *qualunque* distribuzione iniziale. Se la catena è periodica, π esiste ma $\pi^{(t)}$ *oscilla* e non converge.

La presenza di più classi chiuse dà *più* distribuzioni stazionarie: uno stato assorbente ne produce una concentrata su di esso.

Esercizio tipo: classi chiuse da una matrice simbolica

Il 28/01/25 la matrice di transizione è data solo come pattern di $\times$ (elemento > 0) e $-$ (elemento $= 0$). Poiché ogni riga deve sommare a 1, una riga con un solo $\times$ ha quell'elemento uguale a 1: è il caso dello stato 1, che risulta **assorbente**. Il procedimento è sempre lo stesso:

1. disegnare le frecce uscenti da ogni nodo e verificarne la somma;
2. raggruppare i nodi che si raggiungono a vicenda (classi di comunicazione);
3. se da un gruppo non si esce, il gruppo è **chiuso**;
4. se esiste più di una classe, o una classe chiusa propria, la catena **non** è irriducibile.

Appendice B

Guida rapida: quale funzione chiamo?

A che cosa serve questa appendice

All'esame la domanda non è “come si chiama questa distribuzione?” ma “*mi serve un quantile, un p-value, una simulazione: che riga scrivo?*”. Questa appendice risponde a quella domanda. Per ogni funzione: una riga di firma, una riga di spiegazione, un mini-esempio. Tutto il codice è stato eseguito con **numpy** 2.5.3, **scipy** 1.18.1 e **matplotlib** 3.11.2, e gli output mostrati sono quelli realmente prodotti. Le spiegazioni per esteso, con il *perché*, sono nella Parte II (Capitoli 11–18).

B.1 Le tre righe di partenza

```
1 import numpy as np           # array, numeri casuali, medie
2 from scipy import stats      # distribuzioni, test, regressione
3 import matplotlib.pyplot as plt # grafici
```

Libreria	Cosa ci si fa
numpy	Generare numeri casuali, operare su interi vettori in una riga, calcolare medie, somme, prodotti scalari.
scipy.stats	Tutte le distribuzioni notevoli (norm, t, binom, poisson, expon, geom, hypergeom, chi2), i quantili, i <i>p</i> -value, la regressione.
matplotlib.pyplot	Istogrammi, diagrammi a barre, scatter plot, curve, Q-Q plot.

B.2 Generare numeri casuali: **np.random**

Il generatore

```
1 rng = np.random.default_rng(42)    # il seme: stesso seme -> stessa sequenza
```

`default_rng(seme)` restituisce un **generatore**: tutte le estrazioni si fanno chiamando i suoi metodi, e non più le funzioni globali `np.random.*`.

Il seme va messo, e va detto perché

`default_rng(42)` non rende i numeri “più casuali”: li rende **riproducibili**. Con lo stesso seme il compito produce sempre lo stesso output, quindi il correttore può rieseguirlo e voi potete confrontare due simulazioni. È il punto (2) della definizione di numero pseudorandom.

```
1 import numpy as np
2 np.set_printoptions(precision=4, suppress=True) # output più leggibili
3
4 print(np.random.default_rng(42).random(3))
5 print(np.random.default_rng(42).random(3))    # identico al precedente
```

```
[0.774  0.4389 0.8586]
[0.774  0.4389 0.8586]
```

(`set_printoptions` non cambia i numeri, cambia solo come vengono stampati: in un compito un array di 7 cifre per elemento è illeggibile.)

I metodi che servono

Chiamata	Cosa restituisce	Quesito tipico
<code>rng.random(size)</code>	n uniformi in $[0, 1)$	hit or miss, inversione
<code>rng.uniform(a, b, size)</code>	n uniformi in $[a, b)$	punto a caso in un rettangolo
<code>rng.normal(loc, scale, size)</code>	n normali di media <code>loc</code> e scarto <code>scale</code>	gaussiane simulate
<code>rng.exponential(scale, size)</code>	n esponenziali di media <code>scale</code>	tempi di attesa
<code>rng.integers(low, high, size)</code>	n interi in $\{low, \dots, high-1\}$	dadi, carte, indici
<code>rng.choice(a, size, p=...)</code>	n estrazioni da <code>a</code> con reinserimento	urne, linee di produzione
<code>rng.binomial(n, p, size)</code>	n binomiali	monete, difettosi
<code>rng.poisson(lam, size)</code>	n Poisson di media <code>lam</code>	arrivi
<code>rng.permutation(n)</code>	una permutazione di $0, \dots, n-1$	mescolare un mazzo

```
1 rng = np.random.default_rng(0)
2 print("uniform(15,80,4) ->", rng.uniform(15, 80, 4))
3 print("normal(45,2,4) ->", rng.normal(45, 2, 4))
4 print("exponential(.2,3)->", rng.exponential(0.2, 3))
5 print("integers(1,7,5) ->", rng.integers(1, 7, 5))
6 print("choice(p=.,6) ->", rng.choice([0, 1, 2], 6, p=[0.3, 0.5, 0.2]))
7 print("binomial(10,.5,6)->", rng.binomial(10, 0.5, 6))
8 print("poisson(5,6) ->", rng.poisson(5, 6))
```

```
uniform(15,80,4) -> [56.4025 32.5361 17.6633 16.0743]
normal(45,2,4) -> [43.9287 45.7232 47.608 46.8942]
exponential(.2,3)-> [0.5634 1.2116 0.6573]
integers(1,7,5) -> [5 1 3 6 4]
choice(p=.,6) -> [1 0 2 1 0 1]
binomial(10,.5,6)-> [2 3 6 6 5 5]
poisson(5,6) -> [8 7 5 5 4 3]
```

`exponential` vuole la *media*, non λ

È l'errore più insidioso di tutta la libreria. In `scipy.stats` l'esponenziale si parametrizza con `scale = 1/λ`; in `numpy` è lo stesso. Se il testo dà $\lambda = 5$ eventi al secondo, la media dell'attesa è 0.2 secondi e si scrive `rng.exponential(0.2)`, *non* `rng.exponential(5)`.

```
1 lam = 5.0
2 giusto = np.random.default_rng(1).exponential(1/lam, 200_000)
3 sbagliato = np.random.default_rng(1).exponential(lam, 200_000)
4 print(f"scale = 1/lam -> media {giusto.mean():.4f} (attesa {1/lam:.4f})")
5 print(f"scale = lam -> media {sbagliato.mean():.4f} (sbagliato)")
```

```
scale = 1/lam -> media 0.1991 (attesa 0.2000)
scale = lam -> media 4.9787 (sbagliato)
```

Lo stesso vale per `stats.expon`: la chiamata corretta è `stats.expon.cdf(0.4, scale=1/5)`, che dà $0.8647 = 1 - e^{-2}$.

default_rng e il vecchio np.random.seed

Nei capitoli di laboratorio compaiono entrambi gli stili: `np.random.seed(42)` più `np.random.uniform(...)` (stile storico) e `rng = np.random.default_rng(42)` più `rng.uniform(...)` (stile moderno, quello usato qui). Sono due generatori diversi: **lo stesso numero di seme non produce la stessa sequenza** nei due stili. Sceglierne uno e restateci dentro, altrimenti i risultati delle simulazioni non sono confrontabili.

B.3 `scipy.stats`: le quattro funzioni

Ogni distribuzione di `scipy.stats` espone gli stessi quattro metodi. Sono esattamente gli oggetti della teoria:

Metodo	Cosa calcola	Formula
<code>pmf(k, ...)</code> / <code>pdf(x, ...)</code>	la densità puntuale	$p_X(k)$ oppure $f_X(x)$
<code>cdf(x, ...)</code>	la funzione di ripartizione	$\mathbb{P}(X \leq x) = F_X(x)$
<code>sf(x, ...)</code>	la coda destra (<i>survival function</i>)	$\mathbb{P}(X > x) = 1 - F_X(x)$
<code>ppf(q, ...)</code>	l'inversa della cdf	l' x con $F_X(x) = q$, cioè il quantile q_α

```

1 from scipy import stats
2 print("binom.pmf(3,10,0.5) =", round(stats.binom.pmf(3, 10, 0.5), 6))
3 print("binom.cdf(3,10,0.5) =", round(stats.binom.cdf(3, 10, 0.5), 6))
4 print("binom.sf(2,10,0.5)   =", round(stats.binom.sf(2, 10, 0.5), 6))
5 print("norm.ppf(0.975)      =", round(stats.norm.ppf(0.975), 4))
6 print("t.ppf(0.975, 99)     =", round(stats.t.ppf(0.975, 99), 4))
7 print("chi2.ppf(0.975, 99)  =", round(stats.chi2.ppf(0.975, 99), 3))
8 print("expon.ppf(0.5, scale=.2)=", round(stats.expon.ppf(0.5, scale=0.2), 4))

```

```

binom.pmf(3,10,0.5)   = 0.117188
binom.cdf(3,10,0.5)   = 0.171875
binom.sf(2,10,0.5)    = 0.945312
norm.ppf(0.975)       = 1.96
t.ppf(0.975, 99)      = 1.9842
chi2.ppf(0.975, 99)   = 128.422
expon.ppf(0.5, scale=.2)= 0.1386

```

Le tre regole di lettura

- `cdf(x)` risponde a “quanto sta a sinistra di x ?”.
- `sf(x)` risponde a “quanto sta a destra?”. `sf` è preferibile a `1 - cdf` perché non perde precisione nelle code lontane.
- `ppf(q)` è il **verso opposto**: gli si dà una *probabilità* e restituisce un *valore*. È la funzione dei quantili e quindi di tutti gli intervalli di confidenza e di tutte le zone di

rigetto.

Un p -value è quasi sempre un cdf o un sf, mai un ppf. Un quantile critico è quasi sempre un ppf, mai un cdf.

Quale distribuzione, con quali parametri

Modello	Chiamata	Attenzione a...
Binomiale	<code>stats.binom.{pmf,cdf,sf}(k, n, p)</code>	<code>sf(k-1, n, p) = $\mathbb{P}(X \geq k)$</code>
Bernoulli	<code>stats.binom.{pmf,cdf}(k, 1, p)</code>	è una binomiale con $n = 1$
Poisson	<code>stats.poisson.{pmf,cdf,sf}(k, mu)</code>	il parametro si chiama μ ed è λ
Geometrica	<code>stats.geom.{pmf,cdf}(k, p)</code>	supporto $k = 1, 2, \dots$: in $k = 0$ non è definita
Ipergeometrica	<code>stats.hypergeom.{pmf,cdf}(k, M, n, N)</code>	M = popolazione <i>totale</i> , n = elementi con la proprietà, N = estrazioni
Esponenziale	<code>stats.expon.{pdf,cdf,sf}(x, scale=1/lam)</code>	<code>scale</code> è la media $1/\lambda$
Uniforme continua	<code>stats.uniform.{pdf,cdf}(x, loc=a, scale=b-a)</code>	<code>scale</code> è la <i>lunghezza</i> , non l'estremo
Normale	<code>stats.norm.{pdf,cdf,sf}(x, loc=mu, scale=sigma)</code>	<code>scale</code> è lo scarto , non la varianza
t di Student	<code>stats.t.{cdf,sf,ppf}(x, df)</code>	<code>df</code> = $n - 1$ nel test sulla media
χ^2	<code>stats.chi2.{cdf,sf,ppf}(x, df)</code>	<code>df</code> = $n - 1$ nell'intervallo per la varianza

I due parametri che si sbagliano sempre

`scale` in `stats.norm` è lo **scarto quadratico medio** σ , non la varianza: per $N(175, 8)$ si scrive `stats.norm.sf(190, loc=175, scale=np.sqrt(8))`. Se il testo dà “varianza = 8” e voi passate 8, la risposta è sbagliata.

`stats.hypergeom.pmf(k, M, n, N)` ha i parametri in ordine *diverso* da quello della formula degli appunti: qui M è la popolazione totale ($b + r$), n il numero di elementi con la proprietà (b), N il numero di estrazioni. Per il mazzo di Magic del 27/01/26 (60 carte, 26 Terre, 7 pescate) la chiamata è `stats.hypergeom.pmf(3, 60, 26, 7)`, che vale 0.3122; il valore atteso è `stats.hypergeom.mean(60, 26, 7) = 3.0333`, coerente con $n \frac{b}{b+r} = 7 \cdot \frac{26}{60}$.

ppf invece di cdf: l'errore di verso

Sono inverse una dell'altra, quindi scambiarle non dà un errore di esecuzione: dà un numero plausibile e sbagliato. Il controllo di sanità è il **codominio**: `cdf` e `sf` restituiscono sempre un numero in $[0, 1]$; se vi esce 1.96 da un `cdf` avete chiamato il `ppf`. Viceversa `ppf` restituisce un valore nella scala della variabile (un numero di teste, un tempo, un quantile): se vi esce 0.97 da un `ppf` avete chiamato la funzione sbagliata.

B.4 Il Q-Q plot: `probplot`

```
1 (osm, osr), (pendenza, intercetta, r) = stats.probplot(campione, dist="expon", plot=None)
```

Confronta i **quantili** del campione con quelli della distribuzione teorica **dist**: se i punti si allineano sulla bisettrice, il modello è plausibile. È la verifica chiesta il 29/04/26 sui tempi di attesa esponenziali.

```
1 import numpy as np
2 from scipy import stats
3
4 campione = np.random.default_rng(3).exponential(2.0, 1000)
5 (_, _), (p1, i1, r1) = stats.probplot(campione, dist="expon", plot=None)
6 (_, _), (p2, i2, r2) = stats.probplot(campione, dist="norm", plot=None)
7 print(f"contro l'esponenziale: r = {r1:.6f}")
8 print(f"contro la normale : r = {r2:.6f}")
```

```
contro l'esponenziale: r = 0.997972
contro la normale : r = 0.917325
```

Il coefficiente di correlazione del Q-Q plot è più vicino a 1 contro l'esponenziale: il campione viene davvero da lì. Nel compito si disegna il grafico con `plot=plt` (oppure si usa il valore di ritorno) e si commenta la vicinanza dei punti alla retta.

B.5 Media, varianza, deviazione standard: la trappola del `ddof`

Chiamata	Che cosa calcola	Formula
<code>np.mean(x)</code>	media aritmetica	$\bar{x} = \frac{1}{N} \sum_i x_i$
<code>np.average(x, weights=f)</code>	media pesata , per tabelle di frequenze	$\bar{x} = \frac{1}{N} \sum_i x_i f_i$
<code>np.var(x)</code>	varianza empirica (<code>ddof=0</code>)	$\frac{1}{N} \sum_i (x_i - \bar{x})^2$
<code>np.var(x, ddof=1)</code>	varianza campionaria	$\frac{1}{N-1} \sum_i (x_i - \bar{x})^2$
<code>np.std(x)</code>	scarto empirico (<code>ddof=0</code>)	$\sqrt{\text{np.var}(x)}$
<code>np.std(x, ddof=1)</code>	scarto campionario	$\sqrt{\text{np.var}(x, ddof=1)}$

ddof sbagliato: il default è 0, non 1

`np.var` e `np.std` hanno `ddof=0` per impostazione predefinita, cioè dividono per N : danno la varianza *empirica*, che è un indice descrittivo. Quando il compito chiede lo **stimatore non distorto** di σ^2 servono `ddof=1` o la formula a mano con $N - 1$. Con N grande la differenza è piccola, ma non è zero e il correttore la guarda.

```
1 peso = np.arange(17, 31, dtype=float)
2 num = np.array([1,1,2,5,8,14,17,18,12,9,5,5,2,1], float) # 100 biscotti
3 N = num.sum()
4 xbar = np.average(peso, weights=num) # media pesata
5 print(f"N = {N:.0f} media pesata = {xbar:.4f}")
6 print(f"varianza empirica (/N) = {np.sum(num*(peso-xbar)**2)/N:.4f}")
7 print(f"varianza campionaria (/N-1) = {np.sum(num*(peso-xbar)**2)/(N-1):.4f}")
8 dati = np.repeat(peso, num.astype(int)) # la tabella come 100 valori
9 print(f"np.var(dati) (ddof=0) = {np.var(dati):.4f}")
10 print(f"np.var(dati, ddof=1) = {np.var(dati, ddof=1):.4f}")
11 print(f"np.std(dati) (ddof=0) = {np.std(dati):.4f}")
```

```
N = 100 media pesata = 23.6900
varianza empirica (/N) = 6.0939
```

```

varianza campionaria (/N-1) = 6.1555
np.var(dati)                (ddof=0) = 6.0939
np.var(dati, ddof=1)         = 6.1555
np.std(dati)                 (ddof=0) = 2.4686

```

Sui dati del 27/01/26 la differenza è 6.0939 contro 6.1555: piccola, ma è esattamente ciò che distingue la varianza empirica da quella campionaria.

Con una tabella di frequenze non si usa `np.repeat`

`np.repeat` funziona ed è comodo per controllare, ma è inutilmente pesante: con $N = 100$ va bene, con una tabella da milioni di osservazioni no. La forma corretta è pesare: `np.sum(num*(peso-xbar)**2)/N`, che è la formula $\bar{\sigma}_x^2 = \frac{1}{N} \sum_i (x_i - \bar{x})^2 f_i$ degli appunti scritta direttamente.

B.6 Regressione: `scipy.stats.linregress`

```
1 ris = stats.linregress(x, y)           # x = variabile esplicativa, y = risposta
```

Restituisce un oggetto con i campi `slope` ($\hat{\beta}_1$), `intercept` ($\hat{\beta}_0$), `rvalue` (ρ), `pvalue` e `stderr`. I campi sono `ris.slope`, `ris.intercept`, `ris.rvalue`, ...

```

1 import numpy as np
2 from scipy import stats
3
4 x = np.array([1213, 1518, 1550, 1215, 2120, 2207], float)
5 y = np.array([15474, 16497, 17224, 14459, 22186, 23483], float)
6 ris = stats.linregress(x, y)
7 print(f"slope (beta1) = {ris.slope:.4f}    intercept (beta0) = {ris.intercept:.4f}")
8 print(f"rvalue (rho) = {ris.rvalue:.6f}    R = rho^2 = {ris.rvalue**2:.6f}")
9 print(f"pvalue = {ris.pvalue:.3e}    stderr = {ris.stderr:.4f}")
10 print(f"y previsto per x = 2000 : {ris.intercept + ris.slope*2000:.2f}")

```

```

slope (beta1) = 8.4867    intercept (beta0) = 4326.4015
rvalue (rho) = 0.988845    R = rho^2 = 0.977814
pvalue = 1.860e-04    stderr = 0.6392
y previsto per x = 2000 : 21299.75

```

`linregress` non restituisce R

`linregress` dà `rvalue`, cioè ρ . Il coefficiente di determinazione si ottiene elevando al quadrato: $R = \rho^2 = \text{ris.rvalue}^2$. Scrivere $R = \text{ris.rvalue}$ è l'errore più frequente su questo quesito. Inoltre: la prova del 17/02/26 diceva esplicitamente “**non** è consentito l'uso della funzione `scipy.stats.linregress`”. Le formule dei minimi quadrati $\hat{\beta}_1 = \bar{\sigma}_{xy}/\bar{\sigma}_x^2$ e $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ si scrivono a mano in tre righe, ed è quello che il compito chiedeva.

B.7 matplotlib: i grafici che servono

Istogramma: `hist` con `density=True`

```
1 plt.hist(dati, bins=20, density=True, alpha=0.6, edgecolor='white')
```

Con `density=True` l'asse y riporta la **densità** e non il numero di osservazioni: è la condizione per poter sovrapporre una curva teorica. Verifica: la somma di (altezza $\times$ larghezza) di tutti i rettangoli fa 1. Con n esiti interi (numero di teste, numero di Terre) si passano i bordi espliciti, `bins=np.arange(-0.5, n+1.5)`, per centrare le barre sui valori interi.

Barre allineate: confronto simulato contro teorico

È il grafico che il Laboratorio chiede quasi sempre. Si disegnano due **bar** sulle stesse ascisse, spostandone una di mezza larghezza:

```
1 n, Nsim = 10, 2000
2 rng = np.random.default_rng(7)
3 sim = rng.binomial(n, 0.5, Nsim)          # 2000 lanci di 10 monete
4 k = np.arange(0, n+1)
5 emp = np.array([(sim == i).mean() for i in k]) # frequenze relative osservate
6 teo = stats.binom.pmf(k, n, 0.5)          # probabilità teoriche
7
8 larghezza = 0.4
9 plt.bar(k - larghezza/2, emp, larghezza, label='simulata')
10 plt.bar(k + larghezza/2, teo, larghezza, label='teorica')
11 plt.xticks(k); plt.xlabel('numero di teste'); plt.ylabel('probabilità')
12 plt.grid(alpha=0.3, axis='y'); plt.legend(); plt.show()
```

I valori che si leggono:

k	empirica	teorica
0	0.0005	0.0010
1	0.0080	0.0098
2	0.0425	0.0439
3	0.1140	0.1172
4	0.2155	0.2051
5	0.2405	0.2461
6	0.2105	0.2051
7	0.1170	0.1172
8	0.0385	0.0439
9	0.0120	0.0098
10	0.0010	0.0010

Le due colonne coincidono entro le fluttuazioni (massima differenza 0.0104 al valore 4) e le rispettive somme valgono 1: è il commento che il compito chiede di scrivere.

Le due trappole del grafico di confronto

1. **Dimenticare `density=True`.** Senza, l'asse y conta le osservazioni e la curva teorica (che vale al massimo 1) finisce schiacciata sull'asse. Con $N = 2000$ le barre arrivano a centinaia e il confronto è illeggibile.
2. **Confrontare un istogramma con una densità senza allineare le ascisse.** Se il quesito chiede “la probabilità empirica associata a ogni numero di teste”, non è un `hist` ma un `bar` sulle frequenze relative: un istogramma con `density=True` sui valori interi dà la densità, che su classi di ampiezza 1 coincide con la probabilità, ma solo se i `bins` sono larghi esattamente 1.

Curve, scatter e griglia: `plot`, `scatter`, `grid`

```
1 xs = np.linspace(15, 80, 200)
2 plt.plot(xs, ris.intercept + ris.slope*xs, 'r-', label='retta di regressione')
3 plt.scatter(x, y, label='dati')
4 plt.xlabel('X'); plt.ylabel('Y')
```

```

5 plt.grid(alpha=0.3)           # griglia leggera, aiuta a leggere i valori
6 plt.legend()                 # indispensabile se ci sono più serie
7 plt.show()

```

Per sovrapporre una curva teorica a un istogramma si usa `plt.plot(xs, stats.norm.pdf(xs, mu, sigma))` con `xs` fitto (almeno 200 punti), e l'istogramma deve avere `density=True`. Per la distribuzione della media campionaria lo scarto da usare è $\sigma/\sqrt{N}$, non σ .

B.8 L'errore che ho fatto, e come si risolve

Errore	Sintomo	Rimedio
<code>np.var/np.std</code> senza <code>ddof</code>	esce la varianza empirica dove serviva lo stimatore non distorto	<code>np.var(x, ddof=1)</code> , oppure $\frac{1}{N-1} \sum (x_i - \bar{x})^2$ a mano
<code>ppf</code> al posto di <code>cdf</code> (o viceversa)	il risultato non sta in $[0, 1]$, oppure un p -value vale 1.96	<code>cdf/sf</code> danno probabilità, <code>ppf</code> dà quantili
<code>1 - cdf</code> invece di <code>sf</code>	nelle code lontane il p -value esce 0 per cancellazione	<code>stats.norm.sf(x)</code> , <code>stats.t.sf(t, df)</code>
seme dimenticato (o assente)	due esecuzioni danno numeri diversi e il grafico non si può confrontare	<code>rng = np.random.default_rng(42)</code> in cima, sempre
<code>density=True</code> mancante	la curva teorica finisce schiacciata sull'asse delle ascisse	<code>plt.hist(x, bins=30, density=True)</code>
scale sbagliato in <code>norm</code>	la densità è larghissima o strettissima	scale è σ : <code>norm.pdf(x, mu, np.sqrt(var))</code>
scale sbagliato in <code>expon</code>	il tempo medio simulato è λ invece di $1/\lambda$	<code>rng.exponential(1/lam)</code>
rapporto σ contro $\sigma/\sqrt{N}$	la curva della media è troppo larga e non copre l'istogramma	<code>se = sigma/np.sqrt(N)</code>
<code>P.sum(axis=0)</code> per verificare una matrice di transizione	il controllo fallisce e sembra che la matrice sia sbagliata	le righe sommano a 1: si verifica <code>P.sum(axis=1)</code> . Le colonne <i>non</i> devono sommare a 1
distribuzione moltiplicata a sinistra	<code>P @ v0</code> dà un vettore che non è una distribuzione	la legge va scritta come vettore <i>riga</i> : <code>v0 @ P</code> , cioè $\pi^{(t)} = \pi^{(0)} P^t$
<code>P[0]</code> invece di <code>P[:,0]</code>	si legge una riga credendo di leggere una colonna	<code>P[i]</code> è la riga i (da i verso tutti); <code>P[:,j]</code> è la colonna j (da tutti verso j)
<code>eig(P)</code> invece di <code>eig(P.T)</code>	l'autovettore "stazionario" viene costante e sbagliato	$\pi P = \pi$ rende π autovettore <i>sinistro</i> : serve <code>np.linalg.eig(P.T)</code>
probabilità simulata maggiore di 1	errore di normalizzazione	dividere per il numero di <i>simulazioni</i> , non per gli oggetti del problema: $\hat{p}$ = casi favorevoli / simulazioni

Il controllo di sanità in tre righe

Prima di consegnare, tre verifiche che smascherano quasi tutti gli errori sopra. `emp` è il vettore delle frequenze relative e `P`, `pi` sono la matrice di transizione e la distribuzione stazionaria:

```
1 print("somma delle probabilità =", emp.sum())           # deve fare 1.0
2 print("righe stocastiche:", np.allclose(P.sum(axis=1), 1)) # deve fare True
3 print("pi stazionaria:", np.allclose(pi @ P, pi))       # deve fare True
```

Eseguito sui dati di esempio di questa appendice:

```
somma delle probabilità = 1.0
righe stocastiche: True
pi stazionaria: True
```

Se una simulazione di probabilità non somma a 1, o se una “matrice di transizione” non ha le righe che sommano a 1, l'errore è a monte e non serve guardare il resto.

Appendice C

Le domande di teoria ricorrenti

Che cos'è, e come si usa

Questa appendice raccoglie le domande di **teoria** già assegnate nelle nove prove disponibili, raggruppate per argomento e ordinate per **frequenza**: si studia dall'alto verso il basso. Per ciascuna: come è formulata all'esame (con la citazione della prova), la risposta scheletro da dire all'orale, e l'errore che fa perdere punti.

Le prove sono citate con la data che dà il nome al file:

Citazione	File in build/exams/
28/01/25	prova_28-01-25.txt
24/03/25	prova_24-03-25_primo_turno.txt
17/06/25	prova_17-06-25.txt
02/09/25	prova_02-09-25.txt
27/01/26	met_mat_stat_2026_01_27.txt
17/02/26	met_mat_stat_2026_02_17.txt
01/04/26	met_mat_stat_2026_04_01.txt
29/04/26	met_mat_stat_2026_04_29.txt
23/06/26	met_mat_stat_2026_06_23.txt

C.1 Che cosa studiare per primo

Argomento	Prove	Appelli in cui compare
1 Catene di Markov	4 su 9	28/01/25, 17/06/25, 27/01/26, 29/04/26
2 Probabilità: eventi, assiomi, indipendenza	3 su 9	24/03/25, 17/06/25, 27/01/26
3 Stimatori: definizione, non distorsione, stimatore della varianza	3 su 9	28/01/25, 29/04/26, 23/06/26
4 Variabili aleatorie: definizione, densità, momenti	2 su 9	17/06/25, 01/04/26
5 Distribuzioni notevoli: geometrica e binomiale	2 su 9	24/03/25, 17/02/26
6 Media campionaria e legge dei grandi numeri	2 su 9	02/09/25, 01/04/26
7 Statistica descrittiva	2 su 9	02/09/25, 17/02/26
8 Monte Carlo e numeri pseudorandom	2 su 9	02/09/25, 23/06/26
9 Intervalli di confidenza	1 su 9	23/06/26

Come si legge la tabella

Ogni prova ha **due** quesiti di teoria, per un totale di 18 quesiti. Alcuni quesiti toccano due argomenti (per esempio il 17/06/25 mette insieme assiomi di probabilità e variabili aleatorie), quindi la colonna “prove” somma a 21 e non a 9: non è un errore di conteggio.

Il messaggio pratico: **Markov, probabilità di base e stimatori sono metà dell’esame.** Le catene di Markov sono l’unico argomento che è comparso come *Quesito 2* in quattro appelli su nove.

C.2 Catene di Markov (4 su 9)

Come è formulata

Le quattro domande ricorrenti sono sempre le stesse, e sono elencate quasi alla lettera:

- “Dare la definizione di processo stocastico” e “Dare la definizione di catena di Markov” — 28/01/25 (punti a e b) e 29/04/26 (punti a e b), le due prove sono quasi identiche.
- “Dare la definizione di classe chiusa” — 28/01/25 (punto c); “Dare la definizione di classe chiusa e di classe irriducibile” — 29/04/26 (punto c).

- “Dare la definizione di catena di Markov irriducibile” — 17/06/25 (punto b) e 29/04/26 (punto d).
- “Sia data una catena di Markov. Dare la definizione di matrice di transizione” — 17/06/25 (punto a); “Dare la definizione di matrice di transizione ed elencare le due proprietà di cui godono gli elementi di tale matrice” — 27/01/26 (punto a).
- 27/01/26 chiede inoltre “la definizione di matrice di transizione a m passi e spiegarne il significato” (punto b), “la definizione di distribuzione di X_t ” (punto c) e “la definizione di distribuzione stazionaria, spiegandone il significato in maniera intuitiva, eventualmente anche fornendo un esempio” (punto d).
- Due appelli chiudono con un **esercizio** invece che con una definizione: 28/01/25 punto d (“Data la seguente matrice di transizione disegnare il grafo associato e identificare le classi chiuse”) e 17/06/25 punto c–d (“Scrivere la matrice di transizione associata a questa catena e rappresentarla su un grafo”, “Questa catena è irriducibile? Spiegare perché”).

Chiesto in: 28/01/25 Q2; 17/06/25 Q2; 27/01/26 Q2; 29/04/26 Q2

Risposta scheletro.

1. **Processo stocastico.** È una famiglia di variabili aleatorie $\{X_t\}_{t \in T}$ definite tutte sullo stesso spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, indicizzate da un parametro t che rappresenta il tempo (T discreto o continuo); i valori che ciascuna X_t può assumere formano lo **spazio degli stati** E . Esempio: il prezzo di un’azione giorno per giorno.
2. **Catena di Markov.** È un processo stocastico a tempo discreto con spazio degli stati discreto che gode della **proprietà di Markov** (assenza di memoria):

$$\mathbb{P}(X_{t+1} = j \mid X_t = i, X_{t-1} = i_{t-1}, \dots, X_1 = i_1) = \mathbb{P}(X_{t+1} = j \mid X_t = i) = p_{ij}(t).$$

A parole: *il futuro dipende dal presente, e solo dal presente*. È **omogenea** se $p_{ij}(t) \equiv p_{ij}$ non dipende da t .

3. **Matrice di transizione.** $P = (p_{ij})_{i,j \in E}$, dove p_{ij} è la probabilità di passare da i a j in un passo. Le due proprietà: $p_{ij} \geq 0$ per ogni i, j e $\sum_{j \in E} p_{ij} = 1$ per ogni i (le **righe** sommano a 1: partendo da i bisogna pur andare da qualche parte).
4. **Matrice a m passi e legge di X_t .** $p_{ij}^{(m)} = \mathbb{P}(X_{t+m} = j \mid X_t = i)$ e, per il teorema di **Chapman–Kolmogorov**, $P^{(m)} = P^m$ (prodotto riga per colonna). Dette $\pi^{(t)}$ la legge di X_t e $\pi^{(0)}$ la distribuzione iniziale, $\pi^{(t)} = \pi^{(0)} P^t$, cioè $\mathbb{P}(X_t = j) = \sum_i \pi_i^{(0)} p_{ij}^{(t)}$.
5. **Classe chiusa, irriducibilità, stazionaria.** $C \subseteq E$ è **chiusa** se gli stati di C non comunicano con quelli di $E \setminus C$ (equivalentemente $\sum_{j \in C} p_{ij} = 1$ per ogni $i \in C$). Una classe chiusa è **irriducibile** se tutti i suoi stati comunicano, e la catena è **irriducibile** se l’unica classe chiusa è E stesso, cioè se $i \leftrightarrow j$ per ogni i, j . π è **stazionaria** se $\pi = \pi P$ con $\sum_i \pi_i = 1$: è un autovettore *sinistro* di P con autovalore 1, e significa che la distribuzione non cambia nel tempo.

Cosa non dire

- “Un processo stocastico è una variabile aleatoria”. È una famiglia di variabili aleatorie indicizzate dal tempo: è il punto che distingue la risposta completa da quella incompleta.

- **“Le colonne della matrice di transizione sommano a 1”.** Sommano a 1 le righe. La riga i elenca le probabilità di *uscire* da i .
- **Definire la proprietà di Markov senza dire su che processo è definita.** Serve prima dire “processo a tempo discreto con spazio degli stati discreto”, poi la formula.
- **Confondere classe chiusa e classe irriducibile.** La frase che le collega va detta esplicitamente: *una catena è irriducibile quando l'unica classe chiusa è l'intero spazio degli stati*. Aggiungere l'esempio opposto: una catena con uno stato assorbente *non* è irriducibile, perché $\{\text{assorbente}\}$ è una classe chiusa propria.
- **Scrivere $\pi P = \pi$ come $P\pi = \pi$.** π è un vettore *riga* e la moltiplicazione è a sinistra.

L'esercizio che accompagna la domanda: classi chiuse da un pattern

Il 28/01/25 dà la matrice solo come pattern di $\times$ (elemento > 0) e $-$:

$$P = \begin{pmatrix} \times & - & - & - & - & - & - \\ - & \times & \times & - & - & - & - \\ - & \times & - & - & - & \times & - \\ - & - & - & \times & - & \times & - \\ - & - & - & - & - & \times & - \\ - & \times & - & \times & - & - & - \\ \times & - & - & - & - & \times & \times \end{pmatrix}$$

Poiché ogni riga deve sommare a 1, una riga con un solo $\times$ ha quell'elemento uguale a 1: la riga 1 ha solo $p_{11} > 0$, quindi $p_{11} = 1$ e lo stato 1 è **assorbente**. Il procedimento:

1. raggruppare gli stati che si raggiungono a vicenda (classi di comunicazione): $\{1\}$, $\{2, 3, 4, 6\}$, $\{5\}$, $\{7\}$;
2. guardare se da un gruppo si esce: $\{1\}$ è chiuso (da 1 si va solo in 1) e $\{2, 3, 4, 6\}$ è chiuso (da 2, 3, 4, 6 non si esce mai dal gruppo);
3. $\{5\}$ e $\{7\}$ **non** sono chiusi: da 5 si va in 6, da 7 si va in 1 o in 6. Gli stati 5 e 7 sono quindi **transitori**.

Le **classi chiuse** sono $\{1\}$ e $\{2, 3, 4, 6\}$: essendocene più di una, la catena **non** è irriducibile. Da notare che i pesi degli archi non servono: il quesito chiede solo la struttura.

C.3 Probabilità: eventi, assiomi, indipendenza (3 su 9)

Come è formulata

Le due domande “da definizione” e la domanda “da calcolo”, *sempre nello stesso ordine*:

- **“Dare la definizione di evento”** — 24/03/25 (punto a) e 27/01/26 (punto a), identiche.
- **“Dare la definizione di evento incompatibile”** — 24/03/25 (punto b) e 27/01/26 (punto b), identiche.
- **“Dare la definizione assiomatica di probabilità, avendo cura di definire anche gli spazi di probabilità”** — 17/06/25 (punto a).
- Poi il **calcolo**, con la stessa struttura in due prove. 24/03/25: *“Dati i due eventi $A = \text{“Giorgino ha studiato”}$ e $B = \text{“Giorgino ha passato l'esame”}$, esprimere in termini*

di A e B l'evento composto $E = \text{"Giorgino non ha passato l'esame e ha studiato"}$. Sapendo che gli eventi A e B sono indipendenti e sapendo che $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.5$ calcolare la probabilità dell'evento E ". 27/01/26: gli eventi sono i guasti di tastiera, mouse e monitor, con $\mathbb{P}(A) = 0.45$, $\mathbb{P}(B) = 0.35$, $\mathbb{P}(C) = 0.2$ indipendenti, e si chiede di scrivere e calcolare $G = \text{"Giorgino non può lavorare"}$.

Chiesto in: 24/03/25 Q1; 17/06/25 Q1 (punto a); 27/01/26 Q1

Risposta scheletro.

1. **Evento.** Dato lo spazio campionario Ω (l'insieme di tutti i risultati possibili dell'esperimento aleatorio), un evento è un **sottoinsieme** $A \subseteq \Omega$, e si realizza se il risultato dell'esperimento appartiene ad A .
2. **Eventi incompatibili.** A e B sono incompatibili se $A \cap B = \emptyset$, cioè se non possono verificarsi contemporaneamente. Conseguenza: $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$.
3. **Spazio di probabilità e assiomi.** Una terna $(\Omega, \mathcal{A}, \mathbb{P})$ in cui $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ è una σ -algebra (contiene $\emptyset$ e Ω , è chiusa rispetto al complementare e all'unione numerabile) e $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ soddisfa:

- (a) $\mathbb{P}(A) \geq 0$;
- (b) $\mathbb{P}(\Omega) = 1$;
- (c) $\mathbb{P}(\bigcup_i A_i) = \sum_i \mathbb{P}(A_i)$ per eventi a due a due incompatibili.

Da qui si ricavano $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ e $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.

4. **Il calcolo.** Si traducono le frasi in simboli ($\cap$ per "e", $\cup$ per "o", complementare per "non"), poi si usa l'indipendenza, cioè $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$.

- 24/03/25: $E = B^c \cap A$, e poiché A e B sono indipendenti anche A e B^c lo sono, quindi $\mathbb{P}(E) = \mathbb{P}(A)(1 - \mathbb{P}(B)) = 0.3 \cdot 0.5 = 0.15$.
- 27/01/26: "lavora" è $\bar{C} \cap (\bar{A} \cup \bar{B})$, quindi per De Morgan $G = C \cup (A \cap B)$. Attenzione a C : *non* è un evento composto solo da A e B , quindi

$$\mathbb{P}(G) = \mathbb{P}(C) + \mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = 0.2 + 0.45 \cdot 0.35 - 0.45 \cdot 0.35 \cdot 0.2 = 0.326.$$

(La sottrazione serve perché "monitor guasto e sia tastiera che mouse guasti" è contato due volte.)

Cosa non dire

- Definire l'evento come "un insieme di risultati" senza dire che è un *sottoinsieme di* Ω : servono tutti e tre gli elementi (Ω spazio campionario, $A \subseteq \Omega$, si realizza se il risultato appartiene ad A).
- Dare solo la formula $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$ per gli eventi incompatibili senza la condizione $A \cap B = \emptyset$.
- Dimenticare, negli assiomi, che $\mathcal{A}$ deve essere una σ -algebra: è la chiusura rispetto al complementare e all'unione che quasi tutti saltano.
- **Confondere indipendenti e incompatibili.** Due eventi incompatibili con probabilità positiva sono *dipendenti* (anzi, massimamente dipendenti). Nel 27/01/26 la domanda dà esplicitamente per indipendenti; trattarli come incompatibili significherebbe calcolare $\mathbb{P}(G) = \mathbb{P}(C) + \mathbb{P}(A \cap B)$, che presuppone $\mathbb{P}(A \cap B \cap C) = 0$.

- **Scrivere l'evento sbagliato.** Dire $G = C \cup A \cup B$ (“non funziona se uno qualunque dei tre è guasto”) dà $1 - 0.8 \cdot 0.55 \cdot 0.65 = 0.714$, contro il valore corretto 0.326: è un errore di traduzione, non di calcolo. Il testo dice che Giorgino lavora se il monitor funziona e almeno uno tra tastiera e mouse funziona, quindi il complementare è $C \cup (A \cap B)$.
- Trattare A, B, C come indipendenti “a due a due” quando il testo non lo dice: il testo del 27/01/26 dice “*gli eventi A, B e C sono indipendenti*”, che è l'ipotesi più forte.

C.4 Stimatori (3 su 9)

Come è formulata

Due prove quasi sovrapponibili, più una terza variante:

- 28/01/25: “a) Dare la definizione di stimatore. b) Dare la definizione di stimatore non distorto. c) Quale stimatore usereste per stimare la varianza di una distribuzione con media nota? d) Dimostrare che lo stimatore scelto al punto precedente è non distorto”.
- 29/04/26: identica nei punti a–c, con in più il punto d: “Quale stimatore usereste per stimare la varianza di una distribuzione con media non nota? Dire se si tratta uno stimatore distorto o no”.
- 23/06/26: “a) Dare la definizione di stimatore puntuale; b) Dare la definizione di intervallo di confidenza con livello di confidenza $1 - \alpha$; c) Scegliere un particolare intervallo di confidenza e darne una rappresentazione grafica; d) Commentare come cambiano gli estremi dell'intervallo di confidenza scelto al variare di N, σ e α ”.
- 02/09/25 chiede la stessa cosa in forma applicata: “Che stimatore utilizzereste per stimare la media? Calcolarne media e varianza”.

Chiesto in: 28/01/25 Q1; 02/09/25 Q1 (punto b); 29/04/26 Q1; 23/06/26 Q1

Risposta scheletro.

1. **Stimatore puntuale.** Dato un campione $(X_1, \dots, X_n)$ di variabili indipendenti con la stessa distribuzione, uno stimatore di θ è una **funzione del campione** $\hat{\theta} = T(X_1, \dots, X_n)$ che **non dipende da θ** e assume valori nell'immagine di θ . È a sua volta una **variabile aleatoria**; il valore che assume su un campione concreto si chiama *stima* ed è un numero.
2. **Non distorto.** $\hat{\theta}$ è non distorto se $\mathbb{E}[\hat{\theta}] = \theta$; la differenza $\mathbb{E}[\hat{\theta}] - \theta$ è la *distorsione*. Esempio: $\bar{X}_n = \frac{1}{n} \sum_i X_i$ è lo stimatore non distorto di μ , con $\mathbb{E}[\bar{X}_n] = \mu$ e $\text{Var}(\bar{X}_n) = \sigma^2/n$.
3. **Varianza con μ nota:** $\bar{\sigma}_n^2 = \frac{1}{n} \sum_i (X_i - \mu)^2$, ed è **non distorto**. Dimostrazione:

$$\mathbb{E}[\bar{\sigma}_n^2] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] = \frac{1}{n} \cdot n\sigma^2 = \sigma^2.$$

4. **Varianza con μ non nota.** Se si divide per n , $S^2 = \frac{1}{n} \sum_i (X_i - \bar{X}_n)^2$ è **distorto**: $\mathbb{E}[S^2] = \frac{n-1}{n}\sigma^2 < \sigma^2$ (sottostima sistematicamente). Lo stimatore non distorto è

$$\bar{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad \mathbb{E}[\bar{S}_n^2] = \sigma^2.$$

Il motivo del divisore $n-1$: gli n scarti $X_i - \bar{X}_n$ hanno somma nulla, quindi noti $n-1$ di essi l'ultimo è determinato; una unità di informazione è stata “spesa” per stimare μ .

5. **Intervallo di confidenza (23/06/26).** $[I_1, I_2]$ è un intervallo di livello $1 - \alpha$ se $\mathbb{P}(I_1 \leq \theta \leq I_2) = 1 - \alpha$. L'esempio da scegliere è quello per la media con σ^2 nota, $I_\mu = [\bar{X}_n - \varepsilon_\mu, \bar{X}_n + \varepsilon_\mu]$ con $\varepsilon_\mu = \frac{\sigma}{\sqrt{N}} \varphi_{1-\alpha/2}$; il grafico è la campana della distribuzione di $\bar{X}_n$ con l'area centrale $1 - \alpha$ evidenziata. Al variare dei parametri: N su, ampiezza giù come $1/\sqrt{N}$ (per dimezzarla servono quattro volte i dati); σ su, ampiezza su *linearmente*; α giù (più confidenza), $\varphi_{1-\alpha/2}$ su e ampiezza su.

Cosa non dire

- Definire lo stimatore come “una formula” o “un valore”: è una *funzione del campione*, quindi una variabile aleatoria. Il *valore* è la stima.
- Omettere la condizione “non dipende da θ ”: se dipendesse dal parametro non servirebbe a stimarlo.
- **Dire che $\frac{1}{n} \sum (X_i - \bar{X}_n)^2$ è non distorto.** È l'errore centrale di questo argomento: divide per n e sottostima.
- Dire che con μ non nota si divide per $n - 1$ *perché μ è ignota* senza dare la ragione vera (il grado di libertà perso).
- Dire “l'intervallo contiene θ con probabilità 0.95”. Dopo averlo calcolato, θ è un numero fisso e l'intervallo è calcolato: o lo contiene o no. La frase corretta è “*il procedimento produce intervalli che contengono θ nel 95% dei campioni*”.
- Nel commento su N, σ, α fermarsi a “l'ampiezza cambia” senza dire *in che direzione e con quale legge* ($1/\sqrt{N}$, lineare in σ).

C.5 Variabili aleatorie (2 su 9)

Come è formulata

- 17/06/25: “b) Dare la definizione di variabile aleatoria. Qual è la differenza tra variabile aleatoria discreta e continua? c) Sia X una variabile aleatoria discreta. Dare la definizione di legge di X e di densità discreta. d) Di che probabilità gode la densità discreta?”
- 01/04/26: “a) Dare la definizione di variabile aleatoria; b) Dare un esempio di evento e di variabile aleatoria ad esso associata; c) Qual è la differenza tra variabili aleatorie discrete e continue? E tra densità discreta e densità continua? d) Dare la definizione di momento centrato di ordine k sia per variabili aleatorie discrete che per quelle continue e fare un esempio di un momento centrato noto”.

Chiesto in: 17/06/25 Q1 (punti b-d); 01/04/26 Q1

Risposta scheletro.

1. **Definizione.** Dato uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, una variabile aleatoria è una **funzione** $X : \Omega \rightarrow \mathbb{R}$ tale che per ogni $t \in \mathbb{R}$ l'insieme $\{X \leq t\} = \{\omega : X(\omega) \leq t\}$ appartenga ad $\mathcal{A}$ (cioè sia un evento). In parole: una funzione che associa a ogni risultato elementare un numero reale.
2. **Esempio (01/04/26, punto b).** $\Omega = \{T, C\}$ per il lancio di una moneta, evento “esce testa” $= \{T\}$, e $X(T) = 1$, $X(C) = 0$: la variabile aleatoria associata è l'indicatrice dell'evento.
3. **Discreta contro continua.** X è discreta se $X(\Omega)$ è finito o numerabile, continua se $X(\Omega)$ è infinito (più precisamente se ammette densità). Di conseguenza:

- discreta: la **densità discreta** (o legge) è $p(x) = \mathbb{P}(X = x)$, e $\mathbb{P}(X \in A) = \sum_{a \in A} p(a)$;
- continua: la **densità continua** f è tale che $\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx$, e $F_X(t) = \int_{-\infty}^t f(x) dx$.

4. Proprietà della densità discreta (17/06/25, punto d):

$$p(x) \geq 0 \quad \forall x \in \mathbb{R}, \quad \sum_{x \in \mathbb{R}} p(x) = \sum_{i=1}^{\infty} p(x_i) = 1.$$

Per la densità continua l'analogo è $f \geq 0$ e $\int_{\mathbb{R}} f(x) dx = 1$.

5. Momento centrato di ordine k (01/04/26, punto d):

$$\mathbb{E}[(X - \mathbb{E}[X])^k] = \begin{cases} \sum_i (x_i - \mathbb{E}[X])^k p(x_i) & \text{discreta,} \\ \int_{\mathbb{R}} (x - \mathbb{E}[X])^k f(x) dx & \text{continua.} \end{cases}$$

Esempi noti: per $k = 1$ vale 0 (perché $\mathbb{E}[X - \mathbb{E}[X]] = \mathbb{E}[X] - \mathbb{E}[X] = 0$); per $k = 2$ è la **varianza**, $\sigma_X^2 = \text{Var}(X)$.

Cosa non dire

- Dire che una variabile aleatoria è “una variabile che assume valori a caso”. È una **funzione** da Ω a $\mathbb{R}$: è il punto centrale della domanda, e quasi tutti lo saltano.
- Dimenticare la condizione di misurabilità $\{X \leq t\} \in \mathcal{A}$.
- Dire che X è continua “perché assume infiniti valori” (l'affermazione corretta è che la sua immagine è infinita e che ammette densità).
- Dire che $f(x)$ è una probabilità: per una variabile continua $\mathbb{P}(X = x) = 0$, e f può valere più di 1. Solo il suo *integrale* è una probabilità.
- Enunciare solo la formula del momento centrato senza aggiungere che per $k = 1$ vale 0 e per $k = 2$ è la varianza: è esattamente il “fare un esempio di un momento centrato noto” che il punto d chiede.
- Scambiare “momento” e “momento centrato”: $\mathbb{E}[X^k]$ è il momento (semplice), $\mathbb{E}[(X - \mathbb{E}[X])^k]$ quello centrato.

C.6 Distribuzioni notevoli: geometrica e binomiale (2 su 9)

Come è formulata

- 24/03/25 (geometrica): “a) Descrivere la distribuzione geometrica e il suo legame con la distribuzione binomiale. b) Giorgino ha comprato una confezione di caramelle tre gusti: limone, arancia e menta. Sapendo che ci sono 10 caramelle al limone, 7 all'arancia e 13 alla menta, calcolare la probabilità che, pescando a caso dalla confezione, Giorgino debba pescare sei caramelle prima di trovarne una alla menta. c) Di quale proprietà gode questa distribuzione? d) Dimostrare questa proprietà”.
- 17/02/26 (binomiale): “a) Definire la distribuzione binomiale, e darne la formula definendo le quantità coinvolte. b) Dare un esempio di applicazione della distribuzione binomiale, calcolando esplicitamente delle probabilità. c) Dare il valore atteso e la

varianza di una variabile aleatoria che segue una distribuzione binomiale. d) Ricavare le formule del punto precedente”.

Chiesto in: 24/03/25 Q2; 17/02/26 Q2

Risposta scheletro.

1. **Geometrica.** $T \sim \text{Geom}(p)$ è il *tempo di primo successo*: il numero di prove necessarie per ottenere il primo successo in uno schema successo/insuccesso con prove indipendenti di probabilità p . Densità

$$\mathbb{P}(T = n) = p(1-p)^{n-1}, \quad n = 1, 2, \dots, \quad \mathbb{E}[T] = \frac{1}{p}, \quad \text{Var}(T) = \frac{1-p}{p^2}.$$

2. **Legame con la binomiale.** $\mathbb{P}(T > n) = \mathbb{P}(\text{nessun successo nelle prime } n \text{ prove})$, e l'evento “nessun successo in n prove” è governato da $X(n) \sim \text{Bin}(n, p)$:

$$\mathbb{P}(T > n) = \mathbb{P}(X(n) = 0) = (1-p)^n \implies \mathbb{P}(T = n) = \mathbb{P}(T > n-1) - \mathbb{P}(T > n) = p(1-p)^{n-1}.$$

3. **L'esercizio delle caramelle.** Con 30 caramelle totali di cui 13 alla menta, $p = \frac{13}{30}$ e

$$\mathbb{P}(T = 6) = p(1-p)^5 = \frac{13}{30} \left(\frac{17}{30} \right)^5 \approx 0.0253.$$

Attenzione alla lettura: “pescare sei caramelle *prima* di trovarne una alla menta” significa che la menta esce alla sesta estrazione, quindi $T = 6$, non $T = 5$.

4. **La proprietà: assenza di memoria.** Vale $\mathbb{P}(T = m+n \mid T > n) = \mathbb{P}(T = m)$ per ogni $n, m > 0$: il tempo già trascorso non cambia la distribuzione del tempo rimanente. Dimostrazione in una riga:

$$\mathbb{P}(T = m+n \mid T > n) = \frac{\mathbb{P}(T = m+n)}{\mathbb{P}(T > n)} = \frac{p(1-p)^{m+n-1}}{(1-p)^n} = p(1-p)^{m-1} = \mathbb{P}(T = m).$$

5. **Binomiale (17/02/26).** $X \sim \text{Bin}(n, p)$ conta il numero di successi in n prove *indipendenti* con la stessa probabilità di successo p :

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n, \quad \mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p).$$

Derivazione rapida di $\mathbb{E}[X] = np$: si scrive $X = \sum_{i=1}^n X_i$ con $X_i \sim \text{Ber}(p)$ indipendenti, e per la linearità del valore atteso $\mathbb{E}[X] = \sum_i \mathbb{E}[X_i] = np$; analogamente $\text{Var}(X) = \sum_i \text{Var}(X_i) = np(1-p)$. In alternativa, la derivazione esplicita con $k \binom{n}{k} = n \binom{n-1}{k-1}$. *Esempio da portare:* in $n = 5$ prove con $p = \frac{1}{3}$, $\mathbb{P}(X = 1) = \binom{5}{1} \frac{1}{3} \left(\frac{2}{3} \right)^4 \approx 0.3292$ e $\mathbb{P}(X > 3) = \mathbb{P}(X = 4) + \mathbb{P}(X = 5) \approx 0.0453$ (gli errori di stampa distribuiti in tre file).

Cosa non dire

- **Usare la convenzione sbagliata per la geometrica.** I due usi possibili sono: “numero di prove fino al primo successo” (supporto $1, 2, \dots$, $\mathbb{E}[T] = 1/p$) e “numero di insuccessi prima del primo successo” (supporto $0, 1, \dots$, $\mathbb{E}[T] = \frac{1-p}{p}$). **Dichiarate sempre quale convenzione usate** prima di scrivere la formula: qui si usa la prima, quella degli appunti.

- Scrivere $p(1-p)^n$ invece di $p(1-p)^{n-1}$: è l'errore di un esponente, e sposta la risposta di un fattore $(1-p)$.
- Dire che “la geometrica è il caso $p = 1/2$ della binomiale”: il legame è che il tempo di primo successo si esprime tramite la probabilità di *zero* successi in n prove di una binomiale.
- Dimostrare l'assenza di memoria “a parole” senza scrivere il conto $\frac{\mathbb{P}(T=m+n)}{\mathbb{P}(T>n)} = \frac{(1-p)^{m+n}}{(1-p)^n} = (1-p)^m$: il punto d chiede “*dimostrare questa proprietà*”.
- Per la binomiale, dire solo la formula senza definire le quantità coinvolte (n numero di prove, k numero di successi, p probabilità di successo, $q = 1-p$): il punto a chiede esplicitamente di definirle.
- Ricavare $\text{Var}(X) = np(1-p)$ saltando il passaggio: serve dire che le X_i sono *indipendenti*, perché è l'indipendenza che permette di sommare le varianze.

C.7 Media campionaria e legge dei grandi numeri (2 su 9)

Come è formulata

- 02/09/25: “a) Dare la definizione di statistica descrittiva e statistica inferenziale. b) Che stimatore utilizzereste per stimare la media? Calcolarne media e varianza. c) Quale legge ci garantisce che ripetere tante volte un esperimento è un modo furbo per ottenere informazioni sui parametri che descrivono la popolazione? d) Dimostrare tale legge partendo dalla conoscenza della disuguaglianza di Čebyšëv”.
- 01/04/26: “Sia X_n una successione di variabili aleatorie indipendenti definite tutte nello stesso spazio di probabilità. Assumiamo che le X_n abbiano media μ e σ^2 . a) Dare la definizione di media campionaria. È ancora una variabile aleatoria? Argomentare. b) Calcolare media e varianza della media campionaria. c) Enunciare la legge dei grandi numeri. Assumendo vera la disuguaglianza di Čebyšëv dimostrare tale legge. d) Spiegare intuitivamente il significato della legge dei grandi numeri e spiegare come viene utilizzata in statistica”.

Chiesto in: 02/09/25 Q1; 01/04/26 Q2

Risposta scheletro.

1. **Media campionaria.** Per $X_1, \dots, X_n$ indipendenti e con la stessa distribuzione, $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. È ancora una variabile aleatoria, perché è una *funzione* di variabili aleatorie: a ogni esito dell'esperimento associa la media dei valori osservati.
2. **Media e varianza.** $\mathbb{E}[\bar{X}_n] = \mu$ (per linearità, senza bisogno di indipendenza) e $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$ (qui l'indipendenza serve, per annullare le covarianze). Quindi $\bar{X}_n$ è uno stimatore **non distorto** di μ , con errore standard $\sigma/\sqrt{n}$: la precisione migliora come $1/\sqrt{n}$.
3. **Čebyšëv.** $\mathbb{P}(|X - \mathbb{E}[X]| \geq \eta) \leq \frac{\text{Var}(X)}{\eta^2}$; si dimostra applicando Markov, $\mathbb{P}(Y \geq \alpha) \leq \frac{\mathbb{E}[Y]}{\alpha}$ per $Y \geq 0$, alla variabile $Y = (X - \mathbb{E}[X])^2$ con $\alpha = \eta^2$.
4. **Legge dei grandi numeri (debole).** Per ogni $\eta > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \eta) = 0, \quad \text{ovvero} \quad \bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

Dimostrazione: per Čebyšëv applicata a $\bar{X}_n$, che ha media μ e varianza σ^2/n ,

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \eta) \leq \frac{\text{Var}(\bar{X}_n)}{\eta^2} = \frac{\sigma^2}{\eta^2 n} \xrightarrow{n \rightarrow \infty} 0.$$

5. **Significato e uso in statistica.** Al crescere del numero di prove la media dei valori osservati si avvicina alla media teorica μ : è ciò che giustifica la definizione *frequentista* di probabilità ($\mathbb{P}(E) \approx$ frequenza relativa per n grande) e tutte le simulazioni Monte Carlo. In statistica è il motivo per cui si può stimare un parametro ignoto di una popolazione a partire da un campione, e per cui la stima migliora all'aumentare della dimensione campionaria. È anche il punto da collegare alla distinzione del punto a: la statistica **inferenziale** usa il campione per concludere qualcosa sulla popolazione, ed è la legge dei grandi numeri a garantirne la legittimità.

Cosa non dire

- Dire che $\bar{X}_n$ “non è più aleatoria” perché è una media. È una funzione di variabili aleatorie, quindi è una variabile aleatoria: il punto a del 01/04/26 chiede esplicitamente di *argomentare*.
- Dire che la legge dei grandi numeri afferma che $\bar{X}_n$ diventa *esattamente* μ . Afferma che la probabilità di allontanarsene di una quantità fissata η tende a 0: per ogni n finito resta una probabilità positiva di scostamento. È la differenza tra “converge in probabilità” e “è uguale”.
- Citare Čebyšëv senza usarla. Il punto d dice “*dimostrare tale legge partendo dalla conoscenza della disuguaglianza di Čebyšëv*”: la dimostrazione è di tre righe e va scritta per esteso, non citata a memoria.
- Dimenticare che nella disuguaglianza di Čebyšëv va usata la varianza *della media*, σ^2/n , non σ^2 : è esattamente il passaggio che fa funzionare la dimostrazione.
- Confondere descrittiva e inferenziale. La prima *descrive* il campione osservato (frequenze, media, grafici, nessuna ipotesi); la seconda *conclude* sulla popolazione a partire dal campione, con un margine di errore dichiarato (stimatori, intervalli, test). Il criterio distintivo è *campione contro popolazione*.

C.8 Statistica descrittiva (2 su 9)

Come è formulata

Una sola domanda “a elenco”, il 17/02/26, in quattro punti:

- “a) Dare la definizione di frequenza assoluta, frequenza relativa, frequenza accumulata (assoluta e relativa) di un insieme di dati”;
- “b) Dare la formula matematica di media aritmetica nel caso di dati semplici e di dati con frequenza”;
- “c) Definire i quantili di un insieme di dati. Definire la mediana e i quartili. Definire la distanza interquartile”;
- “d) Dare la formula matematica di varianza empirica e campionaria nel caso di dati semplici e di dati con frequenza”.

Il 02/09/25 chiede invece solo la cornice: “Dare la definizione di statistica descrittiva e statistica inferenziale”.

Chiesto in: 02/09/25 Q1 (punto a); 17/02/26 Q1

Risposta scheletro. Per ogni indice: definizione, formula, e una frase sul significato.

1. **Frequenze.** Dati N valori di cui n distinti $x_1, \dots, x_n$:

- **assoluta** f_i : quante volte compare il valore x_i , con $\sum_i f_i = N$;
- **relativa** $p_i = \frac{f_i}{N}$, con $\sum_i p_i = 1$ (sono le probabilità empiriche);
- **cumulata assoluta** $\sum_{j \leq i} f_j$ e **relativa** $F_i = \sum_{j \leq i} p_j$, che è un'approssimazione costante a tratti della funzione di ripartizione.

2. **Media aritmetica.** Dati semplici $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$; da una tabella di frequenze $\bar{x} = \frac{1}{N} \sum_{i=1}^n x_i f_i = \sum_{i=1}^n p_i x_i$.

3. **Quantili, mediana, quartili, IQR.** Il **quantile di ordine** k è l'insieme dei $k - 1$ valori che dividono i dati in k gruppi di uguale numerosità; equivalentemente il quantile di ordine p è il valore sotto cui cade una frazione p dei dati, e con l'interpolazione lineare della funzione di ripartizione coincide con $q_\alpha = \sup\{r : F(r) = \alpha\}$. La **mediana** è il quantile di ordine 0.5: il valore centrale se N è dispari, la media dei due centrali se N è pari; è anche il valore che minimizza $S(a) = \sum_i |x_i - a|$. Il **primo** e il **terzo quartile** sono i quantili di ordine 0.25 e 0.75. La **distanza interquartile** è $IQR = Q_3 - Q_1$.

4. **Varianza empirica e campionaria.**

$$\bar{\sigma}_x^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2 f_i = \sum_{i=1}^n (x_i - \bar{x})^2 p_i,$$

$$\bar{S}_n^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 = \frac{1}{N-1} \sum_{i=1}^n (x_i - \bar{x})^2 f_i.$$

La prima divide per N ed è un indice *descrittivo* del campione; la seconda divide per $N - 1$ ed è lo *stimatore non distorto* di σ^2 . Differiscono del fattore $\frac{N-1}{N}$.

Cosa non dire

- Chiamare “frequenza” sia f_i sia p_i . La distinzione assoluta/relativa va data per entrambe le voci, e così pure per le cumulate (assoluta e relativa: la domanda le chiede entrambe).
- **Scambiare empirica e campionaria.** È l'unica cosa che questa domanda verifica davvero: N contro $N - 1$. La frase decisiva da scrivere: *la prima descrive il campione, la seconda stima la popolazione*.
- Dare la formula della varianza solo per dati semplici, o solo in una delle due forme: il punto d chiede esplicitamente “nel caso di dati semplici e di dati con frequenza”.
- Definire la mediana solo come “valore centrale” senza il caso N pari (media dei due valori centrali).
- Dimenticare la distanza interquartile: è una riga, ma è chiesta per nome.
- Confondere i quantili di un *insieme di dati* con i quantili di una variabile aleatoria: sono la stessa idea, ma nel primo caso si definiscono per interpolazione lineare della funzione di ripartizione empirica.

C.9 Monte Carlo e numeri pseudorandom (2 su 9)

Come è formulata

- 02/09/25: “a) Che cos’è un numero pseudorandom? b) A cosa serve il metodo delle congruenze lineari? c) Si illustri il metodo di inversione della funzione di ripartizione per generare numeri random distribuiti secondo una densità data. d) Si illustri il caso specifico della generazione di numeri distribuiti secondo una distribuzione esponenziale”.
- 23/06/26: “a) Dare la definizione di numero pseudorandom; b) Dare la definizione di metodo Monte Carlo; c) Spiegare quali sono i vantaggi e gli svantaggi dell’utilizzo del metodo Monte Carlo; d) Illustrare a parole il funzionamento del metodo hit or miss per il calcolo degli integrali”.

La domanda “che cos’è un numero pseudorandom?” compare *identica* in entrambe.

Chiesto in: 02/09/25 Q2; 23/06/26 Q2

Risposta scheletro.

1. **Numero pseudorandom.** È un numero che *sembra* estratto a caso ma è prodotto da una **sequenza deterministica** di operazioni aritmetiche a partire da un valore iniziale detto **seme** (*seed*). Tre cose da dire: (i) è deterministico, non generato da un processo fisico; (ii) stesso seme $\Rightarrow$ stessa sequenza, quindi è **riproducibile** (non è un difetto, è ciò che permette di verificare un esperimento); (iii) deve *imitare statisticamente* una sequenza di variabili indipendenti uniformi su $(0, 1)$, con periodo lungo.

2. **Congruenze lineari.** È il generatore storico:

$$X_{n+1} = (aX_n + b) \bmod m, \quad U_n = \frac{X_n}{m} \in [0, 1),$$

con X_0 seme, a moltiplicatore, b incremento, m modulo. Serve a produrre una successione di numeri in $[0, 1)$ che si comporta come casuale. La successione è necessariamente **periodica**: il periodo è il più piccolo T con $X_{n+T} = X_n$, ed è tanto più lungo quanto meglio si scelgono a, b, m . Esempio da citare: $X_{n+1} = (5X_n + 3) \bmod 16$ ha periodo pieno 16. Il generatore usato oggi da numpy è il **Mersenne Twister**, con periodo $2^{19937} - 1$.

3. **Metodo dell’inversione.** Se F è la funzione di ripartizione (strettamente crescente) della distribuzione che voglio ottenere e $U \sim \mathcal{U}([0, 1])$, allora $Y = F^{-1}(U)$ ha funzione di ripartizione F . *Caso esponenziale*: $F(t) = 1 - e^{-\lambda t}$, da cui

$$Y = -\frac{\log(1-U)}{\lambda} = -\frac{\log U}{\lambda} \sim \text{Exp}(\lambda),$$

dove l’ultimo passaggio usa il fatto che se $U \sim \mathcal{U}([0, 1])$ anche $1 - U$ lo è. È l’*unico* caso notevole in cui l’inversione si fa a mano: per la normale F^{-1} non ha forma chiusa.

4. **Metodo Monte Carlo.** È qualunque tecnica che stimi una quantità (una probabilità, un integrale, una media) **campionando** numeri casuali e usando la legge dei grandi numeri per garantire che la stima converga al valore vero. I quattro passi: definire il dominio di input, generare numeri random nel dominio, eseguire un calcolo deterministico, aggregare i risultati. **Vantaggi**: generalità (funziona anche senza primitiva, in dimensione alta, su regioni di forma arbitraria); semplicità di implementazione; errore che va come $1/\sqrt{N}$ *indipendente dalla dimensione*; errore standard stimabile dai dati stessi. **Svantaggi**: convergenza lenta ($1/\sqrt{N}$: per una cifra decimale in più servono cento volte le simulazioni); il risultato è sempre una stima, mai un valore esatto; dipendenza dalla qualità del generatore; costo computazionale elevato per alta precisione.

5. **Hit or miss, a parole.** Serve a calcolare $\int_a^b f(x) dx$ per $f \geq 0$ continua. Si racchiude la regione sotto la curva nel rettangolo $[a, b] \times [0, M]$ con $M = \max_{[a, b]} f$; si estraggono N coppie di punti a caso nel rettangolo e si contano quelle che cadono *sotto* la curva (N_s). La probabilità di “andare a segno” è il rapporto tra le aree, $p = \frac{I}{(b-a)M}$, quindi

$$I \approx \frac{N_s}{N}(b-a)M.$$

Più N è grande, più la stima è accurata. Lo stimatore $\hat{p} = N_s/N$ è non distorto, con errore standard $\sqrt{p(1-p)/N}$.

Cosa non dire

- Dire che i numeri pseudorandom “sono casuali”. Sono *deterministici* e prevedibili noti seme e algoritmo; il punto è che ne imitano le proprietà statistiche.
- Dimenticare di citare il **seme**: è il secondo punto della definizione, ed è ciò che rende una simulazione riproducibile.
- Scrivere $U_n = X_n$ invece di $U_n = X_n/m$: i numeri in $[0, 1)$ si ottengono normalizzando per il modulo.
- Confondere l’inversione con il **rigetto**. Sono due metodi diversi: l’inversione calcola $F^{-1}(U)$ e non scarta nulla; il rigetto genera una coppia (ξ, η) e *accetta* ξ se $\eta \leq f(\xi)$, scartando una frazione dei campioni (probabilità di accettazione $1/M$).
- Dire che i metodi Monte Carlo sono “esatti” o che l’errore diminuisce come $1/N$. Va come $1/\sqrt{N}$: per dimezzare l’errore servono *quattro* volte le simulazioni, e questo è insieme il vantaggio (indipendente dalla dimensione) e lo svantaggio (lentezza).
- Nel punto c del 23/06/26, elencare solo i vantaggi o solo gli svantaggi: la domanda chiede *entrambi*.

C.10 Intervalli di confidenza (1 su 9)

Come è formulata

Una sola volta, il 23/06/26 (Quesito 1, tutto): “a) Dare la definizione di stimatore puntuale; b) Dare la definizione di intervallo di confidenza con livello di confidenza $1 - \alpha$; c) Scegliere un particolare intervallo di confidenza e darne una rappresentazione grafica; d) Commentare come cambiano gli estremi dell’intervallo di confidenza scelto al variare di N , σ e α ”.

Chiesto in: 23/06/26 Q1

Risposta scheletro.

1. **Stimatore puntuale.** Una statistica $\hat{\theta} = T(X_1, \dots, X_n)$ funzione del campione e non dipendente da θ , a valori nell’immagine di θ .
2. **Intervallo di confidenza.** Dati un campione e un livello $\alpha \in [0, 1]$, $[I_1, I_2]$ è un intervallo di confidenza di livello $1 - \alpha$ per θ se $\mathbb{P}(\theta \in [I_1, I_2]) = \mathbb{P}(I_1 \leq \theta \leq I_2) = 1 - \alpha$. α si chiama **livello di significatività**. Gli estremi I_1, I_2 sono funzioni del campione, quindi l’intervallo è *casuale*: la probabilità si riferisce al procedimento.
3. **Un intervallo particolare: la media con σ^2 nota.** La variabile ausiliaria è $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ (grazie alla gaussianità del campione oppure al TLC se $n > 30$). Da

$\mathbb{P}(-\varphi_{1-\alpha/2} \leq Z_n \leq \varphi_{1-\alpha/2}) = 1 - \alpha$ si isola μ :

$$I_\mu = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}} \varphi_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{n}} \varphi_{1-\alpha/2} \right] = [\bar{X}_n - \varepsilon_\mu, \bar{X}_n + \varepsilon_\mu],$$

simmetrico rispetto a $\bar{X}_n$, con margine di errore $\varepsilon_\mu = \frac{\sigma}{\sqrt{n}} \varphi_{1-\alpha/2}$. *Grafico*: la campana di $\bar{X}_n \sim N(\mu, \sigma^2/n)$ con l'area centrale $1 - \alpha$ evidenziata e i due estremi segnati.

4. **Dipendenza da N , σ , α .** Tutto dipende da ε_μ :

- N cresce $\Rightarrow$ l'intervallo si *restringe* come $1/\sqrt{N}$: quadruplicando N la semilarghezza si dimezza, ma con rendimenti decrescenti;
- σ cresce $\Rightarrow$ l'intervallo si *allarga linearmente*: più variabilità, meno informazione in ogni osservazione;
- α diminuisce (più confidenza, per esempio dal 95% al 99%) $\Rightarrow \varphi_{1-\alpha/2}$ cresce ($1.9600 \rightarrow 2.5758$) e l'intervallo si *allarga* del 31.4%: maggiore confidenza si paga con minore precisione.

Numero minimo di dati per un margine E : $N \geq (\varphi_{1-\alpha/2} \sigma / E)^2$.

Cosa non dire

- **“ θ cade nell'intervallo con probabilità 0.95”.** È l'errore interpretativo classico: dopo il calcolo θ è un numero fisso e l'intervallo è deterministico. La frase corretta è “il procedimento produce intervalli che contengono θ nel 95% dei campioni”.
- Dire che l'intervallo “si restringe linearmente” con N : va come $1/\sqrt{N}$. Con σ invece è lineare. Scambiare le due leggi è l'errore che il punto d verifica.
- Dire genericamente “l'ampiezza cambia” senza dire in che direzione: serve “ N su, ampiezza giù; σ su, ampiezza su; α giù, ampiezza su”.
- Scegliere l'intervallo per la media con σ^2 *non nota* e poi usare il quantile $\varphi_{1-\alpha/2}$ della normale: se σ non è nota si usa la t di Student con $N - 1$ gradi di libertà. Se il punto c dice “scegliere un particolare intervallo”, la scelta va *motivata*.
- Dimenticare il grafico: il punto c chiede esplicitamente “darne una rappresentazione grafica”.
- Nel commento finale, citare solo il caso σ^2 nota senza dire che nel caso σ^2 non nota la dipendenza è analoga ma con $\bar{S}_n^2$ e t_α al posto di σ e φ_α .